Introduction à l'économétrie

Chapitre 15 : Les erreurs groupées

Jaouad Madkour

29 octobre 2026

Plan du chapitre

Des observations par paquets **2**
Ce que H4 exigeait . . . 2
Sur notre enquête de ménages . . . 2
Ce que montre la figure . . . 2
Le mécanisme . . . 3
La corrélation intra-grappe . . . 3

Ce que cela coûte **3**
Le facteur de Moulton . . . 3
Le facteur, selon la corrélation . . . 4
La version complète de la formule . . . 4
Ce que dit le tableau . . . 5
Les conséquences . . . 6
L'effectif équivalent . . . 6

Le remède **7**
Les écarts-types de grappe . . . 7
Ce que le tableau montre . . . 7
Comment elle fonctionne . . . 7
À quel niveau regrouper . . . 8
Une condition de validité . . . 8

Lien avec les séries **9**
Le même problème, une autre forme . . . 9

Sur machine **9**
Trois erreurs-types avec R . . . 9
La grappe avec Python . . . 10
Ce que disent les deux sorties . . . 10

S'entraîner **10**
Exercice 1 : le facteur de Moulton . . . 10
Exercice 1 : solution . . . 11
Exercice 2 : quelle variable souffre . . . 11

Exercice 2 : solution 11
Exercice 3 : un plan d'enquête 11
Exercice 3 : solution 11

Ce qu'il faut retenir **12**
Le résumé du chapitre 12

Des observations par paquets

Ce que H4 exigeait

Indépendance des erreurs

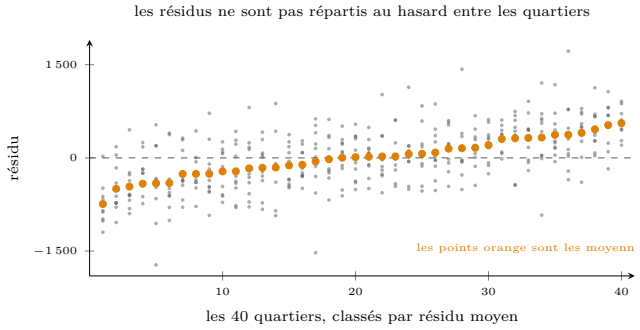
$$\mathrm{cov}(\varepsilon_i, \varepsilon_j) = 0 \qquad \text{pour } i \neq j$$

Ce que le modèle n'explique pas chez un individu ne doit rien avoir de commun avec ce qu'il n'explique pas chez un autre.

Pourquoi c'est rarement vrai

Les données d'enquête ne tombent presque jamais individu par individu. On tire des **quartiers**, des **classes**, des **entreprises**, des **villages** — et l'on interroge tout le monde à l'intérieur.
C'est le sondage par **grappes** du chapitre 1 de l'inférence, et il a une conséquence directe ici.

Sur notre enquête de ménages



Ce que l'hypothèse H4 interdit

$\mathrm{cov}(\varepsilon_i, \varepsilon_j) = 0$ pour $i \neq j$.

Or deux ménages du *même quartier* partagent ce que le modèle ignore : les prix locaux, l'offre commerciale, les habitudes du voisinage.

Leurs erreurs se ressemblent. Les moyennes de quartier s'écartent trop nettement de zéro pour un tirage indépendant — de −743 à +559 dirhams.

C'est le pendant, sur coupe instantanée, de l'autocorrélation des séries temporelles — et il se traite de la même façon, sans qu'il faille sortir du cadre de ce cours.

Ce que montre la figure

Quarante moyennes de résidus

Les résidus du modèle « consommation sur revenu et taille » ont, quartier par quartier, des moyennes qui vont de −743 à +559 dirhams.
Si les dix ménages de chaque quartier étaient indépendants, ces moyennes devraient rester près de zéro : l'écart-type d'une moyenne de dix résidus est d'environ $500/\sqrt{10} \approx 160$ dirhams.

Trop loin de zéro pour être un hasard

Des moyennes à ± 600, c'est près de quatre fois l'écart attendu. **Les ménages d'un même quartier partagent quelque chose** que le revenu et la taille n'expliquent pas.

Le mécanisme

Un terme commun à la grappe

$$\varepsilon_{ig} = u_g + v_{ig}$$

u_g est ce que partagent tous les ménages du quartier g : les prix locaux, l'offre commerciale, les habitudes du voisinage. v_{ig} est propre au ménage.

Deux ménages du même quartier ne sont pas deux observations indépendantes

Ils partagent u_g. Leurs erreurs sont donc corrélées, et l'échantillon contient **moins d'information** que son effectif ne le suggère.
Quatre cents ménages répartis en quarante quartiers ne valent pas quatre cents ménages tirés au hasard dans tout le pays.

La corrélation intra-grappe

La part de la variance qui est commune

$$\rho = \frac{V(u_g)}{V(u_g) + V(v_{ig})} = \operatorname{corr}(\varepsilon_{ig}, \varepsilon_{jg})$$

C'est la corrélation entre les erreurs de deux ménages **du même quartier**.

Sur nos ménages

Estimée par l'analyse de la variance des résidus entre et dans les quartiers : $\rho = 0{,}30$. **Près d'un tiers de ce que le modèle n'explique pas est commun au quartier.**

Ce que cela coûte

Le facteur de Moulton

De combien l'écart-type est sous-estimé

$$\frac{\text{vrai écart-type}}{\text{écart-type MCO}} \approx \sqrt{1 + (m-1)\,\rho}$$

où m est la taille moyenne des grappes et ρ la corrélation des erreurs à l'intérieur d'une grappe.

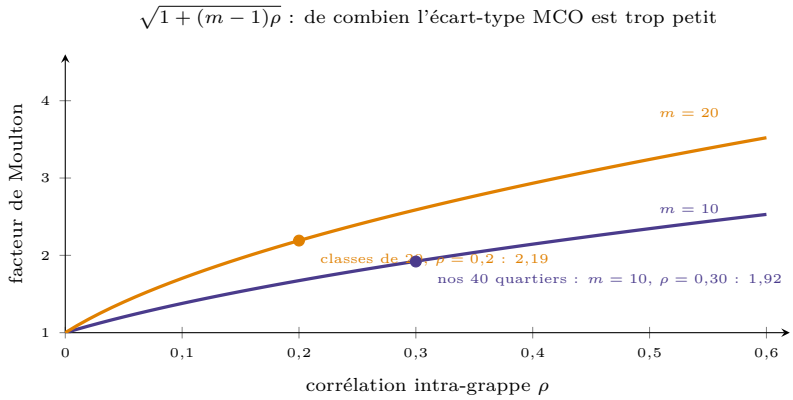
Un exemple qui fait réfléchir

Vingt élèves par classe, une corrélation intra-classe de 0,2 — des valeurs banales en économie de l'éducation :

$$\sqrt{1 + 19 \times 0{,}2} = 2{,}2$$

L'écart-type est plus que doublé. Un t affiché à 4 vaut en réalité moins de 2 : la conclusion s'effondre.

Le facteur, selon la corrélation



Nos quartiers

$m = 10$, $\rho = 0{,}30$: $\sqrt{1 + 9 \times 0{,}30} = \sqrt{3{,}7} = 1{,}92$. Pour une variable constante dans le quartier, l'écart-type des MCO est presque deux fois trop petit.

La version complète de la formule

La variable compte autant que l'erreur

$$\sqrt{1 + (m-1)\,\rho_x\,\rho_\varepsilon}$$

ρ_x est la corrélation intra-grappe **de la variable explicative**. Elle vaut 1 pour une variable constante dans la grappe, et près de 0 pour une variable qui varie librement à l'intérieur.

Démonstration : Le facteur de Moulton : $1 + (m-1), \rho_x \rho_\varepsilon$

Prenons G grappes de même taille m ($n = Gm$), des erreurs de même variance σ_ε^2, de corrélation ρ_ε à l'intérieur d'une grappe et nulle entre grappes. Pour la pente simple, $\hat{\beta}_1 - \beta_1 = \sum_i w_i \varepsilon_i$ avec $w_i = (x_i - \overline{x})/S_{xx}$. Sa variance est la somme de **toutes** les covariances pondérées :

$$\begin{aligned} V(\hat{\beta}_1) &= \sigma_\varepsilon^2 \sum_i w_i^2 + \rho_\varepsilon \sigma_\varepsilon^2 \sum_g \sum_{i \neq j \in g} w_i w_j \\ &= \frac{\sigma_\varepsilon^2}{S_{xx}} \left(1 + \rho_\varepsilon \frac{\sum_g \sum_{i \neq j \in g} (x_i - \overline{x})(x_j - \overline{x})}{S_{xx}} \right). \end{aligned}$$

Il y a $m(m - 1)$ couples ordonnés de ménages distincts dans chaque grappe. Définissons ρ_x comme le produit moyen des écarts à la moyenne de deux ménages d'une même grappe,

rapporté à la variance de x :

$$\rho_x = \frac{\sum_g \sum_{i \neq j \in g} (x_i - \overline{x})(x_j - \overline{x})}{(m-1)\, S_{xx}}.$$

Alors

$$V(\hat{\beta}_1) = \frac{\sigma_\varepsilon^2}{S_{xx}} \Big(1 + (m-1)\, \rho_x \rho_\varepsilon \Big).$$

La formule ordinaire donne $\sigma_\varepsilon^2 / S_{xx}$ ($\hat{\sigma}_\varepsilon^2$ estime σ_ε^2 à un terme d'ordre $1/G$ près). Le rapport des variances est $1 + (m-1)\rho_x \rho_\varepsilon$: on en prend la racine pour les écarts-types.

Une variable constante dans la grappe. Si $x_i = x_g$ pour tout $i \in g$, chaque grappe contribue $m(m-1)(x_g - \overline{x})^2$ au numérateur, et $S_{xx} = m \sum_g (x_g - \overline{x})^2$: donc $\rho_x = 1$ et le facteur est $1 + (m-1)\rho_\varepsilon$. **Une variable qui varie librement** dans la grappe a des écarts de signes quelconques, dont les produits croisés se compensent : $\rho_x \approx 0$, et le regroupement est sans effet.

Le lien avec le mécanisme. Avec $\varepsilon_{ig} = u_g + v_{ig}$, la covariance de deux erreurs de la même grappe est $V(u_g)$ et leur variance $V(u_g) + V(v_{ig})$: leur corrélation est bien $\rho_\varepsilon = V(u_g)/(V(u_g) + V(v_{ig}))$. Sur nos quartiers, $m = 10$ et $\rho_\varepsilon = 0{,}30$: $\sqrt{1 + 9 \times 0{,}30} = 1{,}92$.

■

Trois variables, trois facteurs

Variable	ρ_x	Facteur prévu	Observé, grappe / MCO
Milieu urbain	1	1,92	1,83
Revenu	0,056	1,07	1,57
Taille	0,026	1,03	0,74

Ce que dit le tableau

Le milieu, comme prévu

Le milieu est constant dans le quartier : son écart-type est presque doublé, 55,69 → 101,92, tout près du facteur théorique.

Le revenu et la taille, pour d'autres raisons

Le revenu varie dans le quartier : le regroupement l'affecte peu, et sa hausse vient de l'**hétéroscédasticité** — la correction robuste seule donne déjà 0,0236. Les écarts-types de grappe corrigent les deux problèmes à la fois.
La taille voit son écart-type **baisser**, de 16,67 à 12,29 : la correction n'est pas forcément à la hausse pour une variable qui varie dans les grappes.

Les conséquences

Les mêmes que pour l'hétéroscédasticité

1. Les coefficients restent **sans biais** — H2 n'est pas en cause.
2. Ils ne sont plus efficaces.
3. Les **écarts-types sont faux**, et pour une variable de grappe, **trop petits**.

L'erreur va presque toujours dans le même sens

Pour une variable fixée au niveau de la grappe — une politique, un équipement, un milieu —, le regroupement conduit **toujours** à un excès de confiance.
On croit disposer de quatre cents observations ; on en a l'équivalent de bien moins.

L'effectif équivalent

Combien d'observations indépendantes on a vraiment

$$n_{\text{équivalent}} = \frac{n}{1 + (m-1)\,\rho}$$

Démonstration : L'effectif équivalent est la variance d'une moyenne

Estimons une moyenne par $\overline{y} \quad = \quad \sum_i y_i/n$, c'est-à-dire une régression sur la seule constante. Les poids sont tous égaux à $1/n$, et le calcul de la démonstration précédente, appliqué à ces poids, donne

$$V(\overline{y}) = \sigma_\varepsilon^2 \sum_i \frac{1}{n^2} + \rho\,\sigma_\varepsilon^2 \sum_g \frac{m(m-1)}{n^2} = \frac{\sigma_\varepsilon^2}{n}\Big(1 + (m-1)\,\rho\Big).$$

Un échantillon de $n_{\text{équivalent}}$ observations indépendantes aurait une moyenne de variance $\sigma_\varepsilon^2/n_{\text{équivalent}}$. En identifiant, $n_{\text{équivalent}} = n/(1 + (m-1)\rho)$. Pour $n = 400$, $m = 10$ et $\rho = 0{,}30$: $400/3{,}7 = 108$.

■

Pour le milieu urbain

$400/(1 + 9 \times 0{,}30) = 400/3{,}7 = 108$. **Pour mesurer l'effet du milieu, nos** 400 **ménages valent** 108 **ménages indépendants** — et l'information vient en réalité des 40 quartiers, puisque c'est entre eux que le milieu varie.

Le remède

Les écarts-types de grappe

400 ménages répartis en 40 quartiers de dix

	Coefficient	Écart-type		
		MCO	robuste	**grappes**
Constante	497,34	91,92	87,05	97,03
Revenu	0,7045	0,0148	0,0236	0,0232
	t	47,55	29,85	30,35
Taille du ménage	70,67	16,67	15,39	12,29
	t	4,24	4,59	5,75
Milieu urbain	−99,44	55,69	59,32	101,92
constant dans la grappe	t	−1,79	−1,68	−0,98

La ligne orange est celle qu'il faut regarder.

Le milieu est **constant à l'intérieur de chaque quartier** : les quarante quartiers apportent quarante informations, pas quatre cents. L'écart-type corrigé du regroupement est presque *doublé*, et le coefficient cesse d'être à la limite de la significativité.

Et la correction d'hétéroscédasticité ne le voit pas : 59,32 contre 55,69, à peine un changement. Les deux corrections traitent deux problèmes distincts, et l'une ne remplace pas l'autre.

Règle : dès que les observations sont naturellement groupées — ménages d'un quartier, élèves d'une classe, salariés d'une entreprise — on regroupe au niveau où le traitement ou la politique s'applique.

Ce que le tableau montre

Trois lectures

Le **revenu** varie dans les quartiers : écart-type de 0,0148 à 0,0232, t de 47,6 à 30,4.
Le **milieu** est constant dans la grappe : écart-type presque **doublé**, 55,69 contre 101,92.
La correction d'**hétéroscédasticité seule** ne voit rien de ce second problème : 59,32.

La règle qui en découle

Une variable constante dans les grappes est celle qui souffre le plus. C'est le cas des variables de politique publique — une réforme s'applique à une région entière —, d'où la correction de grappe obligatoire dans toute évaluation de politique.

Comment elle fonctionne

Additionner par grappe avant d'élever au carré

White additionnait les $e_i^2\, x_i x_i'$ observation par observation. La version de grappe additionne d'abord **dans chaque grappe** :

$$\widehat{V} = (X'X)^{-1}\Big(\sum_g \big(\textstyle\sum_{i\in g} x_i e_i\big)\big(\sum_{i\in g} x_i e_i\big)'\Big)(X'X)^{-1}$$

Les produits croisés sont réintroduits

En sommant par grappe avant de mettre au carré, on fait apparaître les produits $e_i e_j$ de deux ménages du même quartier : exactement les covariances que H4 supposait nulles. Celles de deux quartiers différents restent exclues.

Démonstration : D'où vient la variance de grappe

Reprenons la formule de White (chapitre 14), $V(\hat{\beta}) = (X'X)^{-1} X'\Omega X (X'X)^{-1}$, mais avec des erreurs corrélées à l'intérieur des grappes et indépendantes entre elles : Ω est alors **diagonale par blocs**. Notons X_g et ε_g les lignes de X et les erreurs de la grappe g. Alors

$$X'\Omega X = \sum_g X_g' \, E(\varepsilon_g \varepsilon_g') \, X_g = \sum_g E\Big[(X_g'\varepsilon_g)(X_g'\varepsilon_g)'\Big],$$
$$X_g'\varepsilon_g = \sum_{i \in g} x_i \varepsilon_i.$$

Chaque terme est estimé en remplaçant ε_i par e_i, ce qui donne la formule du chapitre. Développé, le carré $(\sum_{i\in g} x_i e_i)(\sum_{j\in g} x_j e_j)'$ contient les termes $e_i^2 \, x_i x_i'$ de White **et** les produits croisés $e_i e_j \, x_i x_j'$ des couples d'une même grappe. Pour la pente simple,

$$\widehat{V}_{\text{grappe}}(\hat{\beta}_1) = \frac{\sum_g \Big(\sum_{i\in g} (x_i - \overline{x}) \, e_i \Big)^2}{S_{xx}^2}.$$

Quand chaque grappe ne compte qu'une observation, on retrouve exactement la variance de White.

■

À quel niveau regrouper

La règle

On regroupe au niveau où **le traitement, la politique ou le tirage** s'applique — pas plus fin.

Trois exemples

Situation	Niveau de regroupement
Enquête par quartiers	le quartier
Réforme scolaire régionale	la région
Salariés de plusieurs entreprises	l'entreprise

Une condition de validité

Il faut assez de grappes, pas assez d'observations

La correction repose sur le **nombre de grappes**, non sur celui des individus. La règle usuelle : au moins **quarante grappes**.

Nous en avons exactement quarante — le minimum acceptable. Avec dix quartiers de quarante ménages, la correction serait elle-même peu fiable, quand bien même l'effectif total serait le même.

La conséquence pour un plan d'enquête

À budget donné, **il vaut mieux beaucoup de petites grappes que peu de grandes**. Quarante quartiers de dix ménages valent mieux, statistiquement, que dix quartiers de quarante — alors que le coût de collecte pousse dans l'autre sens. C'est un arbitrage réel, et il se décide avant la collecte.

Lien avec les séries

Le même problème, une autre forme

Deux visages de H4

Structure	Ce qui lie les erreurs	Le remède
Coupe instantanée	l'appartenance à un **groupe**	écarts-types de grappe
Série temporelle	la **proximité dans le temps**	écarts-types HAC

Pourquoi ce cours s'en tient au premier

Sur série temporelle, l'autocorrélation ne vient jamais seule : elle s'accompagne de tendance et de non-stationnarité, qui posent des problèmes d'une tout autre nature — la régression peut être entièrement fallacieuse.
Il faut alors les tests de racine unitaire et la cointégration, qui relèvent des cours de séries temporelles et d'économétrie avancée. Le principe, lui, est identique à celui de ce chapitre.

Sur machine

Trois erreurs-types avec R

```
suppressPackageStartupMessages(library(lmtest))
library(sandwich)
men <- read.csv("menages.csv", stringsAsFactors = TRUE)
mk2 <- lm(consommation ~ revenu + taille + milieu, data = men)
se <- cbind(MCO = sqrt(diag(vcov(mk2))),
            HC1 = sqrt(diag(vcovHC(mk2, type = "HC1"))),
            CL = sqrt(diag(vcovCL(mk2, cluster = ~ quartier))))
round(se, 4)
#                  MCO     HC1       CL
# (Intercept)  91.9181 87.0487  97.0277
# revenu        0.0148  0.0236   0.0232
# taille       16.6703 15.3882  12.2912
# milieuUrbain 55.6908 59.3173 101.9173
```

La grappe avec Python

```
import pandas as pd
import statsmodels.formula.api as smf
men = pd.read_csv("menages.csv")
f = "consommation ~ revenu + taille + milieu"
mk2 = smf.ols(f, data=men).fit(cov_type="cluster",
                               cov_kwds={"groups": men.quartier})
print(mk2.bse.round(4))
# Intercept            97.0277
# milieu[T.Urbain]    101.9173
# revenu                0.0232
# taille               12.2912
# dtype: float64
print(mk2.tvalues.round(2).tolist())
# [5.13, -0.98, 30.35, 5.75]
```

Ce que disent les deux sorties

Une option, deux syntaxes

En R, `vcovCL(mk2, cluster = ~ quartier)` ; en Python, `cov_type="cluster"` et le vecteur des quartiers dans `cov_kwds`. Les trois colonnes de R reproduisent le tableau du chapitre : MCO, White, grappe.

La même correction de petit nombre de grappes

Les deux logiciels multiplient la variance par un facteur qui tient compte du nombre de grappes, $G/(G-1)$ et $(n-1)/(n-k-1)$: 101,9173 dans les deux cas. Un autre logiciel, avec une autre convention, donnerait un résultat voisin mais pas identique — il faut **dire lequel on a utilisé**.

S'entraîner

Exercice 1 : le facteur de Moulton

Une enquête par villages

On interroge 25 ménages dans chacun de 60 villages. La corrélation intra-village des erreurs vaut 0,1.

1. Calculer le facteur de Moulton pour une variable constante dans le village.
2. Un coefficient de ce type a un t de 3,2 avec les MCO. Que vaut-il après correction ?
3. Quel est l'effectif équivalent ?

Exercice 1 : solution

Un t divisé par 1,84

1. $\sqrt{1 + 24 \times 0{,}1} = \sqrt{3{,}4} = 1{,}84$.
2. $3{,}2/1{,}84 = 1{,}74$: il n'est plus significatif à 5 %.
3. $1\,500/3{,}4 = 441$ ménages indépendants, pour 1 500 interrogés.

Exercice 2 : quelle variable souffre

Une évaluation de politique

On explique la consommation de ménages interrogés par régions, par leur revenu et par le taux d'une taxe régionale.

1. Pour laquelle des deux variables la correction de grappe changera-t-elle le plus l'écart-type ?
2. Pourquoi la correction d'hétéroscédasticité seule ne suffit-elle pas ?
3. À quel niveau regrouper ?

Exercice 2 : solution

La variable de politique

1. Le **taux de la taxe** : il est constant dans la région, $\rho_x = 1$, et subit le facteur de Moulton complet. Le revenu varie entre ménages d'une même région.
2. White ne corrige que des variances inégales : il suppose toujours les erreurs **indépendantes**, et ne voit donc pas la corrélation au sein d'une région — 59,32 contre 101,92 pour le milieu de nos ménages.
3. Au niveau de la **région**, celui où la taxe s'applique — à condition d'avoir assez de régions.

Exercice 3 : un plan d'enquête

Quatre cents entretiens à répartir

Le budget permet 400 entretiens. On veut mesurer l'effet d'une variable de quartier, avec $\rho = 0{,}3$.

1. Calculer l'effectif équivalent pour 10 quartiers de 40, 40 de 10, 80 de 5.
2. Lequel choisir, si le coût par quartier est négligeable ?
3. Pourquoi le plan à 10 quartiers pose-t-il un second problème ?

Exercice 3 : solution

Beaucoup de petites grappes

1. $m = 40$: $400/(1 + 39 \times 0{,}3) = 31{,}5$. $m = 10$: $400/3{,}7 = 108$. $m = 5$: $400/2{,}2 = 182$.
2. 80 quartiers de 5 : près de six fois plus d'information que le premier plan, pour le même nombre d'entretiens.
3. Avec dix grappes, la correction elle-même est peu fiable : il en faut une quarantaine.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. Sur coupe, H4 tombe par **regroupement** : $\varepsilon_{ig} = u_g + v_{ig}$, ici $\rho = 0{,}30$.
2. **Facteur de Moulton** $\sqrt{1 + (m-1)\rho_x\rho_\varepsilon}$: 1,92 pour le milieu, 1,07 pour le revenu.
3. Coefficients **sans biais**, écarts-types trop petits pour les variables de grappe : excès de confiance.
4. Effectif équivalent : nos 400 ménages valent 108 pour mesurer l'effet du milieu.
5. Les **écarts-types de grappe** corrigent, et corrigent aussi l'hétéroscédasticité ; White seul, non.
6. Regrouper au niveau du **traitement**, et prévoir au moins **quarante grappes**.

La suite

Nous en arrivons à la seule ligne orange de la carte : celle qui biaise les coefficients eux-mêmes. Et l'on va vérifier, à la quatrième décimale, que sa formule prédit exactement ce qu'elle annonce.