

Chapitre 8

Estimation et R carré ajusté

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Économétrie — Introduction

1 Exercices du chapitre

Correction — Exercice 1

(a) $\bar{R}^2 = 1 - (1 - R^2) \frac{n-1}{n-k-1}$.

(b) $\bar{R}^2 = 1 - (1 - 0,55) \times \frac{39}{34} = 1 - 0,45 \times 1,1471 = 1 - 0,5162 \approx \mathbf{0,484}$.

(c) Oui, $0,484 < 0,55$. Dès que $k \geq 1$, le facteur $(n-1)/(n-k-1)$ est strictement supérieur à 1, ce qui **amplifie** $(1 - R^2)$ avant de le soustraire de 1 : $\bar{R}^2$ est donc toujours inférieur ou égal à R^2 , l'égalité n'ayant lieu que dans des cas dégénérés.

Correction — Exercice 2

(a) $k = 2 : \bar{R}^2 = 1 - (1 - 0,50) \times \frac{29}{27} = 1 - 0,50 \times 1,0741 = 1 - 0,5370 \approx \mathbf{0,463}$. $k = 3 : \bar{R}^2 = 1 - (1 - 0,53) \times \frac{29}{26} = 1 - 0,47 \times 1,1154 = 1 - 0,5242 \approx \mathbf{0,476}$.

(b) Oui, le R^2 simple est passé de 0,50 à 0,53. Cela ne suffit **pas**, seul, à justifier de garder la variable : le R^2 simple augmente **mécaniquement** avec l'ajout de n'importe quelle variable, utile ou non.

(c) Oui, le R^2 ajusté est également passé de 0,463 à 0,476 : il a, lui aussi, augmenté.

(d) Puisque le R^2 ajusté a augmenté, cela suggère que le $|t|$ de la troisième variable dépasse probablement 1 (la condition du cours pour qu'une variable améliore le R^2 ajusté) — la variable apporte donc plus qu'elle ne coûte en degré de liberté, sans que l'on puisse pour autant conclure qu'elle est significative au seuil usuel de 5 % ($|t| > 1,96$), un critère bien plus exigeant.

Correction — Exercice 3

(a) $\bar{R}^2 = 1 - (1 - 0,15) \times \frac{9}{1} = 1 - 0,85 \times 9 = 1 - 7,65 = \mathbf{-6,65}$.

(b) Non, ce n'est pas une erreur : le R^2 ajusté peut légitimement être négatif, notamment lorsque k est grand par rapport à n (ici $k = 8$ pour seulement $n = 10$ observations, soit un degré de liberté restant de $n - k - 1 = 1$ à peine).

(c) Il signifie que le modèle prédit moins bien qu'un modèle qui prédirait simplement la **moyenne** de y pour toutes les observations (l'équivalent d'une droite horizontale, $R^2 = 0$, chapitre 4) — ici, en plus, avec le coût de huit paramètres inutilement estimés sur un échantillon bien trop petit.

(d) Retirer des variables (réduire k), ou collecter davantage d'observations (augmenter n).

2 Exercice cumulatif

Correction — Exercice 4

(a) M1 : $\bar{R}^2 = 1 - (1 - 0,405) \times \frac{499}{498} = 1 - 0,595 \times 1,002 = 1 - 0,5962 \approx \mathbf{0,4038}$, très proche du 0,404 rapporté par le cours (écart dû aux arrondis des valeurs de R^2 elles-mêmes, données à trois décimales).

(b) M2 ($k = 3$) : $\bar{R}^2 = 1 - (1 - 0,642) \times \frac{499}{496} = 1 - 0,358 \times 1,00605 = 1 - 0,3602 \approx \mathbf{0,6398}$. M3

($k = 4$) : $\bar{R}^2 = 1 - (1 - 0,642) \times \frac{499}{495} = 1 - 0,358 \times 1,00808 = 1 - 0,3609 \approx \mathbf{0,6391}$. M3 a un $\bar{R}^2$ **légèrement inférieur** à M2 ($0,6391 < 0,6398$), bien que les deux aient exactement le même R^2 simple.

C'est parfaitement cohérent avec l'ecobox du cours : le sexe, en n'améliorant pas le R^2 simple tout en « coûtant » un degré de liberté supplémentaire, fait légèrement **reculer** le R^2 ajusté.

(c) M4 ($k = 7$) : $\bar{R}^2 = 1 - (1 - 0,668) \times \frac{499}{492} = 1 - 0,332 \times 1,01423 = 1 - 0,3367 \approx \mathbf{0,6633}$, proche du 0,664 rapporté par le cours.

(d) Classement par $\bar{R}^2$ décroissant : M4 (0,6633) > M2 (0,6398) > M3 (0,6391) > M1 (0,4038). Ce classement **ne correspond pas** exactement au classement par k croissant ($1 < 3 < 4 < 7$) : M2 ($k = 3$) devance M3 ($k = 4$), alors qu'un classement fondé sur la seule taille du modèle placerait M3 avant M2. Le modèle le plus grand (M4, $k = 7$) reste ici le meilleur, mais ce n'est pas garanti en général — c'est précisément le renversement M2/M3 qui le montre sur ces données mêmes.

(e) Non, ce ne sont pas la même information : l'écart entre effet brut (277,17, régression simple M1) et effet net (266,74, régression multiple M4) mesure de **combien** l'estimation du coefficient de l'ancienneté **elle-même** change une fois les autres variables ajoutées (un diagnostic sur **ce** coefficient précis). Le gain de $\bar{R}^2$ entre M1 et M4 mesure, lui, l'amélioration de la capacité **globale** du modèle à expliquer la variance du salaire (un diagnostic sur l'ajustement d'ensemble). Un modèle peut très bien voir son R^2 ajusté progresser sans que le coefficient d'une variable particulière ne change beaucoup, et inversement : ce sont deux informations distinctes, complémentaires, tirées du même ensemble de régressions.

3 Applications en sciences économiques

Correction — Exercice 5

(a) $2\,008 - 1\,508 = 500$ DH.

(b) $500/2\,008 \approx 24,9\%$.

(c) Le chiffre « deux tiers » se lit sur $1 - R^2_{M4} = 1 - 0,668 = 0,332 \approx 1/3$ **expliqué**, donc environ deux tiers **inexpliqué** — c'est une lecture de la **part de variance**, pas de l'écart-type résiduel exprimé en dirhams (qui, lui, a baissé d'environ 25 %, pas de deux tiers).

(d) Le cours suggère que la marge de progression restante est limitée par le contenu même du fichier de données : les facteurs qui expliqueraient le reste de la dispersion (poste occupé, performance individuelle, résultat de négociation salariale) ne figurent tout simplement **pas** dans les six colonnes disponibles. Ajouter des variables sans rapport ferait certes monter le R^2 simple (par construction, chapitre 8), mais dégraderait probablement le R^2 ajusté, et n'apporterait aucun progrès réel tant que les variables manquantes ne sont pas effectivement collectées.

Correction — Exercice 6

(a) Non : les deux échantillons ont des n et des k différents, exactement la situation où le cours interdit la comparaison directe des R^2 simples — l'équipe B, avec $k = 10$ sur seulement $n = 60$ observations, bénéficie mécaniquement d'un R^2 plus élevé du seul fait d'avoir davantage de variables relativement à la taille de son échantillon.

(b) Équipe A : $\bar{R}^2 = 1 - (1 - 0,35) \times \frac{199}{195} = 1 - 0,65 \times 1,0205 = 1 - 0,6633 \approx 0,3367$. Équipe B : $\bar{R}^2 = 1 - (1 - 0,45) \times \frac{59}{49} = 1 - 0,55 \times 1,2041 = 1 - 0,6622 \approx 0,3378$.

(c) Le classement ne s'inverse pas complètement (l'équipe B garde un $\bar{R}^2$ très légèrement supérieur, 0,3378 contre 0,3367), mais l'écart, qui était de 0,10 en R^2 simple, se réduit à environ 0,001 une fois la correction appliquée — un écart désormais négligeable, largement dans la marge d'erreur d'estimation. L'essentiel de l'avantage apparent de l'équipe B était donc un artefact de son plus grand nombre de variables relativement à son petit échantillon, et non une preuve d'un modèle réellement plus explicatif.

(d) Avec $k = 10$ variables pour seulement $n = 60$ observations (un rapport k/n élevé), l'équipe B a estimé un modèle relativement « chargé » par rapport à sa taille d'échantillon : le R^2 simple, mécaniquement croissant avec k , en est artificiellement gonflé, tandis que le facteur de correction $(n-1)/(n-k-1) = 59/49 \approx 1,204$ — nettement plus pénalisant que celui de l'équipe A, $199/195 \approx 1,021$ — absorbe presque tout cet avantage apparent une fois le R^2 ajusté calculé.