

Introduction à l'économétrie

Chapitre 8 : Estimation et R carré ajusté

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'économétrie

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Calculer un R^2 ajusté

Une régression sur $n = 40$ entreprises, avec $k = 5$ variables explicatives, donne $R^2 = 0,55$.

- (a) Rappeler la formule du $\bar{R}^2$ ajusté.
- (b) Calculer $\bar{R}^2$ pour cette régression.
- (c) $\bar{R}^2$ est-il, comme toujours, inférieur à R^2 ? Pourquoi cela doit-il nécessairement être le cas dès que $k \geq 1$?

Exercice 2 — Une variable vaut-elle la peine d'être ajoutée ?

Sur les mêmes $n = 30$ entreprises, un modèle à $k = 2$ variables donne $R^2 = 0,50$. En ajoutant une troisième variable, le modèle ($k = 3$) donne $R^2 = 0,53$.

- (a) Calculer $\bar{R}^2$ pour le modèle à $k = 2$, puis pour le modèle à $k = 3$.
- (b) Le R^2 simple a-t-il augmenté avec l'ajout de la troisième variable? Cela suffit-il, seul, à justifier de la garder?
- (c) Le R^2 ajusté a-t-il, lui aussi, augmenté?
- (d) Le cours indique qu'une variable améliore le R^2 ajusté dès que son $|t|$ dépasse 1 (un seuil bien plus permissif que 1,96). Qu'est-ce que le résultat de la question (c) suggère sur le $|t|$ probable de cette troisième variable (largement supérieur à 1, proche de 1, ou inférieur à 1)?

Exercice 3 — Un R^2 ajusté négatif

Une étude exploratoire régresse le chiffre d'affaires de $n = 10$ start-ups sur $k = 8$ variables explicatives (presque autant de variables que d'observations), et obtient $R^2 = 0,15$.

- (a) Calculer $\bar{R}^2$ pour cette régression.
- (b) Ce résultat signifie-t-il qu'il y a une erreur de calcul?
- (c) Un R^2 ajusté négatif signifie que le modèle prédit **moins bien** qu'un prédicteur trivial. Lequel?
- (d) Quelles sont les deux solutions, suggérées par le cours, face à un R^2 ajusté négatif?

2 Exercice cumulatif (chapitre 8 et chapitres précédents)

Exercice 4 — Recalculer la table des quatre modèles

Sur les 500 salariés du cours, on donne les couples (k, R^2) suivants : M1 (ancienneté seule, chapitre 5) $k = 1, R^2 = 0,405$; M2 (+diplôme, chapitre 7) $k = 3, R^2 = 0,642$; M3 (+sexe) $k = 4, R^2 = 0,642$; M4 (+région) $k = 7, R^2 = 0,668$.

- (a) Calculer $\bar{R}^2$ pour M1. Comparer au $\bar{R}^2 = 0,404$ rapporté par le cours.
- (b) Calculer $\bar{R}^2$ pour M2, puis pour M3. M2 et M3 ont le **même** R^2 (0,642) mais un k différent (3 contre 4) : lequel des deux a le $\bar{R}^2$ le plus élevé? Est-ce cohérent avec l'ecobox du cours « le sexe n'apporte rien »?
- (c) Calculer $\bar{R}^2$ pour M4.
- (d) Classer les quatre modèles par $\bar{R}^2$ décroissant. Ce classement correspond-il à celui qu'on obtiendrait en classant par le nombre de variables k (le modèle le plus grand n'est donc pas automatiquement le meilleur au sens du R^2 ajusté, à la différence du R^2 simple)?

- (e) Le chapitre 7 avait distingué l'effet brut (277,17) de l'effet net (266,74) de l'ancienneté. Le passage de M1 à M4 (ajout du diplôme, du sexe et de la région) est-il ce qui a permis de calculer cet effet **net**? Le gain de R^2 ajusté entre M1 et M4 mesure-t-il la même chose que l'écart entre effet brut et effet net, ou s'agit-il de deux informations **distinctes** tirées du même ensemble de régressions?

3 Applications en sciences économiques

Exercice 5 — Le progrès, en dirhams plutôt qu'en pourcentage

Le cours rapporte $\hat{\sigma}_\varepsilon = 2008$ DH pour M1 (ancienneté seule) et $\hat{\sigma}_\varepsilon = 1508$ DH pour M4 (modèle complet).

- (a) Calculer la réduction de l'erreur typique de prévision, en dirhams, entre M1 et M4.
- (b) Calculer cette réduction en pourcentage de $\hat{\sigma}_\varepsilon$ (M1).
- (c) Le cours affirme : « deux tiers de la dispersion des salaires tiennent à des facteurs absents du fichier ». Ce chiffre « deux tiers » se lit-il directement sur $\hat{\sigma}_\varepsilon$, ou plutôt sur $1 - R^2$ de M4 (rappeler $R^2_{M4} = 0,668$, chapitre 4)?
- (d) Une direction générale demande : « pourquoi ne pas simplement ajouter davantage de variables pour faire encore baisser $\hat{\sigma}_\varepsilon$? ». Quelle réponse le cours suggère-t-il, sachant que le fichier ne contient que six colonnes de variables explicatives (ancienneté, diplôme, sexe, région) ?

Exercice 6 — Comparer deux études de tailles différentes

Deux équipes de recherche indépendantes étudient le même phénomène (le rendement scolaire) sur des échantillons différents. Équipe A : $n = 200, k = 4, R^2 = 0,35$. Équipe B : $n = 60, k = 10, R^2 = 0,45$.

- (a) L'équipe B affirme avoir un « meilleur » modèle, puisque son R^2 (0,45) dépasse celui de l'équipe A (0,35). Cette comparaison directe des R^2 est-elle appropriée, sachant que les deux équipes n'ont ni le même n ni le même k ?
- (b) Calculer $\overline{R}^2$ pour l'équipe A, puis pour l'équipe B.
- (c) Le classement change-t-il une fois la correction appliquée ?
- (d) En vous appuyant sur le nombre de variables ($k = 10$) rapporté au nombre d'observations ($n = 60$) de l'équipe B, proposer une explication à l'écart entre son R^2 simple, élevé, et son R^2 ajusté.

1 Exercices du chapitre

Correction — Exercice 1

(a) $\bar{R}^2 = 1 - (1 - R^2) \frac{n-1}{n-k-1}$.

(b) $\bar{R}^2 = 1 - (1 - 0,55) \times \frac{39}{34} = 1 - 0,45 \times 1,1471 = 1 - 0,5162 \approx \mathbf{0,484}$.

(c) Oui, $0,484 < 0,55$. Dès que $k \geq 1$, le facteur $(n-1)/(n-k-1)$ est strictement supérieur à 1, ce qui **amplifie** $(1 - R^2)$ avant de le soustraire de 1 : $\bar{R}^2$ est donc toujours inférieur ou égal à R^2 , l'égalité n'ayant lieu que dans des cas dégénérés.

Correction — Exercice 2

(a) $k = 2 : \bar{R}^2 = 1 - (1 - 0,50) \times \frac{29}{27} = 1 - 0,50 \times 1,0741 = 1 - 0,5370 \approx \mathbf{0,463}$. $k = 3 : \bar{R}^2 = 1 - (1 - 0,53) \times \frac{29}{26} = 1 - 0,47 \times 1,1154 = 1 - 0,5242 \approx \mathbf{0,476}$.

(b) Oui, le R^2 simple est passé de 0,50 à 0,53. Cela ne suffit **pas**, seul, à justifier de garder la variable : le R^2 simple augmente **mécaniquement** avec l'ajout de n'importe quelle variable, utile ou non.

(c) Oui, le R^2 ajusté est également passé de 0,463 à 0,476 : il a, lui aussi, augmenté.

(d) Puisque le R^2 ajusté a augmenté, cela suggère que le $|t|$ de la troisième variable dépasse probablement 1 (la condition du cours pour qu'une variable améliore le R^2 ajusté) — la variable apporte donc plus qu'elle ne coûte en degré de liberté, sans que l'on puisse pour autant conclure qu'elle est significative au seuil usuel de 5 % ($|t| > 1,96$), un critère bien plus exigeant.

Correction — Exercice 3

(a) $\bar{R}^2 = 1 - (1 - 0,15) \times \frac{9}{1} = 1 - 0,85 \times 9 = 1 - 7,65 = \mathbf{-6,65}$.

(b) Non, ce n'est pas une erreur : le R^2 ajusté peut légitimement être négatif, notamment lorsque k est grand par rapport à n (ici $k = 8$ pour seulement $n = 10$ observations, soit un degré de liberté restant de $n - k - 1 = 1$ à peine).

(c) Il signifie que le modèle prédit moins bien qu'un modèle qui prédirait simplement la **moyenne** de y pour toutes les observations (l'équivalent d'une droite horizontale, $R^2 = 0$, chapitre 4) — ici, en plus, avec le coût de huit paramètres inutilement estimés sur un échantillon bien trop petit.

(d) Retirer des variables (réduire k), ou collecter davantage d'observations (augmenter n).

2 Exercice cumulatif

Correction — Exercice 4

(a) M1 : $\bar{R}^2 = 1 - (1 - 0,405) \times \frac{499}{498} = 1 - 0,595 \times 1,002 = 1 - 0,5962 \approx \mathbf{0,4038}$, très proche du 0,404 rapporté par le cours (écart dû aux arrondis des valeurs de R^2 elles-mêmes, données à trois décimales).

(b) M2 ($k = 3$) : $\bar{R}^2 = 1 - (1 - 0,642) \times \frac{499}{496} = 1 - 0,358 \times 1,00605 = 1 - 0,3602 \approx \mathbf{0,6398}$. M3

($k = 4$) : $\bar{R}^2 = 1 - (1 - 0,642) \times \frac{499}{495} = 1 - 0,358 \times 1,00808 = 1 - 0,3609 \approx \mathbf{0,6391}$. M3 a un $\bar{R}^2$ **légèrement inférieur** à M2 ($0,6391 < 0,6398$), bien que les deux aient exactement le même R^2 simple. C'est parfaitement cohérent avec l'ecobox du cours : le sexe, en n'améliorant pas le R^2 simple tout en « coûtant » un degré de liberté supplémentaire, fait légèrement **reculer** le R^2 ajusté.

(c) M4 ($k = 7$) : $\bar{R}^2 = 1 - (1 - 0,668) \times \frac{499}{492} = 1 - \frac{1}{3} \times 0,332 \times 1,01423 = 1 - 0,3367 \approx \mathbf{0,6633}$, proche du 0,664 rapporté par le cours.

(d) Classement par $\bar{R}^2$ décroissant : M4 (0,6633) > M2 (0,6398) > M3 (0,6391) > M1 (0,4038). Ce classement **ne correspond pas** exactement au classement par k croissant ($1 < 3 < 4 < 7$) : M2 ($k = 3$) devance M3 ($k = 4$), alors qu'un classement fondé sur la seule taille du modèle placerait M3 avant M2. Le modèle le plus grand (M4, $k = 7$) reste ici le meilleur, mais ce n'est pas garanti en général — c'est précisément le renversement M2/M3 qui le montre sur ces données mêmes.

(e) Non, ce ne sont pas la même information : l'écart entre effet brut (277,17, régression simple M1) et effet net (266,74, régression multiple M4) mesure de **combien** l'estimation du coefficient de l'ancienneté **elle-même** change une fois les autres variables ajoutées (un diagnostic sur **ce** coefficient précis). Le gain de $\bar{R}^2$ entre M1 et M4 mesure, lui, l'amélioration de la capacité **globale** du modèle à expliquer la variance du salaire (un diagnostic sur l'ajustement d'ensemble). Un modèle peut très bien voir son R^2 ajusté progresser sans que le coefficient d'une variable particulière ne change beaucoup, et inversement : ce sont deux informations distinctes, complémentaires, tirées du même ensemble de régressions.

3 Applications en sciences économiques

Correction — Exercice 5

(a) $2\,008 - 1\,508 = 500$ DH.

(b) $500/2\,008 \approx 24,9\%$.

(c) Le chiffre « deux tiers » se lit sur $1 - R^2_{M4} = 1 - 0,668 = 0,332 \approx 1/3$ **expliqué**, donc environ deux tiers **inexpliqué** — c'est une lecture de la **part de variance**, pas de l'écart-type résiduel exprimé en dirhams (qui, lui, a baissé d'environ 25 %, pas de deux tiers).

(d) Le cours suggère que la marge de progression restante est limitée par le contenu même du fichier de données : les facteurs qui expliqueraient le reste de la dispersion (poste occupé, performance individuelle, résultat de négociation salariale) ne figurent tout simplement **pas** dans les six colonnes disponibles. Ajouter des variables sans rapport ferait certes monter le R^2 simple (par construction, chapitre 8), mais dégraderait probablement le R^2 ajusté, et n'apporterait aucun progrès réel tant que les variables manquantes ne sont pas effectivement collectées.

Correction — Exercice 6

(a) Non : les deux échantillons ont des n et des k différents, exactement la situation où le cours interdit la comparaison directe des R^2 simples — l'équipe B, avec $k = 10$ sur seulement $n = 60$ observations, bénéficie mécaniquement d'un R^2 plus élevé du seul fait d'avoir davantage de variables relativement à la taille de son échantillon.

(b) Équipe A : $\bar{R}^2 = 1 - (1 - 0,35) \times \frac{199}{195} = 1 - 0,65 \times 1,0205 = 1 - 0,6633 \approx 0,3367$. Équipe B : $\bar{R}^2 = 1 - (1 - 0,45) \times \frac{59}{49} = 1 - 0,55 \times 1,2041 = 1 - 0,6622 \approx 0,3378$.

(c) Le classement ne s'inverse pas complètement (l'équipe B garde un $\bar{R}^2$ très légèrement supérieur, 0,3378 contre 0,3367), mais l'écart, qui était de 0,10 en R^2 simple, se réduit à environ 0,001 une fois la correction appliquée — un écart désormais négligeable, largement dans la marge d'erreur d'estimation. L'essentiel de l'avantage apparent de l'équipe B était donc un artefact de son plus grand nombre de variables relativement à son petit échantillon, et non une preuve d'un modèle réellement plus explicatif.

(d) Avec $k = 10$ variables pour seulement $n = 60$ observations (un rapport k/n élevé), l'équipe B a estimé un modèle relativement « chargé » par rapport à sa taille d'échantillon : le R^2 simple, mécaniquement croissant avec k , en est artificiellement gonflé, tandis que le facteur de correction $(n-1)/(n-k-1) = 59/49 \approx 1,204$ — nettement plus pénalisant que celui de l'équipe A, $199/195 \approx 1,021$ — absorbe presque tout cet avantage apparent une fois le R^2 ajusté calculé.