

Chapitre 8

Estimation et R carré ajusté

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Économétrie — Introduction

1 Exercices du chapitre

Exercice 1 — Calculer un R^2 ajusté

Une régression sur $n = 40$ entreprises, avec $k = 5$ variables explicatives, donne $R^2 = 0,55$.

- (a) Rappeler la formule du R^2 ajusté.
- (b) Calculer $\bar{R}^2$ pour cette régression.
- (c) $\bar{R}^2$ est-il, comme toujours, inférieur à R^2 ? Pourquoi cela doit-il nécessairement être le cas dès que $k \geq 1$?

Exercice 2 — Une variable vaut-elle la peine d'être ajoutée ?

Sur les mêmes $n = 30$ entreprises, un modèle à $k = 2$ variables donne $R^2 = 0,50$. En ajoutant une troisième variable, le modèle ($k = 3$) donne $R^2 = 0,53$.

- (a) Calculer $\bar{R}^2$ pour le modèle à $k = 2$, puis pour le modèle à $k = 3$.
- (b) Le R^2 simple a-t-il augmenté avec l'ajout de la troisième variable? Cela suffit-il, seul, à justifier de la garder?
- (c) Le R^2 ajusté a-t-il, lui aussi, augmenté?
- (d) Le cours indique qu'une variable améliore le R^2 ajusté dès que son $|t|$ dépasse 1 (un seuil bien plus permissif que 1,96). Qu'est-ce que le résultat de la question (c) suggère sur le $|t|$ probable de cette troisième variable (largement supérieur à 1, proche de 1, ou inférieur à 1)?

Exercice 3 — Un R^2 ajusté négatif

Une étude exploratoire régresse le chiffre d'affaires de $n = 10$ start-ups sur $k = 8$ variables explicatives (presque autant de variables que d'observations), et obtient $R^2 = 0,15$.

- (a) Calculer $\bar{R}^2$ pour cette régression.
- (b) Ce résultat signifie-t-il qu'il y a une erreur de calcul?
- (c) Un R^2 ajusté négatif signifie que le modèle prédit **moins bien** qu'un prédicteur trivial. Lequel?
- (d) Quelles sont les deux solutions, suggérées par le cours, face à un R^2 ajusté négatif?

2 Exercice cumulatif (chapitre 8 et chapitres précédents)

Exercice 4 — Recalculer la table des quatre modèles

Sur les 500 salariés du cours, on donne les couples (k, R^2) suivants : M1 (ancienneté seule, chapitre 5) $k = 1, R^2 = 0,405$; M2 (+diplôme, chapitre 7) $k = 3, R^2 = 0,642$; M3 (+sexe) $k = 4, R^2 = 0,642$; M4 (+région) $k = 7, R^2 = 0,668$.

- (a) Calculer $\bar{R}^2$ pour M1. Comparer au $\bar{R}^2 = 0,404$ rapporté par le cours.
- (b) Calculer $\bar{R}^2$ pour M2, puis pour M3. M2 et M3 ont le **même** R^2 (0,642) mais un k différent (3 contre 4) : lequel des deux a le $\bar{R}^2$ le plus élevé? Est-ce cohérent avec l'ecobox du cours « le sexe n'apporte rien »?
- (c) Calculer $\bar{R}^2$ pour M4.
- (d) Classer les quatre modèles par $\bar{R}^2$ décroissant. Ce classement correspond-il à celui qu'on obtiendrait en classant par le nombre de variables k (le modèle le plus grand n'est donc pas automatiquement le meilleur au sens du R^2 ajusté, à la différence du R^2 simple)?

- (e) Le chapitre 7 avait distingué l'effet brut (277,17) de l'effet net (266,74) de l'ancienneté. Le passage de M1 à M4 (ajout du diplôme, du sexe et de la région) est-il ce qui a permis de calculer cet effet **net**? Le gain de R^2 ajusté entre M1 et M4 mesure-t-il la même chose que l'écart entre effet brut et effet net, ou s'agit-il de deux informations **distinctes** tirées du même ensemble de régressions?

3 Applications en sciences économiques

Exercice 5 — Le progrès, en dirhams plutôt qu'en pourcentage

Le cours rapporte $\hat{\sigma}_\varepsilon = 2\,008$ DH pour M1 (ancienneté seule) et $\hat{\sigma}_\varepsilon = 1\,508$ DH pour M4 (modèle complet).

- Calculer la réduction de l'erreur typique de prévision, en dirhams, entre M1 et M4.
- Calculer cette réduction en pourcentage de $\hat{\sigma}_\varepsilon$ (M1).
- Le cours affirme : « deux tiers de la dispersion des salaires tiennent à des facteurs absents du fichier ». Ce chiffre « deux tiers » se lit-il directement sur $\hat{\sigma}_\varepsilon$, ou plutôt sur $1 - R^2$ de M4 (rappeler $R^2_{M4} = 0,668$, chapitre 4)?
- Une direction générale demande : « pourquoi ne pas simplement ajouter davantage de variables pour faire encore baisser $\hat{\sigma}_\varepsilon$? ». Quelle réponse le cours suggère-t-il, sachant que le fichier ne contient que six colonnes de variables explicatives (ancienneté, diplôme, sexe, région)?

Exercice 6 — Comparer deux études de tailles différentes

Deux équipes de recherche indépendantes étudient le même phénomène (le rendement scolaire) sur des échantillons différents. Équipe A : $n = 200, k = 4, R^2 = 0,35$. Équipe B : $n = 60, k = 10, R^2 = 0,45$.

- L'équipe B affirme avoir un « meilleur » modèle, puisque son R^2 (0,45) dépasse celui de l'équipe A (0,35). Cette comparaison directe des R^2 est-elle appropriée, sachant que les deux équipes n'ont ni le même n ni le même k ?
- Calculer $\bar{R}^2$ pour l'équipe A, puis pour l'équipe B.
- Le classement change-t-il une fois la correction appliquée?
- En vous appuyant sur le nombre de variables ($k = 10$) rapporté au nombre d'observations ($n = 60$) de l'équipe B, proposer une explication à l'écart entre son R^2 simple, élevé, et son R^2 ajusté.