

Introduction à l'économétrie

Chapitre 8 : Estimation et R carré ajusté

Jaouad Madkour

24 septembre 2026

Plan du chapitre

Le défaut du R carré	1
Une propriété gênante	1
La correction	2
Sa formule et sa logique	2
Trois propriétés à connaître	2
Sur nos données	3
Les cinq modèles	3
Les cinq modèles, ligne par ligne	3
L'écart-type résiduel, encore	3
Ce qu'il faut retenir	4
Le résumé du chapitre	4

Le défaut du R carré

Une propriété gênante


Le R^2 ne peut jamais baisser

Ajouter une variable explicative ne peut pas augmenter la somme des carrés résiduels. Au pire, son coefficient estimé sort nul et le modèle est inchangé. Le R^2 est donc **croissant par construction** avec le nombre de variables.

La conséquence est radicale

Choisir le modèle de plus grand R^2 revient à choisir **le modèle le plus long**, toujours. En ajoutant assez de variables sans rapport, on atteint $R^2 = 1$ — et l'on n'a rien expliqué du tout. Le R^2 est donc inutilisable pour comparer des modèles de tailles différentes.

La correction



Pourquoi le R^2 monte toujours

Ajouter une variable ne peut pas augmenter la somme des carrés résiduels : au pire, son coefficient sort nul. Le R^2 est donc **croissant par construction** — et par conséquent inutilisable pour choisir un modèle.

La correction

$$\bar{R}^2 = 1 - (1 - R^2) \frac{n-1}{n-k-1}$$

Elle facture chaque variable ajoutée. Une variable n'améliore le R^2 ajusté que si elle apporte plus que ce qu'elle coûte en degré de liberté.

Le R^2 ajusté peut être négatif. Ce n'est pas une erreur de calcul : cela signale un modèle qui prédit moins bien que la simple moyenne.

Sa formule et sa logique

Le R^2 ajusté

$$\bar{R}^2 = 1 - (1 - R^2) \frac{n-1}{n-k-1}$$

Chaque variable ajoutée réduit $n - k - 1$, donc gonfle le second facteur : elle est **facturée**.

Ce que la facture signifie

Une variable n'améliore le R^2 ajusté que si elle apporte **plus qu'elle ne coûte en degré de liberté**.

On peut montrer que cela équivaut à ce que son $|t|$ dépasse 1 — un seuil bien plus permissif que 1,96. Le R^2 ajusté est donc un critère **indulgent**, et le chapitre 19 en présentera de plus sévères.

Trois propriétés à connaître

Ce qui distingue les deux

	R^2	R^2 ajusté
Ajout d'une variable	monte toujours	monte ou baisse
Valeurs possibles	$[0 ; 1]$	peut être négatif
Usage	décrire l'ajustement	comparer des modèles

Un R^2 ajusté négatif n'est pas une erreur de calcul

Il signale un modèle qui prédit **moins bien que la simple moyenne** de y .

Cela arrive avec beaucoup de variables sur peu d'observations. Le message est clair : il faut retirer des variables, ou en collecter davantage.

Sur nos données

Les cinq modèles

Ce que chaque ajout apporte

Modèle	k	R^2	R^2 ajusté
M1 ancienneté	1	0,405	0,404
M2 + diplôme	3	0,642	0,640
M3 + sexe	4	0,642	0,640
M4 + région	7	0,668	0,664

Les cinq modèles, ligne par ligne

La lecture, ligne par ligne

Le **diplôme** est décisif : le R^2 passe de 0,405 à 0,642. Il expliquait à lui seul un quart de la dispersion, comme l'ANOVA du chapitre 17 de l'inférence l'avait établi.

Le **sexe** n'apporte rien : R^2 inchangé, R^2 ajusté qui baisse au troisième chiffre. La variable coûte plus qu'elle ne rapporte.

La **région** apporte encore deux points et demi. Le marché du travail marocain n'est pas homogène géographiquement.

L'écart-type résiduel, encore

La lecture concrète du progrès

Modèle	$\hat{\sigma}_\varepsilon$
M1	2 008 dh
M2	1 561 dh
M4	1 508 dh

Elle dit la même chose, en dirhams

Le modèle complet se trompe typiquement de mille cinq cents dirhams sur un salaire individuel, contre deux mille pour le modèle initial.

C'est un progrès réel, et il reste modeste. Deux tiers de la dispersion des salaires tiennent à des facteurs absents du fichier : poste, performance, négociation. Aucune régression ne fera mieux avec ces six colonnes.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. Le R^2 **monte toujours** quand on ajoute une variable : il ne peut pas servir à choisir.
2. $\overline{R}^2 = 1 - (1 - R^2) \frac{n-1}{n-k-1}$: chaque variable est **facturée**.
3. Une variable améliore le R^2 ajusté dès que son $|t|$ dépasse 1 — critère indulgent.
4. Le R^2 ajusté peut être **négatif** : le modèle fait alors moins bien que la moyenne.
5. Sur nos données : le diplôme est décisif, le sexe n'apporte rien, la région compte un peu.
6. $\hat{\sigma}_\varepsilon$ passe de 2 008 à 1 508 dirhams — un progrès réel et modeste.

La suite

Avec plusieurs variables, une question nouvelle se pose : tester chaque coefficient séparément suffit-il ?

Le chapitre 9 montre que non — et que trois tests différents cohabitent, dont les réponses peuvent diverger sans se contredire.