Introduction à l'économétrie

Chapitre 8 : Estimation et R carré ajusté

Jaouad Madkour

29 octobre 2026

Plan du chapitre

Le défaut du R carré **2**
- Une propriété gênante . . . 2
- La correction . . . 2
- Sa formule et sa logique . . . 3
- Le R^2 ajusté, autrement écrit . . . 3
- Trois propriétés à connaître . . . 3

À la main, sur les cinq ménages **4**
- Ajouter la taille : le R^2 monte . . . 4
- Pourquoi exactement : un t égal à 1 . . . 4

Sur nos données **6**
- Les quatre premiers modèles . . . 6
- Les modèles, ligne par ligne . . . 6
- L'écart-type résiduel, encore . . . 6
- Des variables de pur hasard . . . 7

Sur machine **7**
- Les quatre modèles avec R . . . 7
- Les cinq ménages avec Python . . . 7

S'entraîner **8**
- Exercice 1 : deux modèles à comparer . . . 8
- Exercice 1 : solution . . . 8
- Exercice 2 : un R^2 ajusté négatif . . . 8
- Exercice 2 : solution . . . 8
- Exercice 3 : la règle du t égal à 1 . . . 9
- Exercice 3 : solution . . . 9

Ce qu'il faut retenir **9**
- Le résumé du chapitre . . . 9

Le défaut du R carré

Une propriété gênante

Le R^2 ne peut jamais baisser

Ajouter une variable explicative ne peut pas augmenter la somme des carrés résiduels. Au pire, son coefficient estimé sort nul et le modèle est inchangé. Le R^2 est donc **croissant par construction** avec le nombre de variables.

Démonstration : Le R^2 ne peut pas baisser quand on ajoute une variable

Le modèle court, à k variables, est un cas particulier du modèle long, à $k + 1$ variables : il correspond à un coefficient nul pour la variable ajoutée. Les moindres carrés du modèle long cherchent le minimum de la somme des carrés sur un ensemble de coefficients plus vaste, qui contient la solution du modèle court. Le minimum ne peut donc pas être plus grand :

$$\mathrm{SCR}_{\text{long}} \leq \mathrm{SCR}_{\text{court}}.$$

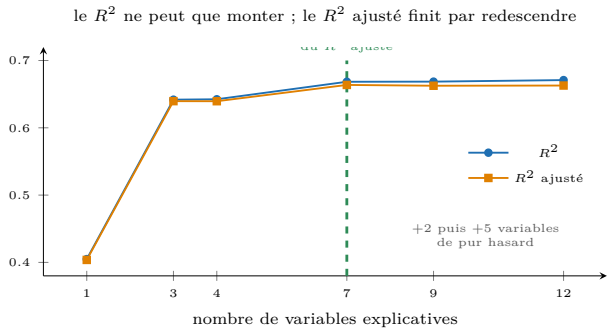
La somme des carrés totale ne dépend pas du modèle, donc $R^2_{\text{long}} = 1 - \mathrm{SCR}_{\text{long}}/\mathrm{SCT} \geq R^2_{\text{court}}$. L'égalité n'a lieu que si la solution du modèle court est aussi celle du modèle long, c'est-à-dire si le coefficient estimé de la variable ajoutée est nul (voir la démonstration ci-dessous sur le R^2 ajusté).

■

La conséquence est radicale

Choisir le modèle de plus grand R^2 revient à choisir **le modèle le plus long**, toujours. En ajoutant assez de variables sans rapport, on atteint $R^2 = 1$ — et l'on n'a rien expliqué du tout. Le R^2 est donc inutilisable pour comparer des modèles de tailles différentes.

La correction



Pourquoi le R^2 monte toujours

Ajouter une variable ne peut pas augmenter la somme des carrés résiduels : au pire, son coefficient sort nul. Le R^2 est donc **croissant par construction** — et par conséquent inutilisable pour choisir un modèle.

La correction

$$\overline{R}^2 = 1 - (1 - R^2)\frac{n-1}{n-k-1}$$

Elle facture chaque variable ajoutée. Les variables de hasard, tirées d'une loi normale, font monter le R^2 de 0,6684 à 0,6709 ; le R^2 ajusté, lui, baisse.

Le R^2 ajusté peut être négatif. Ce n'est pas une erreur de calcul : cela signale un modèle qui prédit moins bien que la simple moyenne.

Sa formule et sa logique

Le R^2 ajusté

$$\overline{R}^2 = 1 - (1 - R^2)\,\frac{n-1}{n-k-1}$$

Chaque variable ajoutée réduit $n-k-1$, donc gonfle le second facteur : elle est **facturée**.

Ce que la facture signifie

Une variable n'améliore le R^2 ajusté que si elle apporte **plus qu'elle ne coûte en degré de liberté**.
On peut montrer que cela équivaut à ce que son $|t|$ dépasse 1 — un seuil bien plus permissif que 1,96. Le R^2 ajusté est donc un critère **indulgent**, et le chapitre 19 en présentera de plus sévères.

Le R² ajusté, autrement écrit

Deux variances corrigées

Comme $1 - R^2 = \text{SCR}/\text{SCT}$:

$$\overline{R}^2 = 1 - \frac{\text{SCR}/(n-k-1)}{\text{SCT}/(n-1)} = 1 - \frac{\hat{\sigma}_\varepsilon^2}{s_y^2}$$

Maximiser l'un, c'est minimiser l'autre

s_y^2 ne dépend pas du modèle. **Le modèle de plus grand R^2 ajusté est celui de plus petit $\hat{\sigma}_\varepsilon$.**
Sur M4 : $s_y = 2\,600{,}70$ et $\hat{\sigma}_\varepsilon = 1\,508{,}25$, d'où $1 - (1\,508{,}25/2\,600{,}70)^2 = 1 - 0{,}3363 = 0{,}6637$.

Trois propriétés à connaître

Ce qui distingue les deux

	R^2	R^2 ajusté
Ajout d'une variable	monte toujours	monte ou baisse
Valeurs possibles	$[0\,;1]$	peut être **négatif**
Usage	décrire l'ajustement	comparer des modèles

Un R^2 ajusté négatif n'est pas une erreur de calcul

Il signale un modèle qui prédit **moins bien que la simple moyenne** de y.
Cela arrive avec beaucoup de variables sur peu d'observations. Le message est clair : il faut retirer des variables, ou en collecter davantage.

Démonstration : $\overline{R}^2 = 1-\hat{\sigma}_\varepsilon^2/s_y^2$, et il est négatif si et seulement si $R^2 < k/(n-1)$

Comme $1 - R^2 = \text{SCR}/\text{SCT}$,

$$\overline{R}^2 = 1 - \frac{\text{SCR}}{\text{SCT}} \cdot \frac{n-1}{n-k-1} = 1 - \frac{\text{SCR}/(n-k-1)}{\text{SCT}/(n-1)} = 1 - \frac{\hat{\sigma}_\varepsilon^2}{s_y^2}.$$

Il est négatif si et seulement si $\hat{\sigma}_\varepsilon^2 > s_y^2$, c'est-à-dire

$$(1-R^2)\,\frac{n-1}{n-k-1} > 1 \iff 1 - R^2 > \frac{n-k-1}{n-1}$$
$$\iff R^2 < \frac{k}{n-1}.$$

Avec $k = 5$ variables sur $n = 11$ observations, le R^2 ajusté est donc négatif dès que $R^2 < 0{,}5$: la variance résiduelle corrigée du modèle dépasse alors celle de y, que donnerait la simple moyenne.

■

À la main, sur les cinq ménages

Ajouter la taille : le R² monte

Deux modèles, cinq ménages

	C sur R	C sur R et T
SCR	7,5	5
$R^2 = 1 - \text{SCR}/30$	0,750	0,833
$n-k-1$	3	2
$\hat{\sigma}_\varepsilon^2$	$7{,}5/3 = 2{,}5$	$5/2 = 2{,}5$
$\overline{R}^2$	$1 - 0{,}25 \times \frac{4}{3} = 0{,}667$	$1 - \frac{1}{6} \times \frac{4}{2} = 0{,}667$

Le R^2 gagne huit points, le R^2 ajusté aucun

La taille fait baisser la somme des carrés résiduels de 7,5 à 5, mais elle coûte un degré de liberté sur trois. **Les deux effets se compensent exactement** : même $\hat{\sigma}_\varepsilon^2$, même R^2 ajusté.

Pourquoi exactement : un t égal à 1

Le seuil, vérifié

Dans le modèle à deux variables, l'erreur-type de la taille vaut 0,5 et son coefficient 0,5 : $t = 1$ **exactement**.
Or le R^2 ajusté monte si $|t| > 1$, baisse si $|t| < 1$, et ne bouge pas si $|t| = 1$.

La règle, en une phrase

Ajouter une variable fait passer $\hat{\sigma}_\varepsilon^2$ de $\mathrm{SCR}_0/(n-k-1)$ à $\mathrm{SCR}_1/(n-k-2)$. On montre que la seconde est plus petite si et seulement si $(\mathrm{SCR}_0 - \mathrm{SCR}_1)/\hat{\sigma}_1^2 > 1$ — c'est-à-dire $t^2 > 1$. Le chapitre 9 appellera ce rapport un **Fisher partiel**.

Démonstration : Le R^2 ajusté monte si et seulement si $|t| > 1$

Comparons le modèle court (variables Z, constante comprise, k variables explicatives) au modèle long, qui ajoute la variable x. Soit u le résidu de la régression de x sur Z, et notons $y = Z\hat{\gamma} + \hat{\beta}\,x + e_1$ le modèle long, dont les résidus e_1 sont orthogonaux à Z et à x, donc à u.

La baisse de la somme des carrés. Retirons de chaque terme sa part expliquée par Z. Le résidu de y sur Z est e_0, les résidus du modèle court. Celui de $Z\hat{\gamma}$ est nul, celui de x est u, celui de e_1 est e_1 lui-même (il est déjà orthogonal à Z). Le résidu d'une somme étant la somme des résidus, $e_0 = \hat{\beta}\,u + e_1$, avec $e_1 \perp u$. Par Pythagore,

$$\mathrm{SCR}_0 = \hat{\beta}^2 \sum_i u_i^2 + \mathrm{SCR}_1,$$
$$\text{soit} \quad \mathrm{SCR}_0 - \mathrm{SCR}_1 = \hat{\beta}^2 \sum_i u_i^2.$$

Le t de la variable ajoutée. C'est le raisonnement de Frisch-Waugh (chapitre 7) : en multipliant le modèle long par u et en sommant, on obtient $\sum_i u_i y_i = \hat{\beta} \sum_i u_i^2$, car $u \perp Z$, $u \perp e_1$ et $\sum_i u_i x_i = \sum_i u_i^2$. Avec $y = Z\gamma + \beta x + \varepsilon$, $\hat{\beta} = \beta + \sum_i u_i \varepsilon_i / \sum_i u_i^2$, d'où $V(\hat{\beta}) = \sigma_\varepsilon^2 / \sum_i u_i^2$. L'erreur-type estimée est $\hat{\sigma}_1 / \sqrt{\sum_i u_i^2}$, avec $\hat{\sigma}_1^2 = \mathrm{SCR}_1/(n-k-2)$, et

$$t^2 = \frac{\hat{\beta}^2 \sum_i u_i^2}{\hat{\sigma}_1^2} = \frac{\mathrm{SCR}_0 - \mathrm{SCR}_1}{\hat{\sigma}_1^2}.$$

Le critère. Comme s_y^2 ne dépend pas du modèle, $\overline{R}^2$ monte si et seulement si $\hat{\sigma}^2$ baisse :

$$\frac{\mathrm{SCR}_1}{n-k-2} < \frac{\mathrm{SCR}_0}{n-k-1}$$
$$\iff \mathrm{SCR}_1 < (n-k-2)\,(\mathrm{SCR}_0 - \mathrm{SCR}_1)$$
$$\iff 1 < \frac{\mathrm{SCR}_0 - \mathrm{SCR}_1}{\mathrm{SCR}_1/(n-k-2)} = t^2.$$

Il baisse si $t^2 < 1$ et ne bouge pas si $t^2 = 1$, comme sur les cinq ménages. Cette identité est aussi celle qui fait du Fisher partiel à une restriction le carré du t (chapitre 9).

■

Sur nos données

Les quatre premiers modèles

Ce que chaque ajout apporte

Modèle	k	R^2	R^2 ajusté
M1 ancienneté	1	0,405	0,404
M2 + diplôme	3	0,642	0,640
M3 + sexe	4	0,642	0,640
M4 + région	7	0,668	0,664

Le sexe, au quatrième chiffre

M3 a un R^2 ajusté de 0,6395 contre 0,6396 pour M2 : il **baisse**. La règle le prévoyait, puisque le t du sexe vaut $0{,}93 < 1$.

Les modèles, ligne par ligne

La lecture, ligne par ligne

Le **diplôme** est décisif : le R^2 passe de 0,405 à 0,642. Il expliquait à lui seul un quart de la dispersion, comme l'ANOVA du chapitre 17 de l'inférence l'avait établi.
Le **sexe** n'apporte rien : R^2 inchangé, R^2 ajusté qui baisse au quatrième chiffre. La variable coûte plus qu'elle ne rapporte.
La **région** apporte encore deux points et demi. Le marché du travail marocain n'est pas homogène géographiquement.

L'écart-type résiduel, encore

La lecture concrète du progrès

Modèle	$\hat{\sigma}_\varepsilon$
M1	2 008 dh
M2	1 561 dh
M4	1 508 dh

Elle dit la même chose, en dirhams

Le modèle complet se trompe typiquement de mille cinq cents dirhams sur un salaire individuel, contre deux mille pour le modèle initial.
C'est un progrès réel, et il reste modeste. Un tiers de la dispersion des salaires tient à des facteurs absents du fichier : poste, performance, négociation. Aucune régression ne fera mieux avec ces six colonnes.

Des variables de pur hasard

M4, puis M4 plus des variables tirées au hasard

Modèle	k	R^2	R^2 ajusté
M4	7	0,6684	0,6637
M4 +2 variables de hasard	9	0,6686	0,6625
M4 +5 variables de hasard	12	0,6709	0,6628

Le R^2 ajusté résiste, sans être infaillible

Le R^2 monte avec du bruit, le R^2 ajusté baisse : c'est le cas de la figure. Mais avec **dix** variables de hasard, cinq ont par chance un $|t|$ supérieur à 1, et le R^2 ajusté remonte à 0,6655 — au-dessus de M4. Le seuil $|t| > 1$ est trop indulgent ; le chapitre 19 proposera plus sévère.

Sur machine

Les quatre modèles avec R

```r
sal <- read.csv("salaires.csv", stringsAsFactors = TRUE)
m1 <- lm(salaire ~ anciennete, data = sal)
m2 <- update(m1, . ~ . + diplome)     # on ajoute une variable
m3 <- update(m2, . ~ . + sexe)
m4 <- update(m3, . ~ . + region)
r <- sapply(list(M1 = m1, M2 = m2, M3 = m3, M4 = m4), function(m)
  c(R2 = summary(m)$r.squared, R2aj = summary(m)$adj.r.squared))
round(t(r), 4)
#        R2   R2aj
# M1 0.4049 0.4037
# M2 0.6418 0.6396
# M3 0.6424 0.6395
# M4 0.6684 0.6637
```

Les cinq ménages avec Python

```python
import pandas as pd
import statsmodels.formula.api as smf
cinq = pd.DataFrame({"R": [2, 4, 6, 8, 10], "C": [3, 6, 4, 7, 10],
                     "T": [1, 5, 4, 3, 7]})
for f in ("C ~ R", "C ~ R + T"):
    m = smf.ols(f, data=cinq).fit()
    print(f, round(m.rsquared, 4), round(m.rsquared_adj, 4))
# C ~ R 0.75 0.6667
# C ~ R + T 0.8333 0.6667
m = smf.ols("C ~ R + T", data=cinq).fit()
print(m.tvalues.round(4).tolist())      # t de la taille : 1
```

```
# [0.5774, 1.4142, 1.0]
```

S'entraîner

Exercice 1 : deux modèles à comparer

Plus long ou plus court

Sur $n = 30$ entreprises, on estime deux modèles du chiffre d'affaires.

- Modèle A : $k = 3$ variables, $R^2 = 0{,}40$.
- Modèle B : $k = 10$ variables, $R^2 = 0{,}50$.

1. Calculer le R^2 ajusté de chacun.
2. Lequel retenir selon ce critère ?
3. Que penser du gain de R^2 de B ?

Exercice 1 : solution

Le modèle court l'emporte

1. A : $1 - 0{,}60 \times 29/26 = 0{,}331$. B : $1 - 0{,}50 \times 29/19 = 0{,}237$.
2. Le modèle **A**, malgré son R^2 plus faible.
3. Dix points de R^2 pour sept variables de plus, sur trente observations : c'est à peine ce que donnerait du bruit. Les sept variables ajoutées coûtent plus qu'elles ne rapportent.

Exercice 2 : un R² ajusté négatif

Douze observations, cinq variables

Un étudiant explique la croissance de 12 pays par 5 variables et obtient $R^2 = 0{,}30$.

1. Calculer le R^2 ajusté.
2. Comment l'interpréter ?
3. Que lui conseiller ?

Exercice 2 : solution

Moins bien que la moyenne

1. $1 - 0{,}70 \times 11/6 = 1 - 1{,}283 = -0{,}283$.
2. Une fois les degrés de liberté facturés, le modèle prévoit **moins bien que la simple moyenne** des taux de croissance : $\hat{\sigma}_\varepsilon$ dépasse l'écart-type de y.
3. Réduire le nombre de variables à celles que la théorie impose, ou réunir davantage de pays. Six degrés de liberté ne permettent pas d'estimer six paramètres sérieusement.

Exercice 3 : la règle du t égal à 1

Prévoir sans recalculer

On ajoute successivement à un modèle trois variables, de t respectifs 0,8, 1,5 et $-2{,}3$ une fois incluses.

1. Pour chacune, le R^2 ajusté monte-t-il ou baisse-t-il ?
2. Laquelle serait aussi retenue par un test à 5 % ?
3. Dans M3, le sexe a $t = 0{,}93$: que fallait-il attendre du R^2 ajusté ?

Exercice 3 : solution

Le signe ne compte pas, la valeur absolue si

1. 0,8 : il **baisse**. 1,5 et $-2{,}3$: il **monte**, car $|t| > 1$.
2. Seule la troisième dépasse 1,96 en valeur absolue. La deuxième améliore le R^2 ajusté sans être significative : c'est l'indulgence du critère.
3. Une baisse, puisque $0{,}93 < 1$: $0{,}6396 \to 0{,}6395$. C'est exactement ce que donne le tableau.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. Le R^2 **monte toujours** quand on ajoute une variable : il ne peut pas servir à choisir.
2. $\overline{R}^2 = 1 - (1 - R^2)\dfrac{n-1}{n-k-1} = 1 - \hat{\sigma}^2_\varepsilon / s^2_y$: chaque variable est **facturée**.
3. Une variable améliore le R^2 ajusté dès que son $|t|$ dépasse 1 — critère indulgent.
4. Cinq ménages : la taille, de $t = 1$ exactement, laisse le R^2 ajusté à 0,667.
5. Salaires : le diplôme est décisif, le sexe n'apporte rien, la région compte un peu.
6. Le R^2 ajusté peut être **négatif** : le modèle fait alors moins bien que la moyenne.

La suite

Avec plusieurs variables, une question nouvelle se pose : tester chaque coefficient séparément suffit-il ? Le chapitre 9 montre que non — et que trois tests différents cohabitent.