

Introduction à l'économétrie

Chapitre 20 : Étude de cas

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'économétrie

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Retrouver l'écart-type et tester une hypothèse précise

L'étude de la consommation donne $\hat{\beta}_1 = 0,6960$, avec $t = 47,3$ pour le test usuel de nullité.

- (a) Sachant que $t = \hat{\beta}_1 / \widehat{\sigma}(\hat{\beta}_1)$, retrouver l'écart-type $\widehat{\sigma}(\hat{\beta}_1)$.
- (b) Calculer le t du test de l'hypothèse $H_0 : \beta_1 = 1$ (et non $\beta_1 = 0$), à l'aide de $t = (\hat{\beta}_1 - 1) / \widehat{\sigma}(\hat{\beta}_1)$.
- (c) Ce t correspond-il à celui rapporté par le cours ($-20,66$) ?
- (d) Que signifie économiquement le rejet de $H_0 : \beta_1 = 1$ dans le cadre de la loi psychologique fondamentale de Keynes ?

Exercice 2 — Les huit étapes, dans le bon ordre

Un étudiant présente son travail dans l'ordre suivant : (1) il commente ses coefficients, (2) il collecte ses données, (3) il vérifie les diagnostics, (4) il formule sa question de recherche, (5) il rédige ses limites, (6) il estime son modèle, (7) il corrige les problèmes détectés, (8) il spécifie son modèle.

- (a) Réordonner ces huit étapes selon l'ordre recommandé par le cours.
- (b) Quelle erreur précise l'étudiant commet-il en plaçant le commentaire des coefficients avant les diagnostics ?
- (c) Pourquoi le cours affirme-t-il que « commenter d'abord et vérifier ensuite conduit invariablement à défendre un résultat auquel on s'est déjà attaché » ?
- (d) Laquelle des huit étapes le cours qualifie-t-il de « plus importante », et pour quelle raison ?

Exercice 3 — Trois mots qui sauvent une phrase

Le cours propose la phrase : « une année d'ancienneté supplémentaire est associée à un salaire supérieur de 3,5 %, à diplôme et région comparables ».

- (a) Identifier les trois précautions verbales de cette phrase, et le rôle de chacune.
- (b) Récrire la phrase en retirant le mot « associée » au profit de « augmente ». Quel type d'erreur cela introduit-il (rappeler le chapitre 19) ?
- (c) Récrire la phrase en retirant « à diplôme et région comparables ». Quelle information essentielle disparaît alors ?
- (d) Une phrase du cours affirme : « le modèle rend compte de 65 % de la dispersion des logarithmes de salaires ». Que perdrait-on à écrire simplement « des salaires » au lieu de « des logarithmes de salaires » (rappeler le chapitre 18) ?

2 Exercice cumulatif (chapitre 20 et chapitres précédents)

Exercice 4 — Deux études, quatre chapitres convoqués

Le tableau de diagnostics de l'étude de la consommation rapporte : Breusch-Pagan 59,5 contre un seuil de 5,99 ; des résidus moyens par quartier allant de -743 à $+559$; des écarts-types de grappe passant de 0,0148 à 0,0232. Celui de l'étude du salaire rapporte : Breusch-Pagan qui rejette (écarts-types robustes appliqués), Jarque-Bera qui rejette (sans effet, $n = 500$), un VIF maximal de 2,08 (rien à signaler), et une distance de Cook dépassant le seuil pour quelques points (estimation avec et sans).

- (a) Pour l'étude de la consommation, à quel chapitre du cours renvoie le diagnostic de Breusch-Pagan, et à quel chapitre renvoie la dispersion des résidus moyens par quartier ?
- (b) Pour l'étude du salaire, à quel chapitre renvoie chacun des quatre diagnostics (Breusch-Pagan, Jarque-Bera, VIF, distance de Cook) ?
- (c) Dans les deux études, aucun des diagnostics ne biaise les coefficients estimés. Pourquoi peut-

on l'affirmer sans même recalculer les coefficients avec et sans correction, dans le cas de l'hétéroscédasticité et du regroupement ?

- (d) Le cours affirme, à propos de l'étude de la consommation : « avec $t = 47$, la conclusion ne change pas — mais sur un résultat limite, comme celui du milieu urbain, elle aurait pu tout changer ». En s'appuyant sur les chapitres 14 et 15, expliquer pourquoi un t très élevé rend la correction des écarts-types presque sans enjeu pratique, alors qu'un t proche du seuil de significativité la rendrait décisive.

3 Applications en sciences économiques

Exercice 5 — Rédiger la section des limites

Une étude régionale mesure l'effet de la distance à la ville la plus proche sur le revenu agricole de 600 exploitations, dans une seule région et sur une seule campagne agricole. Aucune donnée sur la qualité des sols ou l'accès à l'irrigation n'est disponible.

- (a) En suivant le modèle de l'étape 8 du cours, rédiger le premier point des limites : quelles variables omises pertinentes (qualité des sols, irrigation) risquent de biaiser le coefficient de la distance, et dans quel sens (indice : les terres proches de la ville sont souvent aussi les plus fertiles, historiquement mises en valeur en premier) ?
- (b) Rédiger le second point : en quoi le fait de porter sur une seule région et une seule campagne limite-t-il la généralisation des résultats ?
- (c) Rédiger le troisième point : quelle formulation adopter pour ne pas affirmer que la distance « cause » la baisse de revenu agricole ?
- (d) Pourquoi le cours affirme-t-il qu'un lecteur compétent lit la section des limites **en premier** ?

Exercice 6 — Généraliser, ou pas

Un institut de statistique reproduit l'étude de la consommation du cours sur une enquête de budgets menée cinq ans plus tard, dans un pays voisin, et trouve $\hat{\beta}_1 = 0,61$.

- (a) Le cours affirme qu'une coupe instantanée « ne dit rien de l'évolution dans le temps ». La comparaison entre 0,6960 (étude initiale) et 0,61 (cinq ans plus tard, pays voisin) permet-elle de conclure que la propension marginale à consommer a **diminué dans le temps** ?
- (b) Quelles autres explications, indépendantes d'une évolution temporelle, pourraient expliquer cet écart entre les deux coefficients ?
- (c) Si l'institut voulait réellement étudier l'évolution de la propension marginale à consommer dans le temps pour une même population, quel type de données (rappeler le chapitre 1 de l'économétrie) faudrait-il collecter plutôt que deux coupes instantanées distinctes ?
- (d) En quoi cette question illustre-t-elle la limite « aucune généralisation à une autre population ou à une autre date » déjà mentionnée dans l'étude de cas du cours ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) $\widehat{\sigma}(\hat{\beta}_1) = 0,6960/47,3 \approx 0,01471$.
- (b) $t = (0,6960 - 1)/0,01471 = -0,3040/0,01471 \approx -20,66$.
- (c) Oui, ce résultat correspond exactement au $-20,66$ rapporté par le cours.
- (d) Le rejet de $H_0 : \beta_1 = 1$ signifie que la propension marginale à consommer est statistiquement, et très significativement, **inférieure à un** : une partie du revenu supplémentaire est épargnée plutôt qu'intégralement consommée. C'est précisément ce que prédit la loi psychologique fondamentale de Keynes ($0 < \beta_1 < 1$), ici confirmée avec une force statistique considérable.

Correction — Exercice 2

- (a) Ordre correct : (4) la question, (2) les données, (8) la spécification, (6) l'estimation, (3) les diagnostics, (7) les corrections, (1) le commentaire des coefficients (la lecture), (5) les limites.
- (b) L'étudiant inverse l'ordre des étapes 5 (diagnostics) et 7 (lecture) du cours : il commente des coefficients avant de savoir si leur écart-type, et donc leur significativité affichée, est fiable — il pourrait interpréter comme solide un résultat dont l'inférence est en réalité corrompue par de l'hétéroscédasticité ou du regroupement non corrigés.
- (c) Parce qu'un chercheur qui a déjà commenté et adopté une interprétation de ses résultats développe un biais de confirmation : face à un diagnostic défavorable découvert ensuite, il sera tenté de minimiser le problème ou de choisir la correction qui préserve sa conclusion déjà écrite, plutôt que d'évaluer objectivement si le résultat tient encore.
- (d) Le cours qualifie l'étape des **limites** (étape 8) de plus importante, car « un lecteur compétent la lit en premier » : elle indique si l'auteur a compris ce qu'il a fait, alors que produire une régression et un commentaire de coefficients ne requiert, en comparaison, aucune maîtrise particulière des limites de la méthode.

Correction — Exercice 3

- (a) « associée » (et non « augmente ») évite d'affirmer une causalité non établie ; « à diplôme et région comparables » rappelle le *ceteris paribus*, c'est-à-dire que la comparaison porte sur des individus par ailleurs similaires ; « des logarithmes » (dans la troisième phrase du cours) rappelle que le R^2 porte sur la variable transformée, pas sur le salaire en niveau.
- (b) « Une année d'ancienneté supplémentaire augmente le salaire de 3,5 %, à diplôme et région comparables » affirmerait une relation **causale** au lieu d'une simple association conditionnelle — exactement l'erreur d'interprétation identifiée au chapitre 19 (« dépasse les données »), puisque des variables non observées (capacités, réseau) pourraient expliquer une partie de cet écart.
- (c) En retirant « à diplôme et région comparables », on perd le rappel que la comparaison est *ceteris paribus* : le lecteur pourrait croire, à tort, que l'ancienneté expliquerait à elle seule tout l'écart de salaire observé entre deux salariés quelconques, sans tenir compte du fait que le diplôme et la région sont maintenus constants dans la comparaison.
- (d) En écrivant simplement « des salaires » au lieu de « des logarithmes de salaires », on laisserait croire que le $R^2 = 0,654$ mesure la part de variance du salaire en niveau expliquée par le modèle — alors qu'il mesure la part de variance du *logarithme* du salaire. Le chapitre 18 avait justement averti que les R^2 de modèles portant sur des variables expliquées différentes (y contre $\ln y$) ne sont pas comparables ; la précision « des logarithmes » évite ce contresens.

2 Exercice cumulatif

Correction — Exercice 4

- (a) Le diagnostic de Breusch-Pagan renvoie au **chapitre 14** (hétéroscédasticité) ; la dispersion des résidus moyens par quartier renvoie au **chapitre 15** (erreurs groupées), puisqu'elle révèle que les ménages d'un même quartier partagent un terme d'erreur commun.
- (b) Breusch-Pagan renvoie au **chapitre 14** (hétéroscédasticité) ; Jarque-Bera renvoie au **chapitre 17** (normalité des résidus) ; le VIF renvoie au **chapitre 13** (multicolinéarité) ; la distance de Cook renvoie également au **chapitre 17** (points influents).
- (c) Parce que le cours a établi, aux chapitres 14 et 15, une propriété générale et non spécifique à un jeu de données particulier : ni l'hétéroscédasticité ni le regroupement non corrigé ne violent l'hypothèse d'exogénéité (H2) des moindres carrés — ils dégradent uniquement la précision des écarts-types, jamais l'espérance des coefficients. Cette propriété, démontrée une fois pour toutes de façon générale, s'applique donc automatiquement ici sans qu'il soit nécessaire de la revérifier numériquement sur ce jeu de données précis.
- (d) Un t très élevé (comme 47 ici) offre une marge de sécurité considérable : même si le vrai écart-type corrigé est 1,5 à 2 fois plus grand que l'écart-type MCO affiché (l'ordre de grandeur observé aux chapitres 14 et 15), le t corrigé resterait très largement au-dessus du seuil de 1,96, et la conclusion de significativité ne changerait pas. À l'inverse, un t proche du seuil (par exemple 2,1) ne dispose d'aucune marge : la même correction pourrait faire passer le t corrigé en-dessous de 1,96, inversant la conclusion — c'est exactement ce que montre le facteur de Moulton du chapitre 15, capable de diviser un t affiché par plus de deux.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) « Variables omises : la qualité des sols et l'accès à l'irrigation, non observées dans cette étude, sont probablement corrélées à la fois au revenu agricole et à la distance à la ville (les terres proches des villes ayant souvent été historiquement mises en valeur en premier, avec de meilleurs sols et un accès à l'irrigation plus ancien). Le coefficient de la distance est donc probablement **surestimé** en valeur absolue : une partie de l'écart de revenu attribué à la distance reflète en réalité ces différences de qualité des terres. »
- (b) « L'étude portant sur une seule région et une seule campagne agricole, ses résultats ne peuvent être généralisés ni à d'autres régions aux conditions agro-climatiques différentes, ni à d'autres campagnes marquées par des conditions météorologiques ou des prix agricoles différents. »
- (c) « La distance à la ville est **associée** à un revenu agricole inférieur, à (les caractéristiques observées) comparables ; ce résultat ne permet pas d'affirmer que réduire la distance *causerait* une hausse du revenu agricole. »
- (d) Parce qu'elle indique immédiatement si l'auteur a conscience des failles de son propre travail : un chercheur capable d'énoncer précisément ce que ses données ne permettent pas de conclure démontre une maîtrise réelle de sa méthode, ce que la seule présentation de coefficients significatifs ne suffit jamais à établir.

Correction — Exercice 6

- (a) Non : la comparaison entre les deux coupes instantanées ne permet pas d'isoler un effet **temporel**, car les deux études diffèrent simultanément par la date *et* par la population (pays voisin) — deux facteurs confondus qu'aucune des deux coupes ne permet de séparer.
- (b) L'écart pourrait s'expliquer par des différences structurelles entre les deux populations (niveau de vie, habitudes de consommation, structure des prix, système de protection sociale), indépendamment de toute évolution temporelle de la propension à consommer — ou par des différences méthodologiques entre les deux enquêtes (échantillonnage, définition des variables).

(c) Il faudrait des données de **panel** (rappelées au chapitre 1 de l'économétrie), c'est-à-dire suivre les *mêmes* ménages à plusieurs dates, ce qui permettrait de mesurer une évolution réelle dans le temps pour une population inchangée, plutôt que de comparer deux coupes instantanées portant sur des populations différentes.

(d) Cette question illustre exactement la limite énoncée dans l'étude de cas du cours : un coefficient estimé sur une coupe instantanée ne peut être généralisé ni à une autre population ni à une autre date, et encore moins aux deux changements simultanément — toute tentative de comparaison directe entre les deux résultats confond ce qui relève du temps et ce qui relève de la population.