Introduction à l'économétrie

Chapitre 20 : Étude de cas

Jaouad Madkour

23 octobre 2026

Plan du chapitre

Deux études, de bout en bout **2**
Un chapitre sans notion nouvelle . . . 2
Les huit étapes, et le chapitre qui les outille . . . 2

Étude : la consommation **2**
Les quatre premières étapes . . . 2
Le résultat, lu économiquement . . . 3
Les diagnostics . . . 3
La correction, et le test de Keynes refait . . . 3
La conclusion, et ses limites . . . 4

Étude : l'équation de salaire **4**
Les étapes 1 à 4 . . . 4
Le tableau final . . . 4
Les diagnostics et les corrections . . . 5
La robustesse, vérifiée . . . 5
Une vérification qu'on oublie . . . 5
La lecture, telle qu'on la rédige . . . 6
Les limites, écrites noir sur blanc . . . 6

Sur machine **6**
L'étude de Keynes avec R . . . 6
L'étude des salaires avec Python . . . 7

S'entraîner **7**
Exercice 1 : planifier une étude . . . 7
Exercice 1 : solution . . . 7
Exercice 2 : relire un rapport . . . 7
Exercice 2 : solution . . . 8
Exercice 3 : l'étude en miniature . . . 8
Exercice 3 : solution . . . 8

Ce qu'il faut retenir **8**
Le résumé du chapitre . . . 8

Deux études, de bout en bout

Un chapitre sans notion nouvelle

Ce que fait ce chapitre

Rien de neuf n'y est introduit. Il conduit deux travaux complets, dans l'ordre où on les mène réellement.
Parce que la difficulté d'un mémoire n'est jamais une formule : c'est l'enchaînement.

Les huit étapes d'un travail économétrique

1. La question économique. 2. Les données. 3. La spécification. 4. L'estimation.
2. Les diagnostics. 6. Les corrections. 7. La lecture. 8. Les limites.

Les huit étapes, et le chapitre qui les outille

Tout le cours, rangé dans l'ordre du travail

Étape	Outils	Chapitres
1. Question	théorie, signe attendu	1
2. Données	structure, unité, grappes	intro, 15
3. Spécification	variables, forme, indicatrices	7, 10, 18
4. Estimation	MCO, R^2, tests	3 à 9
5. Diagnostics	résidus, BP, VIF, Cook	12 à 17
6. Corrections	robustes, grappe, logarithme	14, 15, 18
7. Lecture	*ceteris paribus*, pourcentages	7, 18
8. Limites	variable omise, causalité	16, 19

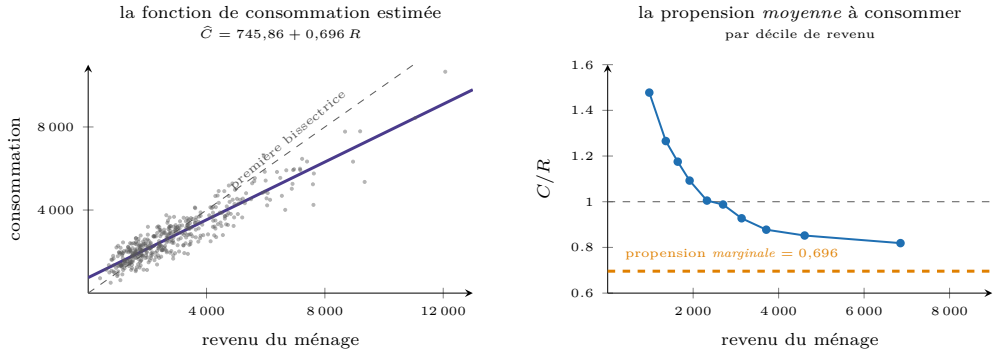
Étude : la consommation

Les quatre premières étapes

Question, données, spécification, estimation

Question : la loi psychologique fondamentale de Keynes est-elle vérifiée ?
Données : une enquête de budgets, 400 ménages répartis en 40 quartiers.
Spécification : $C_i = \beta_0 + \beta_1 R_i + \varepsilon_i$, avec $0 < \beta_1 < 1$ attendu.
Estimation : $\widehat{C} = 745{,}86 + 0{,}6960\, R$, avec $t = 47{,}3$ et $R^2 = 0{,}849$.

Le résultat, lu économiquement



Trois lectures, et la troisième n'était pas dans la théorie.

1. La propension marginale vaut 0,696 : d'un dirham supplémentaire, 70 centimes sont consommés. **2.** La loi de Keynes n'est pas contredite : $0 < 0{,}696 < 1$ et $\beta_0 = 745{,}86 > 0$.

3. La propension *moyenne* décroît avec le revenu : 1,34 dans le quartile bas — les ménages modestes s'endettent ou puisent dans leur épargne — contre 0,84 dans le quartile haut.

Ce dernier résultat *découle* de $\beta_0 > 0$ et $\beta_1 < 1$; aucune lecture littéraire de Keynes ne le donnait.

Les diagnostics

Étape 5, sur le modèle complété par la taille

Diagnostic	Résultat	Verdict
Breusch-Pagan	59,5 contre 5,99	hétéroscédasticité
Résidus par quartier	moyennes de -743 à $+559$	erreurs groupées
Corrélation intra-quartier	$\rho = 0{,}30$	effectif équivalent réduit

Ce qu'on en fait

Ni l'un ni l'autre ne biaise $\hat{\beta}_1 = 0{,}6960$: la propension marginale reste correctement estimée. Tous deux **faussent l'écart-type**. Avec $t = 47$, la conclusion ne change pas — mais sur un résultat limite, comme celui du milieu urbain, elle aurait pu tout changer.

La correction, et le test de Keynes refait

Étape 6 : trois écarts-types pour la propension marginale

Écarts-types	$\hat{\sigma}(\hat{\beta}_1)$	t contre $\beta_1 = 0$	t contre $\beta_1 = 1$
MCO	0,0147	47,3	$-20{,}7$
White HC1	0,0220	31,6	$-13{,}8$
Grappe, quartier	0,0212	32,8	$-14{,}3$

La conclusion tient, sur ses vraies bases

L'écart-type est multiplié par 1,45, et le test de $\beta_1 = 1$ passe de $-20{,}7$ à $-14{,}3$. On rejette toujours, massivement. **On publie la troisième ligne** : c'est la seule qui respecte à la fois l'hétéroscédasticité et le tirage par quartiers.

La conclusion, et ses limites

Étapes 7 et 8

Ce qu'on peut affirmer : dans cette population, la consommation croît de 70 centimes par dirham de revenu supplémentaire. La loi de Keynes n'est pas contredite ; l'hypothèse $\beta_1 = 1$ est rejetée. Et la propension **moyenne** décroît de 1,34 à 0,84 du quartile bas au quartile haut.

Ce qu'on ne peut pas affirmer : que ce coefficient vaudrait le même dans une autre population, ou à une autre date. Une coupe instantanée ne dit rien de l'évolution dans le temps.

Ce qu'un travail sérieux ajouterait

Le patrimoine du ménage, l'accès au crédit, la position dans le cycle de vie — autant de variables absentes qui expliquent la consommation et sont liées au revenu.

C'est très exactement le problème du chapitre 16, et il ne se règle pas par une correction d'écarts-types.

Étude : l'équation de salaire

Les étapes 1 à 4

Le cheminement

Question : quels facteurs expliquent le salaire, et de combien ?

Données : 500 salariés, six variables.

Spécification : $\ln S = \beta_0 + \beta_1 A + \beta_2 D_2 + \beta_3 D_5 + \text{régions} + \varepsilon$, forme semi-logarithmique justifiée au chapitre 18.

Estimation : $R^2 = 0{,}654$, $F(6\,;493) = 155{,}2$.

Le tableau final

variable expliquée : le **logarithme** du salaire

	Coefficient	Statistique t	Lecture
Constante	8,2158	280,2	le niveau de référence
Ancienneté	0,0345	22,33	+3,5 % **par année**
Bac+2	0,1786	8,59	+19,6 % contre le Bac
Bac+5	0,4353	17,96	+54,5 % **contre le Bac**
Casablanca	0,1655	5,75	+18,0 %
Rabat	0,1379	4,52	+14,8 %
Tanger-Tétouan	0,0592	2,15	+6,1 %
$n = 500$	$R^2 = 0{,}654$	$\widehat{\sigma}_\varepsilon = 0{,}20$	

L'équation de gains de Mincer

Publiée en 1974, c'est l'un des modèles les plus estimés de toute l'économie appliquée. Sa forme est exactement celle-ci : le *logarithme* du salaire expliqué par la formation et l'expérience.

Pourquoi le logarithme

Parce qu'un coefficient devient un **pourcentage**, directement comparable d'un pays et d'une époque à l'autre. Le rendement d'une année de formation se situe partout entre 5 et 10 % : c'est un ordre de grandeur universel, et il ne le serait pas en dirhams.

Une approximation, et sa correction

100β approche l'effet en pourcentage. Au-delà de 0,2, il faut la formule exacte $100(e^{\beta} - 1)$: 0,4353 donne 54,5 % et non 43,5.

Les diagnostics et les corrections

Étapes 5 et 6, sur le modèle en logarithme

Diagnostic	Résultat	Décision
Breusch-Pagan	8,25, $p = 0{,}22$	robustes par précaution
Jarque-Bera	3,10, $p = 0{,}21$	rien à signaler
VIF maximal	2,08	rien à signaler
Distance de Cook	23 points au-dessus de $4/n$	estimation avec et sans

L'ordre compte

On diagnostique **avant** de commenter les coefficients, jamais après.
Commenter d'abord et vérifier ensuite conduit invariablement à défendre un résultat auquel on s'est déjà attaché.

La robustesse, vérifiée

Trois coefficients, trois versions

Coefficient	MCO	e.-t. MCO	e.-t. HC1	Sans les 23 points
Ancienneté	0,0345	0,0015	0,0015	0,0349
Bac+2	0,1786	0,0208	0,0201	0,1643
Bac+5	0,4353	0,0242	0,0255	0,4210

Le logarithme a fait le travail

Les écarts-types robustes ne diffèrent presque plus des ordinaires, et retirer les points influents ne déplace les coefficients que de quelques millièmes. **Une fois la bonne forme trouvée, les corrections deviennent des formalités.**

Une vérification qu'on oublie

Le sexe, écarté en niveau, revient en logarithme

Le sexe avait été écarté sur le modèle en dirhams : $t = 1{,}27$, AIC et BIC d'accord. Réintroduit dans le modèle en logarithme, il donne 0,0417, soit +4,3 % pour les hommes, avec $t = 2{,}24$ en écarts-types robustes.

Changer de forme, c'est rouvrir la spécification

L'AIC garde désormais le sexe, le BIC l'écarte encore : le résultat est **fragile**, et il faut le dire. La leçon est générale : une variable écartée dans une forme fonctionnelle doit être **retestée** dans la nouvelle. Un écart en pourcentage n'est pas un écart en dirhams.

La lecture, telle qu'on la rédige

Étape 7 — trois phrases pour un rapport

« Une année d'ancienneté supplémentaire est associée à un salaire supérieur de 3,5 %, à diplôme et région comparables. »
« Les titulaires d'un Bac+5 gagnent 54,5 % de plus que les titulaires d'un Bac, à ancienneté et région comparables. »
« Le modèle rend compte de 65 % de la dispersion des logarithmes de salaires. »

Trois précautions, toutes dans les mots

« **associée** », et non « augmente ». « **à diplôme et région comparables** », qui rappelle le *ceteris paribus*. « **des logarithmes** », qui rappelle la forme retenue.
Aucune de ces trois précautions n'alourdit vraiment la phrase, et chacune évite un contre-sens.

Les limites, écrites noir sur blanc

Étape 8 — la partie qu'on saute et qu'il ne faut pas sauter

1. **Variables omises** : poste, performance, capacités, réseau. Le rendement du diplôme est probablement **surestimé** — le raisonnement du chapitre 16 en donne le sens.
2. **Une seule entreprise, une seule date** : aucune généralisation au marché du travail.
3. **Aucune causalité établie** : les résultats décrivent des associations conditionnelles.

Pourquoi cette section est la plus importante

Un lecteur compétent la lit en premier. Elle indique si l'auteur a compris ce qu'il a fait.
Un travail sans limites déclarées n'est pas un travail sans limites : c'est un travail dont on ignore les limites.

Sur machine

L'étude de Keynes avec R

```r
men <- read.csv("menages.csv")
mk <- lm(consommation ~ revenu, data = men)
V <- sandwich::vcovCL(mk, cluster = ~ quartier)  # grappe
lmtest::coeftest(mk, vcov = V)
#
# t test of coefficients:
#
#              Estimate Std. Error t value  Pr(>|t|)
# (Intercept) 745.860473  66.040567  11.294 < 2.2e-16
# revenu        0.696015   0.021242  32.767 < 2.2e-16
b <- coef(mk)[2]; se <- sqrt(V[2, 2])
round(unname((b - 1) / se), 2)              # beta1 = 1 ?
# [1] -14.31
```

L'étude des salaires avec Python

```
import numpy as np, pandas as pd
import statsmodels.formula.api as smf
sal = pd.read_csv("salaires.csv")
f = "np.log(salaire) ~ anciennete + diplome + region"
m = smf.ols(f, data=sal).fit(cov_type="HC1")
print((100 * (np.exp(m.params) - 1)).round(1).tolist()[1:])
# [19.6, 54.5, 18.0, 14.8, 6.1, 3.5]
m_s = smf.ols(f + " + sexe", data=sal).fit(cov_type="HC1")
b, t = m_s.params["sexe[T.H]"], m_s.tvalues["sexe[T.H]"]
print(round(b, 4), round(t, 2))       # le sexe, re-testé
# 0.0417 2.24
```

S'entraîner

Exercice 1 : planifier une étude

La demande d'électricité des ménages

Une agence veut savoir comment la consommation d'électricité des ménages réagit à son prix. Elle dispose d'une enquête auprès de 2 000 ménages de 50 communes, chacune ayant son propre tarif.

1. Proposer une spécification, et justifier sa forme.
2. Quel problème de données la structure par commune pose-t-elle, et comment le traiter ?
3. Citer une variable omise plausible et le sens du biais qu'elle induirait.

Exercice 1 : solution

Une élasticité, des grappes, un biais probable

1. $\ln Q = \beta_0 + \beta_1 \ln P + \beta_2 \ln R + \cdots$: log-log, pour lire directement l'élasticité-prix β_1, attendue négative.
2. Le tarif est **constant dans la commune** : $\rho_x = 1$, facteur de Moulton complet. Écarts-types de grappe par commune — et 50 grappes suffisent tout juste.
3. Le climat : les communes chaudes consomment plus (climatisation) et ont peut-être des tarifs différents. Si les tarifs y sont plus élevés, $\gamma > 0$ et $\delta > 0$: l'élasticité paraît **moins négative** qu'elle n'est.

Exercice 2 : relire un rapport

Quatre fautes dans un paragraphe

« Nous avons estimé le salaire en fonction du diplôme sur 500 salariés. Le Bac+5 augmente le salaire de 43,5 %, comme le montre son coefficient de 0,435 dans le modèle en logarithme. Le modèle est excellent, avec un R^2 de 0,65, supérieur à celui du modèle en niveau. Les écarts-types sont ceux des MCO. »
Trouver les quatre fautes.

Exercice 2 : solution

Causalité, approximation, R^2, écarts-types

1. « **augmente** » : le coefficient établit une association, pas une causalité.
2. 43,5 % : c'est l'approximation 100β ; l'effet exact est $100(\mathrm{e}^{0{,}435} - 1) = 54{,}5\,\%$.
3. Comparer le R^2 du logarithme à celui du **niveau** n'a pas de sens — et le niveau a d'ailleurs 0,667.
4. Sur données individuelles, il faut des écarts-types **robustes**, et le dire.

Exercice 3 : l'étude en miniature

Les cinq ménages, en huit étapes

Rédiger, en une ligne par étape, l'étude de la consommation des cinq ménages, en reprenant les résultats du cours.

Exercice 3 : solution

Huit lignes, et une conclusion modeste

1. Keynes : $0 < \beta_1 < 1$? 2. Cinq ménages, une coupe. 3. $C = \beta_0 + \beta_1 R + \beta_2 T$. 4. $\widehat{C} = 1 + 0{,}5\,R + 0{,}5\,T$, $R^2 = 0{,}83$.
2. Breusch-Pagan nul ; E très influent, Cook 0,75. 6. Aucune correction utile sur cinq points.
3. À taille égale, 500 dirhams de consommation par millier de revenu.
4. $t = 1{,}41$: **rien n'est établi**. Il faut des centaines de ménages — c'est l'étude précédente.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. Huit étapes, toujours les mêmes : question, données, spécification, estimation, diagnostics, corrections, lecture, limites.
2. **Keynes** : $\widehat{\beta}_1 = 0{,}6960$; avec écarts-types de grappe, $\beta_1 = 1$ reste rejeté à $t = -14{,}3$.
3. Hétéroscédasticité **et** erreurs groupées : deux corrections, aucun biais.
4. **Mincer** : +3,5 % par année, +54,5 % pour un Bac+5 ; le logarithme rend les corrections presque inutiles.
5. Changer de forme rouvre la spécification : le sexe, écarté en niveau, revient en logarithme.
6. Trois mots sauvent une conclusion : « **associée** », « **comparables** », « **logarithmes** ».

La suite

Le chapitre 21 refait l'ensemble en quelques lignes de R et de Python — et montre que la sortie d'un logiciel ne contient rien que nous n'ayons établi.