

Introduction à l'économétrie

Chapitre 14 : L'hétéroscédasticité

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'économétrie

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Le comportement économique produit la dispersion

Le cours rapporte un écart-type des résidus de 1 319 DH chez les titulaires d'un Bac, contre 2 156 DH chez les Bac+5.

- (a) Calculer le rapport entre ces deux écarts-types.
- (b) Proposer une explication économique (rappelée par le cours) à cette différence : pourquoi les salariés les plus diplômés, en général mieux rémunérés, présentent-ils une dispersion salariale plus grande autour de la droite de régression ?
- (c) Cette hétéroscédasticité est-elle, selon le cours, un défaut des données à corriger comme une erreur de mesure, ou un reflet fidèle d'un phénomène économique réel ?
- (d) Sur des données de ménages, quelle comparaison analogue (déjà évoquée dans le cours à propos des ménages pauvres et aisés) illustre le même mécanisme ?

Exercice 2 — Breusch-Pagan et White, côte à côte

Sur le modèle M2 du cours, Breusch-Pagan donne une statistique de 57,60 (3 degrés de liberté, seuil 7,81) ; White donne 48,55 (2 degrés de liberté, seuil 5,99).

- (a) Les deux tests suivent-ils le même principe général (rappelé au chapitre 12) ? Lequel ?
- (b) Pour chacun des deux tests, comparer la statistique au seuil et conclure.
- (c) Les deux tests aboutissent-ils à la même décision, malgré des statistiques et des degrés de liberté différents ?
- (d) Le cours affirme que « le graphique avait déjà tout dit ». Qu'apporte alors, en plus du graphique, le résultat chiffré de ces deux tests ?

Exercice 3 — Ce que l'hétéroscédasticité coûte, et ce qu'elle ne coûte pas

On énonce trois affirmations à propos d'un modèle dont les résidus sont hétéroscédastiques.

- P_1 . Les coefficients estimés sont biaisés.
 - P_2 . Les moindres carrés cessent d'être BLUE (variance minimale parmi les estimateurs linéaires sans biais).
 - P_3 . Les écarts-types calculés par la formule usuelle sont faux, ainsi que tous les tests et intervalles qui en dépendent.
- (a) Laquelle de ces trois affirmations est **fausse** ? Quelle hypothèse de Gauss-Markov reste, malgré l'hétéroscédasticité, respectée ?
 - (b) Les deux autres affirmations sont-elles vraies ?
 - (c) Le cours affirme que la troisième conséquence est « la seule qui compte en pratique ». Pourquoi « on peut vivre avec une efficacité dégradée » (la deuxième conséquence), mais pas avec des tests faux (la troisième) ?
 - (d) Le sens de l'erreur sur les écarts-types (sous-estimés ou surestimés) est-il prévisible à l'avance, selon le cours ?

2 Exercice cumulatif (chapitre 14 et chapitres précédents)

Exercice 4 — Le sens de la correction, variable par variable

Le cours rapporte, sur le modèle salaire du chapitre 8 : ancienneté, $t_{MCO} = 23,06$, $t_{robuste} = 20,78$; Bac+2, $t_{MCO} = 6,93$, $t_{robuste} = 7,94$; Bac+5, $t_{MCO} = 18,11$, $t_{robuste} = 14,75$.

- (a) Les coefficients eux-mêmes (rappeler le chapitre 7 : 266,74 pour l'ancienneté) changent-ils entre

l'estimation MCO et l'estimation avec écarts-types robustes ?

- (b) Puisque le coefficient est inchangé, le rapport $t_{\text{MCO}}/t_{\text{robuste}}$ est exactement égal au rapport $\hat{\sigma}_{\text{robuste}}/\hat{\sigma}_{\text{MCO}}$. Calculer ce rapport pour l'ancienneté, pour Bac+2, et pour Bac+5.
- (c) Pour laquelle des trois variables l'écart-type MCO **sous**-estimait-il le plus fortement l'incertitude réelle ? De quel pourcentage ?
- (d) Pour laquelle des trois variables l'écart-type MCO, au contraire, **sur**-estimait-il l'incertitude (l'écart-type robuste étant **plus petit**), faisant paraître la variable moins significative qu'elle ne l'est réellement ?
- (e) Un chercheur, par prudence, déciderait-il de ne rapporter les écarts-types robustes que pour la variable où ils sont plus grands (Bac+5 et ancienneté), et de garder les écarts-types MCO pour Bac+2 (où ils sont plus favorables à la significativité) ? Pourquoi cette pratique serait-elle malhonnête, à la lumière de l'avertissement du cours : « il n'y a pas de sens prudent » ?

3 Applications en sciences économiques

Exercice 5 — L'arbitrage des ménages aisés

Une enquête de budget observe que les ménages du premier décile de revenu ont un écart-type de consommation résiduelle de 200 DH, contre 1 800 DH pour le dernier décile.

- (a) Calculer le rapport entre ces deux écarts-types.
- (b) Un ménage pauvre a peu de marge : la quasi-totalité de son revenu est consacrée à des dépenses contraintes (alimentation, logement). Un ménage aisé arbitre entre consommation, épargne, placements, et projets. Relier cet argument à l'ampleur du rapport calculé en (a).
- (c) Cette hétéroscédasticité affecte-t-elle la validité du coefficient estimé de la propension marginale à consommer (chapitre 1 et 3) ?
- (d) Quelle action pratique, recommandée comme « usage professionnel » par ce chapitre, l'analyste devrait-il appliquer **systématiquement** sur ce type de données individuelles, sans même avoir besoin de tester au préalable ?

Exercice 6 — Réparer la conséquence, ou supprimer la cause ?

Une équipe de recherche observe une hétéroscédasticité très marquée sur un modèle de salaire en niveau (non transformé). Le cours suggère qu'un passage au logarithme du salaire réduit sensiblement ce problème.

- (a) Les écarts-types robustes de White « réparent » l'hétéroscédasticité en corrigeant quoi, précisément : les coefficients, ou seulement la mesure de leur incertitude ?
- (b) Le passage au logarithme, lui, agit sur autre chose : sur quoi, précisément, agit une transformation de la variable expliquée elle-même ?
- (c) Le cours résume : « les écarts-types robustes réparent la conséquence ; le logarithme supprime parfois la cause ». En vous appuyant sur l'exemple du salaire (une dispersion **proportionnelle** au niveau de salaire, plus grande en valeur absolue pour les hauts salaires), expliquer intuitivement pourquoi passer en logarithme peut stabiliser la dispersion (indice : un même écart **relatif** de salaire produit un même écart de logarithme, quel que soit le niveau).
- (d) Une hétéroscédasticité très marquée doit-elle toujours être interprétée comme un signal de mauvaise spécification (comme dans cet exemple), ou peut-elle aussi être, comme le montre l'exercice 5, un reflet légitime d'un comportement économique réel qui persiste même après une bonne spécification ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) $2\,156/1\,319 \approx 1,63$: l'écart-type des résidus chez les Bac+5 est environ 1,6 fois plus grand que chez les titulaires d'un simple Bac.
- (b) Un salarié faiblement diplômé, souvent proche du bas de l'échelle salariale, a peu de marge de négociation ou de diversité de trajectoires : son salaire reste proche de ce que prédit le modèle. Un salarié très diplômé peut, à diplôme et ancienneté égaux, connaître des trajectoires beaucoup plus variées (poste de direction, expertise pointue, négociation individuelle, secteur d'activité) : le modèle explique moins bien son salaire précis, d'où des résidus plus dispersés.
- (c) C'est un reflet fidèle d'un phénomène économique réel, pas un défaut des données à corriger comme une erreur de mesure : la variance croissante avec le diplôme correspond à un mécanisme économique authentique (plus de marge de manœuvre, plus de diversité de situations), pas à un bruit de mesure.
- (d) La comparaison entre ménages pauvres (peu de marge, dépenses contraintes, faible dispersion de consommation) et ménages aisés (arbitrages entre consommation, épargne, placements, forte dispersion) illustre exactement le même mécanisme : la dispersion croît avec le niveau de la variable explicative parce que la marge de choix économique croît elle aussi.

Correction — Exercice 2

- (a) Oui : les deux tests reposent sur le même principe général, rappelé au chapitre 12, de la **régression auxiliaire** — régresser le carré (ou une fonction) des résidus sur des variables explicatives, puis comparer nR_{aux}^2 à un seuil du χ^2 .
- (b) Breusch-Pagan : $57,60 > 7,81$, on rejette largement H_0 (homoscédasticité). White : $48,55 > 5,99$, on rejette également, tout aussi largement.
- (c) Oui, les deux tests aboutissent à la même décision (rejet massif de l'homoscédasticité), malgré des statistiques et des degrés de liberté différents : Breusch-Pagan et White ne testent pas exactement la même forme de dépendance (BP suppose une forme linéaire dans les variables explicatives, White ajoute les carrés et produits croisés), mais les deux détectent ici le même problème sous-jacent.
- (d) Le graphique donne un diagnostic **visuel** convaincant mais qualitatif (« l'entonnoir » des résidus). Les tests chiffrés apportent une mesure **quantitative et objective** du phénomène, utilisable pour documenter la décision dans un rapport, comparer la sévérité du problème d'un modèle à l'autre, ou trancher dans les cas où le graphique serait ambigu à l'œil nu.

Correction — Exercice 3

- (a) P_1 est **fausse** : les coefficients estimés restent sans biais. L'hypothèse de Gauss-Markov qui reste respectée est H2 (exogénéité, $E(\varepsilon|X) = 0$) : l'hétéroscédasticité ne viole que H4 (homoscédasticité), pas H2.
- (b) Oui, P_2 et P_3 sont vraies : les MCO perdent leur statut de BLUE (un autre estimateur linéaire sans biais peut avoir une variance plus faible), et les écarts-types calculés par la formule usuelle des MCO sont faux, entraînant des tests et intervalles de confiance également faux.
- (c) Une efficacité dégradée (perte de la propriété de variance minimale) signifie seulement que l'estimateur MCO n'est plus le *meilleur* estimateur possible : il reste néanmoins sans biais et utilisable, seulement moins précis qu'un autre estimateur idéal. Des tests faux, en revanche, conduisent à des **décisions incorrectes** (rejeter ou ne pas rejeter H_0 à tort) : c'est le résultat concret du travail économétrique qui devient non fiable, pas seulement son optimalité théorique.
- (d) Non : le cours précise que le sens de l'erreur (sous-estimation ou surestimation) n'est **pas prévisible à l'avance** — cela dépend de la structure précise de l'hétéroscédasticité dans les données, et peut jouer dans un sens pour une variable et dans l'autre sens pour une autre variable du même modèle.

2 Exercice cumulatif

Correction — Exercice 4

- (a) Non, les coefficients ne changent pas : la correction de White ne recalcule que la matrice de variance-covariance des estimateurs, jamais les coefficients eux-mêmes ($\hat{\beta} = 266,74$ pour l'ancienneté reste strictement identique avec ou sans correction).
- (b) Puisque $\hat{\beta}$ est inchangé, $t = \hat{\beta} / \hat{\sigma}(\hat{\beta})$, donc $\hat{\sigma}_{\text{robuste}} / \hat{\sigma}_{\text{MCO}} = t_{\text{MCO}} / t_{\text{robuste}}$. Ancienneté : $23,06 / 20,78 \approx 1,110$. Bac+2 : $6,93 / 7,94 \approx 0,873$. Bac+5 : $18,11 / 14,75 \approx 1,228$.
- (c) C'est pour **Bac+5** que le MCO sous-estimait le plus l'incertitude réelle : l'écart-type robuste est 22,8 % plus grand que l'écart-type MCO ($1,228 - 1 \approx 0,228$), très proche du « vingt-trois pour cent » annoncé par le cours.
- (d) C'est pour **Bac+2** que le MCO, au contraire, surestimait l'incertitude : l'écart-type robuste est plus petit que l'écart-type MCO (rapport $0,873 < 1$, soit une baisse d'environ 12,7 %), ce qui rend cette variable en réalité *plus* significative que ne le laissait croire l'estimation MCO classique.
- (e) Cette pratique serait malhonnête, car elle reviendrait à choisir, variable par variable, la méthode d'estimation des écarts-types qui **arrange le résultat souhaité** plutôt que la méthode statistiquement correcte. Le cours est explicite : « il n'y a pas de sens prudent », car le sens de la correction (hausse ou baisse de l'écart-type) n'est pas prévisible à l'avance et n'a rien à voir avec la volonté du chercheur — les écarts-types robustes doivent être utilisés **systématiquement**, pour toutes les variables du modèle, précisément parce qu'on ne sait pas d'avance dans quel sens ils vont corriger chaque coefficient.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) $1\,800 / 200 = 9$: l'écart-type de consommation résiduelle est 9 fois plus grand pour le dernier décile que pour le premier.
- (b) Un ménage du premier décile consacre la quasi-totalité de son revenu à des dépenses contraintes : son comportement de consommation est donc très prévisible, peu de marge = peu de dispersion. Un ménage du dernier décile a le choix entre consommer davantage, épargner, investir, ou financer des projets : cette liberté d'arbitrage se traduit par des trajectoires de consommation beaucoup plus variées d'un ménage à l'autre, donc un écart-type bien plus élevé — cohérent avec le rapport de 9 trouvé en (a), plus marqué encore que le rapport de 1,6 observé sur les salaires du cours.
- (c) Non : l'hétéroscédasticité n'affecte pas la validité (l'absence de biais) du coefficient estimé de la propension marginale à consommer — ce coefficient reste un estimateur sans biais de la vraie propension marginale, comme au chapitre 1 et 3. Ce qui est affecté, ce sont les écarts-types et donc les tests et intervalles de confiance construits autour de ce coefficient.
- (d) L'analyste devrait systématiquement utiliser des **écarts-types robustes de White** sur ce type de données individuelles, sans même tester au préalable — c'est l'usage professionnel moderne recommandé par le cours, puisque l'hétéroscédasticité est ici « la règle » plutôt que l'exception sur données individuelles.

Correction — Exercice 6

- (a) Les écarts-types robustes de White corrigent uniquement la **mesure de l'incertitude** (la variance des estimateurs) ; ils ne touchent jamais aux coefficients eux-mêmes, qui restent ceux calculés par les MCO ordinaires.
- (b) Le passage au logarithme agit sur la **forme fonctionnelle** du modèle lui-même : il change la façon dont la variable expliquée réagit aux variables explicatives, et peut, ce faisant, faire disparaître ou réduire la dépendance de la variance des résidus au niveau des variables explicatives, à la source du problème plutôt que sur sa conséquence statistique.
- (c) Si la dispersion des salaires est **proportionnelle** au niveau de salaire (un salarié à 30 000 DH a une

dispersion « normale » de $\pm 3\,000$ DH tandis qu'un salarié à 10 000 DH a une dispersion de $\pm 1\,000$ DH, soit le même écart *relatif* de 10 %), alors en niveau, l'écart-type absolu des résidus croît mécaniquement avec le salaire, produisant de l'hétéroscédasticité. En passant au logarithme, un même écart *relatif* de salaire (par exemple 10 %, quel que soit le niveau de départ) produit toujours approximativement le *même* écart de $\ln(\text{salaire})$: la dispersion en logarithme devient donc à peu près constante d'un niveau de salaire à l'autre, ce qui réduit ou supprime l'hétéroscédasticité.

(d) Non : une hétéroscédasticité marquée n'est pas toujours le signal d'une mauvaise spécification. L'exercice 5 montre qu'elle peut aussi être un reflet parfaitement légitime d'un comportement économique réel (l'arbitrage croissant des ménages aisés) qui persisterait même dans un modèle par ailleurs bien spécifié. Il faut donc, au cas par cas, se demander si le problème vient d'une forme fonctionnelle inadaptée (auquel cas une transformation comme le logarithme peut aider) ou d'un phénomène économique authentique (auquel cas seule la correction des écarts-types, par la méthode de White, est appropriée — transformer les données ne ferait alors que masquer un fait réel).