Introduction à l'économétrie

Chapitre 14 : L'hétéroscédasticité

Jaouad Madkour

23 octobre 2026

Plan du chapitre

Voir le problème **2**
Ce que H3 exigeait . . . 2
Sur nos ménages, d'abord . . . 2
Sur nos salaires . . . 3
Les tests . . . 3
Ce qu'ils donnent . . . 3
Les deux régressions auxiliaires . . . 4

Ce que cela coûte **4**
Trois conséquences, et une seule grave . . . 4
Le remède . . . 4
Comment il fonctionne . . . 5
En régression simple, une formule à la main . . . 5
Le sens de la correction n'est pas garanti . . . 5
HC0, HC1, HC3 : une famille de corrections . . . 6

La pratique actuelle **6**
Ne plus tester, corriger d'emblée . . . 6
Une remarque de méthode . . . 6
Le logarithme, vérifié . . . 7

Sur machine **7**
Écarts-types robustes avec R . . . 7
Quatre erreurs-types avec Python . . . 7
Ce que disent les deux sorties . . . 8

S'entraîner **8**
Exercice 1 : White à la main . . . 8
Exercice 1 : solution . . . 8
Exercice 2 : relire une sortie . . . 8
Exercice 2 : solution . . . 9
Exercice 3 : pourquoi le logarithme . . . 9
Exercice 3 : solution . . . 9

Ce qu'il faut retenir **9**
Le résumé du chapitre 9

Voir le problème

Ce que H3 exigeait

Homoscédasticité et son contraire

$$V(\varepsilon_i) = \sigma_\varepsilon^2 \quad \text{pour tout } i$$

Quand cette variance dépend des variables explicatives, on parle d'**hétéroscédasticité** — littéralement, une dispersion inégale.

Pourquoi c'est la règle sur données individuelles

Les ménages pauvres consomment presque tout leur revenu : peu de latitude, donc peu de dispersion.
Les ménages aisés arbitrent entre consommation, épargne et placement : beaucoup de latitude, donc beaucoup de dispersion.
Le comportement économique lui-même produit l'hétéroscédasticité. Ce n'est pas un défaut des données.

Sur nos ménages, d'abord

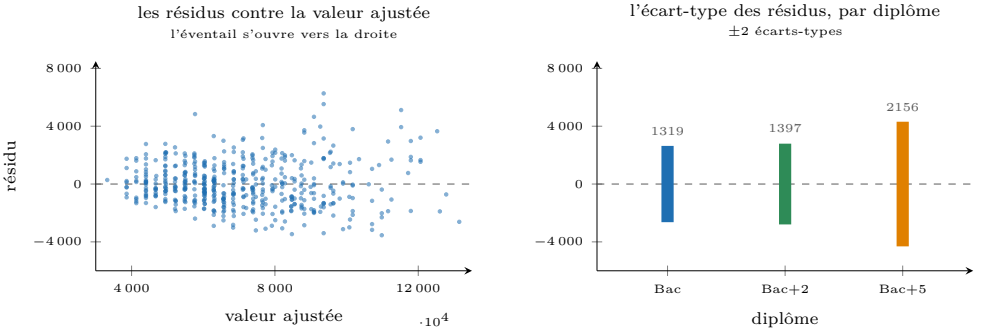
L'écart-type des résidus, par quartile de revenu

Quartile de revenu	1	2	3	4
Écart-type des résidus	404 dh	446 dh	501 dh	677 dh

La latitude se voit dans les chiffres

Les ménages du dernier quartile s'écartent de la droite de Keynes deux tiers plus que ceux du premier. Breusch-Pagan sur le modèle simple : 52,5, contre un seuil de 3,84.

Sur nos salaires

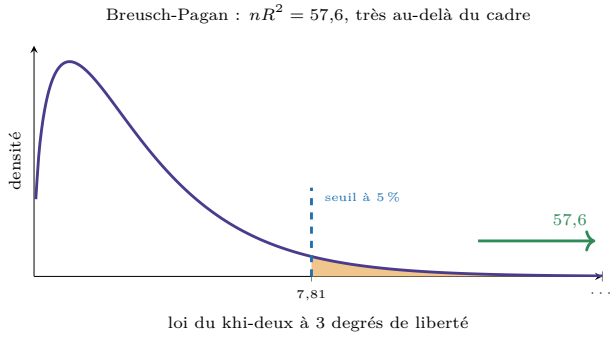


La dispersion des salaires n'est pas la même en haut et en bas de l'échelle.

Chez les titulaires d'un Bac, les résidus s'écartent de 1 319 dirhams ; chez les Bac+5, de 2 156. L'hypothèse H3 est visiblement fausse — et cela n'a rien d'anormal : **sur des données individuelles, l'hétéroscédasticité est la règle, non l'exception.**

Les coefficients restent sans biais. Ce sont les *écarts-types* qui sont faux, donc tous les t, toutes les p-values et tous les intervalles. Le remède tient en une option de la commande d'estimation.

Les tests



Le principe des deux tests

On régresse le **carré des résidus** sur les variables explicatives. Si elles l'expliquent, la variance dépend d'elles : c'est l'hétéroscédasticité.

Breusch-Pagan : sur les variables du modèle.
White : sur les variables, leurs carrés et leurs produits croisés — plus général, plus gourmand en degrés de liberté.

Statistique : nR^2 de cette seconde régression, à lire dans un khi-deux.

Sur nos données : 57,6 pour Breusch-Pagan, 48,6 pour White. Les deux rejettent massivement.

Un test qui rejette ne dit pas *combien* c'est grave : regardez toujours le graphique des résidus.

Ce qu'ils donnent

Les deux, sur le modèle M2

Test	Statistique	Degrés de liberté	Seuil
Breusch-Pagan	57,60	3	7,81
White, forme simplifiée	48,55	2	5,99

Le rejet est massif, et ce n'est pas une surprise

L'écart-type des résidus passe de 1 319 dirhams chez les titulaires d'un Bac à 2 156 chez les Bac+5 : un rapport de 1,6.
Le graphique avait déjà tout dit. Le test ne fait que le confirmer avec un chiffre.

Les deux régressions auxiliaires

Ce que chaque test régresse

Breusch-Pagan : e_i^2 sur l'ancienneté, D_2 et D_5. $R^2_{\text{aux}} = 0{,}1152$, donc $nR^2 = 57{,}6$ avec 3 degrés de liberté.
White, forme simplifiée : e_i^2 sur $\hat{y}_i$ et $\hat{y}_i^2$. Deux variables, 2 degrés de liberté : $nR^2 = 48{,}55$.

Pourquoi la forme simplifiée

White complet régresse e^2 sur les variables, leurs carrés et leurs produits croisés. Avec des indicatrices, beaucoup de ces termes sont redondants — $D_2^2 = D_2$, $D_2 D_5 = 0$. La forme en $\hat{y}$ et $\hat{y}^2$ capte la même idée avec deux termes seulement.

Ce que cela coûte

Trois conséquences, et une seule grave

L'inventaire

1. Les coefficients restent **sans biais** — H2 n'est pas en cause.
2. Ils ne sont plus de **variance minimale** : les MCO cessent d'être BLUE.
3. Les **écarts-types calculés sont faux**, donc tous les t, p-values et intervalles.

La troisième est la seule qui compte en pratique

On peut vivre avec une efficacité dégradée. On ne peut pas vivre avec des tests faux.
Et le sens de l'erreur n'est **pas prévisible** : les écarts-types peuvent être sous-estimés — on croit à une significativité qu'on n'a pas — ou surestimés.

Le remède

Les coefficients ne bougent pas d'un centime. Seuls les écarts-types changent.

	Coefficient	Écart-type		Statistique t	
		MCO	robuste	MCO	robuste
Constante	3 320,42	158,85	144,37	20,90	23,00
Ancienneté	270,27	11,72	13,00	23,06	20,78
Bac+2	1 099,57	158,59	138,43	6,93	7,94
Bac+5	3 336,99	184,25	226,28	18,11	14,75

C'est exactement ce que la théorie annonçait : l'hétéroscédasticité ne biaise rien, elle fausse la précision.

La correction de White ne modifie pas l'estimation : elle recalcule sa variance sans supposer que le bruit est le même partout.

La ligne Bac+5 est la plus instructive. C'est le groupe le plus dispersé, et son écart-type passe de 184 à 226 : les MCO le **sous-estimaient** de 23 %, donc surestimaient sa significativité. Ailleurs la correction joue en sens inverse.

Rien ne garantit le sens du changement — c'est bien pourquoi on ne peut pas s'en passer par prudence. Sur données individuelles, l'usage est aujourd'hui de publier **systématiquement** les écarts-types robustes.

Comment il fonctionne

Les écarts-types de White

On ne suppose plus que la variance est la même partout : on l'**estime observation par observation** à partir du carré des résidus.

$$\widehat{V}(\hat{\beta}) = (X'X)^{-1}\left(\sum_i e_i^2\, x_i x_i'\right)(X'X)^{-1}$$

Ce qu'il ne change pas, et ce qu'il change

Les coefficients ne bougent pas d'un centime : on ne réestime rien.
Seule la **variance** est recalculée. C'est une correction de la mesure d'incertitude, pas de l'estimation — et c'est exactement ce que la théorie annonçait.

En régression simple, une formule à la main

La variance de White pour une pente

Au chapitre 11, $V(\hat{\beta}_1) = \sum_i w_i^2 \sigma_i^2$ avec $w_i = (x_i - \overline{x})/S_{xx}$. White remplace chaque σ_i^2 inconnu par e_i^2 :

$$\widehat{V}_{\text{HC0}}(\hat{\beta}_1) = \frac{\sum_i (x_i - \overline{x})^2\, e_i^2}{S_{xx}^2}$$

Sur les cinq ménages

$\sum (R - \overline{R})^2 e^2 = 16 \times 0 + 4 \times 2{,}25 + 0 \times 4 + 4 \times 0{,}25 + 16 \times 1 = 26$, d'où $26/40^2 = 0{,}01625$ et une erreur-type de 0,127.
Avec la correction de petit échantillon HC1, $\times\, n/(n-k-1) = 5/3$: 0,165. L'erreur-type ordinaire valait 0,25.

Le sens de la correction n'est pas garanti

Sur nos données, il joue dans les deux sens

Variable	t MCO	t robuste
Ancienneté	23,06	20,78
Bac+2	6,93	7,94
Bac+5	18,11	14,75

La ligne Bac+5 est la plus instructive

C'est le groupe le plus dispersé, et son écart-type passe de 184 à 226 : les MCO le **sous-estimaient de vingt-trois pour cent**, donc surestimaient sa significativité.
Ailleurs la correction joue en sens inverse — et sur les cinq ménages aussi, de 0,25 à 0,165. **On ne peut donc pas s'en passer par prudence** — il n'y a pas de sens « prudent ».

HC0, HC1, HC3 : une famille de corrections

Les erreurs-types de M2, quatre façons

Variable	MCO	HC0	HC1	HC3
Constante	158,85	143,79	144,37	146,01
Ancienneté	11,72	12,95	13,00	13,21
Bac+2	158,59	137,88	138,43	138,96
Bac+5	184,25	225,37	226,28	227,87

Les trois versions robustes se ressemblent

HC0 est la formule de White ; HC1 la multiplie par $n/(n - k - 1)$; HC3 corrige davantage les observations à fort levier. Sur 500 observations, l'écart est de quelques dirhams. **Sur un petit échantillon, préférer HC3.**

La pratique actuelle

Ne plus tester, corriger d'emblée

L'usage professionnel

Sur données individuelles, on publie **systématiquement** des écarts-types robustes, sans tester au préalable.
La correction ne coûte rien, ne fait aucun mal si les erreurs sont homoscédastiques, et évite une faute grave si elles ne le sont pas.

Pourquoi apprendre les tests, alors

Parce qu'ils font comprendre le mécanisme, et parce qu'ils gardent leur utilité ailleurs : quand le remède coûte quelque chose, ou quand la forme de l'hétéroscédasticité intéresse en elle-même.
Un économiste qui constate que la dispersion des salaires croît avec le diplôme n'a pas trouvé un défaut : il a trouvé un fait économique.

Une remarque de méthode

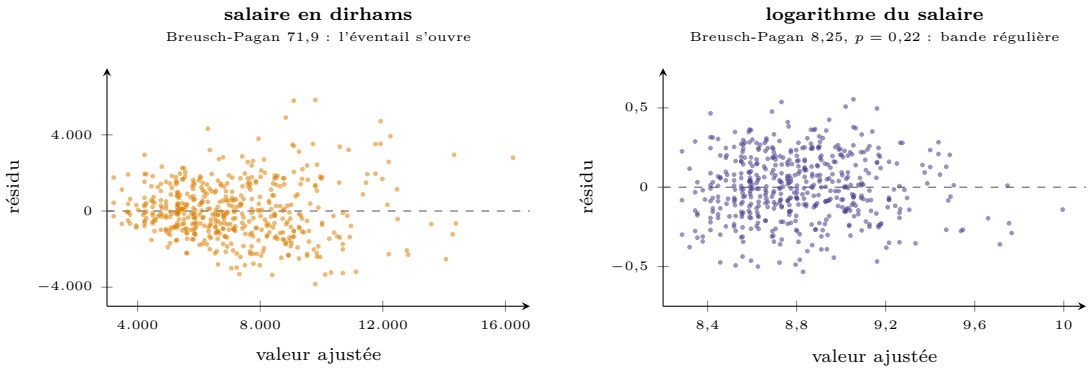
L'hétéroscédasticité comme signal

Une hétéroscédasticité très marquée signale parfois une **forme fonctionnelle mal choisie**. Sur nos salaires, passer au logarithme réduit sensiblement le problème : la dispersion des salaires croît avec le niveau, mais celle des *logarithmes* est bien plus stable. Le chapitre 18 y reviendra.

La leçon générale

Avant de corriger un symptôme, se demander s'il ne révèle pas une erreur de spécification.
Les écarts-types robustes réparent la conséquence ; le logarithme supprime parfois la cause.

Le logarithme, vérifié



Un même modèle, deux variables expliquées

Ancienneté, diplôme, région. En dirhams, Breusch-Pagan vaut 71,9 et l'écart-type des résidus va de 1 270 (Bac) à 2 100 (Bac+5). En logarithme : 8,25, $p = 0{,}22$, et de 0,209 à 0,219. **L'hétéroscédasticité a disparu.**

Sur machine

Écarts-types robustes avec R

```r
suppressPackageStartupMessages(library(lmtest))
library(sandwich)
sal <- read.csv("salaires.csv", stringsAsFactors = TRUE)
m2 <- lm(salaire ~ anciennete + diplome, data = sal)
coeftest(m2, vcov = vcovHC(m2, type = "HC1"))
#
# t test of coefficients:
#
#              Estimate Std. Error t value  Pr(>|t|)
# (Intercept)  3320.421    144.365 23.0002 < 2.2e-16
# anciennete    270.269     13.003 20.7844 < 2.2e-16
# diplomeBac+2 1099.570    138.431  7.9431 1.332e-14
# diplomeBac+5 3336.992    226.280 14.7472 < 2.2e-16
```

Quatre erreurs-types avec Python

```python
import pandas as pd
import statsmodels.formula.api as smf
sal = pd.read_csv("salaires.csv")
f = "salaire ~ anciennete + diplome"
t = pd.DataFrame({k: smf.ols(f, data=sal).fit(cov_type=k).bse
                  for k in ("nonrobust", "HC0", "HC1", "HC3")})
print(t.round(2))
#                  nonrobust     HC0     HC1     HC3
```

```
# Intercept            158.85  143.79  144.37  146.01
# diplome[T.Bac+2]     158.59  137.88  138.43  138.96
# diplome[T.Bac+5]     184.25  225.37  226.28  227.87
# anciennete            11.72   12.95   13.00   13.21
```

Ce que disent les deux sorties

Deux paquets en R, une option en Python

`sandwich` calcule la matrice de White — la « tranche » $\sum e_i^2 x_i x_i'$ entre deux $(X'X)^{-1}$ —, `lmtest` en tire les t : on retrouve 226,28 pour le Bac+5.
En Python, `fit(cov_type="HC1")` : les coefficients sont les mêmes, seuls changent les écarts-types et tout ce qui en découle.

Annoncer la correction utilisée

Un tableau de régression doit dire quels écarts-types il publie : « écarts-types robustes HC1 ». Sans cette mention, le lecteur suppose les MCO ordinaires — et il ne peut pas refaire le calcul.

S'entraîner

Exercice 1 : White à la main

Les quatre magasins

Pour $\hat{y} = 0{,}5 + 1{,}5\,x$, on a $x - \overline{x} = -2, -1, 1, 2$, $S_{xx} = 10$, résidus 0 ; 0,5 ; −1,5 ; 1, et une erreur-type ordinaire de 0,418.

1. Calculer l'erreur-type robuste HC0 de la pente.
2. Puis HC1, avec le facteur $n/(n-2)$.
3. La correction rend-elle la pente plus ou moins significative ?

Exercice 1 : solution

Plus significative, cette fois

1. $\sum (x-\overline{x})^2 e^2 = 4\times 0 + 1\times 0{,}25 + 1\times 2{,}25 + 4\times 1 = 6{,}5$; $6{,}5/10^2 = 0{,}065$; erreur-type 0,255.
2. $0{,}065 \times 4/2 = 0{,}13$; erreur-type 0,361.
3. $0{,}361 < 0{,}418$: le t passe de 3,59 à 4,16. La correction joue ici à la baisse — et rien ne permettait de le prévoir.

Exercice 2 : relire une sortie

Deux coefficients, deux erreurs-types

Une étude publie, pour $n = 400$:

Variable	Coefficient	e.-t. MCO	e.-t. robuste
Âge	52	24	31

Diplôme	410	190	160

1. Calculer les deux t de chaque variable.
2. Quelle conclusion change selon l'écart-type retenu ?
3. Lequel faut-il publier ?

Exercice 2 : solution

L'âge perd sa significativité

1. Âge : $52/24 = 2{,}17$ puis $52/31 = 1{,}68$. Diplôme : $410/190 = 2{,}16$ puis $410/160 = 2{,}56$.
2. L'âge est significatif à 5 % avec les MCO, **plus** avec l'écart-type robuste. Le diplôme l'est dans les deux cas.
3. L'écart-type **robuste**, sur données individuelles, sans hésiter : publier l'autre parce qu'il arrange serait de la pêche aux résultats.

Exercice 3 : pourquoi le logarithme

Un choc proportionnel

Deux salariés gagnent 3 000 et 15 000 dirhams. Chacun connaît, d'une année à l'autre, des variations de ± 10 % dues à des primes.

1. Quelle est l'amplitude de ces variations en dirhams, pour chacun ?
2. Et en logarithme ?
3. Qu'en conclure pour le choix de la variable expliquée ?

Exercice 3 : solution

Additif en logarithme

1. ± 300 dirhams pour le premier, $\pm 1\,500$ pour le second : une dispersion **cinq fois** plus grande.
2. $\ln(1{,}1) \approx 0{,}095$ pour les deux : la même dispersion.
3. Si les écarts sont **proportionnels**, le modèle en dirhams est hétéroscédastique par construction et le modèle en logarithme ne l'est pas. C'est le cas des salaires — chapitre 18.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. L'hétéroscédasticité est la **règle** sur données individuelles : ménages de 404 à 677 dh, salaires de 1 319 à 2 156.
2. Breusch-Pagan 57,6 et White 48,6 : rejet massif, confirmé par le graphique.
3. Les coefficients restent **sans biais** ; seuls les **écarts-types** sont faux.
4. Les écarts-types **robustes de White** corrigent sans toucher aux coefficients : $\sum (x - \overline{x})^2 e^2 / S_{xx}^2$.

5. Le sens de la correction n'est pas prévisible : la prudence ne dispense pas de corriger.
6. Le **logarithme** supprime ici la cause : Breusch-Pagan tombe à 8,25.

La suite

Sur l'enquête de ménages, un second problème s'ajoute : les observations n'y sont pas tombées une par une, mais par **quartiers**. C'est le chapitre 15.