

Introduction à l'économétrie

Chapitre 11 : Les hypothèses de Gauss-Markov

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'économétrie

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	4

1 Exercices du chapitre

Exercice 1 — Linéaire en les paramètres, ou pas

On propose quatre spécifications.

$$M_1. y = \beta_0 + \beta_1 x + \beta_2 x^2 + \varepsilon$$

$$M_2. y = \beta_0 + \beta_1^2 x + \varepsilon$$

$$M_3. \ln y = \beta_0 + \beta_1 \ln x + \varepsilon$$

$$M_4. y = \beta_0 e^{\beta_1 x} \varepsilon \text{ (forme multiplicative, avant toute transformation)}$$

- Pour chacune des quatre spécifications, indiquer si elle est linéaire **en les paramètres** $(\beta_0, \beta_1, \beta_2)$, en justifiant.
- M_1 est-elle linéaire en x ? Cela pose-t-il un problème pour l'hypothèse H1?
- M_3 décrit une relation en puissance entre y et x ($y = e^{\beta_0} x^{\beta_1}$). Pourquoi peut-elle malgré tout être estimée par les moindres carrés ordinaires « tels quels »?
- M_4 , prise directement, viole H1. Quelle transformation simple (indice : un logarithme) permettrait de la ramener à une forme satisfaisant H1?

Exercice 2 — Quelle hypothèse tombe ?

Trois situations sont observées sur une base de données d'entreprises.

- S_1 . La dispersion des bénéfices résiduels est nettement plus grande chez les grandes entreprises que chez les petites.
 - S_2 . Plusieurs entreprises d'un même groupe industriel partagent des chocs de marché non observés dans le modèle (une même maison mère, une même exposition à un fournisseur commun).
 - S_3 . La productivité managériale, non mesurée, est corrélée à la fois à la taille de l'entreprise (incluse dans le modèle) et à sa rentabilité (la variable expliquée).
- Associer chacune des trois situations à l'hypothèse de Gauss-Markov qu'elle met en cause (H2 exogénéité, H3 homoscedasticité, ou H4 indépendance).
 - Parmi les trois, laquelle biaise les coefficients estimés, et laquelle ne fait que fausser les écarts-types?
 - Le cours affirme qu'H3 et H4 « ne touchent que les écarts-types », jamais les coefficients eux-mêmes. En quoi cela distingue-t-il fondamentalement leur gravité de celle d'une violation de H2?
 - Pour S_2 (observations groupées par groupe industriel), quel outil, déjà nommé par un chapitre antérieur du cours (« erreurs groupées »), permettrait de corriger le problème sans changer les coefficients eux-mêmes?

Exercice 3 — Ce que BLUE garantit, et ce qu'il ne garantit pas

Le sigle BLUE résume le théorème de Gauss-Markov : *Best Linear Unbiased Estimator*.

- Quelle hypothèse, à elle seule, garantit le « U » (*Unbiased*) ?
- Quelles hypothèses garantissent le « B » (*Best*, variance minimale) ?
- Le « L » (*Linear*) n'est pas une hypothèse mais une **restriction de la classe** des estimateurs comparés. Expliquer ce que cela signifie : les MCO sont-ils nécessairement le meilleur estimateur possible, toutes classes confondues ?
- Citer, d'après le cours, un exemple d'estimateur **non** linéaire qui peut faire mieux que les MCO dès qu'on connaît la loi des erreurs.

2 Exercice cumulatif (chapitre 11 et chapitres précédents)

Exercice 4 — Relire trois chapitres à la lumière de Gauss-Markov

On relit trois résultats déjà rencontrés dans ce cours.

- (a) Le chapitre 2 avait montré que la taille du ménage, omise et corrélée au revenu, biaisait $\hat{\beta}_1$ dans le modèle de consommation. De quelle hypothèse de Gauss-Markov s'agissait-il ?
- (b) Le chapitre 7 (exercice 3) avait montré qu'une variable exactement proportionnelle à une autre ($x_4 = 2x_2$) rendait $X'X$ non inversible. De quelle hypothèse de Gauss-Markov s'agissait-il ?
- (c) Le chapitre 9 (exercice 6) avait examiné le cas de la R&D et des brevets, corrélés à $r = 0,97$ mais **pas** parfaitement colinéaires : la régression restait calculable, mais les t individuels étaient peu fiables. Cette situation viole-t-elle formellement H5, ou se situe-t-elle dans une zone que le cours réserve pour un chapitre **ultérieur** (le chapitre 13) ?
- (d) Classer ces trois situations selon qu'elles biaisent les coefficients (comme H2), qu'elles rendent le calcul impossible (comme une violation stricte de H5), ou qu'elles restent calculables mais fragiles (la colinéarité **presque** parfaite).
- (e) En quoi ce chapitre 11 fournit-il, rétrospectivement, le **cadre unifié** qui explique pourquoi ces trois épisodes du cours, en apparence disparates, relevaient en réalité chacun d'une hypothèse précise et nommée ?

3 Applications en sciences économiques

Exercice 5 — Grand échantillon, petit échantillon

Une première étude porte sur $n = 500$ salariés ; une seconde, sur $n = 15$ dirigeants d'entreprises familiales (un sous-groupe rare et difficile à échantillonner davantage).

- (a) Pour l'étude à $n = 500$, l'hypothèse H6 (normalité des erreurs) doit-elle être vérifiée avant de faire confiance aux tests t ? Quel résultat statistique, déjà rencontré dans un cours antérieur, justifie cette réponse ?
- (b) Pour l'étude à $n = 15$, cette même hypothèse est-elle, au contraire, décisive ? Quelle vérification pratique le cours recommande-t-il avant de publier le moindre test t sur un tel échantillon ?
- (c) H6 fait-elle partie des cinq hypothèses de Gauss-Markov proprement dites ? À quoi sert-elle précisément, si les MCO sont déjà BLUE sans elle ?
- (d) Un chercheur affirme : « avec 15 observations seulement, mes estimateurs ne sont de toute façon plus BLUE ». Cette affirmation est-elle exacte ? Rappeler que le statut BLUE ne dépend que des hypothèses H1 à H5, pas de la taille de l'échantillon.

Exercice 6 — Quand un autre estimateur fait mieux

Une banque veut modéliser la probabilité qu'un emprunteur fasse défaut sur son crédit, en fonction de son revenu et de son taux d'endettement. La variable expliquée ne prend que deux valeurs : 0 (pas de défaut) ou 1 (défaut).

- (a) Un premier stagiaire propose une régression linéaire classique (MCO) de cette variable binaire sur le revenu et le taux d'endettement. Les MCO restent-ils BLUE, au sens strict du théorème, tant que H1 à H5 sont respectées, même si y ne prend que deux valeurs ?
- (b) Le cours annonce que, dès qu'on connaît (ou qu'on suppose) la loi des erreurs, un estimateur **non linéaire** peut faire mieux que les MCO. Quel est cet estimateur, nommé dans ce chapitre ?
- (c) Pourquoi une probabilité de défaut estimée par une droite MCO risque-t-elle de produire des prédictions absurdes (par exemple, une probabilité négative ou supérieure à 1) pour certains emprunteurs, un problème qu'un modèle non linéaire adapté aux variables binaires peut éviter par construction ?
- (d) En quoi cet exemple illustre-t-il concrètement la « restriction cachée » du théorème de Gauss-

Markov, à savoir que « meilleur » n'est garanti que **parmi les estimateurs linéaires** ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) M_1 : **linéaire en les paramètres** ($\beta_0, \beta_1, \beta_2$ apparaissent au premier degré, sans produit ni fonction entre eux). M_2 : **non linéaire** en les paramètres (β_1 apparaît au carré). M_3 : **linéaire en les paramètres** (β_0, β_1 apparaissent au premier degré; c'est $\ln x$, une variable transformée, qui multiplie β_1). M_4 , prise telle quelle : **non linéaire** en les paramètres (β_1 apparaît en exposant).
- (b) Non, M_1 n'est pas linéaire en x (il y a un terme en x^2), mais cela ne pose **aucun** problème pour $H1$: l'hypothèse porte sur les paramètres, jamais sur les variables. x^2 est simplement traité comme une variable explicative supplémentaire.
- (c) Parce que M_3 est déjà écrite sous une forme où les paramètres β_0 et β_1 apparaissent linéairement : bien que la relation **originale** entre y et x soit une puissance ($y = e^{\beta_0} x^{\beta_1}$), la transformation logarithmique déjà appliquée aux deux variables ($\ln y, \ln x$) rend le modèle directement estimable par les MCO, sans aucune modification supplémentaire de la méthode.
- (d) En prenant le logarithme des deux côtés : $\ln y = \ln \beta_0 + \beta_1 x + \ln \varepsilon$, qui redevient linéaire en les paramètres $\ln \beta_0$ (une nouvelle constante) et β_1 .

Correction — Exercice 2

- (a) S_1 (dispersion croissante avec la taille) : **H3, homoscédasticité**. S_2 (chocs partagés au sein d'un groupe) : **H4, indépendance**. S_3 (variable omise corrélée à la fois à une variable incluse et à y) : **H2, exogénéité**.
- (b) Seule S_3 (violation de H2) biaise les coefficients estimés. S_1 et S_2 (violations de H3 et H4) ne faussent que les écarts-types, laissant les coefficients eux-mêmes sans biais.
- (c) Un coefficient biaisé (violation de H2) vise systématiquement à côté de la vraie valeur, quelle que soit la taille de l'échantillon : aucune collecte de données supplémentaire ne corrige ce problème. Des écarts-types faussés (violations de H3 ou H4) n'affectent que la **précision apparente** des tests et intervalles : les coefficients restent corrects en moyenne, et le problème se corrige par des méthodes d'estimation de la variance appropriées (sans changer l'estimation des coefficients eux-mêmes).
- (d) La méthode des erreurs-types groupées (« erreurs groupées », chapitre 15 du cours), qui corrige les écarts-types pour tenir compte de la corrélation des erreurs à l'intérieur de chaque groupe, sans changer les coefficients estimés par MCO.

Correction — Exercice 3

- (a) H2 (exogénéité, $E(\varepsilon | X) = 0$) garantit, à elle seule, le « U » (*Unbiased*).
- (b) H3 (homoscédasticité) et H4 (indépendance) garantissent, ensemble, le « B » (*Best*, variance minimale parmi les estimateurs linéaires sans biais).
- (c) Cela signifie que la comparaison n'est faite qu'à l'intérieur de la classe des estimateurs qui sont à la fois linéaires (des combinaisons linéaires des y_i) et sans biais. Non, les MCO ne sont donc pas nécessairement le meilleur estimateur possible toutes classes confondues : un estimateur non linéaire, en dehors de cette classe restreinte, pourrait faire mieux.
- (d) L'estimateur du **maximum de vraisemblance**, qui peut surpasser les MCO dès que la loi de probabilité des erreurs est connue (ou raisonnablement supposée).

2 Exercice cumulatif

Correction — Exercice 4

- (a) Il s'agissait d'une violation de **H2** (exogénéité) : la taille du ménage, omise et corrélée au revenu, rendait $E(\varepsilon | R) \neq 0$, biaisant $\hat{\beta}_1$.
- (b) Il s'agissait d'une violation de **H5** (pas de colinéarité parfaite) : $x_4 = 2x_2$ rendait $X'X$ strictement non inversible, empêchant tout calcul.
- (c) Non, cette situation ($r = 0,97$, sans relation exacte) ne viole **pas formellement** H5 — la régression restait calculable, donc $X'X$ restait, techniquement, inversible. Elle se situe dans la zone intermédiaire, réservée par le cours au chapitre 13 (la multicollinéarité **forte mais non parfaite**), qui n'est pas couverte par les cinq hypothèses strictes de Gauss-Markov mais en constitue un prolongement pratique important.
- (d) La situation (a) biaise les coefficients (violation de H2). La situation (b) rend le calcul impossible (violation stricte de H5). La situation (c) reste calculable mais fragile (colinéarité forte, non parfaite, ni strictement couverte ni exclue par H5).
- (e) Ce chapitre montre que ces trois épisodes, présentés à des moments différents du cours autour d'exemples concrets variés (ménages, indicatrices dupliées, R&D et brevets), ne sont pas des curiosités isolées mais des manifestations précises et nommées d'un même corpus d'hypothèses (H2 pour le biais, H5 pour l'existence du calcul, et la zone grise entre H5 stricte et le chapitre 13 pour la fragilité). Le cadre de Gauss-Markov permet ainsi de **classer** rétrospectivement chaque incident rencontré selon la nature précise de son origine, plutôt que de les traiter comme des problèmes disparates.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) Non, H6 n'a pas besoin d'être vérifiée pour $n = 500$: le **théorème central limite** garantit que $\hat{\beta}_j$ est approximativement normal, quelle que soit la loi véritable des erreurs, dès que l'échantillon est suffisamment grand.
- (b) Oui, H6 devient décisive pour $n = 15$: le théorème central limite ne peut plus être invoqué pour un échantillon aussi petit. Le cours recommande d'examiner l'histogramme des résidus avant de publier le moindre test t , afin de vérifier que l'hypothèse de normalité n'est pas manifestement violée.
- (c) Non, H6 ne fait **pas** partie des cinq hypothèses de Gauss-Markov : les MCO restent BLUE sous H1 à H5 seules, sans avoir besoin de la normalité. H6 sert uniquement à rendre les tests statistiques (t , F) **exacts** à petit échantillon, plutôt qu'approximatifs.
- (d) Non, cette affirmation est inexacte : le statut BLUE ne dépend que du respect de H1 à H5, pas de la taille de l'échantillon n . Avec $n = 15$, les MCO restent BLUE si H1 à H5 tiennent ; ce qui devient fragile, en revanche, c'est la validité **exacte** des tests d'hypothèses en l'absence de normalité des erreurs (H6), une question totalement distincte du statut BLUE des estimateurs eux-mêmes.

Correction — Exercice 6

- (a) Oui, au sens strict du théorème : si H1 à H5 sont respectées, les MCO restent BLUE, même quand y ne prend que deux valeurs — le théorème de Gauss-Markov ne fait aucune hypothèse sur la nature (continue ou binaire) de la variable expliquée.
- (b) L'estimateur du **maximum de vraisemblance** (typiquement, dans ce contexte, appliqué à un modèle logit ou probit, adapté aux variables binaires).
- (c) Une droite MCO, par construction, peut prendre n'importe quelle valeur réelle selon les valeurs du revenu et du taux d'endettement, y compris des valeurs inférieures à 0 ou supérieures à 1 — des probabilités absurdes. Un modèle non linéaire adapté (logit, probit) contraint, lui, ses prédictions à l'intervalle $[0, 1]$ par la forme même de sa fonction, évitant structurellement ce problème.
- (d) Cet exemple illustre exactement la restriction cachée du théorème : les MCO peuvent rester BLUE,

et pourtant produire des prédictions absurdes, précisément parce que « meilleur » n'est garanti que dans la classe restreinte des estimateurs **linéaires**. Un estimateur non linéaire (maximum de vraisemblance sur un modèle logit ou probit), en sortant de cette classe, peut être à la fois plus adapté au problème (probabilités bornées) et plus performant, sans que cela contredise en rien le théorème de Gauss-Markov — qui ne prétend jamais que les MCO sont le meilleur choix en toutes circonstances, seulement le meilleur **parmi les estimateurs linéaires sans biais**.