

Chapitre 11

Les hypothèses de Gauss-Markov

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Économétrie — Introduction

1 Exercices du chapitre

Exercice 1 — Linéaire en les paramètres, ou pas

On propose quatre spécifications.

$$M_1. y = \beta_0 + \beta_1 x + \beta_2 x^2 + \varepsilon$$

$$M_2. y = \beta_0 + \beta_1^2 x + \varepsilon$$

$$M_3. \ln y = \beta_0 + \beta_1 \ln x + \varepsilon$$

$$M_4. y = \beta_0 e^{\beta_1 x} \varepsilon \text{ (forme multiplicative, avant toute transformation)}$$

- (a) Pour chacune des quatre spécifications, indiquer si elle est linéaire **en les paramètres** $(\beta_0, \beta_1, \beta_2)$, en justifiant.
- (b) M_1 est-elle linéaire en x ? Cela pose-t-il un problème pour l'hypothèse H1?
- (c) M_3 décrit une relation en puissance entre y et x ($y = e^{\beta_0} x^{\beta_1}$). Pourquoi peut-elle malgré tout être estimée par les moindres carrés ordinaires « tels quels »?
- (d) M_4 , prise directement, viole H1. Quelle transformation simple (indice : un logarithme) permettrait de la ramener à une forme satisfaisant H1?

Exercice 2 — Quelle hypothèse tombe ?

Trois situations sont observées sur une base de données d'entreprises.

- S_1 . La dispersion des bénéfices résiduels est nettement plus grande chez les grandes entreprises que chez les petites.
 - S_2 . Plusieurs entreprises d'un même groupe industriel partagent des chocs de marché non observés dans le modèle (une même maison mère, une même exposition à un fournisseur commun).
 - S_3 . La productivité managériale, non mesurée, est corrélée à la fois à la taille de l'entreprise (incluse dans le modèle) et à sa rentabilité (la variable expliquée).
- (a) Associer chacune des trois situations à l'hypothèse de Gauss-Markov qu'elle met en cause (H2 exogénéité, H3 homoscedasticité, ou H4 indépendance).
 - (b) Parmi les trois, laquelle biaise les coefficients estimés, et laquelle ne fait que fausser les écarts-types?
 - (c) Le cours affirme qu'H3 et H4 « ne touchent que les écarts-types », jamais les coefficients eux-mêmes. En quoi cela distingue-t-il fondamentalement leur gravité de celle d'une violation de H2?
 - (d) Pour S_2 (observations groupées par groupe industriel), quel outil, déjà nommé par un chapitre antérieur du cours (« erreurs groupées »), permettrait de corriger le problème sans changer les coefficients eux-mêmes?

Exercice 3 — Ce que BLUE garantit, et ce qu'il ne garantit pas

Le sigle BLUE résume le théorème de Gauss-Markov : *Best Linear Unbiased Estimator*.

- (a) Quelle hypothèse, à elle seule, garantit le « U » (*Unbiased*)?
- (b) Quelles hypothèses garantissent le « B » (*Best*, variance minimale)?
- (c) Le « L » (*Linear*) n'est pas une hypothèse mais une **restriction de la classe** des estimateurs comparés. Expliquer ce que cela signifie : les MCO sont-ils nécessairement le meilleur estimateur possible, toutes classes confondues?
- (d) Citer, d'après le cours, un exemple d'estimateur **non** linéaire qui peut faire mieux que les MCO dès qu'on connaît la loi des erreurs.

2 Exercice cumulatif (chapitre 11 et chapitres précédents)

Exercice 4 — Relire trois chapitres à la lumière de Gauss-Markov

On relit trois résultats déjà rencontrés dans ce cours.

- (a) Le chapitre 2 avait montré que la taille du ménage, omise et corrélée au revenu, biaisait $\hat{\beta}_1$ dans le modèle de consommation. De quelle hypothèse de Gauss-Markov s'agissait-il ?
- (b) Le chapitre 7 (exercice 3) avait montré qu'une variable exactement proportionnelle à une autre ($x_4 = 2x_2$) rendait $X'X$ non inversible. De quelle hypothèse de Gauss-Markov s'agissait-il ?
- (c) Le chapitre 9 (exercice 6) avait examiné le cas de la R&D et des brevets, corrélés à $r = 0,97$ mais **pas** parfaitement colinéaires : la régression restait calculable, mais les t individuels étaient peu fiables. Cette situation viole-t-elle formellement H5, ou se situe-t-elle dans une zone que le cours réserve pour un chapitre **ultérieur** (le chapitre 13) ?
- (d) Classer ces trois situations selon qu'elles biaisent les coefficients (comme H2), qu'elles rendent le calcul impossible (comme une violation stricte de H5), ou qu'elles restent calculables mais fragiles (la colinéarité **presque** parfaite).
- (e) En quoi ce chapitre 11 fournit-il, rétrospectivement, le **cadre unifié** qui explique pourquoi ces trois épisodes du cours, en apparence disparates, relevaient en réalité chacun d'une hypothèse précise et nommée ?

3 Applications en sciences économiques

Exercice 5 — Grand échantillon, petit échantillon

Une première étude porte sur $n = 500$ salariés ; une seconde, sur $n = 15$ dirigeants d'entreprises familiales (un sous-groupe rare et difficile à échantillonner davantage).

- (a) Pour l'étude à $n = 500$, l'hypothèse H6 (normalité des erreurs) doit-elle être vérifiée avant de faire confiance aux tests t ? Quel résultat statistique, déjà rencontré dans un cours antérieur, justifie cette réponse ?
- (b) Pour l'étude à $n = 15$, cette même hypothèse est-elle, au contraire, décisive ? Quelle vérification pratique le cours recommande-t-il avant de publier le moindre test t sur un tel échantillon ?
- (c) H6 fait-elle partie des cinq hypothèses de Gauss-Markov proprement dites ? À quoi sert-elle précisément, si les MCO sont déjà BLUE sans elle ?
- (d) Un chercheur affirme : « avec 15 observations seulement, mes estimateurs ne sont de toute façon plus BLUE ». Cette affirmation est-elle exacte ? Rappeler que le statut BLUE ne dépend que des hypothèses H1 à H5, pas de la taille de l'échantillon.

Exercice 6 — Quand un autre estimateur fait mieux

Une banque veut modéliser la probabilité qu'un emprunteur fasse défaut sur son crédit, en fonction de son revenu et de son taux d'endettement. La variable expliquée ne prend que deux valeurs : 0 (pas de défaut) ou 1 (défaut).

- (a) Un premier stagiaire propose une régression linéaire classique (MCO) de cette variable binaire sur le revenu et le taux d'endettement. Les MCO restent-ils BLUE, au sens strict du théorème, tant que H1 à H5 sont respectées, même si y ne prend que deux valeurs ?
- (b) Le cours annonce que, dès qu'on connaît (ou qu'on suppose) la loi des erreurs, un estimateur **non linéaire** peut faire mieux que les MCO. Quel est cet estimateur, nommé dans ce chapitre ?
- (c) Pourquoi une probabilité de défaut estimée par une droite MCO risque-t-elle de produire des prédictions absurdes (par exemple, une probabilité négative ou supérieure à 1) pour certains emprunteurs, un problème qu'un modèle non linéaire adapté aux variables binaires peut éviter par construction ?
- (d) En quoi cet exemple illustre-t-il concrètement la « restriction cachée » du théorème de Gauss-

Markov, à savoir que « meilleur » n'est garanti que **parmi les estimateurs linéaires** ?