Introduction à l'économétrie

Chapitre 11 : Les hypothèses de Gauss-Markov

Jaouad Madkour

23 octobre 2026

Plan du chapitre

À quelles conditions **2**
Ce que les chapitres précédents ont supposé sans le dire . . . 2
Les six hypothèses . . . 2

Les cinq de Gauss-Markov **2**
H1 — La linéarité . . . 2
H2 — L'exogénéité . . . 3
Pourquoi H2 suffit au non-biais . . . 3
H3 et H4 — Sur la structure des erreurs . . . 3
H3 et H4 donnent la formule de l'erreur-type . . . 4
H5 — Pas de colinéarité parfaite . . . 4

La sixième **4**
La normalité des erreurs . . . 4
Ce que le théorème garantit exactement . . . 5

Le théorème, mis à l'épreuve **5**
Deux concurrents des moindres carrés . . . 5
Dix mille échantillons de cinq ménages . . . 6

Sur machine **6**
Gauss-Markov par simulation avec R . . . 6
Gauss-Markov par simulation avec Python . . . 6
Ce que disent les deux simulations . . . 7

S'entraîner **7**
Exercice 1 : un troisième concurrent . . . 7
Exercice 1 : solution . . . 7
Exercice 2 : quelle hypothèse tombe . . . 8
Exercice 2 : solution . . . 8
Exercice 3 : linéaire en les paramètres . . . 8
Exercice 3 : solution . . . 8

Ce qu'il faut retenir **9**

Le résumé du chapitre 9

À quelles conditions

Ce que les chapitres précédents ont supposé sans le dire

Dix chapitres de résultats, et une dette

Nous avons estimé, testé, encadré, prévu — en admettant chaque fois que les formules étaient valides.
Elles ne le sont que sous conditions. Ce chapitre les énonce, le suivant montre ce qui tombe quand elles ne tiennent pas.

Le théorème de Gauss-Markov

Sous cinq hypothèses, les estimateurs des moindres carrés sont **BLUE** : *Best Linear Unbiased Estimator*.
Le meilleur — au sens de la variance minimale — parmi les estimateurs **linéaires** et **sans biais**.

Les six hypothèses

Cinq hypothèses de Gauss-Markov, et une sixième qui ne sert qu'aux petits échantillons.

	L'hypothèse	Ce qu'elle garantit
H1	Le modèle est **linéaire** en ses paramètres	la forme estimée est la bonne
H2	$E(\varepsilon_i \mid X) = 0$ — **exogénéité**	les estimateurs sont **sans biais**
H3	$V(\varepsilon_i) = \sigma^2_\varepsilon$ — **homoscédasticité**	les écarts-types sont justes
H4	$\mathrm{cov}(\varepsilon_i, \varepsilon_j) = 0$ — **indépendance**	les écarts-types sont justes
H5	Pas de **colinéarité parfaite**	le calcul est possible, et unique
H6	Les ε_i sont **normales**	les tests sont exacts à petit n

Ce que le théorème conclut
Sous H1 à H5, les moindres carrés sont **BLUE** : le meilleur estimateur linéaire sans biais. Sans biais, et de variance minimale dans sa classe.

H2 est d'une autre nature que les autres
Elle seule concerne le *biais*. H3 et H4 ne touchent que la *précision* et les écarts-types — graves, mais réparables.

H1 est moins restrictive qu'elle n'en a l'air
« Linéaire en les paramètres » : $\ln y = \beta_0 + \beta_1 \ln x + \varepsilon$ l'est. La courbure passe par la transformation des variables, non par l'abandon des MCO.

H6 est en gris parce qu'au-delà de trente observations, le théorème central limite la rend inutile.

Les cinq de Gauss-Markov

H1 — La linéarité

Linéaire en les paramètres

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k + \varepsilon$$

Les β apparaissent au premier degré, sans produit ni fonction entre eux.

Beaucoup moins restrictif qu'il n'y paraît

$\ln y = \beta_0 + \beta_1 \ln x + \varepsilon$ est **linéaire en les paramètres**, bien que la relation entre y et x soit une puissance.
La courbure passe par la **transformation des variables**, non par l'abandon des moindres carrés. Le chapitre 18 en fait un usage systématique.

H2 — L'exogénéité

La plus importante de toutes

$$E(\varepsilon_i \mid X) = 0$$

L'erreur ne contient rien de systématiquement lié aux variables explicatives.

Elle seule concerne le biais

Sous H2, $E(\hat{\beta}_j) = \beta_j$: l'estimation vise juste.
Sans elle, tout le reste devient sans objet. Un estimateur biaisé peut être très précis autour de la mauvaise valeur — c'est la deuxième cible du chapitre 5 de l'inférence, la plus traître des quatre.

Pourquoi H2 suffit au non-biais

La pente est une moyenne pondérée des y

$$\hat{\beta}_1 = \sum_i w_i\, y_i \quad \text{avec} \quad w_i = \frac{x_i - \overline{x}}{S_{xx}}, \qquad \sum_i w_i = 0, \quad \sum_i w_i x_i = 1$$

En remplaçant y_i par $\beta_0 + \beta_1 x_i + \varepsilon_i$: $\hat{\beta}_1 = \beta_1 + \sum_i w_i\, \varepsilon_i$.

Sur les cinq ménages

$w = (-4, -2, 0, 2, 4)/40 = -0{,}1\ ;\ -0{,}05\ ;\ 0\ ;\ 0{,}05\ ;\ 0{,}1$. Si $E(\varepsilon_i \mid R) = 0$, l'espérance de $\sum w_i \varepsilon_i$ est nulle : $E(\hat{\beta}_1) = \beta_1$. **Le mot « linéaire » de BLUE, c'est cela** : $\hat{\beta}_1$ est une combinaison linéaire des y_i.

H3 et H4 — Sur la structure des erreurs

Homoscédasticité et indépendance

$$V(\varepsilon_i) = \sigma_\varepsilon^2 \quad \text{pour tout } i \qquad\qquad \operatorname{cov}(\varepsilon_i, \varepsilon_j) = 0 \quad \text{pour } i \neq j$$

La même dispersion partout ; aucune liaison entre les erreurs.

Les deux sont violées sur nos données

H3 tombe dès que la dispersion dépend du niveau : les salaires élevés sont plus dispersés que les bas.
H4 tombe dès que les observations sont **groupées** : deux ménages du même quartier partagent ce que le modèle ignore.
Aucune des deux ne biaise les coefficients. Toutes deux faussent les **écarts-types**.

H3 et H4 donnent la formule de l'erreur-type

Une variance de somme pondérée

$\hat{\beta}_1 - \beta_1 = \sum_i w_i \varepsilon_i$. Si les ε_i sont non corrélés (H4) et de même variance (H3) :

$$V(\hat{\beta}_1) = \sum_i w_i^2 \sigma_\varepsilon^2 = \frac{\sigma_\varepsilon^2}{S_{xx}}$$

Sans elles, la formule ne vaut plus

Sans H3, chaque ε_i a sa variance σ_i^2, et $V(\hat{\beta}_1) = \sum_i w_i^2 \sigma_i^2$: le $\sigma_\varepsilon^2 / S_{xx}$ des chapitres 5 à 10 devient faux. Sans H4, des covariances s'ajoutent. **Ce sont les deux remèdes des chapitres 14 et 15.**

H5 — Pas de colinéarité parfaite

La condition d'existence

Aucune variable explicative ne doit être une combinaison linéaire exacte des autres.

Ce n'est pas une hypothèse statistique

C'est une condition **algébrique** : sans elle, $X'X$ n'est pas inversible et le calcul est impossible.
Le logiciel refuse alors d'estimer, ou supprime une variable de lui-même. Le cas dangereux n'est pas la colinéarité parfaite — visible immédiatement — mais la colinéarité **presque** parfaite, qui laisse le calcul aboutir. C'est le chapitre 13.

La sixième

La normalité des erreurs

Elle ne fait pas partie de Gauss-Markov

$$\varepsilon_i \sim \mathcal{N}(0\,;\sigma_\varepsilon^2)$$

Elle n'est pas nécessaire pour que les MCO soient BLUE. Elle sert uniquement à rendre les tests **exacts** à petit échantillon.

Quand elle importe, et quand elle n'importe pas

Sur cinq cents observations, elle est inutile : le théorème central limite rend $\hat{\beta}_j$ approximativement normal quelle que soit la loi des erreurs.
Sur cinq ménages, elle est décisive : c'est elle qui justifie le seuil de Student 3,182 du chapitre 5. Il faut alors regarder les résidus avant de publier le moindre t.

Ce que le théorème garantit exactement

Trois mots, trois portées

Mot	Ce qu'il signifie
Unbiased	$E(\hat{\beta}_j) = \beta_j$ — exige H2
Linear	on se restreint aux estimateurs combinaisons linéaires des y_i
Best	variance minimale **dans cette classe** — exige H3 et H4

La restriction cachée est dans « Linear »

Les MCO sont le meilleur estimateur **parmi les linéaires sans biais**, pas le meilleur possible. Un estimateur non linéaire peut faire mieux — le maximum de vraisemblance du chapitre 7 de l'inférence, dès qu'on connaît la loi des erreurs.

Le théorème, mis à l'épreuve

Deux concurrents des moindres carrés

Deux pentes linéaires et sans biais

Sur les cinq ménages, on peut aussi estimer la pente par les seuls ménages extrêmes, ou par B et D :

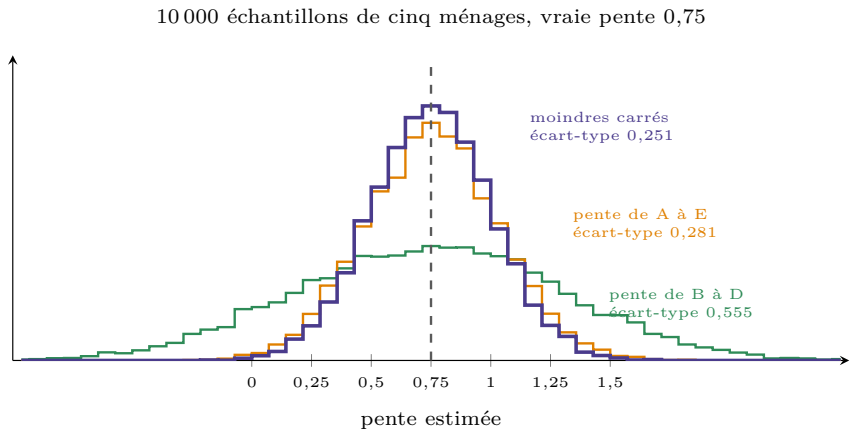
$$\tilde{\beta}_{AE} = \frac{C_E - C_A}{10 - 2} \qquad \tilde{\beta}_{BD} = \frac{C_D - C_B}{8 - 4}$$

Toutes deux sont linéaires en C, et sans biais : $E(\tilde{\beta}_{AE}) = \beta_1 \times 8/8 = \beta_1$.

Leurs variances, à la main

$V(\tilde{\beta}_{AE}) = 2\sigma^2/64 = \sigma^2/32$; $V(\tilde{\beta}_{BD}) = 2\sigma^2/16 = \sigma^2/8$; moindres carrés : $\sigma^2/40$.
Avec $\sigma^2 = 2{,}5$, écarts-types 0,280 ; 0,559 ; 0,250. **Les moindres carrés gagnent**, comme le théorème l'annonce.

Dix mille échantillons de cinq ménages



Ce que montre la simulation

Les trois histogrammes sont centrés sur 0,75 : les trois estimateurs sont **sans biais**. Mais celui des moindres carrés est le plus resserré : 0,251, contre 0,281 et 0,555. C'est exactement « Best » parmi les « Linear Unbiased ».

Sur machine

Gauss-Markov par simulation avec R

```r
set.seed(20261022)
R <- c(2, 4, 6, 8, 10)
simule <- function() {                  # un échantillon
  C <- 1.5 + 0.75 * R + rnorm(5, 0, sqrt(2.5))
  c(mco = unname(coef(lm(C ~ R))[2]),
    AE = (C[5] - C[1]) / 8, BD = (C[4] - C[2]) / 4)
}
b <- replicate(10000, simule())
round(rowMeans(b), 3)                   # sans biais tous les trois
#   mco    AE    BD
# 0.752 0.750 0.758
round(apply(b, 1, sd), 3)               # mais pas aussi précis
#   mco    AE    BD
# 0.253 0.282 0.559
```

Gauss-Markov par simulation avec Python

```python
import numpy as np
rng = np.random.default_rng(20261022)
R = np.array([2, 4, 6, 8, 10])
C = 1.5 + 0.75 * R + rng.normal(0, np.sqrt(2.5), (10000, 5))
d = R - R.mean()
```

```
mco = C @ d / (d @ d)                    # 10 000 pentes MCO
ae = (C[:, 4] - C[:, 0]) / 8
print(mco.mean().round(3), ae.mean().round(3))
# 0.752 0.755
print(mco.std().round(3), ae.std().round(3))
# 0.251 0.281
print((mco.var() / ae.var()).round(3)) # théorie : 0,8
# 0.8
```

Ce que disent les deux simulations

Le rapport des variances

$V(\text{MCO})/V(\tilde{\beta}_{AE})$ vaut en théorie $(1/40)/(1/32) = 0{,}8$: la simulation le retrouve. Les moindres carrés ont besoin de 20 % d'observations en moins pour la même précision.

Une simulation ne prouve pas, elle montre

Le théorème se démontre en quelques lignes ; la simulation le rend **visible**, sur un cas. Elle sert aussi là où la démonstration manque : c'est ainsi qu'on étudie les estimateurs dont on ne connaît pas la loi exacte.

S'entraîner

Exercice 1 : un troisième concurrent

La pente de B à D

On estime la pente des cinq ménages par $\tilde{\beta}_{BD} = (C_D - C_B)/4$.

1. Montrer que cet estimateur est sans biais sous H2.
2. Calculer sa variance sous H3 et H4, en fonction de σ^2.
3. Combien de fois plus grande est-elle que celle des moindres carrés ?
4. Sur les données observées, que vaut $\tilde{\beta}_{BD}$?

Exercice 1 : solution

Cinq fois moins précis

1. $C_D - C_B = \beta_1(8-4) + \varepsilon_D - \varepsilon_B$, d'espérance $4\beta_1$: divisé par 4, on obtient β_1.
2. $V = (\sigma^2 + \sigma^2)/16 = \sigma^2/8$.
3. $(\sigma^2/8)/(\sigma^2/40) = 5$ fois plus grande.
4. $(7-6)/4 = 0{,}25$: très loin de 0,75. Ce n'est pas un biais, c'est la **variance** — un tirage malheureux pour un estimateur imprécis.

Exercice 2 : quelle hypothèse tombe

Cinq situations

Pour chacune, dire quelle hypothèse est violée et ce qui est touché — les coefficients ou les écarts-types.

1. On inclut le salaire annuel et le salaire mensuel multiplié par douze.
2. La dispersion des salaires des Bac+5 est le double de celle des Bac.
3. Les ménages ont été interrogés par quartiers entiers.
4. Les capacités, omises, sont liées au diplôme.
5. On dispose de douze observations aux résidus très asymétriques.

Exercice 2 : solution

Une seule touche les coefficients

1. **H5** : colinéarité parfaite, le calcul est impossible.
2. **H3** : écarts-types faux, coefficients sans biais.
3. **H4** : écarts-types faux — trop petits —, coefficients sans biais.
4. **H2** : les **coefficients** sont biaisés. C'est la seule situation grave.
5. **H6** : à douze observations, les tests de Student ne sont plus exacts.

Exercice 3 : linéaire en les paramètres

Cinq modèles

Lesquels peuvent être estimés par les moindres carrés, éventuellement après transformation ?

1. $y = \beta_0 + \beta_1 x^2 + \varepsilon$
2. $y = \beta_0 + \beta_1^2\, x + \varepsilon$
3. $\ln y = \beta_0 + \beta_1 \ln x + \varepsilon$
4. $y = \beta_0\, x^{\beta_1}\, \mathrm{e}^{\varepsilon}$
5. $y = \beta_0 + x^{\beta_1} + \varepsilon$

Exercice 3 : solution

Quatre sur cinq

1. **Oui** : on régresse y sur la variable x^2.
2. **Oui** en pratique : on estime $\gamma = \beta_1^2$ par les MCO ; seul le signe de β_1 reste inconnu.
3. **Oui** : c'est le modèle log-log du chapitre 18.
4. **Oui** après logarithme : $\ln y = \ln \beta_0 + \beta_1 \ln x + \varepsilon$.
5. **Non** : β_1 est un exposant, aucune transformation ne le rend linéaire. Il faut des moindres carrés non linéaires.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. **Gauss-Markov** : sous H1 à H5, les MCO sont **BLUE**.
2. **H1 linéarité** — en les *paramètres* : les transformations de variables restent permises.
3. **H2 exogénéité** : la seule qui concerne le **biais**, car $\hat{\beta}_1 = \beta_1 + \sum w_i \varepsilon_i$.
4. **H3** et **H4** donnent $V(\hat{\beta}_1) = \sigma_\varepsilon^2 / S_{xx}$; sans elles, les écarts-types sont faux.
5. **H5** est une condition algébrique ; **H6** ne sert qu'aux petits échantillons.
6. Cinq ménages : MCO 0,25 contre 0,28 et 0,56 pour deux concurrents linéaires sans biais.

La suite

Six hypothèses, et aucune n'est vérifiée exactement sur des données réelles. La question n'est donc pas *si* elles tombent, mais **laquelle**, et **avec quelles conséquences**. Le chapitre 12 en dresse la carte.