

Introduction à l'économétrie

Chapitre 6 : La prévision

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'économétrie

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Une seule prévision ponctuelle, deux questions

Sur les 500 salariés du cours, la droite estimée est $\hat{y} = 4\,347,23 + 277,17x$, où x est l'ancienneté en années.

- (a) Calculer la prévision ponctuelle $\hat{y}$ pour $x_h = 20$ ans d'ancienneté.
- (b) Formuler, en une phrase chacune, les deux questions distinctes que ce même nombre pourrait prétendre répondre.
- (c) Laquelle des deux questions est, par nature, la plus incertaine? Pourquoi (rappeler ce que chacune ignore)?
- (d) Le nombre $\hat{y}$ calculé en (a) suffit-il, à lui seul, à répondre correctement à l'une ou l'autre de ces deux questions? Que faut-il lui adjoindre?

Exercice 2 — Les deux intervalles, chiffrés sur un exemple neuf

On dispose de $n = 10$ observations, $\bar{x} = 5$, $\sum_i (x_i - \bar{x})^2 = 50$, $\hat{\sigma}_\varepsilon = 200$, et de la droite $\hat{y} = 1\,000 + 50x$. Le seuil de Student à 8 degrés de liberté, au risque 5 %, vaut $t_{0,025;8} = 2,306$.

- (a) Calculer $\hat{y}_h$ pour $x_h = 5$ (qui coïncide avec $\bar{x}$), puis pour $x_h = 9$.
- (b) Pour $x_h = 5$, calculer l'intervalle de confiance de la **moyenne** et l'intervalle de **prévision individuelle**. Que remarque-t-on sur le terme $(x_h - \bar{x})^2$ dans ce cas particulier?
- (c) Pour $x_h = 9$, calculer les deux mêmes intervalles.
- (d) Comparer la largeur de l'intervalle de la moyenne en $x_h = 5$ et en $x_h = 9$. Le résultat est-il cohérent avec la mise en garde du cours sur l'évasement des bandes à mesure qu'on s'éloigne du centre?

Exercice 3 — Extrapoler, ou ne pas extrapoler

Une chaîne immobilière a estimé, sur les prix de vente observés entre 2010 et 2020 (une période de hausse ininterrompue), un modèle qui prédit le prix futur d'un bien à partir de son prix actuel et d'un taux de croissance annuel constant.

- (a) Rappeler les trois conditions, énoncées par le cours, que doit satisfaire une prévision pour être fiable.
- (b) La chaîne souhaite utiliser ce modèle pour prédire les prix en 2026, dans un contexte de resserrement du crédit immobilier inédit sur la période 2010-2020. Laquelle des trois conditions est la plus manifestement menacée?
- (c) Rappeler l'exemple donné par le cours sur les modèles de risque immobilier d'avant 2007. En quoi illustre-t-il concrètement cette même condition?
- (d) Le cours affirme que « rien ne garantit que la relation reste linéaire hors du domaine observé », et que « aucune formule ne prévient » contre ce risque. Qu'est-ce que cela signifie sur les **limites** des intervalles de confiance eux-mêmes : protègent-ils contre ce risque précis, ou seulement contre l'incertitude d'échantillonnage à l'intérieur d'une relation supposée stable et linéaire?

2 Exercice cumulatif (chapitre 6 et chapitres précédents)

Exercice 4 — Prévoir dans le domaine, et hors du domaine

On reprend les cinq ménages du chapitre 3 : $\hat{C} = 1,36 + 0,46R$, $\hat{\sigma}_\varepsilon = 0,0894$, $n = 5$, $\bar{R} = 4$, $\sum_i (R_i - \bar{R})^2 = 10$, $t_{0,025;3} = 3,182$. Les revenus observés dans l'échantillon vont de $R = 2$ à $R = 6$ (en milliers de DH).

- (a) Calculer la prévision ponctuelle $\hat{C}$ pour $R_h = 5$ (à l'intérieur du domaine observé), puis pour

$R_h = 10$ (bien au-delà du maximum observé, $R = 6$).

- (b) Pour $R_h = 5$, calculer l'intervalle de confiance de la moyenne et l'intervalle de prévision individuelle (on admet les facteurs $\sqrt{1/5 + (5 - 4)^2/10} \approx 0,5477$ et $\sqrt{1 + 1/5 + (5 - 4)^2/10} \approx 1,1402$).
- (c) Pour $R_h = 10$, calculer les deux mêmes intervalles (on admet les facteurs $\sqrt{1/5 + (10 - 4)^2/10} \approx 1,9494$ et $\sqrt{1 + 1/5 + (10 - 4)^2/10} \approx 2,1909$).
- (d) Comparer la largeur des intervalles obtenus en (b) et (c). Au-delà de cet évasement mécanique des bandes, quelle mise en garde **supplémentaire** et plus fondamentale le chapitre 6 formule-t-il à propos de $R_h = 10$, sachant que ce revenu est très largement en dehors des revenus observés dans l'échantillon (2 à 6) ?
- (e) Rappeler la conclusion du chapitre 3 (exercice 5) sur la fragilité des moindres carrés face à une observation aberrante. En quoi cette fragilité aggrave-t-elle, spécifiquement pour une prévision en $R_h = 10$, le risque déjà identifié à la question (d) ?

3 Applications en sciences économiques

Exercice 5 — Un intervalle qui interdit une décision

Le cours rapporte, pour 10 ans d'ancienneté : intervalle de la moyenne [6 943 ; 7 295] DH, intervalle individuel [3 179 ; 11 059] DH.

- (a) Une direction des ressources humaines veut fixer une grille salariale **collective** pour les postes à dix ans d'ancienneté. Lequel des deux intervalles est directement utilisable pour cet usage ?
- (b) Cette même direction veut annoncer à un candidat individuel, Karim, un salaire précis attendu compte tenu de son ancienneté. Lequel des deux intervalles décrit correctement l'incertitude réelle sur **son** salaire ?
- (c) Le cours qualifie l'annonce d'un intervalle de [3 179 ; 11 059] à Karim « pas une prévision, mais un aveu ». Expliquer ce que cette formule signifie : que reconnaît-on, en substance, en donnant un intervalle aussi large ?
- (d) Le fait que l'intervalle individuel ne puisse **jamais** descendre sous $\pm 1,96 \hat{\sigma}_\varepsilon$, quel que soit n , a-t-il une conséquence pratique sur les attentes qu'on peut raisonnablement placer dans un modèle à une seule variable explicative pour prédire un cas individuel ?

Exercice 6 — La critique de Lucas, sur un cas concret

Un gouvernement a estimé, sur dix années de données, l'effet d'une baisse du taux d'imposition sur la consommation des ménages, et prévoit d'utiliser ce modèle pour évaluer l'effet d'une **nouvelle** réforme fiscale plus ambitieuse que toutes celles observées dans l'échantillon.

- (a) Rappeler l'énoncé de la critique de Lucas en une phrase.
- (b) En quoi le fait que les ménages puissent **anticiper** et **ajuster leur comportement** face à une réforme fiscale d'ampleur inédite menace-t-il la validité du modèle pour cette prévision précise ?
- (c) Cette situation relève-t-elle de la première condition du cours (bonne spécification), de la deuxième (stabilité de la relation), ou de la troisième (domaine observé) ?
- (d) Le cours affirme : « le modèle ne peut donc pas servir à évaluer la politique qui le rendrait faux ». Reformuler cette phrase avec vos propres mots, appliquée à l'exemple de la réforme fiscale.

1 Exercices du chapitre

Correction — Exercice 1

- (a) $\hat{y} = 4\,347,23 + 277,17 \times 20 = 4\,347,23 + 5\,543,40 = \mathbf{9\,890,63}$ DH.
- (b) « Quel est le salaire **moyen** des salariés ayant vingt ans d'ancienneté? » et « Quel sera le salaire d'un **salarié précis**, qui a vingt ans d'ancienneté? »
- (c) La seconde question (l'individu précis) est la plus incertaine : prévoir une moyenne n'ignore que la position exacte de la vraie droite (l'incertitude d'échantillonnage sur β_0, β_1), tandis que prévoir un individu ignore **en plus** son écart personnel ε à la droite, totalement imprévisible.
- (d) Non, ce nombre seul ne suffit pas : il faut lui adjoindre un intervalle — l'intervalle de confiance de la moyenne pour la première question, l'intervalle de prévision individuelle (bien plus large) pour la seconde.

Correction — Exercice 2

- (a) $\hat{y}_h(5) = 1\,000 + 50 \times 5 = \mathbf{1\,250}$. $\hat{y}_h(9) = 1\,000 + 50 \times 9 = \mathbf{1\,450}$.
- (b) Facteur moyenne = $\sqrt{1/10 + 0/50} = \sqrt{0,1} \approx 0,3162$. Facteur individu = $\sqrt{1 + 1/10 + 0} = \sqrt{1,1} \approx 1,0488$. IC moyenne = $1\,250 \pm 2,306 \times 200 \times 0,3162 = 1\,250 \pm 145,84 \approx [\mathbf{1\,104,2} ; \mathbf{1\,395,8}]$. IC individuel = $1\,250 \pm 2,306 \times 200 \times 1,0488 = 1\,250 \pm 483,71 \approx [\mathbf{766,3} ; \mathbf{1\,733,7}]$. Puisque $x_h = \bar{x}$, le terme $(x_h - \bar{x})^2$ est nul : c'est la situation où l'intervalle est le plus étroit possible pour un n et un $\hat{\sigma}_\varepsilon$ donnés.
- (c) Facteur moyenne = $\sqrt{1/10 + 16/50} = \sqrt{0,1 + 0,32} = \sqrt{0,42} \approx 0,6481$. Facteur individu = $\sqrt{1,42} \approx 1,1916$. IC moyenne = $1\,450 \pm 2,306 \times 200 \times 0,6481 = 1\,450 \pm 298,89 \approx [\mathbf{1\,151,1} ; \mathbf{1\,748,9}]$. IC individuel = $1\,450 \pm 2,306 \times 200 \times 1,1916 = 1\,450 \pm 549,58 \approx [\mathbf{900,4} ; \mathbf{1\,999,6}]$.
- (d) La demi-largeur de l'IC de la moyenne passe de 145,84 (en $x_h = 5$) à 298,89 (en $x_h = 9$), soit plus du double. Oui, ce résultat est cohérent avec l'évasement des bandes annoncé par le cours : plus x_h s'éloigne de $\bar{x}$, plus $(x_h - \bar{x})^2$ grandit, et plus l'intervalle s'élargit.

Correction — Exercice 3

- (a) 1) Le modèle est bien spécifié. 2) La relation reste stable entre estimation et prévision. 3) Le point à prévoir est dans le domaine des données observées.
- (b) La deuxième condition (stabilité de la relation) est la plus manifestement menacée : le resserrement du crédit immobilier de 2026 constitue un changement de régime, absent de la période d'estimation (2010-2020), qui risque de modifier le mécanisme économique lui-même (la relation entre les variables), pas seulement de sortir du domaine observé des variables.
- (c) Les modèles de risque immobilier d'avant 2007 avaient été estimés sur une période n'ayant jamais connu de baisse nationale des prix : leur domaine de validité (au sens de la stabilité du mécanisme sous-jacent) ne contenait tout simplement pas l'événement qui allait survenir. C'est un exemple direct de violation de la deuxième condition, aux conséquences réelles et coûteuses (crise financière de 2008).
- (d) Les intervalles de confiance protègent uniquement contre l'incertitude d'échantillonnage, à l'intérieur d'une relation supposée rester stable et linéaire : ils élargissent mécaniquement la fourchette quand on s'éloigne du centre des données observées (le terme $(x_h - \bar{x})^2$), mais ils ne peuvent absolument rien contre un changement **structurel** du mécanisme économique lui-même, un risque qu'aucune formule statistique ne peut anticiper ni quantifier a priori.

2 Exercice cumulatif

Correction — Exercice 4

- (a) $\widehat{C}(5) = 1,36 + 0,46 \times 5 = 1,36 + 2,30 = \mathbf{3,66}$. $\widehat{C}(10) = 1,36 + 0,46 \times 10 = 1,36 + 4,60 = \mathbf{5,96}$.
- (b) IC moyenne ($R_h = 5$) : $3,66 \pm 3,182 \times 0,0894 \times 0,5477 = 3,66 \pm 0,1557 \approx [3,504 ; 3,816]$. IC individuel ($R_h = 5$) : $3,66 \pm 3,182 \times 0,0894 \times 1,1402 = 3,66 \pm 0,3243 \approx [3,336 ; 3,984]$.
- (c) IC moyenne ($R_h = 10$) : $5,96 \pm 3,182 \times 0,0894 \times 1,9494 = 5,96 \pm 0,5546 \approx [5,405 ; 6,515]$. IC individuel ($R_h = 10$) : $5,96 \pm 3,182 \times 0,0894 \times 2,1909 = 5,96 \pm 0,6235 \approx [5,336 ; 6,584]$.
- (d) Les intervalles en $R_h = 10$ sont environ 3,5 à 4 fois plus larges qu'en $R_h = 5$, conséquence mécanique de l'éloignement par rapport à $\bar{R} = 4$. Mais la mise en garde **supplémentaire** du chapitre 6 est plus fondamentale : $R_h = 10$ est situé bien au-delà du revenu maximal observé dans l'échantillon ($R = 6$) — c'est une pure **extrapolation**, hors du domaine des données. Rien ne garantit que la relation linéaire estimée entre 2 et 6 reste valable jusqu'à 10 ; ce risque n'est **pas** capturé par l'élargissement mécanique de l'intervalle calculé en (c), qui suppose toujours implicitement que la droite reste la bonne description de la relation.
- (e) Le chapitre 3 avait montré qu'une seule observation aberrante (sur cinq) pouvait faire plus que tripler la pente estimée et inverser le signe de l'intercept. Cette fragilité aggrave spécifiquement le risque en $R_h = 10$: une droite déjà instable, sensible au moindre point extrême **à l'intérieur** du domaine observé, offre d'autant moins de garantie une fois extrapolée loin **en dehors** de ce domaine — l'erreur potentielle de spécification (une pente mal estimée à cause d'un point influent) se combine alors à l'erreur d'extrapolation (une relation supposée linéaire hors de son domaine de validité), sans qu'aucun des deux intervalles calculés ne puisse en rendre compte.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) L'intervalle de la **moyenne** [6 943 ; 7 295] est directement utilisable pour une grille salariale collective : il décrit la fourchette plausible du salaire **moyen** de l'ensemble des salariés à dix ans d'ancienneté.
- (b) L'intervalle **individuel** [3 179 ; 11 059] décrit correctement l'incertitude réelle sur le salaire de Karim pris individuellement, puisqu'il intègre en plus l'aléa personnel ε propre à chaque individu.
- (c) Cette formule signifie qu'annoncer un intervalle aussi large revient, en pratique, à reconnaître que le modèle (une seule variable explicative, l'ancienneté) est **trop pauvre** pour prédire précisément le salaire d'un individu donné : la variabilité individuelle, non expliquée par la seule ancienneté, est si grande que la « prévision » ne restreint presque pas l'éventail des possibles — ce n'est plus une information utile, c'est un constat d'impuissance du modèle face au cas particulier.
- (d) Oui : puisque le terme « 1 » sous la racine (la variance de l'erreur individuelle) ne dépend pas de n , augmenter la taille de l'échantillon, aussi grande soit-elle, ne permettra **jamais** de rendre l'intervalle individuel arbitrairement étroit. Cela signifie qu'un modèle à une seule variable explicative a une limite structurelle et irréductible pour la prévision individuelle : seul l'ajout de variables explicatives supplémentaires, pertinentes et propres à l'individu (poste, diplôme, secteur, etc. — objet de la partie suivante du cours), peut réduire cet aléa individuel résiduel.

Correction — Exercice 6

- (a) Un modèle estimé sous un régime de politique économique donné cesse d'être valable si l'on change ce régime, précisément parce que les agents économiques adaptent leur comportement à la nouvelle politique.
- (b) Si les ménages anticipent et ajustent leur comportement de consommation et d'épargne face à une réforme fiscale d'ampleur inédite (par exemple en modifiant leurs habitudes d'épargne de précaution, ou leurs anticipations de revenu futur), la relation **elle-même** entre taux d'imposition et consommation, telle qu'estimée sur les réformes passées plus modestes, n'a aucune raison de rester

valable pour cette réforme d'ampleur inédite : ce n'est pas seulement une extrapolation sur les valeurs de x , c'est un changement du mécanisme économique sous-jacent.

(c) Cette situation relève de la **deuxième** condition (stabilité de la relation) : c'est le comportement des ménages face à la politique, et non les variables observées elles-mêmes, qui change avec l'ampleur inédite de la réforme.

(d) Le modèle a été estimé sur des données où les ménages n'avaient jamais connu de réforme de cette ampleur ; une fois la réforme mise en œuvre, le comportement des ménages qui a produit ces données historiques n'a plus de raison de se reproduire à l'identique — utiliser ce même modèle pour évaluer les effets de la réforme reviendrait donc à supposer stable exactement la relation que la réforme elle-même est susceptible de bouleverser, un raisonnement circulaire que la critique de Lucas met précisément en garde contre.