Introduction à l'économétrie

Chapitre 6 : La prévision

Jaouad Madkour

29 octobre 2026

Plan du chapitre

Deux questions, pas une **2**
La prévision ponctuelle . . . 2
Mais qu'a-t-on prévu au juste . . . 2

Les deux intervalles **2**
La figure décide . . . 2
Les deux formules . . . 3
D'où viennent les deux racines . . . 3
Sur nos données . . . 4

À la main, sur les cinq ménages **5**
Deux revenus, quatre intervalles . . . 5
Les deux bandes . . . 5

Les pièges de la prévision **5**
L'extrapolation . . . 5
Un exemple qui a coûté cher . . . 6
Ce que la prévision suppose . . . 6

Sur machine **6**
Prévoir avec R . . . 6
Prévoir avec Python . . . 7
Ce que disent les deux sorties . . . 7

S'entraîner **7**
Exercice 1 : deux intervalles à la main . . . 7
Exercice 1 : solution . . . 8
Exercice 2 : choisir le bon intervalle . . . 8
Exercice 2 : solution . . . 8
Exercice 3 : quand n devient très grand . . . 8
Exercice 3 : solution . . . 8

Ce qu'il faut retenir **9**
Le résumé du chapitre . . . 9

Deux questions, pas une

La prévision ponctuelle

Elle est immédiate

$$\hat{y}_h = \hat{\beta}_0 + \hat{\beta}_1 x_h$$

On remplace x par la valeur voulue dans la droite estimée.

Sur nos salaires

Pour dix ans d'ancienneté :

$$\hat{y} = 4\,347{,}23 + 277{,}17 \times 10 = 7\,118{,}93 \text{ dirhams}$$

Mais qu'a-t-on prévu au juste

Deux questions se cachent derrière ce nombre

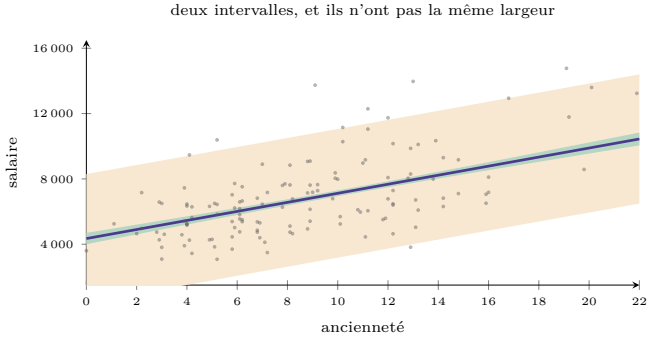
« Quel est le salaire moyen des salariés ayant dix ans d'ancienneté ? »
« Quel sera le salaire de Karim, qui a dix ans d'ancienneté ? »
La réponse ponctuelle est la même : 7 119. La **précision** ne l'est pas du tout.

Pourquoi la seconde est plus incertaine

Prévoir une moyenne, c'est ignorer seulement où passe la vraie droite.
Prévoir un individu, c'est ignorer cela **et** son écart personnel à la droite — son ε, que rien ne permet d'anticiper.

Les deux intervalles

La figure décide



Deux questions différentes

La bande étroite encadre le *salaire moyen* des salariés ayant cette ancienneté. Elle se resserre quand n grandit.

La bande large encadre le salaire d'*un* salarié donné. Elle ne se resserre jamais en dessous de $\pm 1{,}96\,\widehat{\sigma}_\varepsilon$: l'individu garde son aléa propre.

$$\widehat{y}_h \pm t_{\alpha/2}\,\widehat{\sigma}\sqrt{\boxed{1} + \frac{1}{n} + \frac{(x_h - \overline{x})^2}{\sum (x_i - \overline{x})^2}}$$

Le 1 encadré n'apparaît que pour la prévision individuelle. C'est toute la différence.

Les deux bandes s'**évasent** en s'éloignant de $\overline{x}$: extrapoler coûte cher.

Les deux formules

Elles ne diffèrent que par un terme

Intervalle de confiance de la moyenne :

$$\hat{y}_h \pm t_{\alpha/2}\,\hat{\sigma}_\varepsilon\sqrt{\frac{1}{n}+\frac{(x_h-\overline{x})^2}{\sum_i (x_i-\overline{x})^2}}$$

Intervalle de prévision d'une observation :

$$\hat{y}_h \pm t_{\alpha/2}\,\hat{\sigma}_\varepsilon\sqrt{\boxed{1}+\frac{1}{n}+\frac{(x_h-\overline{x})^2}{\sum_i (x_i-\overline{x})^2}}$$

Le 1 encadré est toute la différence

Il représente la variance de l'erreur individuelle, et il ne dépend pas de n : **l'intervalle individuel ne descendra jamais sous** $\pm 1{,}96\,\hat{\sigma}_\varepsilon$**.** L'aléa personnel ne se dilue pas.

D'où viennent les deux racines

Deux variances

La droite estimée passe par $(\overline{x},\overline{y})$: $\hat{y}_h = \overline{y} + \hat{\beta}_1(x_h-\overline{x})$. Les deux termes sont non corrélés, d'où

$$V(\hat{y}_h) = \frac{\sigma_\varepsilon^2}{n} + (x_h-\overline{x})^2\,\frac{\sigma_\varepsilon^2}{S_{xx}}$$

Pour un individu, $y_h - \hat{y}_h = \varepsilon_h - (\hat{y}_h - Ey_h)$: on ajoute la variance de ε_h, soit σ_ε^2.

Démonstration : La variance de la valeur ajustée : $\sigma_\varepsilon^2(1/n + (x_h-\overline{x})^2/S_{xx})$

Mêmes hypothèses qu'au chapitre 5 : erreurs d'espérance nulle, de variance σ_ε^2, non corrélées entre elles, les x_i étant donnés. Avec $\overline{y} = \beta_0 + \beta_1\overline{x} + \overline{\varepsilon}$ et $\hat{\beta}_1 = \beta_1 + \sum_i w_i\varepsilon_i$ (poids $w_i = (x_i-\overline{x})/S_{xx}$, chapitre 5),

$$\hat{y}_h = \overline{y} + \hat{\beta}_1(x_h-\overline{x}) = \beta_0 + \beta_1 x_h + \sum_i c_i\,\varepsilon_i,$$

$$c_i = \frac{1}{n} + (x_h-\overline{x})\,w_i.$$

L'espérance est $\beta_0+\beta_1 x_h$: la valeur ajustée est sans biais pour la moyenne en x_h. Comme les erreurs sont non corrélées, $\sum_i w_i = 0$ et $\sum_i w_i^2 = 1/S_{xx}$,

$$\begin{aligned} V(\hat{y}_h) &= \sigma_\varepsilon^2 \sum_i c_i^2 \\ &= \sigma_\varepsilon^2\Big(\frac{1}{n} + \frac{2(x_h-\overline{x})}{n}\sum_i w_i + (x_h-\overline{x})^2\sum_i w_i^2\Big) \\ &= \sigma_\varepsilon^2\Big(\frac{1}{n} + \frac{(x_h-\overline{x})^2}{S_{xx}}\Big). \end{aligned}$$

Pour $x_h = 0$, on retrouve la variance de la constante (chapitre 5).

■

Démonstration : L'erreur de prévision d'une observation : variance $\sigma_\varepsilon^2(1 + 1/n + (x_h - \overline{x})^2/S_{xx})$

L'individu à prévoir n'est pas dans l'échantillon : $y_h = \beta_0 + \beta_1 x_h + \varepsilon_h$, avec une erreur ε_h de variance σ_ε^2, non corrélée à $\varepsilon_1, \dots, \varepsilon_n$. D'après la démonstration précédente,

$$y_h - \hat{y}_h = \varepsilon_h - \sum_i c_i\, \varepsilon_i,$$

d'espérance nulle. Les $n+1$ erreurs étant non corrélées,

$$V(y_h - \hat{y}_h) = \sigma_\varepsilon^2\Big(1 + \sum_i c_i^2\Big) = \sigma_\varepsilon^2\Big(1 + \frac{1}{n} + \frac{(x_h - \overline{x})^2}{S_{xx}}\Big).$$

Le « 1 » est la variance de ε_h : il ne dépend pas de n, et c'est lui qui borne l'intervalle individuel par $\pm t\,\hat{\sigma}_\varepsilon$.

Loi de l'erreur normalisée. Si les erreurs sont normales, $y_h - \hat{y}_h$ est normale. Elle est aussi indépendante de SCR : ε_h l'est par construction ; $\hat{\beta}_1$ l'est d'après la démonstration du chapitre 5 sur la loi de Student ; et $\overline{y}$ aussi, car $e_i = (\varepsilon_i - \overline{\varepsilon}) - (\hat{\beta}_1 - \beta_1)(x_i - \overline{x})$ donne $\operatorname{cov}(\overline{y}, e_i) = (\frac{\sigma_\varepsilon^2}{n} - \frac{\sigma_\varepsilon^2}{n}) - (x_i - \overline{x}) \cdot 0 = 0$. En remplaçant σ_ε par $\hat{\sigma}_\varepsilon$, le rapport suit donc une loi de Student à $n-2$ degrés de liberté, d'où l'intervalle du chapitre.

■

Trois sources d'incertitude, trois termes

$1/n$: on ignore la **hauteur** exacte de la droite. $(x_h - \overline{x})^2/S_{xx}$: on ignore sa **pente**, et l'erreur grandit en s'éloignant du centre. 1 : on ignore l'**écart personnel**.

Sur nos données

Les deux, chiffrés

$\hat{\sigma}_\varepsilon = 2\,008$, $n = 500$, $x_h = 10 \approx \overline{x}$.
Moyenne : $7\,119 \pm 1{,}96 \times 2\,008 \times 0{,}045 = [\,6\,943\ ;\ 7\,295\,]$
Individu : $7\,119 \pm 1{,}96 \times 2\,008 \times 1{,}001 = [\,3\,179\ ;\ 11\,059\,]$

Un écart qui décide de l'usage

Le premier intervalle est étroit : on peut fonder une grille salariale dessus.
Le second est immense : il ne permet **aucune décision individuelle**. Annoncer à Karim que son salaire sera entre trois mille et onze mille dirhams n'est pas une prévision, c'est un aveu.

À la main, sur les cinq ménages

Deux revenus, quatre intervalles

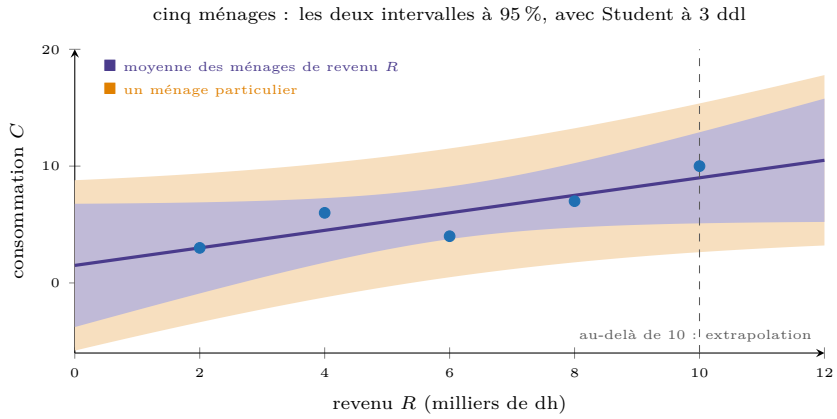
Variance résiduelle 2,5, n = 5, t de Student 3,182

R_h	$\widehat{C}_h$	moyenne	un ménage
6	6	$6 \pm 2{,}25$	$6 \pm 5{,}51$
10	9	$9 \pm 3{,}90$	$9 \pm 6{,}36$

Le détail du calcul

En $R = 6$, le facteur vaut $\frac{1}{5} + 0 = 0{,}2$: $3{,}182\sqrt{2{,}5 \times 0{,}2} = 2{,}25$. En $R = 10$, $\frac{1}{5} + \frac{(10-6)^2}{40} = 0{,}6$: $3{,}182\sqrt{2{,}5 \times 0{,}6} = 3{,}182 \times 1{,}225 = 3{,}90$.
Pour un ménage : $3{,}182 \times \sqrt{2{,}5 \times 1{,}6} = 3{,}182 \times 2 = 6{,}36$.

Les deux bandes



Ce que cinq ménages permettent de prévoir

Presque rien : un ménage de 10 milliers consommerait entre 2,6 et 15,4 milliers. L'étroitesse viendra du nombre — et, pour l'intervalle individuel, d'un $\hat{\sigma}_\varepsilon$ plus petit, que seule une meilleure spécification peut donner.

Les pièges de la prévision

L'extrapolation

Les bandes s'évasent

Le terme $(x_h - \overline{x})^2$ grandit dès qu'on s'écarte du centre : plus on extrapole, moins on est précis. C'est visible sur les deux figures.
Et ce n'est que la moitié du problème. **Rien ne garantit que la relation reste linéaire hors du domaine observé** — et là, aucune formule ne prévient.

De combien les bandes s'élargissent

Salaires, moyenne des salariés à 10 ans : ± 176 dirhams ; à 35 ans, l'ancienneté maximale du fichier : ± 756, plus de quatre fois plus.
Cinq ménages, à $R = 12$, hors des données : $\pm 5{,}28$ pour la moyenne, contre $\pm 2{,}25$ au centre.

Un exemple qui a coûté cher

Le domaine de validité

Extrapoler une hausse des prix de l'immobilier observée sur dix ans revient à supposer que le mécanisme qui l'a produite continue de jouer.
Les modèles de risque immobilier d'avant 2007 n'avaient jamais observé de baisse nationale des prix. Leur domaine de validité ne contenait pas l'événement qui allait survenir.

Une règle simple

Avant toute prévision, vérifier que x_h est **dans l'étendue** des données : entre 0 et 35 ans pour l'ancienneté, entre 402 et 12 069 dirhams pour le revenu des ménages. Au-delà, la prévision n'est plus une conclusion des données, c'est un pari.

Ce que la prévision suppose

Trois conditions, souvent tues

1. Le modèle est **bien spécifié** — les bonnes variables, la bonne forme.
2. La relation **reste stable** entre la période d'estimation et celle de prévision.
3. Le point à prévoir est **dans le domaine** des données observées.

La deuxième est la plus fragile

En économie, les comportements changent : une réforme fiscale, une crise, un changement de génération modifient la relation elle-même.
C'est la **critique de Lucas** : un modèle estimé sous un régime de politique économique cesse d'être valable si l'on change ce régime — précisément parce que les agents s'adaptent.
Le modèle ne peut donc pas servir à évaluer la politique qui le rendrait faux.

Sur machine

Prévoir avec R

```r
R <- c(2, 4, 6, 8, 10)
C <- c(3, 6, 4, 7, 10)
m <- lm(C ~ R)
nouv <- data.frame(R = c(6, 10))
predict(m, nouv, interval = "confidence")   # la moyenne
#   fit      lwr      upr
# 1   6 3.749671  8.250329
# 2   9 5.102315 12.897685
predict(m, nouv, interval = "prediction")   # un ménage
```

```
#   fit       lwr      upr
# 1   6 0.4878413 11.51216
# 2   9 2.6351074 15.36489
```

Prévoir avec Python

```python
import pandas as pd
import statsmodels.formula.api as smf
sal = pd.read_csv("salaires.csv")
m1 = smf.ols("salaire ~ ancienete", data=sal).fit()
p = m1.get_prediction(pd.DataFrame({"ancienete": [10, 35]}))
t = p.summary_frame(alpha=0.05).round(1)
print(t[["mean", "mean_ci_lower", "mean_ci_upper"]])
#       mean  mean_ci_lower  mean_ci_upper
# 0   7118.9         6942.4         7295.4
# 1  14048.1        13291.8        14804.4
print(t[["obs_ci_lower", "obs_ci_upper"]])
#    obs_ci_lower  obs_ci_upper
# 0        3169.1       11068.7
# 1       10030.4       18065.8
```

Ce que disent les deux sorties

Deux mots changent tout

En R, `interval = "confidence"` donne l'intervalle de la moyenne, `"prediction"` celui d'un ménage : on retrouve $6 \pm 2{,}25$ et $6 \pm 5{,}51$.
En Python, `mean_ci` est l'intervalle de la moyenne, `obs_ci` celui d'un individu.

Quelques dirhams d'écart avec le calcul à la main

Pour les salaires à 10 ans, la machine donne $[3\,169\,;11\,069]$ et non $[3\,179\,;11\,059]$: elle prend le quantile de Student, 1,965, là où nous avons pris 1,96. **À 35 ans**, au bord du fichier, l'intervalle de la moyenne atteint ± 756 dirhams.

S'entraîner

Exercice 1 : deux intervalles à la main

Les quatre magasins, au centre et au bord

Avec $\hat{y} = 0{,}5 + 1{,}5\,x$, $n = 4$, $\overline{x} = 3$, $S_{xx} = 10$, $\hat{\sigma}^2_\varepsilon = 1{,}75$ et $t_2 = 4{,}303$:

1. Calculer les deux intervalles pour $x_h = 3$.
2. Puis pour $x_h = 6$, hors des données.
3. De combien l'intervalle de la moyenne s'est-il élargi ?

Exercice 1 : solution

Plus de deux fois plus large au bord

1. $\hat{y} = 5$. Moyenne : $4{,}303\sqrt{1{,}75 \times 0{,}25} = 2{,}85$, soit $[2{,}15\,;7{,}85]$. Magasin : $4{,}303\sqrt{1{,}75 \times 1{,}25} = 6{,}36$, soit $[-1{,}36\,;11{,}36]$.
2. $\hat{y} = 9{,}5$. Le facteur vaut $0{,}25 + 9/10 = 1{,}15$. Moyenne : $4{,}303\sqrt{1{,}75 \times 1{,}15} = 6{,}10$. Magasin : $4{,}303\sqrt{1{,}75 \times 2{,}15} = 8{,}35$.
3. De 2,85 à 6,10 : un facteur 2,1. Et l'on extrapole, ce qu'aucune formule ne couvre.

Exercice 2 : choisir le bon intervalle

Trois décideurs

Pour chacun, dire quel intervalle utiliser.

1. Un ministère prévoit la consommation **totale** des ménages d'un quartier, connaissant leur revenu.
2. Une banque évalue la capacité de remboursement d'**un** ménage qui demande un crédit.
3. Une entreprise fixe le salaire d'embauche moyen de ses **futurs** ingénieurs débutants.

Exercice 2 : solution

Une moyenne ou un individu

1. **Moyenne** : sur un grand nombre de ménages, les écarts individuels se compensent.
2. **Individu** : la banque prête à ce ménage-là, avec son écart personnel. C'est pourquoi elle exige des garanties.
3. **Moyenne**, pour la grille ; mais chaque candidat négociera autour d'elle, dans la marge de l'intervalle individuel.

Exercice 3 : quand n devient très grand

La limite des deux intervalles

Sur les salaires, $\hat{\sigma}_\varepsilon = 2\,008$.

1. Que devient la demi-largeur de l'intervalle de la moyenne, en $x_h = \overline{x}$, si n passe de 500 à 50 000 ?
2. Et celle de l'intervalle individuel ?
3. Quelle conclusion en tirer pour la prévision individuelle ?

Exercice 3 : solution

L'aléa personnel ne se dilue pas

1. Elle vaut $1{,}96 \times 2\,008/\sqrt{n}$: 176 dirhams pour $n = 500$, 17,6 pour 50 000. Elle tend vers 0.
2. Elle vaut $1{,}96 \times 2\,008\sqrt{1 + 1/n}$: 3 940 puis 3 936. Elle ne descend pas sous 3 936.
3. Plus de données n'améliorent pas la prévision individuelle : il faut **d'autres variables**, qui réduisent $\hat{\sigma}_\varepsilon$. Le chapitre 7 les ajoute.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. La prévision ponctuelle est immédiate : $\hat{y}_h = \hat{\beta}_0 + \hat{\beta}_1 x_h$.
2. Deux questions se cachent derrière : prévoir une **moyenne** ou prévoir un **individu**.
3. Les deux formules ne diffèrent que par un 1 sous la racine — la variance de l'erreur individuelle.
4. Ce 1 ne dépend pas de n : l'intervalle individuel ne se resserre jamais complètement.
5. Salaires : $[6\,943\,;7\,295]$ contre $[3\,179\,;11\,059]$; cinq ménages à $R = 6$: $6 \pm 2{,}25$ contre $6 \pm 5{,}51$.
6. **Ne jamais extrapoler** hors du domaine observé, et se méfier des changements de régime.

La suite

Une seule variable explicative ne suffit à rien décrire : le salaire dépend aussi du diplôme et de la région. La troisième partie généralise tout ce qui précède — et introduit l'apport propre de l'économétrie : le **ceteris paribus**.