

Introduction à l'économétrie

Chapitre 2 : Le modèle économétrique

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'économétrie

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	4

1 Exercices du chapitre

Exercice 1 — Quatre sources, deux statuts

On modélise le salaire S_i des employés d'une entreprise par $S_i = \beta_0 + \beta_1 D_i + \varepsilon_i$, où D_i est le nombre d'années de diplôme. Quatre situations peuvent contribuer à ε_i :

1. Le salaire déclaré par les employés dans l'enquête comporte de petites erreurs d'arrondi.
 2. La relation entre diplôme et salaire est en réalité légèrement courbe, mais on l'approxime par une droite.
 3. Un employé a reçu une prime exceptionnelle totalement imprévisible, liée à un heureux concours de circonstances.
 4. L'expérience professionnelle, absente du modèle, est corrélée au diplôme (les diplômés plus âgés ont aussi plus d'expérience) et influence elle-même le salaire.
- (a) Pour chacune des quatre situations, l'associer à l'une des quatre sources nommées dans le cours (erreur de mesure, forme fonctionnelle, imprévisibilité, variable omise).
- (b) Lesquelles de ces quatre sources sont « bénignes » (bruit qui dégrade la précision sans biaiser) ? Laquelle est « dangereuse » (biais) ?
- (c) Pour la situation 4 seule : pourquoi la corrélation entre la variable omise (expérience) et la variable incluse (diplôme) est-elle la condition précise qui transforme une simple omission en un problème de biais ? Que se passerait-il si l'expérience, tout en influençant le salaire, était **indépendante** du diplôme ?

Exercice 2 — L'exogénéité, mise à l'épreuve sur un exemple chiffré

On étudie $C_i = \beta_0 + \beta_1 R_i + \varepsilon_i$. Une enquête complémentaire révèle la taille moyenne du ménage selon la tranche de revenu :

Tranche	Revenu moyen	Taille moyenne du ménage
Basse	3 000	2,1 personnes
Haute	6 000	4,3 personnes

On admet, par ailleurs, qu'un ménage plus nombreux consomme davantage, à revenu égal (plus de bouches à nourrir).

- (a) La taille du ménage figure-t-elle explicitement dans le modèle $C_i = \beta_0 + \beta_1 R_i + \varepsilon_i$? Si non, dans quel terme se retrouve-t-elle nécessairement ?
- (b) La taille moyenne du ménage varie-t-elle systématiquement avec la tranche de revenu, d'après le tableau ?
- (c) L'hypothèse d'exogénéité $E(\varepsilon_i | R_i) = 0$ est-elle plausible ici ? Justifier en reliant votre réponse aux deux réponses précédentes.
- (d) Si cette hypothèse est violée, la pente estimée $\hat{\beta}_1$ risque-t-elle de **sous-estimer** ou de **surestimer** l'effet propre du revenu sur la consommation — sachant que la taille du ménage, ici, augmente avec le revenu **et** augmente elle-même la consommation ? (Il ne s'agit pas de calculer un biais exact, hors programme à ce stade, mais de raisonner sur le sens de la contamination.)

Exercice 3 — Erreur inconnue, résidu calculé

On dispose d'une droite **estimée** $\hat{C} = \hat{\beta}_0 + \hat{\beta}_1 R = 900 + 0,6R$ (obtenue au chapitre 1). Un ménage a un revenu $R = 4\,500$ DH et une consommation observée $C = 3\,800$ DH.

- (a) Calculer la consommation **prédite** $\hat{C}$ pour ce ménage.
- (b) Calculer le résidu $e = C - \hat{C}$ pour ce ménage.
- (c) Ce résidu de 200 DH est-il l'erreur **vraie** ε du modèle, ou une quantité différente ? Justifier à partir

des deux définitions du cours ($\varepsilon_i = y_i - (\beta_0 + \beta_1 x_i)$ contre $e_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)$).

- (d) Pourquoi, en pratique, seul le résidu (et non l'erreur) pourra-t-il servir, au chapitre 12, à « diagnostiquer » les propriétés du modèle ?

2 Exercice cumulatif (chapitre 2, chapitre 1 et introduction)

Exercice 4 — Résidus sur les quatre ménages de revenu identique

On reprend les quatre ménages du chapitre 1 (exercice 3), tous de revenu $R = 4\,000$ DH, avec $C = (3\,200, 3\,400, 3\,100, 3\,300)$, et la droite $\hat{C} = 900 + 0,6R$ obtenue à l'exercice cumulatif du chapitre 1.

- Calculer la consommation prédite $\hat{C}$ (identique pour les quatre, puisque leur revenu est identique).
- Calculer le résidu de chacun des quatre ménages.
- Calculer la somme des quatre résidus. Est-elle nulle ?
- Le chapitre 3 énoncera une propriété des moindres carrés ordinaires : la somme des résidus, **sur l'échantillon qui a servi à estimer la droite**, est toujours exactement nulle. La droite $\hat{C} = 900 + 0,6R$ a-t-elle été estimée sur ces quatre ménages, ou sur les deux tranches de revenu de l'introduction ? Cela explique-t-il pourquoi la somme calculée en (c) n'est **pas** nulle ici ?
- Au chapitre 1 (exercice 3), on avait conclu qu'il fallait ajouter un terme pour rendre compte des différences entre ménages de même revenu. Ce terme porte-t-il maintenant un nom précis ? Les résidus calculés en (b) en sont-ils une estimation directe, ou seulement une approximation qui dépend de la droite utilisée ?

3 Applications en sciences économiques

Exercice 5 — La productivité du travail, sans le capital

Un économiste régresse la production Y_i de 30 usines sur leur seul effectif de travailleurs L_i : $Y_i = \beta_0 + \beta_1 L_i + \varepsilon_i$, en omettant le stock de capital K_i (machines, équipements) de chaque usine.

- On observe que les usines qui emploient le plus de travailleurs sont aussi, en général, celles qui disposent du plus de machines (les grandes usines ont les deux en abondance). Cette observation est-elle compatible avec l'hypothèse d'exogénéité de L_i dans ce modèle tronqué ?
- Le capital K_i contribue-t-il, par lui-même, à la production Y_i , indépendamment du travail ? Si oui, dans quel terme du modèle tronqué cette contribution se retrouve-t-elle nécessairement ?
- Le coefficient estimé $\hat{\beta}_1$ sur le travail va-t-il, selon toute vraisemblance, **sur-estimer** ou **sous-estimer** le **véritable** effet propre du travail sur la production, sachant que le capital omis est positivement lié à la fois au travail et à la production ?
- Quelle est la seule façon rigoureuse de corriger ce problème, entre (i) changer la méthode d'estimation tout en gardant le même modèle tronqué, ou (ii) réintroduire K_i explicitement dans le modèle ? Relier votre réponse à l'ecobox du cours : « quand l'exogénéité tombe, aucune formule ne répare ».

Exercice 6 — Ce que la droite prédit vraiment

Le modèle $E(C | R) = 900 + 0,6R$ est utilisé par une association de consommateurs pour anticiper le budget des ménages.

- Calculer la consommation **moyenne** prédite pour un revenu $R = 5\,000$ DH.
- L'association reçoit ensuite les données d'un ménage précis, de revenu $R = 5\,000$ DH, dont la consommation réelle s'avère être 4 300 DH. Ce résultat individuel contredit-il le modèle ?

- (c) Le modèle affirme-t-il que **tous** les ménages de revenu 5 000 DH consomment 3 900 DH, ou quelque chose de plus modeste ? Reformuler précisément ce que le modèle prédit, en utilisant la notion d'espérance conditionnelle.
- (d) En quoi cette « modestie » du modèle (annoncer d'emblée qu'il ne prédit qu'une moyenne, et range l'écart individuel dans ε) le rend-elle, selon le cours, plus utile plutôt que moins utile ? Pourquoi un modèle qui prétendrait prédire exactement chaque ménage serait-il, au contraire, suspect ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) Situation 1 : **erreur de mesure**. Situation 2 : **forme fonctionnelle** (approximation linéaire d'une relation courbe). Situation 3 : **imprévisibilité humaine**. Situation 4 : **variable omise**.
- (b) Les situations 1, 2 et 3 sont bénignes : elles ajoutent du bruit, dégradent la précision, mais ne biaisent pas l'estimation. La situation 4 est dangereuse : elle biaise $\hat{\beta}_1$.
- (c) La variable omise ne devient un problème que si elle est **corrélée** à la variable incluse (D_i) : c'est cette corrélation qui fait que l'erreur ε_i (qui contient l'expérience omise) devient elle-même corrélée à D_i , violant ainsi $E(\varepsilon_i | D_i) = 0$. Si l'expérience professionnelle influençait le salaire mais était **indépendante** du diplôme (par exemple si diplôme et expérience se répartissaient au hasard dans la population), son omission ajouterait seulement du bruit à ε_i sans corrompre l'exogénéité : le coefficient $\hat{\beta}_1$ resterait alors sans biais, seulement moins précis.

Correction — Exercice 2

- (a) Non, la taille du ménage ne figure pas explicitement dans le modèle : elle se retrouve nécessairement dans le terme d'erreur ε_i , comme toute variable omise qui influence C_i .
- (b) Oui : la taille moyenne passe de 2,1 à 4,3 personnes entre la tranche basse et la tranche haute — elle varie systématiquement, et dans le même sens, que le revenu.
- (c) Non, elle n'est pas plausible ici : puisque la taille du ménage (contenue dans ε_i) varie systématiquement avec R_i , l'erreur n'est pas indépendante de la variable explicative en moyenne — $E(\varepsilon_i | R_i) \neq 0$ à toutes les valeurs de R_i , ce qui contredit directement l'hypothèse d'exogénéité.
- (d) $\hat{\beta}_1$ risque de **surestimer** l'effet propre du revenu : une partie de l'écart de consommation entre tranches, en réalité due à la taille plus grande des ménages aisés (qui consomment plus « à cause » du nombre de bouches à nourrir, pas uniquement à cause du revenu), sera à tort attribuée au revenu seul, puisque le modèle ne peut pas séparer les deux effets qui évoluent ensemble.

Correction — Exercice 3

- (a) $\hat{C} = 900 + 0,6 \times 4\,500 = 900 + 2\,700 = 3\,600$ DH.
- (b) $e = 3\,800 - 3\,600 = 200$ DH.
- (c) C'est le **résidu**, pas l'erreur vraie : le résidu se mesure par rapport à la droite **estimée** ($\hat{\beta}_0, \hat{\beta}_1$), une quantité calculable à partir des données observées, tandis que l'erreur vraie ε se mesure par rapport aux paramètres **vrais et inconnus** (β_0, β_1) de la population — une quantité que l'on ne peut, par construction, jamais observer.
- (d) Parce que ε n'est **jamais observable**, quelle que soit la qualité des données ou de l'estimation : c'est une caractéristique de la vraie relation dans la population, à jamais inconnue. Le résidu, lui, est directement **calculable** dès qu'on dispose d'une droite estimée — c'est donc la seule quantité disponible en pratique pour examiner, a posteriori, si le modèle se comporte comme attendu (absence de forme suspecte dans les résidus, homogénéité de leur dispersion, etc.), même si cet examen reste indirect puisque le résidu n'est jamais qu'une approximation de l'erreur vraie.

2 Exercice cumulatif

Correction — Exercice 4

- (a) $\hat{C} = 900 + 0,6 \times 4\,000 = 900 + 2\,400 = 3\,300$ DH (identique pour les quatre ménages).
- (b) Résidus : $3\,200 - 3\,300 = -100$; $3\,400 - 3\,300 = +100$; $3\,100 - 3\,300 = -200$; $3\,300 - 3\,300 = 0$.
- (c) Somme = $-100 + 100 - 200 + 0 = -200$. Elle n'est **pas** nulle.
- (d) La droite $\hat{C} = 900 + 0,6R$ a été estimée sur les **deux tranches de revenu** de l'introduction (un ajustement exact à deux points), et non sur ces quatre ménages précis. La propriété « somme des

résidus nulle » du chapitre 3 ne s'applique qu'à l'échantillon effectivement utilisé pour l'estimation — ici, appliquer la droite à un échantillon **différent** (les quatre ménages) n'a aucune raison de produire des résidus de somme nulle, ce qui explique exactement le résultat de la question (c).

(e) Oui, ce terme porte maintenant un nom : c'est le terme d'erreur ε_i (ou, une fois calculé sur des données et une droite estimées, le résidu e_i). Les résidus calculés en (b) n'en sont qu'une **approximation dépendante de la droite utilisée** : puisque cette droite n'a pas été estimée sur ces quatre ménages, ces résidus mélangent l'écart individuel « véritable » de chaque ménage avec l'imperfection de la droite elle-même sur ce sous-échantillon particulier — une estimation plus fidèle exigerait d'ajuster une droite directement sur ces données, ce que la méthode des moindres carrés (chapitre 3) permettra de faire correctement.

3 Applications en sciences économiques

Correction — Exercice 5

(a) Non : puisque le capital omis K_i (contenu dans ε_i) varie systématiquement avec le travail L_i (les grandes usines ont les deux en abondance), l'hypothèse d'exogénéité de L_i est violée — exactement le même mécanisme que dans l'exercice 2.

(b) Oui, le capital contribue à la production indépendamment du travail (c'est un facteur de production à part entière) ; cette contribution se retrouve nécessairement dans le terme d'erreur ε_i du modèle tronqué, puisque K_i n'y figure pas explicitement.

(c) $\hat{\beta}_1$ va **surestimer** l'effet propre du travail : une partie de la production supplémentaire des usines à fort effectif, en réalité due à leur capital également abondant, sera attribuée à tort au travail seul.

(d) Seule l'option (ii), réintroduire K_i explicitement dans le modèle, corrige le problème : changer la **méthode** d'estimation tout en gardant le modèle tronqué ne répare rien, puisque le problème n'est pas une question de précision ou d'efficacité de l'estimateur mais de **justesse** de la spécification elle-même. C'est exactement l'ecobox du cours : l'exogénéité concerne la justesse, pas la précision — quand elle tombe à cause d'une variable omise corrélée, aucune formule statistique ne la restaure ; il faut changer le **modèle** (ici, ajouter K_i).

Correction — Exercice 6

(a) $E(C \mid R = 5\,000) = 900 + 0,6 \times 5\,000 = 900 + 3\,000 = 3\,900$ DH.

(b) Non : le modèle prédit une **moyenne**, pas la consommation exacte de chaque ménage individuel. Un ménage particulier consommant 4 300 DH au lieu de 3 900 DH illustre simplement l'écart individuel ε_i (ici positif, 400 DH), parfaitement compatible avec un modèle qui ne prétend décrire que la tendance moyenne.

(c) Le modèle affirme quelque chose de plus modeste : que la consommation **moyenne**, calculée sur l'ensemble des ménages de revenu 5 000 DH, vaut 3 900 DH — pas que chaque ménage pris individuellement consomme exactement ce montant. Formellement, $E(C \mid R = 5\,000) = 3\,900$: c'est une espérance conditionnelle, une moyenne sur la sous-population des ménages à ce niveau de revenu, non une prédiction déterministe valable pour chaque cas particulier.

(d) Cette modestie rend le modèle **honnête et vérifiable** : en reconnaissant d'emblée qu'il existe une variabilité individuelle qu'il n'explique pas (et qu'il range explicitement dans ε), le modèle peut être confronté aux données sans être automatiquement réfuté par la première observation individuelle venue. Un modèle qui prétendrait prédire **exactement** chaque ménage serait au contraire suspect, car aucune relation économique réelle entre deux grandeurs socio-économiques n'est parfaitement déterministe : un tel modèle masquerait, plutôt qu'il ne révélerait, l'existence d'une hétérogénéité individuelle bien réelle.