

Introduction à l'économétrie

Chapitre 21 : Mise en œuvre sur R et Python

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'économétrie

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Lire un intervalle de confiance produit par `confint()`

La commande `confint(m2)` renvoie, pour l'ancienneté, l'intervalle [247,65 ; 293,19].

- (a) Calculer le centre de cet intervalle. Correspond-il approximativement au coefficient 270,27 rapporté ailleurs dans le chapitre ?
- (b) Calculer la demi-largeur de l'intervalle.
- (c) La valeur 250 appartient-elle à cet intervalle ? Que peut-on en conclure sur l'hypothèse $H_0 : \beta_{\text{anciennete}} = 250$ au seuil de 5 % ?
- (d) La valeur 300 appartient-elle à cet intervalle ? Que peut-on en conclure sur l'hypothèse $H_0 : \beta_{\text{anciennete}} = 300$?

Exercice 2 — La correspondance R / Python

Compléter le tableau de correspondance des commandes.

- (a) Quelle commande Python correspond à `lm(y ~ x, data=d)` en R ?
- (b) Quelle commande R correspond à `smf.ols(...).get_robustcov_results(cov_type="HC1")` en Python ?
- (c) En R, `relevel(d$diplome, ref="Bac")` fixe la modalité de référence d'une variable qualitative. Quelle est la commande équivalente en Python, utilisée dans la formule du modèle ?
- (d) Pourquoi le cours insiste-t-il pour que l'on « vérifie toujours » quelle modalité de référence a été retenue, plutôt que de faire confiance au choix par défaut du logiciel ?

Exercice 3 — Les coefficients n'ont pas bougé

La sortie `coeftest(m2, vcov = vcovHC(m2, type = "HC1"))` donne, pour l'ancienneté : estimation 270,27, écart-type 13,00, $t = 20,78$.

- (a) Vérifier que $t = 270,27 / 13,00$ redonne bien (à l'arrondi près) le $t = 20,78$ rapporté.
- (b) Le chapitre 14 rapportait, pour la même variable, $t_{\text{MCO}} = 23,06$ et $t_{\text{robuste}} = 20,78$. Ce dernier correspond-il à la valeur de cette sortie R ?
- (c) L'estimation du coefficient (270,27) est-elle différente de celle obtenue par `summary(m2)` sans correction ?
- (d) En quoi cette sortie R constitue-t-elle, selon le cours, « la vérification la plus convaincante » du principe du chapitre 14 (les écarts-types robustes ne changent jamais les coefficients) ?

2 Exercice cumulatif (chapitre 21 et chapitres précédents)

Exercice 4 — Trois lignes de code, trois chapitres

Le chapitre fournit trois sorties : `anova(m1, m2)` donnant $F = 164,0$; `coeftest(mk2, vcov = vcovCL(mk2, cluster = ~ quartier))` donnant, pour `milieuUrbain`, un écart-type de 101,9173 (contre 55,69 sans correction); et `100 * (np.exp(mincer.params) - 1)` appliqué au coefficient de `Bac+5` (0,4353).

- (a) À quel chapitre renvoie le résultat de `anova(m1, m2)`, et quelle question économique ce test permet-il de trancher ?
- (b) À quel chapitre renvoie la correction `vcovCL`, et pourquoi la variable `milieuUrbain` y est-elle particulièrement sensible (rappeler pourquoi une variable constante dans le quartier souffre plus du regroupement) ?
- (c) Calculer $100 \times (e^{0,4353} - 1)$ et vérifier que ce calcul correspond au « +54,5 % » annoncé. À quel

chapitre renvoie cette formule, plutôt que l'approximation $100 \times 0,4353$?

- (d) En observant que ces trois lignes de code résument à elles seules les chapitres 9, 15 et 18, que peut-on dire de la relation entre la difficulté conceptuelle d'une notion économétrique et la longueur du code nécessaire pour l'appliquer une fois comprise ?

3 Applications en sciences économiques

Exercice 5 — Ce que la sortie ne dit pas

Un stagiaire présente une régression du chiffre d'affaires d'un point de vente sur ses dépenses publicitaires mensuelles : $R^2 = 0,81$, $t = 15,2$ pour le coefficient des dépenses publicitaires, résidus visuellement homogènes.

- (a) Le stagiaire conclut que « la publicité cause manifestement une hausse du chiffre d'affaires, vu la qualité de la régression ». Un R^2 élevé et un t écrasant garantissent-ils l'absence d'endogénéité ?
- (b) Le budget publicitaire d'un point de vente est souvent fixé en fonction des ventes anticipées ou passées. Quelle source d'endogénéité, parmi les trois du chapitre 19, cela évoque-t-il ?
- (c) Le logiciel utilisé par le stagiaire a-t-il signalé ce problème dans sa sortie (résidus, R^2 , t) ?
- (d) Reformuler la conclusion du stagiaire de façon à ne pas dépasser ce que les données permettent d'établir.

Exercice 6 — La démarche des quatre étapes, en une commande

Le cours affirme, à propos de `linearHypothesis(mk, "revenu = 1")` : « la démarche des quatre étapes s'achève sur une commande ».

- (a) Quelles sont, selon le cours (chapitres 1 à 3 de l'économétrie), les quatre étapes qui mènent de la théorie économique à une estimation numérique ?
- (b) En quoi la commande `linearHypothesis` met-elle en œuvre, en une seule ligne, l'étape consistant à confronter un modèle théorique (ici, la loi psychologique fondamentale de Keynes, $0 < \beta_1 < 1$) à des données réelles ?
- (c) Le résultat de cette commande ($F = 426,9$, soit $t = -20,66$) a-t-il, à lui seul, permis de **choisir** la spécification du modèle, ou seulement de la **tester** une fois choisie ?
- (d) Pourquoi le cours conclut-il que « aucun de ces quatre cours n'a introduit d'outil que le précédent n'annonçait pas » — en quel sens ce chapitre final ne fait-il qu'exécuter, en code, des idées déjà entièrement établies à la main ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) $(247,65 + 293,19)/2 = 270,42$, très proche du coefficient 270,27 rapporté ailleurs (le petit écart provient des arrondis successifs entre les différentes sorties du logiciel).
- (b) $(293,19 - 247,65)/2 = 22,77$.
- (c) Oui, $250 \in [247,65; 293,19]$: on ne peut pas rejeter $H_0 : \beta_{\text{anciennete}} = 250$ au seuil de 5 %.
- (d) Oui également, 300 n'appartient **pas** à cet intervalle ($300 > 293,19$) : on **rejette** $H_0 : \beta_{\text{anciennete}} = 300$ au seuil de 5 % — une augmentation de salaire de 300 DH par année d'ancienneté est statistiquement incompatible avec les données.

Correction — Exercice 2

- (a) `smf.ols("y ~ x", data=d).fit()`.
- (b) `coefest(m, vcov = vcovHC(m, type="HC1"))`.
- (c) `C(diplome, Treatment('Bac'))`, utilisée directement dans la formule du modèle.
- (d) Parce que le choix par défaut (la première modalité par ordre alphabétique en R) peut être arbitraire et sans pertinence économique : sur d'autres données, la modalité choisie par défaut par le logiciel pourrait être une référence absurde (par exemple une catégorie très minoritaire ou dépourvue de sens comme point de comparaison), ce qui changerait entièrement l'interprétation des coefficients des indicatrices sans que rien dans la sortie ne le signale explicitement.

Correction — Exercice 3

- (a) $270,27/13,00 \approx 20,79$, conforme (à l'arrondi près) au $t = 20,78$ rapporté.
- (b) Oui, cette valeur ($t_{\text{robuste}} = 20,78$) correspond exactement à celle déjà rapportée et vérifiée au chapitre 14.
- (c) Non : l'estimation du coefficient (270,27) est **identique**, au centime près, à celle de `summary(m2)` sans correction — seule la colonne des écarts-types (et donc des t) change entre les deux sorties.
- (d) Parce qu'elle permet de comparer, ligne à ligne, deux sorties du *même* modèle estimé sur les *mêmes* données, avec et sans correction : voir que l'estimation ne bouge pas d'un centime pendant que l'écart-type change constitue une preuve empirique directe, et non plus seulement théorique, que la correction de White ne touche qu'à la précision, jamais à l'exactitude du coefficient.

2 Exercice cumulatif

Correction — Exercice 4

- (a) `anova(m1, m2)` renvoie au **chapitre 9** (les trois niveaux de test, en particulier le test de Fisher partiel) : il tranche la question de savoir si l'ajout du diplôme au modèle (en passant de `m1` à `m2`) améliore significativement l'ajustement, c'est-à-dire si le diplôme, pris comme groupe de variables, a un pouvoir explicatif conjoint significatif.
- (b) `vcovCL` renvoie au **chapitre 15** (les erreurs groupées). La variable `milieuUrbain` y est particulièrement sensible car elle est **constante à l'intérieur de chaque quartier** : comme établi à l'exercice 3 du chapitre 15, une variable qui ne varie jamais entre les ménages d'une même grappe ne bénéficie d'aucune information supplémentaire apportée par les observations additionnelles de ce quartier, ce qui maximise l'effet du regroupement sur son écart-type.
- (c) $100 \times (e^{0,4353} - 1) \approx 100 \times 0,5454 = 54,54\%$, conforme au « +54,5 % » annoncé. Cette formule renvoie au **chapitre 18** (les formes fonctionnelles), qui établit que 100β n'est qu'une approximation, insuffisante au-delà de $\beta \approx 0,2$.
- (d) On peut observer une relation **inverse** : les notions les plus subtiles à établir — pourquoi le Fisher partiel est la bonne façon de tester un groupe de variables, pourquoi le regroupement biaise

spécifiquement les variables constantes dans la grappe, pourquoi l'approximation 100β devient fausse — tiennent, une fois comprises, en une seule ligne de code. La difficulté d'un cours d'économétrie ne réside donc pas dans la longueur du code à écrire, mais dans la compréhension préalable de ce que chaque ligne accomplit et pourquoi elle est nécessaire.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) Non : ni un R^2 élevé, ni un t écrasant, ni des résidus visuellement homogènes ne garantissent l'absence d'endogénéité. Le cours est explicite : « la sortie reste parfaitement propre [...] et le coefficient peut être faux ».
- (b) Cela évoque une **causalité inverse** : si le budget publicitaire est fixé en fonction des ventes anticipées ou passées, la variable explicative (publicité) est en partie déterminée par la variable expliquée (chiffre d'affaires), ce qui viole l'hypothèse d'exogénéité.
- (c) Non : aucun des éléments usuels de la sortie du logiciel (R^2 , t , aspect des résidus) ne signale un problème de causalité inverse — c'est précisément la limite rappelée par le chapitre 19, reprise dans ce chapitre final : « aucun test ne le détecte ».
- (d) Une reformulation prudente serait : « les dépenses publicitaires sont associées à un chiffre d'affaires plus élevé, mais cette relation ne permet pas d'établir un lien de causalité, le budget publicitaire pouvant lui-même être déterminé par les ventes anticipées ou passées ».

Correction — Exercice 6

- (a) Les quatre étapes sont : la théorie économique (poser un modèle, comme la loi psychologique fondamentale de Keynes), le modèle de génération des données (la spécification probabiliste), l'échantillonnage (les données observées), et l'estimation/le test (confronter le modèle théorique aux données).
- (b) La commande `linearHypothesis` met en œuvre en une ligne la confrontation directe entre une prédiction théorique précise ($\beta_1 = 1$, ou plus largement $0 < \beta_1 < 1$) et l'estimation empirique obtenue sur les données réelles, produisant immédiatement la statistique de test qui permet de juger si la théorie est compatible avec les faits observés.
- (c) Seulement de la **tester** une fois choisie : la spécification du modèle ($C = \beta_0 + \beta_1 R + \varepsilon$) a été fixée en amont par la théorie économique de Keynes, et `linearHypothesis` sert uniquement à vérifier, après estimation, si les données sont compatibles avec la contrainte que cette théorie impose sur le coefficient — elle ne participe pas au choix des variables à inclure dans le modèle.
- (d) Parce que chaque commande de ce chapitre final (`lm`, `coeftest` avec `vcovHC`, `vcovCL`, `linearHypothesis`, la transformation en logarithme) exécute mécaniquement un principe entièrement établi à la main dans les chapitres précédents (l'estimation MCO, la correction de White, la correction de grappe, le test d'une contrainte linéaire, la conversion exacte en pourcentage) : le logiciel ne fait qu'accélérer l'application de notions déjà comprises, il n'introduit aucune idée nouvelle — ce qui confirme que la maîtrise du cours réside dans la compréhension conceptuelle, non dans la syntaxe du code.