

Introduction à l'économétrie

Chapitre 7 : Le modèle multiple et le ceteris paribus

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'économétrie

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	4

1 Exercices du chapitre

Exercice 1 — Interpréter un modèle à trois variables

Une entreprise estime : $\widehat{\text{Salaire}} = 3\,000 + 250 \text{ Anc} + 900 \text{ Dip} - 350 \text{ Sexe}$, où Anc est l'ancienneté (années), Dip le niveau de diplôme (années après le bac) et Sexe vaut 1 pour une femme, 0 pour un homme.

- (a) Interpréter le coefficient 250 de l'ancienneté, au sens *ceteris paribus*, en une phrase complète.
- (b) Interpréter le coefficient -350 du sexe, au sens *ceteris paribus*, en une phrase complète.
- (c) Calculer le salaire prédit pour un homme ayant 8 ans d'ancienneté et 5 ans de diplôme post-bac, puis pour une femme ayant exactement le même profil (ancienneté et diplôme identiques).
- (d) Calculer le salaire prédit pour un homme ayant 9 ans d'ancienneté (diplôme inchangé, 5 ans). L'écart avec la question (c) correspond-il exactement au coefficient de l'ancienneté? Pourquoi cela n'est-il vrai que parce que le diplôme et le sexe ont été maintenus **constants** dans la comparaison?

Exercice 2 — Effet brut contre effet net

Une étude sur le rendement de l'éducation trouve, en régression **simple**, qu'une année d'études supplémentaire est associée à $+15\%$ de revenu. En ajoutant un score de test cognitif mesuré à l'entrée à l'école (une proxy de capacité innée) comme second régresseur, l'effet estimé d'une année d'études supplémentaire tombe à $+9\%$.

- (a) Lequel des deux chiffres (15% ou 9%) est l'effet **brut**? Lequel est l'effet **net**?
- (b) Pourquoi l'effet net est-il plus faible ici? Que capturerait, dans le modèle simple, la partie de l'effet « perdue » entre 15% et 9% ?
- (c) Un décideur public veut évaluer : « si l'on finance une année d'études supplémentaire pour un individu donné (sans changer sa capacité innée), de combien son revenu futur augmentera-t-il? ». Lequel des deux chiffres répond le mieux à cette question?
- (d) Le modèle avec le score de test cognitif contrôle-t-il **tous** les facteurs de confusion possibles (motivation, réseau familial, qualité de l'école fréquentée, etc.)? Relier votre réponse à l'avertissement du cours : « le *ceteris paribus* est toujours partiel ».

Exercice 3 — Degrés de liberté et colinéarité parfaite

Une régression multiple est estimée sur $n = 50$ entreprises, avec $k = 3$ variables explicatives (chiffre d'affaires, effectif, âge de l'entreprise).

- (a) Calculer le nombre de degrés de liberté $n - k - 1$ de cette régression.
- (b) Un analyste ajoute une quatrième variable, « effectif en équivalents temps plein », qui se trouve être **exactement** le double de l'effectif déjà présent dans le modèle ($x_4 = 2x_2$). Que devient k dans ce cas, et pourquoi la régression, techniquement, ne peut-elle plus être estimée (indice : la matrice $X'X$)?
- (c) Expliquer, avec vos propres mots et sans recourir au calcul matriciel, pourquoi il est **logiquement impossible** de séparer l'effet propre de x_2 de celui de x_4 quand l'un est une transformation exacte de l'autre.
- (d) Si, au lieu d'être exactement proportionnelles, les deux variables étaient seulement **fortement corrélées** (sans relation exacte), la régression serait-elle encore impossible à calculer? Quel est, alors, le problème résiduel (annoncé pour un chapitre ultérieur)?

2 Exercice cumulatif (chapitre 7 et chapitres précédents)

Exercice 4 — Du modèle simple au modèle multiple, sur le même fil rouge

Le cours rapporte, sur les 500 salariés déjà utilisés aux chapitres 5 et 6 : effet brut de l'ancienneté (régression simple) $\hat{\beta}_1 = 277,17$ ($t = 18,41$, chapitre 5) ; effet net de l'ancienneté (régression multiple, à diplôme, sexe et région donnés) $\hat{\beta}_1 = 266,74$.

- Calculer l'écart entre les deux coefficients, en valeur absolue et en pourcentage de l'effet brut.
- Le chapitre 5 avait testé et rejeté $H_0 : \beta_1 = 0$ pour l'effet brut, avec $t = 18,41$. Le fait que l'effet net (266,74) soit proche de l'effet brut (277,17), plutôt que très éloigné, suggère-t-il que l'ancienneté était fortement, ou au contraire faiblement, corrélée au diplôme, au sexe et à la région dans cet échantillon (relier au raisonnement du chapitre 2 sur le sens et l'ampleur d'un biais de variable omise) ?
- Rappeler la prévision du chapitre 6 pour un salarié à 10 ans d'ancienneté : $\hat{y} = 7\,118,93$ DH, obtenue avec le modèle **simple**. Cette prévision est-elle celle d'un salarié « moyen » à dix ans d'ancienneté **quel que soit** son diplôme, son sexe et sa région, ou bien celle d'un salarié à diplôme, sexe et région **ceteris paribus** ?
- Pour prédire le salaire d'un salarié **précis** (par exemple, dix ans d'ancienneté, un diplôme donné, une région donnée), lequel des deux modèles (simple ou multiple) est le plus adapté ? Pourquoi le modèle multiple, malgré la proximité des deux coefficients constatée en (a), reste-t-il préférable pour cet usage ?

3 Applications en sciences économiques

Exercice 5 — Négocier une grille salariale sur l'effet net

Une entreprise doit fixer l'augmentation salariale annuelle liée à l'ancienneté, à qualification égale, pour l'ensemble de son personnel.

- Le service des ressources humaines dispose de deux chiffres : l'effet brut (277,17 DH/an) et l'effet net (266,74 DH/an, à diplôme, sexe et région donnés). Lequel des deux doit fonder la grille, si l'objectif est de rémunérer **spécifiquement** l'ancienneté, et non les autres caractéristiques qui lui sont associées dans l'échantillon ?
- Si l'entreprise utilisait par erreur l'effet **brut** pour fixer cette augmentation, quel risque courrait-elle (indice : une partie de 277,17 reflète des différences de diplôme, sexe ou région entre salariés d'ancienneté différente, pas l'ancienneté en tant que telle) ?
- Formuler, à partir de cet exemple, la règle générale que le cours énonce : quelle question (« combien gagne en moyenne » contre « combien rapporte à qualification égale ») appelle quel effet (brut ou net) ?

Exercice 6 — Deux variables trop proches pour être séparées

Un cabinet d'étude veut mesurer séparément l'effet des dépenses de recherche et développement (R&D) et du nombre de brevets déposés sur la rentabilité de 60 entreprises technologiques. Il constate que les deux variables sont corrélées à $r = 0,97$ dans son échantillon (les entreprises qui dépensent le plus en R&D déposent presque toujours proportionnellement le plus de brevets).

- Cette corrélation de 0,97 est-elle une colinéarité **parfaite** (au sens strict de l'exercice 3, où $x_4 = 2x_2$ exactement) ?
- La régression est-elle, techniquement, calculable dans ce cas (la matrice $X'X$ est-elle strictement non inversible) ?
- Même si la régression est techniquement calculable, quel type de problème pratique le cours laisse-t-il présager pour l'interprétation *ceteris paribus* des deux coefficients (celui de la R&D et celui des brevets), étant donné qu'il est presque impossible, dans cet échantillon, de faire varier l'un sans l'autre ?

- (d) Quelle recommandation, en attendant le traitement complet de ce problème dans un chapitre ultérieur, semble raisonnable pour ce cabinet : présenter les deux coefficients séparément comme des effets nets fiables, ou rester prudent sur leur interprétation individuelle tout en faisant confiance à leur effet **conjoint** sur la rentabilité?

1 Exercices du chapitre

Correction — Exercice 1

- (a) « À diplôme et sexe donnés (maintenus constants), une année d'ancienneté supplémentaire est associée à une augmentation de salaire de 250 DH. »
- (b) « À ancienneté et diplôme donnés (maintenus constants), le salaire d'une femme est, dans cet échantillon, inférieur de 350 DH à celui d'un homme. » (Cette association statistique ne dit rien, à elle seule, de ses causes.)
- (c) Homme, Anc = 8, Dip = 5 : $3\,000 + 250 \times 8 + 900 \times 5 - 350 \times 0 = 3\,000 + 2\,000 + 4\,500 = 9\,500$ DH.
Femme, même profil : $9\,500 - 350 = 9\,150$ DH.
- (d) Homme, Anc = 9, Dip = 5 : $3\,000 + 250 \times 9 + 900 \times 5 = 3\,000 + 2\,250 + 4\,500 = 9\,750$ DH. Écart avec (c) : $9\,750 - 9\,500 = 250$ DH, exactement le coefficient de l'ancienneté. Cette égalité n'est vraie que parce que le diplôme (5) et le sexe (0) sont restés strictement identiques entre les deux salariés comparés : c'est la définition même du *ceteris paribus* — isoler l'effet d'une seule variable en maintenant toutes les autres inchangées.

Correction — Exercice 2

- (a) 15 % est l'effet **brut** (régression simple, sans contrôle). 9 % est l'effet **net** (régression multiple, à capacité cognitive donnée).
- (b) L'effet net est plus faible parce qu'une partie de l'association observée en régression simple entre études et revenu reflétait, en réalité, la capacité cognitive elle-même : les individus plus doués tendent à la fois à faire plus d'études **et** à gagner davantage, indépendamment du nombre d'années d'études. Sans le contrôle, cet effet de la capacité était à tort entièrement attribué à l'éducation.
- (c) Le chiffre de 9 % (l'effet net) répond le mieux à cette question : il isole l'effet propre d'une année d'études supplémentaire, la capacité innée étant maintenue constante — exactement la situation d'un individu donné à qui l'on financerait une année d'études de plus, sans changer sa capacité.
- (d) Non : le modèle contrôle uniquement la capacité cognitive mesurée par ce test précis, mais ne contrôle ni la motivation, ni le réseau familial, ni la qualité de l'école fréquentée, ni d'innombrables autres facteurs non observés. Le *ceteris paribus* de ce modèle est donc réel mais **partiel** : 9 % demeure une meilleure approximation de l'effet causal que 15 %, sans pour autant être une mesure causale parfaitement pure.

Correction — Exercice 3

- (a) $n - k - 1 = 50 - 3 - 1 = 46$ degrés de liberté.
- (b) k passerait formellement à 4, mais la régression ne peut techniquement plus être estimée : la matrice $X'X$ devient **singulière** (non inversible), car les colonnes correspondant à x_2 et $x_4 = 2x_2$ sont linéairement dépendantes — une des conditions mathématiques du calcul de $\hat{\beta} = (X'X)^{-1}X'y$ n'est plus remplie.
- (c) Puisque x_4 est toujours exactement le double de x_2 , il est impossible d'observer, dans les données, une situation où x_2 varie sans que x_4 varie **proportionnellement** avec lui (et réciproquement) : il n'existe donc, dans l'échantillon, aucune variation « propre » à l'un des deux qui ne soit pas aussi une variation de l'autre. Séparer leurs effets reviendrait à demander « que se passe-t-il si x_2 change et que x_4 reste fixe », une situation qui ne s'est **jamais produite** dans les données et qui est même logiquement exclue par leur relation exacte.
- (d) Non, la régression resterait techniquement calculable (la matrice $X'X$ resterait, de justesse, inversible), mais le problème résiduel est la **multicolinéarité** (sans le qualificatif « parfaite ») : les coefficients individuels deviendraient très instables et leurs erreurs-types très gonflées, rendant les tests individuels peu fiables, même si les prédictions globales du modèle restent, elles, généralement correctes. C'est le sujet annoncé pour un chapitre ultérieur du cours.

2 Exercice cumulatif

Correction — Exercice 4

- (a) Écart = $277,17 - 266,74 = 10,43$ DH, soit $10,43/277,17 \approx 3,76\%$ de l'effet brut.
- (b) Cette proximité (un écart de seulement 3,76 %) suggère que l'ancienneté était, dans cet échantillon, **faiblement** corrélée au diplôme, au sexe et à la région (ou que ces variables ont un effet propre modeste sur le salaire une fois l'ancienneté prise en compte) : rappelant le raisonnement du chapitre 2, un biais de variable omise n'est important que si la variable omise est **fortement** corrélée à la variable d'intérêt **et** qu'elle a elle-même un effet substantiel sur y ; un écart aussi faible entre effet brut et effet net indique que ces conditions ne sont, ici, que faiblement réunies.
- (c) Cette prévision est celle d'un salarié « moyen » à dix ans d'ancienneté, **quel que soit** son diplôme, son sexe et sa région : le modèle simple ne contrôle aucune de ces variables, donc 277,17 (et la prévision qui en découle) moyenne implicitement sur toute la répartition de ces caractéristiques dans l'échantillon.
- (d) Le modèle multiple est le plus adapté pour prédire le salaire d'un salarié **précis** dont on connaît le diplôme, le sexe et la région : il permet d'incorporer ces informations individuelles dans la prévision plutôt que de se contenter d'une moyenne globale. Même si les deux coefficients sur l'ancienneté sont proches (277,17 contre 266,74), le modèle multiple reste préférable car les **autres** coefficients (diplôme, sexe, région) apportent une information supplémentaire directement exploitable pour ce salarié précis, que le modèle simple ignore entièrement.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) L'effet **net** (266,74 DH/an) doit fonder la grille, puisque l'objectif est de rémunérer spécifiquement l'ancienneté, à qualification égale — exactement la définition du *ceteris paribus*.
- (b) En utilisant l'effet brut, l'entreprise récompenserait, en plus de l'ancienneté elle-même, une partie des différences de diplôme, de sexe ou de région qui se trouvent statistiquement associées à l'ancienneté dans son échantillon — une confusion entre « rémunérer l'ancienneté » et « rémunérer tout ce qui va de pair avec elle », potentiellement source d'iniquités salariales non voulues et non justifiées par l'ancienneté en tant que telle.
- (c) La question « combien gagne en moyenne un salarié ayant une année d'ancienneté de plus » appelle l'effet **brut** (une description de l'écart moyen observé, toutes différences confondues) ; la question « combien rapporte une année d'ancienneté à qualification égale » appelle l'effet **net** (utile pour agir, décider, fixer une grille salariale).

Correction — Exercice 6

- (a) Non : $r = 0,97$ est une corrélation très forte mais **pas** parfaite ($r \neq 1$ ou -1 exactement, et la relation n'est pas une transformation linéaire exacte comme $x_4 = 2x_2$) — ce n'est donc pas une colinéarité parfaite au sens strict.
- (b) Oui, techniquement, la matrice $X'X$ reste inversible (de justesse), et la régression peut donc être calculée numériquement.
- (c) Le cours laisse présager un problème de **multicolinéarité** (forte, sans être parfaite) : les erreurs-types des deux coefficients risquent d'être fortement gonflées, rendant les coefficients individuels imprécis et instables (de petites variations dans les données pouvant fortement changer leurs valeurs estimées), même si le modèle explique globalement bien la rentabilité.
- (d) La seconde attitude est la plus raisonnable : rester prudent sur l'interprétation *individuelle* de chacun des deux coefficients (R&D et brevets séparément), tout en faisant confiance à leur effet **conjoint** (la combinaison des deux) sur la rentabilité — puisqu'il est presque impossible, dans cet échantillon, d'isoler la variation propre à l'une des deux variables sans l'autre, la décomposition précise de l'effet entre les deux reste fragile, en attendant les outils de diagnostic de multicolinéarité.

qu'un chapitre ultérieur du cours introduira.