Introduction à l'économétrie

Chapitre 7 : Le modèle multiple et le ceteris paribus

Jaouad Madkour

23 octobre 2026

Plan du chapitre

Plusieurs causes **2**
Pourquoi une seule variable ne suffit pas . . . 2

Le ceteris paribus **2**
Ce que devient un coefficient . . . 2
Effet brut et effet net . . . 2
Lire la colonne M4 . . . 3
Ce que le ceteris paribus n'accomplit pas . . . 3

À la main, sur les cinq ménages **3**
Ajouter la taille du ménage . . . 3
Les deux formules de la régression à deux variables . . . 4
Effet brut 0,75, effet net 0,5 . . . 4
Frisch-Waugh : ce que « à taille égale » veut dire . . . 5
Ce que le théorème enseigne . . . 5

L'estimation **5**
Le principe ne change pas . . . 5
Ce qui change vraiment . . . 6
La prévision promise en introduction . . . 6

Sur machine **6**
Effet brut et effet net avec R . . . 6
La prévision de M2 avec Python . . . 7

S'entraîner **7**
Exercice 1 : lire le modèle M4 . . . 7
Exercice 1 : solution . . . 7
Exercice 2 : effet brut, effet net . . . 7
Exercice 2 : solution . . . 8
Exercice 3 : la bonne phrase . . . 8
Exercice 3 : solution . . . 8

Ce qu'il faut retenir **8**

Le résumé du chapitre 8

Plusieurs causes

Pourquoi une seule variable ne suffit pas

Le monde n'a jamais une seule cause

Le salaire dépend de l'ancienneté — mais aussi du diplôme, de la région, du poste, de la performance.
Les laisser hors du modèle ne les fait pas disparaître : elles se réfugient dans le terme d'erreur, et le chapitre 2 a dit ce qu'il en coûte.

Le modèle de régression multiple

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \cdots + \beta_k x_{ki} + \varepsilon_i$$

k variables explicatives, $k+1$ paramètres à estimer.

Le ceteris paribus

Ce que devient un coefficient

L'interprétation, à retenir mot pour mot

β_j est la variation de y associée à une variation d'une unité de x_j, **toutes les autres variables du modèle étant maintenues constantes**.

C'est l'apport propre de l'économétrie

L'introduction rappelait que l'économiste ne peut pas expérimenter : il ne peut pas maintenir les choses constantes dans le monde réel.
La régression multiple le fait statistiquement. Elle ne supprime pas la variation des autres facteurs — elle la retire du calcul. C'est un laboratoire de papier, et c'est ce qui a fait la fortune de la méthode.

Effet brut et effet net

quatre modèles emboîtés, écarts-types entre parenthèses

	M1	M2	M3	M4
Ancienneté	277,17	270,27	270,57	266,74
	(15,06)	(11,72)	(11,73)	(11,38)
Bac+2	—	1 099,6	1 098,4	1 095,5
Bac+5	—	3 337,0	3 339,4	3 276,6
Homme	—	—	131,4	174,2
			(141,1)	(136,8)
Région	—	—	—	oui
R^2	0,405	0,642	0,642	0,668
R^2 ajusté	0,404	0,640	0,640	0,664

Lire un coefficient « toutes choses égales par ailleurs »

266,74 est l'effet d'une année d'ancienneté *à diplôme, sexe et région donnés*. Ce n'est pas l'écart brut entre deux salariés : c'est ce qui resterait si tout le reste était identique.

Ce que la colonne M2 apprend

Ajouter le diplôme fait passer le R^2 de 0,405 à 0,642 — et ne bouge la pente de l'ancienneté que de 277 à 270. Le chapitre 16 montrera que ce déplacement de 6,9 dirhams se calcule *à l'avance*.

Le sexe reste non significatif

131 puis 174 dirhams, pour des écarts-types de 140 : le résultat du chapitre 16 de l'inférence tient, même après contrôle du diplôme et de la région.

Lire la colonne M4

Le coefficient de l'ancienneté

266,74 dirhams par année d'ancienneté, **à diplôme, sexe et région donnés**.
Ce n'est pas l'écart de salaire moyen entre deux salariés qui diffèrent d'une année : ceux-là diffèrent aussi, en moyenne, par leur diplôme et leur région.

Deux questions, deux réponses légitimes

« Combien gagne en moyenne un salarié de plus d'ancienneté ? » — c'est l'effet **brut**, 277,17.
« Combien rapporte une année d'ancienneté à qualification égale ? » — c'est l'effet **net**, 266,74.
La seconde est celle qui sert à décider d'une grille salariale. La première décrit ; seule la seconde permet d'agir.

Ce que le ceteris paribus n'accomplit pas

Il ne contrôle que ce qui est dans le modèle

Maintenir constants le diplôme, le sexe et la région ne dit rien du poste occupé, de la performance ou du réseau — qui ne sont pas dans les données.
Le ceteris paribus est toujours partiel. Il vaut *toutes choses observées égales par ailleurs*, et c'est une nuance considérable.

La conséquence, annoncée dès maintenant

C'est exactement le problème de la variable omise, chapitre 16, et de l'endogénéité, chapitre 19.
Ajouter des variables réduit le risque sans jamais l'annuler : il restera toujours quelque chose hors du tableau. **Un coefficient de régression n'est jamais un effet causal par le seul fait d'être significatif.**

À la main, sur les cinq ménages

Ajouter la taille du ménage

Deux explicatives, toutes les sommes utiles

Ménage	$R-\overline{R}$	$T-\overline{T}$	$C-\overline{C}$
A	-4	-3	-3
B	-2	1	0
C	0	0	-2
D	2	-1	1
E	4	3	4

$\overline{R} = 6$, $\overline{T} = 4$, $\overline{C} = 6$. Sommes de produits : $S_{RR} = 40$, $S_{TT} = 20$, $S_{RT} = 20$, $S_{RC} = 30$, $S_{TC} = 20$.

Les deux formules de la régression à deux variables

Elles généralisent la pente simple

$$\hat{\beta}_R = \frac{S_{RC}\,S_{TT} - S_{TC}\,S_{RT}}{S_{RR}\,S_{TT} - S_{RT}^2} \qquad \hat{\beta}_T = \frac{S_{TC}\,S_{RR} - S_{RC}\,S_{RT}}{S_{RR}\,S_{TT} - S_{RT}^2}$$

et $\hat{\beta}_0 = \overline{C} - \hat{\beta}_R\overline{R} - \hat{\beta}_T\overline{T}$.

Le calcul

Dénominateur : $40 \times 20 - 20^2 = 400$. $\hat{\beta}_R = (30 \times 20 - 20 \times 20)/400 = 0{,}5$; $\hat{\beta}_T = (20 \times 40 - 30 \times 20)/400 = 0{,}5$; $\hat{\beta}_0 = 6 - 3 - 2 = 1$.

$$\widehat{C} = 1 + 0{,}5\,R + 0{,}5\,T$$

Effet brut 0,75, effet net 0,5

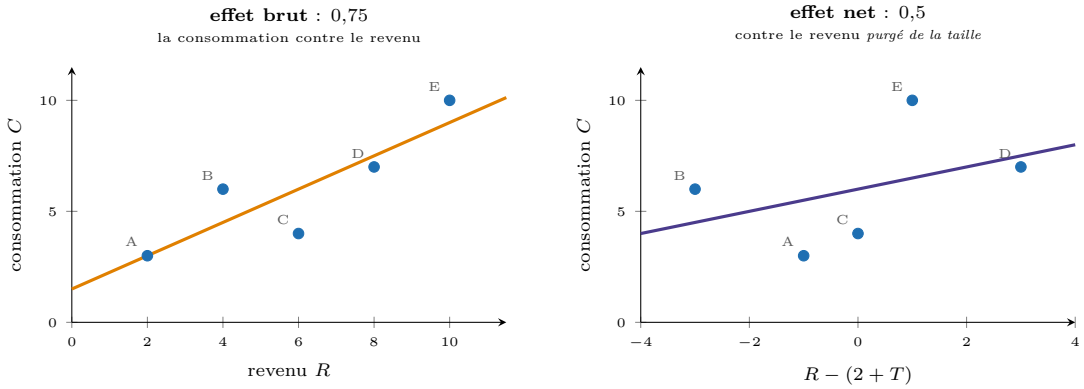
Où sont passés les 0,25

Seul, le revenu « explique » 0,75 millier de consommation par millier de revenu. À taille égale, il n'en explique que 0,5.
La différence vient de ce que les ménages riches sont aussi, ici, **plus nombreux** : chaque millier de revenu va de pair avec une demi-personne de plus. Seul, le revenu s'attribue une partie de l'effet de la taille.

La lecture correcte des deux coefficients

0,5 : à taille du ménage donnée, un millier de dirhams de revenu en plus est associé à 500 dirhams de consommation en plus.
0,5 aussi pour la taille : à revenu donné, une personne de plus est associée à 500 dirhams de consommation en plus.

Frisch-Waugh : ce que « à taille égale » veut dire



Le théorème

Régresser R sur T donne $\widehat{R} = 2 + T$, de résidus $u = -1, -3, 0, 3, 1$: le revenu **purgé de la taille**. Régresser C sur u redonne exactement le coefficient net : $\sum u\,C / \sum u^2 = 10/20 = 0{,}5$.

Ce que le théorème enseigne

Le coefficient net n'utilise qu'une partie de l'information

Seule compte la part du revenu que la taille **ne prédit pas**. Un ménage riche parce qu'il est nombreux n'apporte rien à $\hat{\beta}_R$; un ménage plus riche que sa taille ne le laisse attendre apporte tout.

C'est le laboratoire de papier, rendu visible : la régression multiple compare des ménages qui ne diffèrent que par la part « libre » du revenu.

La conséquence pour la précision

Si R et T étaient presque confondus, u serait presque nul : il ne resterait presque rien pour estimer l'effet propre du revenu. C'est la **multicolinéarité** du chapitre 13, déjà visible ici.

L'estimation

Le principe ne change pas

Le même critère

$$\min \sum_{i=1}^{n} \left(y_i - \beta_0 - \beta_1 x_{1i} - \cdots - \beta_k x_{ki}\right)^2$$

On annule les $k+1$ dérivées partielles : un système de $k+1$ équations à $k+1$ inconnues.

La forme matricielle, pour information

$$\hat{\beta} = (X'X)^{-1} X'y$$

C'est le système des chapitres 8 à 11 du cours de mathématiques, écrit en une ligne. **On ne**

la calcule jamais à la main — mais elle explique pourquoi la colinéarité parfaite rend le modèle insoluble : la matrice $X'X$ n'est alors pas inversible.

Ce qui change vraiment

Trois nouveautés, et trois seulement

1. Les **degrés de liberté** : $n-k-1$ au lieu de $n-2$.
2. Un **second niveau de test** : le F global, à côté des t individuels.
3. Un R^2 **ajusté**, parce que le R^2 simple devient trompeur.

Le reste est identique

Les erreurs-types, les t, les intervalles, les résidus, la prévision : tout se lit comme au chapitre 5.
La régression multiple n'est pas une méthode nouvelle — c'est la même, avec plusieurs colonnes. Les trois chapitres qui suivent traitent exactement les trois nouveautés ci-dessus.

La prévision promise en introduction

Un Bac+5 avec dix ans d'ancienneté, selon M2

$$\widehat{S} = 3\,320{,}42 + 270{,}27 \times 10 + 3\,336{,}99 = 9\,360 \text{ dirhams}$$

Intervalle de la **moyenne** de ces salariés : $[9\,063\,;9\,657]$. Intervalle pour **un** salarié : $[6\,278\,;12\,442]$.

Pourquoi l'intervalle individuel a rétréci

Avec la seule ancienneté, l'intervalle individuel avait une demi-largeur de près de 3 950 dirhams. Avec le diplôme, 3 082 : $\hat{\sigma}_\varepsilon$ est passé de 2 008 à 1 561.
Ajouter une variable pertinente est la seule façon de mieux prévoir un individu — le chapitre 6 l'annonçait.

Sur machine

Effet brut et effet net avec R

```
R <- c(2, 4, 6, 8, 10)
C <- c(3, 6, 4, 7, 10)
T <- c(1, 5, 4, 3, 7)                # taille du ménage
coef(lm(C ~ R))                      # effet brut
# (Intercept)           R
#        1.50        0.75
coef(lm(C ~ R + T))                  # effet net
# (Intercept)           R           T
#         1.0         0.5         0.5
u <- residuals(lm(R ~ T))            # revenu purgé de la taille
```

```r
coef(lm(C ~ u))[2]                    # Frisch-Waugh : 0,5
#   u
# 0.5
```

La prévision de M2 avec Python

```python
import pandas as pd
import statsmodels.formula.api as smf
sal = pd.read_csv("salaires.csv")
m2 = smf.ols("salaire ~ ancienneté + diplome", data=sal).fit()
print(m2.params.round(2).tolist())   # Bac en référence
# [3320.42, 1099.57, 3336.99, 270.27]
nouveau = pd.DataFrame({"ancienneté": [10], "diplome": ["Bac+5"]})
p = m2.get_prediction(nouveau).summary_frame().round(1)
print(p[["mean", "mean_ci_lower", "mean_ci_upper"]])
#      mean  mean_ci_lower  mean_ci_upper
# 0  9360.1         9063.2         9657.0
```

S'entraîner

Exercice 1 : lire le modèle M4

Deux salariés à comparer

M4 donne : constante 2 580,73 ; ancienneté 266,74 ; Bac+2 1 095,55 ; Bac+5 3 276,61 ; homme 174,17 ; Casablanca 1 177,84 ; Rabat 978,52 ; Tanger-Tétouan 467,25. Références : Bac, femme, « Autres » régions.

1. Calculer le salaire ajusté d'un homme Bac+2, cinq ans d'ancienneté, à Casablanca.
2. Quel écart prévu entre une femme Bac+5 à Rabat et une femme Bac+5 à Tanger, de même ancienneté ?

Exercice 1 : solution

Les termes communs disparaissent

1. $2\,580{,}73 + 5 \times 266{,}74 + 1\,095{,}55 + 174{,}17 + 1\,177{,}84 = 6\,362$ dirhams.
2. Tout est identique sauf la région : $978{,}52 - 467{,}25 = 511{,}27$ dirhams en faveur de Rabat. **On n'a pas eu besoin de l'ancienneté** : c'est le sens même du *ceteris paribus*.

Exercice 2 : effet brut, effet net

Sans les données individuelles

Sur un échantillon, on dispose de $S_{11} = 10$, $S_{22} = 5$, $S_{12} = 5$, $S_{1y} = 20$, $S_{2y} = 15$.

1. Calculer la pente de la régression simple de y sur x_1.
2. Calculer $\hat{\beta}_1$ et $\hat{\beta}_2$ dans la régression de y sur x_1 et x_2.
3. Calculer la pente de x_2 sur x_1, et vérifier : pente simple $= \hat{\beta}_1 + \hat{\beta}_2 \times$ cette pente.

Exercice 2 : solution

La moitié de l'effet brut était empruntée

1. $S_{1y}/S_{11} = 20/10 = 2$.
2. Dénominateur $10\times5-25 = 25$. $\hat{\beta}_1 = (20\times5-15\times5)/25 = 1$; $\hat{\beta}_2 = (15\times10-20\times5)/25 = 2$.
3. $S_{12}/S_{11} = 0{,}5$, et $1 + 2 \times 0{,}5 = 2$. **Cette identité est la formule du biais de variable omise**, qu'on retrouvera au chapitre 16.

Exercice 3 : la bonne phrase

Trois rédactions du même coefficient

Dans M4, le coefficient de Casablanca vaut 1 177,84. Laquelle de ces phrases est exacte ?

1. « Les salariés de Casablanca gagnent en moyenne 1 178 dirhams de plus que les autres. »
2. « À ancienneté, diplôme et sexe égaux, travailler à Casablanca plutôt que dans les autres régions est associé à 1 178 dirhams de plus. »
3. « Déménager à Casablanca fait gagner 1 178 dirhams. »

Exercice 3 : solution

La deuxième, et elle seule

1. **Fausse** : c'est un écart brut, que le coefficient ne mesure pas, et la comparaison est avec les régions « Autres », pas avec toutes.
2. **Exacte** : elle dit le *ceteris paribus* et la référence.
3. **Fausse** : elle suppose une causalité. Les salariés de Casablanca peuvent différer par des caractéristiques absentes du fichier — le poste, le secteur.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. β_j s'interprète **toutes autres variables du modèle constantes** : c'est le *ceteris paribus*.
2. C'est l'apport propre de l'économétrie : un contrôle statistique, à défaut d'expérience.
3. Cinq ménages : effet brut 0,75, effet net 0,5 — les ménages riches sont aussi plus nombreux.
4. **Frisch-Waugh** : le coefficient net est la pente sur la partie de x_j que les autres ne prédisent pas.
5. Le ceteris paribus ne contrôle **que ce qui est dans le modèle**.
6. Même critère d'estimation ; seuls changent les degrés de liberté, le test global et le R^2 ajusté.

La suite

Puisqu'ajouter une variable ne peut jamais faire baisser le R^2, celui-ci cesse d'être un critère de choix. Le chapitre 8 le corrige — et montre qu'il faut facturer chaque variable ajoutée.