

Introduction à l'économétrie

Chapitre 3 : Les moindres carrés ordinaires

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'économétrie

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Calculer une droite des moindres carrés, à la main

Cinq ménages ont un revenu R_i (en milliers de DH) et une consommation C_i (en milliers de DH) :

R_i	2	3	4	5	6
C_i	2,2	2,8	3,3	3,6	4,1

- (a) Calculer $\bar{R}$ et $\bar{C}$.
- (b) Calculer $\text{cov}(R, C) = \frac{1}{n} \sum_i (R_i - \bar{R})(C_i - \bar{C})$ et $V(R) = \frac{1}{n} \sum_i (R_i - \bar{R})^2$.
- (c) En déduire $\hat{\beta}_1 = \text{cov}(R, C)/V(R)$ et $\hat{\beta}_0 = \bar{C} - \hat{\beta}_1 \bar{R}$.
- (d) Cette pente est-elle compatible avec la théorie de Keynes (chapitre 1) ?

Exercice 2 — La pente dit combien, la corrélation dit à quel point

Deux secteurs présentent le **même** coefficient de corrélation entre dépenses publicitaires P et ventes V (en millions de DH) : $r = 0,90$ dans les deux cas. Mais l'écart-type des ventes diffère fortement : $\sigma_V = 20$ dans l'agroalimentaire, $\sigma_V = 60$ dans la technologie. L'écart-type des dépenses publicitaires est, dans les deux secteurs, $\sigma_P = 4$.

- (a) Rappeler la formule reliant $\hat{\beta}_1$, r , σ_V et σ_P .
- (b) Calculer $\hat{\beta}_1$ pour le secteur agroalimentaire, puis pour le secteur technologique.
- (c) Un directeur marketing affirme : « la relation publicité-ventes est **tout aussi forte** dans les deux secteurs, puisque r est identique ». Est-ce vrai concernant la **force** statistique de la relation (à quel point les points sont alignés) ?
- (d) Ce même directeur en déduit que « 1 million de DH de publicité supplémentaire rapporte donc **le même** surcroît de ventes dans les deux secteurs ». Cette déduction est-elle correcte ? Distinguer précisément ce que r mesure de ce que $\hat{\beta}_1$ mesure.

Exercice 3 — Des identités vraies même pour un très mauvais modèle

On observe trois points : $X = (1, 2, 3)$, $Y = (10, 1, 10)$ — une forme en « V », clairement non linéaire.

- (a) Calculer $\bar{X}$, $\bar{Y}$, $\text{cov}(X, Y)$ et $V(X)$.
- (b) En déduire $\hat{\beta}_1$ et $\hat{\beta}_0$. La droite obtenue est-elle horizontale, croissante ou décroissante ?
- (c) Calculer les trois résidus $e_i = Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i$, puis leur somme.
- (d) Calculer $\sum_i X_i e_i$.
- (e) Cette droite « explique »-t-elle quoi que ce soit de la forme en V des données (visiblement non), et pourtant les deux identités des questions (c) et (d) sont-elles vérifiées ? Qu'est-ce que cet exemple démontre très concrètement sur la mise en garde du cours : « voir des résidus de somme nulle n'est pas un contrôle de qualité » ?

2 Exercice cumulatif (chapitre 3 et chapitres précédents)

Exercice 4 — Pourquoi il faut de la variation dans R pour estimer une pente

On reprend les quatre ménages du chapitre 1 (exercice 3) et du chapitre 2 (exercice cumulatif), tous de revenu **identique** $R = 4\,000$ DH, avec $C = (3\,200, 3\,400, 3\,100, 3\,300)$.

- (a) Calculer $V(R)$ pour ces quatre ménages (tous les R_i sont égaux à $\bar{R}$).
- (b) La formule $\hat{\beta}_1 = \text{cov}(R, C)/V(R)$ est-elle calculable sur ces quatre ménages ? Que se passe-t-il quand on tente de l'appliquer ?

- (c) Rappeler la pente $\hat{\beta}_1 = 0,6$ obtenue au chapitre 1 à partir des **deux tranches** de revenu de l'introduction ($R_1 = 3\,000$, $R_2 = 6\,000$). Cette pente avait-elle pu être calculée parce que les deux tranches avaient, elles, des revenus **différents** ?
- (d) En comparant les questions (b) et (c), formuler en une phrase la condition nécessaire, révélée par la formule des moindres carrés elle-même, pour qu'un coefficient de pente soit **identifiable** à partir de données.
- (e) Le jeu de données de l'exercice 1 de ce chapitre ($R = 2, 3, 4, 5, 6$) satisfait-il cette condition ? Calculer $V(R)$ pour ce jeu et comparer à celui de la question (a).

3 Applications en sciences économiques

Exercice 5 — Une observation aberrante peut tout changer

On reprend le jeu de données de l'exercice 1 ($R = (2, 3, 4, 5, 6)$, $C = (2, 2, 2, 8, 3, 3, 3, 6, 4, 1)$, $\hat{\beta}_1 = 0,46$, $\hat{\beta}_0 = 1,36$). On remplace la dernière observation par une valeur aberrante : le cinquième ménage déclare, par erreur de saisie ou événement exceptionnel, $C_5 = 9,0$ au lieu de 4,1.

- (a) On admet que la nouvelle pente vaut $\hat{\beta}_1 = 1,44$ et la nouvelle ordonnée $\hat{\beta}_0 = -1,58$. Calculer le facteur multiplicatif par lequel la pente a été modifiée par cette seule observation (sur cinq).
- (b) La nouvelle pente (1,44) est-elle encore compatible avec la théorie de Keynes ($0 < \beta_1 < 1$, chapitre 1) ?
- (c) Le nouvel intercept ($-1,58$) est-il encore compatible avec l'hypothèse $\beta_0 > 0$?
- (d) En quoi cet exemple illustre-t-il concrètement l'ecobox du cours : « les moindres carrés sont efficaces et fragiles » ? Une seule observation sur cinq (20 % de l'échantillon) a-t-elle simplement « un peu » déplacé la droite, ou a-t-elle complètement renversé les conclusions économiques qu'on en tirerait ?

Exercice 6 — Choisir entre deux estimations concurrentes

Un cabinet de conseil dispose de deux estimations de la relation entre le budget marketing M (en millions de DH) et le chiffre d'affaires CA (en millions de DH) d'une chaîne de distribution : Modèle A, $\widehat{CA} = 12 + 3,2M$; Modèle B, $\widehat{CA} = 8 + 3,2M + \varepsilon$ avec r_{AB} non précisé, mais le cabinet précise que le modèle B a été estimé après avoir retiré une agence dont le budget marketing était exceptionnellement élevé (un cas extrême du reste de l'échantillon).

- (a) Les deux modèles ont la **même** pente (3,2) mais un intercept différent (12 contre 8). Sachant que $\hat{\beta}_0 = \overline{CA} - \hat{\beta}_1 \overline{M}$, qu'est-ce que cela suggère sur la moyenne $\overline{CA}$ ou $\overline{M}$ de l'échantillon utilisé dans chaque cas ?
- (b) Si l'agence retirée du modèle B avait un budget marketing bien supérieur à la moyenne et un chiffre d'affaires disproportionné par rapport à ce que la relation linéaire prédirait pour les autres agences, quel est le risque à l'avoir **gardée** dans l'estimation (modèle A) ?
- (c) Le cabinet doit-il nécessairement préférer le modèle qui exclut l'observation extrême ? Quelle vérification supplémentaire (au-delà de la simple exclusion) le cours annonce-t-il pour le chapitre 17, avant de décider de retirer ou non un point influent ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) $\bar{R} = (2 + 3 + 4 + 5 + 6)/5 = 20/5 = 4$. $\bar{C} = (2,2 + 2,8 + 3,3 + 3,6 + 4,1)/5 = 16/5 = 3,2$.
(b) Écarts $R_i - \bar{R}$: $-2, -1, 0, 1, 2$. Écarts $C_i - \bar{C}$: $-1,0, -0,4, 0,1, 0,4, 0,9$. Produits : $2,0, 0,4, 0, 0,4, 1,8$, somme = $4,6$, d'où $\text{cov}(R, C) = 4,6/5 = 0,92$. Carrés des écarts de R : $4, 1, 0, 1, 4$, somme = 10 , d'où $V(R) = 10/5 = 2$.
(c) $\hat{\beta}_1 = 0,92/2 = 0,46$. $\hat{\beta}_0 = 3,2 - 0,46 \times 4 = 3,2 - 1,84 = 1,36$.
(d) Oui : $0 < 0,46 < 1$, compatible avec $0 < \beta_1 < 1$.

Correction — Exercice 2

- (a) $\hat{\beta}_1 = r \sigma_V / \sigma_P$.
(b) Agroalimentaire : $\hat{\beta}_1 = 0,90 \times 20/4 = 4,5$. Technologie : $\hat{\beta}_1 = 0,90 \times 60/4 = 13,5$.
(c) Oui, concernant la **force** de la relation (l'alignement des points autour de la droite), l'affirmation est correcte : un même $r = 0,90$ signifie un ajustement de qualité comparable (même $R^2 = 0,81$) dans les deux secteurs.
(d) Non, cette déduction est incorrecte : la pente diffère fortement entre les deux secteurs ($4,5$ contre $13,5$, soit un facteur 3), précisément parce que σ_V diffère. r mesure **à quel point** les deux variables sont linéairement liées (une notion sans unité, comparable entre contextes), tandis que $\hat{\beta}_1$ mesure **combien** de ventes supplémentaires un million de DH de publicité rapporte (une notion exprimée dans les unités du problème, qui dépend de la dispersion propre à chaque secteur). Les deux secteurs ont une relation « tout aussi solide » statistiquement, mais économiquement très différente en intensité.

Correction — Exercice 3

- (a) $\bar{X} = (1+2+3)/3 = 2$. $\bar{Y} = (10+1+10)/3 = 7$. Écarts X : $-1, 0, 1$. Écarts Y : $3, -6, 3$. Produits : $-3, 0, 3$, somme = 0 , donc $\text{cov}(X, Y) = 0$. Carrés des écarts de X : $1, 0, 1$, somme = 2 , $V(X) = 2/3 \approx 0,667$.
(b) $\hat{\beta}_1 = 0/V(X) = 0$. $\hat{\beta}_0 = \bar{Y} - 0 \times \bar{X} = 7$. La droite est **horizontale** ($\hat{Y} = 7$ pour tout X).
(c) $e_1 = 10 - 7 = 3$; $e_2 = 1 - 7 = -6$; $e_3 = 10 - 7 = 3$. Somme = $3 - 6 + 3 = 0$.
(d) $\sum_i X_i e_i = 1 \times 3 + 2 \times (-6) + 3 \times 3 = 3 - 12 + 9 = 0$.
(e) Non, cette droite horizontale n'explique **rien** de la forme en V des données : elle prédit la même valeur (7) quel que soit X , alors que Y varie fortement et de façon structurée (bas au milieu, haut aux extrémités) selon X . Et pourtant les deux identités (c) et (d) sont parfaitement vérifiées. Cela démontre que ces identités sont des **conséquences mécaniques** des équations normales — vraies pour **n'importe quelle** droite obtenue par ce critère, aussi mauvaise soit l'adéquation du modèle linéaire aux données — et non un signe que le modèle « fonctionne bien ». Un résidu de somme nulle ne prouve absolument rien sur la qualité du modèle ; c'est une propriété algébrique, pas un diagnostic.

2 Exercice cumulatif

Correction — Exercice 4

- (a) Puisque les quatre R_i valent tous $4\,000 = \bar{R}$, chaque écart $R_i - \bar{R}$ est nul, donc $V(R) = 0$.
(b) Non, elle n'est pas calculable : $\hat{\beta}_1 = \text{cov}(R, C)/V(R)$ impliquerait une division par 0 , ce qui est indéfini. La formule échoue purement et simplement.
(c) Oui : les deux tranches avaient des revenus **différents** ($3\,000$ et $6\,000$), ce qui donnait $V(R) > 0$ et permettait de calculer une pente non triviale.
(d) Il faut que la variable explicative R présente de la **variation** dans l'échantillon (au moins deux valeurs distinctes, donc $V(R) > 0$) pour qu'un coefficient de pente puisse être identifié — sans quoi le dénominateur de la formule des moindres carrés s'annule.

(e) Oui, ce jeu de données satisfait la condition : les valeurs de R vont de 2 à 6 (cinq valeurs distinctes), avec $V(R) = 2 > 0$ (calculé à la question (b) de l'exercice 1), contre $V(R) = 0$ pour les quatre ménages de revenu identique de la question (a) ci-dessus.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) $1,44/0,46 \approx 3,13$: la pente a plus que **triplé** sous l'effet d'une seule observation modifiée.
- (b) Non : $1,44 > 1$, ce qui **viole** la contrainte $\beta_1 < 1$ de la théorie de Keynes — la nouvelle estimation impliquerait qu'un dirham de revenu supplémentaire génère plus d'un dirham de consommation supplémentaire, une absurdité économique déjà identifiée au chapitre 1 (exercice 2).
- (c) Non : $-1,58 < 0$, ce qui viole $\beta_0 > 0$ — le nouveau modèle prédirait une consommation **négative** pour un ménage sans revenu, ce qui n'a aucun sens.
- (d) Cet exemple illustre exactement la fragilité annoncée par le cours : une seule observation, modifiée parmi cinq (20 % de l'échantillon, mais une seule valeur), ne se contente pas de « légèrement » déplacer la droite — elle **renverse complètement** les conclusions économiques qu'on en tirerait, faisant passer le modèle d'une confirmation nette de la théorie de Keynes à une double violation de ses deux contraintes fondamentales. C'est précisément parce que le critère des moindres carrés pénalise les écarts au **carré** qu'un point très éloigné de la droite pèse disproportionnellement dans l'ajustement final.

Correction — Exercice 6

- (a) Puisque $\hat{\beta}_0 = \overline{CA} - \hat{\beta}_1 \overline{M}$ et que $\hat{\beta}_1 = 3,2$ est identique dans les deux modèles, un intercept plus faible dans le modèle B (8 contre 12) suggère que $\overline{CA} - 3,2 \times \overline{M}$ est plus petit dans l'échantillon du modèle B — cohérent avec le retrait d'une agence à budget marketing **exceptionnellement élevé**, qui aurait tiré $\overline{M}$ (et potentiellement $\overline{CA}$) vers le haut dans l'échantillon complet utilisé par le modèle A.
- (b) Le risque est que cette agence, si son chiffre d'affaires ne suit pas la même relation linéaire que les autres (par exemple si son CA est disproportionnellement élevé ou faible compte tenu de son budget), **déforme** l'estimation de la pente et de l'intercept pour l'ensemble de l'échantillon — exactement comme dans l'exercice 5, où une seule observation extrême a fait plus que tripler la pente estimée.
- (c) Non, il ne faut pas systématiquement l'exclure : retirer une observation seulement parce qu'elle est extrême, sans autre justification, revient à écarter arbitrairement de l'information potentiellement légitime (cette agence existe réellement et pourrait révéler un phénomène économique réel à grande échelle de budget). Le cours annonce, pour le chapitre 17, des outils formels de diagnostic (au-delà du simple constat visuel qu'un point « semble » extrême) pour distinguer un point réellement **influent** — dont la présence ou l'absence change qualitativement les conclusions — d'un point simplement éloigné mais cohérent avec la tendance générale, avant de décider, sur des bases objectives, de le conserver, de l'examiner plus avant, ou de le retirer.