Introduction à l'économétrie

Chapitre 3 : Les moindres carrés ordinaires

Jaouad Madkour

29 octobre 2026

Plan du chapitre

Le critère **2**
- Trois questions sur une même figure . . . 2
- Le programme d'optimisation . . . 2
- Les équations normales . . . 2
- D'où vient la solution . . . 3

À la main, sur les cinq ménages **4**
- Le tableau de calcul . . . 4
- La droite et ses résidus . . . 4
- Aucune autre droite ne fait mieux . . . 5

Sur nos deux jeux de données **5**
- Les mêmes formules, sur les fichiers . . . 5
- Ce que disent les deux droites . . . 5

Ce que les formules disent **6**
- Deux lectures de la pente . . . 6
- Le lien, vérifié deux fois . . . 6
- Trois propriétés algébriques . . . 7
- Ce que ces propriétés ne prouvent pas . . . 7
- Pourquoi ce critère plutôt qu'un autre . . . 7
- Ce que deviennent les coefficients quand on change d'unité . . . 8

Sur machine **8**
- Les moindres carrés avec R . . . 8
- Les moindres carrés avec Python . . . 9
- Les 400 ménages, dans les deux langages . . . 9

S'entraîner **9**
- Exercice 1 : une droite à la main . . . 9
- Exercice 1 : solution . . . 10
- Exercice 2 : changer d'unité . . . 10
- Exercice 2 : solution . . . 10
- Exercice 3 : une droite à partir de résumés . . . 10

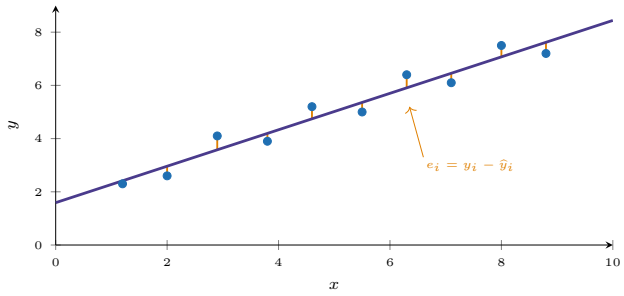
Exercice 3 : solution 10

Ce qu'il faut retenir **11**
Le résumé du chapitre 11

Le critère

Trois questions sur une même figure

les moindres carrés : on minimise la somme des carrés des segments verticaux



Trois questions, trois réponses

Pourquoi vertical ?
Parce qu'on explique y *par* x. L'erreur porte sur y, pas sur x : la distance pertinente est celle-là.

Pourquoi au carré ?
Pour que les écarts positifs et négatifs ne se compensent pas, et pour pénaliser davantage les gros écarts. La valeur absolue conviendrait aussi, mais elle n'est pas dérivable.

Pourquoi cette droite-là ?
Elle est *unique* : annuler les deux dérivées donne un système de deux équations à deux inconnues, résolu au chapitre 10 du cours de mathématiques.

Le programme d'optimisation

Ce que l'on minimise

$$\min_{\beta_0,\beta_1} \; S(\beta_0,\beta_1) = \sum_{i=1}^{n} \left(y_i - \beta_0 - \beta_1 x_i\right)^2$$

On cherche la droite qui rend la somme des carrés des écarts verticaux la plus petite possible.

Un problème du cours de mathématiques

Une fonction de deux variables, dont on cherche le minimum : on annule les deux dérivées partielles.
C'est le chapitre 6 du cours de mathématiques pour la gestion, appliqué tel quel. Le système obtenu — deux équations, deux inconnues — se résout par la méthode du chapitre 10.

Les équations normales

Annuler les deux dérivées

$$\frac{\partial S}{\partial \beta_0} = -2\sum_i (y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\frac{\partial S}{\partial \beta_1} = -2\sum_i x_i(y_i - \beta_0 - \beta_1 x_i) = 0$$

La solution

$$\hat{\beta}_1 = \frac{\operatorname{cov}(x,y)}{V(x)} \qquad \hat{\beta}_0 = \overline{y} - \hat{\beta}_1\,\overline{x}$$

D'où vient la solution

Trois lignes de calcul

La première équation, divisée par n, donne $\overline{y} = \beta_0 + \beta_1\overline{x}$, donc $\beta_0 = \overline{y} - \beta_1\overline{x}$.
On remplace dans la seconde : $\sum_i x_i[(y_i - \overline{y}) - \beta_1(x_i - \overline{x})] = 0$.
Comme $\sum_i \overline{x}\,(y_i - \overline{y}) = 0$, on peut remplacer x_i par $x_i - \overline{x}$:

$$\beta_1 = \frac{\sum_i (x_i - \overline{x})(y_i - \overline{y})}{\sum_i (x_i - \overline{x})^2} = \frac{S_{xy}}{S_{xx}}$$

Deux écritures de la même pente

En divisant haut et bas par n : $S_{xy}/n = \operatorname{cov}(x,y)$ et $S_{xx}/n = V(x)$. **Les sommes de produits et la covariance donnent la même pente** ; à la main, on travaille avec les sommes.

Démonstration : La solution annule les dérivées, et c'est bien le minimum

Étape 1 : les dérivées. Chaque terme $(y_i - \beta_0 - \beta_1 x_i)^2$ se dérive comme un carré : $2\,(y_i - \beta_0 - \beta_1 x_i)$ fois la dérivée de l'intérieur, qui vaut -1 par rapport à β_0 et $-x_i$ par rapport à β_1. En sommant sur i, on retrouve les deux équations de la diapositive.

Étape 2 : les résoudre. La première équation, $\sum_i (y_i - \beta_0 - \beta_1 x_i) = 0$, s'écrit $n\overline{y} - n\beta_0 - n\beta_1\overline{x} = 0$, donc $\beta_0 = \overline{y} - \beta_1\overline{x}$. Reportée dans la seconde, elle donne $y_i - \beta_0 - \beta_1 x_i = (y_i - \overline{y}) - \beta_1(x_i - \overline{x})$, d'où

$$\sum_i x_i(y_i - \overline{y}) \;-\; \beta_1 \sum_i x_i(x_i - \overline{x}) = 0.$$

Or $\sum_i x_i(y_i - \overline{y}) = \sum_i (x_i - \overline{x})(y_i - \overline{y}) + \overline{x}\sum_i (y_i - \overline{y}) = S_{xy} + 0$, et de même $\sum_i x_i(x_i - \overline{x}) = S_{xx}$. L'équation devient $S_{xy} - \beta_1 S_{xx} = 0$, soit $\beta_1 = S_{xy}/S_{xx}$. Cette division est possible dès que $S_{xx} \neq 0$, c'est-à-dire dès que les x_i ne sont pas tous égaux : si tous les points sont sur une même verticale, la pente n'est pas définie.

Étape 3 : c'est un minimum, et le seul. Annuler les dérivées ne suffit pas, ce pourrait être un maximum. Notons $\hat{\beta}_0, \hat{\beta}_1$ la solution et $e_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$ les résidus : les deux équations disent que $\sum_i e_i = 0$ et $\sum_i x_i e_i = 0$. Prenons une droite quelconque (b_0, b_1) et posons $d_0 = \hat{\beta}_0 - b_0$, $d_1 = \hat{\beta}_1 - b_1$. Alors $y_i - b_0 - b_1 x_i = e_i + d_0 + d_1 x_i$, et

$$\begin{aligned} S(b_0,b_1) &= \sum_i e_i^2 + 2d_0 \underbrace{\sum_i e_i}_{0} + 2d_1 \underbrace{\sum_i x_i e_i}_{0} \\ &\quad + \sum_i (d_0 + d_1 x_i)^2 \\ &= S(\hat{\beta}_0, \hat{\beta}_1) + \sum_i (d_0 + d_1 x_i)^2. \end{aligned}$$

La dernière somme est positive ou nulle. Elle ne s'annule que si $d_0 + d_1 x_i = 0$ pour tout i ; comme deux des x_i au moins diffèrent, cela force $d_1 = 0$, puis $d_0 = 0$. Toute autre droite fait donc **strictement** pire : la solution est l'unique minimum global.

■

À la main, sur les cinq ménages

Le tableau de calcul

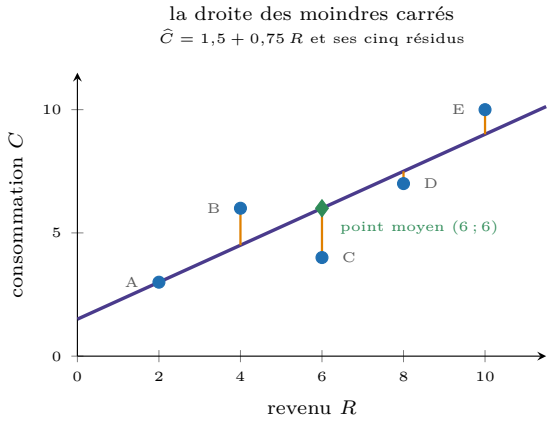
Revenu et consommation, en milliers de dirhams

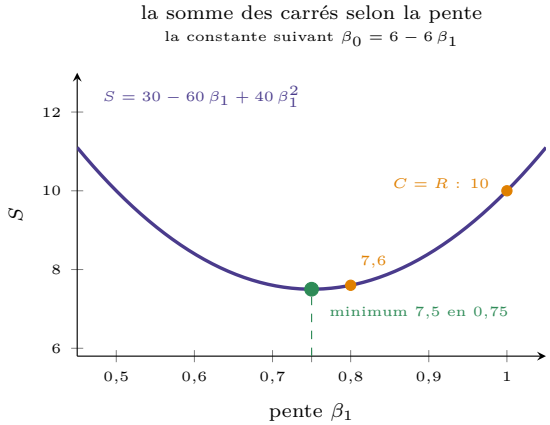
Ménage	R	C	$R-\overline{R}$	$C-\overline{C}$	produit	$(R-\overline{R})^2$
A	2	3	−4	−3	12	16
B	4	6	−2	0	0	4
C	6	4	0	−2	0	0
D	8	7	2	1	2	4
E	10	10	4	4	16	16
Somme	30	30	0	0	30	40

Les deux coefficients

$$\hat{\beta}_1 = \frac{S_{RC}}{S_{RR}} = \frac{30}{40} = 0{,}75 \qquad \hat{\beta}_0 = \overline{C} - \hat{\beta}_1 \overline{R} = 6 - 0{,}75 \times 6 = 1{,}5$$

La droite et ses résidus





Valeurs ajustées et résidus

$\widehat{C} = 1{,}5 + 0{,}75\,R$ donne 3 ; 4,5 ; 6 ; 7,5 ; 9. Résidus $e = C - \widehat{C}$: 0 ; 1,5 ; −2 ; −0,5 ; 1. Leur somme des carrés : $0 + 2{,}25 + 4 + 0{,}25 + 1 = 7{,}5$.

Aucune autre droite ne fait mieux

Trois candidates, trois sommes de carrés

Droite	Résidus	S
$C = R$	1 ; 2 ; −2 ; −1 ; 0	10
$C = 1{,}2 + 0{,}8\,R$	0,2 ; 1,6 ; −2 ; −0,6 ; 0,8	7,6
$C = 1{,}5 + 0{,}75\,R$	0 ; 1,5 ; −2 ; −0,5 ; 1	**7,5**

La parabole de la figure le garantit

En imposant $\beta_0 = 6 - 6\,\beta_1$, la somme des carrés devient $S = 30 - 60\,\beta_1 + 40\,\beta_1^2$: une parabole, minimale en $\beta_1 = 60/80 = 0{,}75$.
Toute autre pente fait pire — et toute autre constante aussi, puisque la meilleure passe par le point moyen.

Sur nos deux jeux de données

Les mêmes formules, sur les fichiers

Les salaires

$$\text{cov} = 9\,859{,}9 \qquad V(x) = 35{,}574$$

$$\hat{\beta}_1 = \frac{9\,859{,}9}{35{,}574} = 277{,}17 \qquad \hat{\beta}_0 = 7\,158{,}26 - 277{,}17 \times 10{,}142 = 4\,347{,}23$$

La consommation

$$\hat{\beta}_1 = \frac{2\,145\,709}{3\,082\,849} = 0{,}6960 \qquad \hat{\beta}_0 = 2\,779{,}43 - 0{,}6960 \times 2\,921{,}73 = 745{,}86$$

La propension marginale vaut 0,696 : comprise entre zéro et un, comme Keynes l'annonçait. Et $\hat{\beta}_0 > 0$, comme il l'annonçait aussi.

Ce que disent les deux droites

Lire les coefficients dans leurs unités

Salaires : chaque année d'ancienneté est associée à 277 dirhams de salaire mensuel en plus. La constante, 4 347 dirhams, est le salaire ajusté d'un débutant.
Consommation : sur chaque dirham de revenu supplémentaire, 0,70 dirham est consommé et 0,30 épargné. La constante, 746 dirhams, est la consommation qu'aurait un ménage sans revenu.

Une constante n'a pas toujours de sens propre

Aucun ménage de l'enquête n'a un revenu nul : le plus pauvre gagne 402 dirhams. 745,86 est donc une **extrapolation** de la droite, utile au calcul, à lire avec prudence.
Pour les salaires, l'ancienneté nulle existe — les débutants — et la constante se lit littérale-

ment.

Ce que les formules disent

Deux lectures de la pente

La covariance, normalisée

$$\hat{\beta}_1 = \frac{\operatorname{cov}(x,y)}{V(x)} \qquad \text{et} \qquad r = \frac{\operatorname{cov}(x,y)}{\sigma_x\,\sigma_y}$$

La pente et la corrélation ont le **même numérateur**. Ils portent donc toujours le même signe, et l'un est nul si et seulement si l'autre l'est.

Le lien exact

$$\hat{\beta}_1 = r\,\frac{\sigma_y}{\sigma_x}$$

La corrélation est sans unité ; la pente ne l'est pas. **La pente dit combien, la corrélation dit à quel point.** Ce sont deux questions distinctes, et le chapitre 4 y reviendra.

Démonstration : $\hat{\beta}_1 = r\sigma_y/\sigma_x$

En divisant par n le numérateur et le dénominateur de S_{xy}/S_{xx}, on obtient $\hat{\beta}_1 = \operatorname{cov}(x,y)/\sigma_x^2$. Or $r = \operatorname{cov}(x,y)/(\sigma_x\sigma_y)$, donc $\operatorname{cov}(x,y) = r\,\sigma_x\sigma_y$. Il vient

$$\hat{\beta}_1 = \frac{r\,\sigma_x\sigma_y}{\sigma_x^2} = r\,\frac{\sigma_y}{\sigma_x}.$$

Le dénominateur σ_x n'est pas nul, puisque $S_{xx} \neq 0$.

■

Le lien, vérifié deux fois

Sur les cinq ménages

$\sigma_R = \sqrt{40/5} = 2{,}828$, $\sigma_C = \sqrt{30/5} = 2{,}449$, $r = 30/\sqrt{40\times 30} = 0{,}866$.

$$r\,\frac{\sigma_C}{\sigma_R} = 0{,}866 \times \frac{2{,}449}{2{,}828} = 0{,}75$$

Sur les salaires

$r = 0{,}6363$, $\sigma_S = 2\,598{,}10$, $\sigma_A = 5{,}964$:

$$0{,}6363 \times \frac{2\,598{,}10}{5{,}964} = 277{,}2$$

Une corrélation moyenne, et pourtant une pente forte : 277 dirhams par an, c'est près de 4 % du salaire moyen.

Trois propriétés algébriques

Vraies par construction, quelles que soient les données

1. $\sum_i e_i = 0$: les résidus somment à zéro.
2. $\sum_i x_i e_i = 0$: ils sont orthogonaux à la variable explicative.
3. La droite passe par le **point moyen** $(\overline{x}, \overline{y})$.

Sur les cinq ménages

$0 + 1{,}5 - 2 - 0{,}5 + 1 = 0$; $2 \times 0 + 4 \times 1{,}5 - 6 \times 2 - 8 \times 0{,}5 + 10 \times 1 = 0$; $1{,}5 + 0{,}75 \times 6 = 6$.
Ce sont les deux équations normales, relues sur les résidus.

Démonstration : Les trois propriétés découlent des équations normales

Avec $e_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$, les deux équations normales (les dérivées annulées, au facteur -2 près) s'écrivent

$$\sum_i e_i = 0 \qquad \text{et} \qquad \sum_i x_i e_i = 0.$$

Ce sont exactement les propriétés 1 et 2. Pour la propriété 3, développons la première : $\sum_i y_i - n\hat{\beta}_0 - \hat{\beta}_1 \sum_i x_i = 0$. Divisée par n, elle donne $\overline{y} = \hat{\beta}_0 + \hat{\beta}_1 \overline{x}$: le point moyen $(\overline{x}, \overline{y})$ est sur la droite.

■

Ce que ces propriétés ne prouvent pas

Elles ne prouvent rien sur le modèle

Ces trois propriétés découlent des équations normales : elles sont vraies même si le modèle est absurde.
Voir des résidus de somme nulle n'est donc pas un contrôle de qualité — c'est une identité. Le vrai diagnostic viendra du chapitre 12.

Pourquoi les erreurs, elles, ne somment pas à zéro

Au chapitre 2, les erreurs mesurées à la vraie droite sommaient à 1. Les résidus somment à 0 parce que la droite estimée est **choisie** pour cela : elle s'ajuste aux aléas de l'échantillon. C'est la raison pour laquelle on divisera la somme des carrés des résidus par $n-2$, et non par n, au chapitre 4.

Pourquoi ce critère plutôt qu'un autre

Trois raisons, dans l'ordre d'importance

1. **La solution est unique et explicite** : deux formules, aucun algorithme.
2. **Elle est optimale** : le théorème de Gauss-Markov, chapitre 11.
3. **Elle est dérivable** : la valeur absolue ne l'est pas en zéro.

Sa faiblesse, et il faut la connaître

Le carré pénalise lourdement les grands écarts : une seule observation aberrante peut déplacer sensiblement la droite.
C'est le même compromis que celui de la moyenne contre la médiane, chapitre 6 de l'inférence. **Les moindres carrés sont efficaces et fragiles** — le chapitre 17 montrera comment repérer les points qui en abusent.

Ce que deviennent les coefficients quand on change d'unité

La pente suit le rapport des unités

Si y est multiplié par a et x par b, la pente est multipliée par a/b et la constante par a.

Démonstration : Pourquoi la pente suit le rapport des unités

Posons $y^* = ay$ et $x^* = bx$, avec $a, b \neq 0$. Les moyennes deviennent $\overline{x}^* = b\overline{x}$ et $\overline{y}^* = a\overline{y}$, et les écarts à la moyenne $x_i^* - \overline{x}^* = b(x_i - \overline{x})$, $y_i^* - \overline{y}^* = a(y_i - \overline{y})$. Donc $S_{xy}^* = ab\,S_{xy}$ et $S_{xx}^* = b^2 S_{xx}$, d'où

$$\hat{\beta}_1^* = \frac{ab\,S_{xy}}{b^2\,S_{xx}} = \frac{a}{b}\,\hat{\beta}_1, \qquad \hat{\beta}_0^* = \overline{y}^* - \hat{\beta}_1^*\,\overline{x}^* = a\overline{y} - \frac{a}{b}\hat{\beta}_1\,b\overline{x} = a\,\hat{\beta}_0.$$

Le coefficient de corrélation, lui, ne bouge pas : $r^* = \dfrac{ab\,S_{xy}}{\sqrt{b^2 S_{xx}\;a^2 S_{yy}}} = \dfrac{ab}{|ab|}\,r = r$ dès que a et b ont le même signe, ce qui est le cas d'un simple changement d'unité.

■

Trois changements, sur nos données

Consommation et revenu **en dirhams** plutôt qu'en milliers : pente inchangée, 0,75 ; constante 1 500 dirhams.
Salaire **en milliers** de dirhams : pente 0,277 millier par année.
Ancienneté **en mois** : pente 277,17/12 = 23,10 dirhams par mois. **Rien n'a changé dans la relation, seulement dans son écriture.**

Sur machine

Les moindres carrés avec R

```
R <- c(2, 4, 6, 8, 10)
C <- c(3, 6, 4, 7, 10)
m <- lm(C ~ R)
coef(m)
# (Intercept)           R
#        1.50        0.75
round(residuals(m), 4)
#    1    2    3    4    5
#  0.0  1.5 -2.0 -0.5  1.0
sum(residuals(m))            # nul, à l'arrondi machine près
```

```
# [1] -2.775558e-16
```

Les moindres carrés avec Python

```python
import pandas as pd
import statsmodels.formula.api as smf
cinq = pd.DataFrame({"R": [2, 4, 6, 8, 10],
                     "C": [3, 6, 4, 7, 10]})
m = smf.ols("C ~ R", data=cinq).fit()
print(m.params.round(4).to_dict())
# {'Intercept': 1.5, 'R': 0.75}
print(m.resid.round(4).tolist())
# [0.0, 1.5, -2.0, -0.5, 1.0]
```

Les 400 ménages, dans les deux langages

```r
men <- read.csv("menages.csv")
coef(lm(consommation ~ revenu, data = men))
# (Intercept)      revenu
#  745.860473    0.696015
```

```python
import pandas as pd
import statsmodels.formula.api as smf
men = pd.read_csv("menages.csv")
mk = smf.ols("consommation ~ revenu", data=men).fit()
print(mk.params.round(4).to_dict())
# {'Intercept': 745.8605, 'revenu': 0.696}
```

Ce que les sorties confirment

1,5 et 0,75 pour les cinq ménages, 745,86 et 0,696 pour les 400. La somme des résidus vaut 10^{-16} et non zéro : c'est l'arrondi de la machine, pas un défaut de la méthode.

S'entraîner

Exercice 1 : une droite à la main

Publicité et ventes

Quatre magasins : dépenses publicitaires x et ventes y, en milliers de dirhams.

Magasin	1	2	3	4
x	1	2	4	5
y	2	4	5	9

1. Calculer S_{xx}, S_{xy}, puis la droite des moindres carrés.
2. Calculer les résidus et vérifier les deux premières propriétés algébriques.

Exercice 1 : solution

Une pente de 1,5

1. $\overline{x} = 3$, $\overline{y} = 5$. Écarts : x : $-2, -1, 1, 2$; y : $-3, -1, 0, 4$. $S_{xx} = 4 + 1 + 1 + 4 = 10$; $S_{xy} = 6 + 1 + 0 + 8 = 15$. $\hat{\beta}_1 = 15/10 = 1{,}5$ et $\hat{\beta}_0 = 5 - 1{,}5 \times 3 = 0{,}5$.
2. Valeurs ajustées : 2 ; 3,5 ; 6,5 ; 8. Résidus : 0 ; 0,5 ; $-1{,}5$; 1. $\sum e_i = 0$ et $\sum x_i e_i = 0 + 1 - 6 + 5 = 0$.

Exercice 2 : changer d'unité

Le salaire en milliers, l'ancienneté en mois

On a estimé $\widehat{S} = 4\,347{,}23 + 277{,}17\,A$, salaire en dirhams, ancienneté en années.

1. Écrire la droite si le salaire est exprimé en milliers de dirhams.
2. Puis si, en plus, l'ancienneté est exprimée en mois.
3. Le coefficient de corrélation change-t-il ?

Exercice 2 : solution

Les coefficients changent, la relation non

1. Tout est divisé par 1 000 : $\widehat{S} = 4{,}347 + 0{,}277\,A$.
2. La pente est en plus divisée par 12 : $\widehat{S} = 4{,}347 + 0{,}0231\,M$, avec M l'ancienneté en mois. La constante ne bouge pas : un débutant a 0 an comme 0 mois.
3. Non : r est **sans unité**, il reste 0,636. C'est toute la différence entre « combien » et « à quel point ».

Exercice 3 : une droite à partir de résumés

Sans les données individuelles

Une étude ne publie que : $n = 200$ entreprises, effectif moyen $\overline{x} = 40$ salariés, chiffre d'affaires moyen $\overline{y} = 12$ millions, $\sigma_x = 15$, $\sigma_y = 5$, $r = 0{,}6$.

1. Calculer la pente et la constante de la droite des moindres carrés de y en x.
2. Quel chiffre d'affaires ajusté pour une entreprise de 55 salariés ?
3. Pourquoi ne peut-on pas calculer les résidus ?

Exercice 3 : solution

Une pente de 0,2 million par salarié

1. $\hat{\beta}_1 = r\,\sigma_y/\sigma_x = 0{,}6 \times 5/15 = 0{,}2$ million par salarié ; $\hat{\beta}_0 = 12 - 0{,}2 \times 40 = 4$ millions.
2. $4 + 0{,}2 \times 55 = 15$ millions de dirhams.
3. Les résidus demandent chaque couple (x_i, y_i). Les cinq résumés suffisent pour la droite, **pas pour la juger** : c'est la limite des études qui ne publient pas leurs données.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. On minimise la somme des **carrés des écarts verticaux** : $\sum_i (y_i - \beta_0 - \beta_1 x_i)^2$.
2. $\hat{\beta}_1 = S_{xy}/S_{xx} = \text{cov}(x,y)/V(x)$ et $\hat{\beta}_0 = \overline{y} - \hat{\beta}_1 \overline{x}$.
3. Cinq ménages : $30/40 = 0{,}75$ et $1{,}5$; aucune autre droite ne descend sous $S = 7{,}5$.
4. $\hat{\beta}_1 = r\,\sigma_y/\sigma_x$: la pente dit **combien**, la corrélation dit **à quel point**.
5. Trois propriétés algébriques, vraies par construction — donc sans valeur de diagnostic.
6. Les MCO sont **efficaces et fragiles** : une observation extrême pèse lourd.

La suite

La droite est calculée. Reste à savoir si elle vaut quelque chose : de quelle part de la dispersion rend-elle compte ? Le chapitre 4 y répond par une décomposition que le cours d'inférence a déjà rencontrée.