

Chapitre 13

La multicolinéarité

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Économétrie — Introduction

1 Exercices du chapitre

Correction — Exercice 1

- (a) $VIF_1 = 1/(1 - 0,85) = 1/0,15 \approx 6,67$. $VIF_2 = 1/(1 - 0,95) = 1/0,05 = 20,0$. $VIF_3 = 1/(1 - 0,20) = 1/0,80 = 1,25$.
- (b) X_1 (6,67) : « à surveiller » (entre 5 et 10). X_2 (20,0) : « multicolinéarité sérieuse » (> 10). X_3 (1,25) : « rien à signaler » (< 5).
- (c) La variance du coefficient de X_1 est 6,67 fois plus grande qu'elle ne le serait si X_1 était indépendante des autres variables. Son écart-type, la racine carrée de la variance, est donc multiplié par $\sqrt{6,67} \approx 2,58$.
- (d) Non, X_3 n'a pas de problème de multicolinéarité significatif : son VIF de 1,25 est très inférieur au seuil de 5 à partir duquel le cours recommande de commencer à surveiller la situation.

Correction — Exercice 2

- (a) $980/12 \approx 81,7$: l'écart-type est multiplié par un facteur d'environ 82. Oui, ce gonflement massif correspond exactement au premier symptôme du cours.
- (b) Modèle A : $t = 250/12 \approx 20,8$ (très significatif). Modèle B : $t = -30/980 \approx -0,031$ (totalement non significatif). Oui, le coefficient devient non significatif dans le modèle B.
- (c) Non, un coefficient **négatif** pour l'ancienneté n'est pas économiquement plausible (on n'attend pas qu'une ancienneté plus grande réduise le salaire). Cela illustre le troisième symptôme : des coefficients qui prennent des valeurs absurdes.
- (d) Les deux R^2 sont pratiquement identiques (0,620 contre 0,621) : le modèle n'a **pas** perdu de pouvoir prédictif. Il a perdu, à la place, sa capacité à **attribuer** l'effet à l'une ou l'autre des deux variables corrélées — exactement le quatrième symptôme, le plus révélateur selon le cours.

Correction — Exercice 3

- (a) Non, les deux variables de C_1 n'apportent **aucune** information distincte : l'une est une transformation exacte (linéaire) de l'autre. Il est parfaitement justifié de retirer l'une des deux — ce n'est même pas un cas de multicolinéarité « imparfaite » au sens du chapitre, mais un doublon pur et simple, proche d'une colinéarité parfaite (H5).
- (b) Non, les deux variables de C_2 ne sont pas redondantes au sens économique : chacune capture un mécanisme **distinct** (capital culturel pour le diplôme des parents, ressources matérielles pour le revenu), même si elles sont statistiquement corrélées dans l'échantillon.
- (c) Pour C_1 : retirer l'une des deux variables est justifié, puisqu'elle n'a économiquement **aucune** place propre dans le modèle (c'est un doublon, pas une variable distincte). Pour C_2 : aucune des deux ne doit être retirée sur ce seul critère, puisque chacune est justifiée par un mécanisme économique différent, quelle que soit leur corrélation statistique.
- (d) Retirer l'une des deux variables de C_2 uniquement à cause d'un VIF élevé ou d'un t faible reviendrait à créer une **variable omise** : si la variable retirée a un effet propre sur la réussite scolaire (ce qui est probable, étant justifiée par un mécanisme distinct), son absence contaminera le terme d'erreur et biaiserait le coefficient de la variable restante, corrélée à elle — un problème de biais bien plus grave que le problème de précision qu'on cherchait à corriger.

2 Exercice cumulatif

Correction — Exercice 4

- (a) $r^2 = 0,97^2 = 0,9409$.
- (b) $VIF = 1/(1 - 0,9409) = 1/0,0591 \approx 16,92$.
- (c) Oui, $16,92 > 10$: ce VIF dépasse le seuil de « multicolinéarité sérieuse ».
- (d) $16,92/2,08 \approx 8,1$: le cas R&D/brevets est environ 8 fois plus sévère, en VIF, que le pire cas rencontré

dans le modèle M4 du cours (Tanger, 2,08) — ce dernier restant, selon le cours, « parfaitement sain ». (e) Les VIF rencontrés en pratique s'étendent sur une échelle considérable : de 2,08 (données réelles saines, M4), à 16,9 (un cas réel de forte corrélation entre deux variables théoriquement proches, R&D/brevets, déjà « sérieux »), jusqu'à 8 084 (un cas **extrême**, fabriqué délibérément par le cours pour illustrer le phénomène à son paroxysme). Cette échelle montre qu'un VIF « sérieux » selon les repères usuels (> 10) reste, malgré tout, très loin des valeurs qu'une colinéarité **quasi parfaite** peut produire.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) Non, un VIF de 2,0 est très inférieur au seuil de 5 à partir duquel une surveillance est recommandée : « rien à signaler ».
- (b) Oui, les deux variables sont justifiées par des mécanismes distincts : le capital culturel transmis par le diplôme des parents n'est pas la même chose que les ressources matérielles associées à leur revenu, même si les deux tendent à être corrélées dans la population.
- (c) « Ne rien faire » est la plus appropriée : la multicollinéarité, ici modeste ($VIF \approx 2,0$) qui plus est, ne biaise rien, et les deux variables sont théoriquement justifiées — il n'y a donc aucune raison économique de les retirer, les combiner, ou de chercher davantage de données uniquement pour ce motif.
- (d) Retirer le revenu des parents créerait un problème de **variable omise** : si le revenu a un effet propre sur la réussite scolaire (ressources matérielles, accès à des activités éducatives, etc.) et qu'il est corrélé au diplôme des parents resté dans le modèle, son retrait biaiserait le coefficient du diplôme, qui absorberait alors une partie de l'effet du revenu retiré.

Correction — Exercice 6

- (a) C'est le symptôme d'un **nouveau problème**, pas un résultat plus propre : le passage d'un coefficient non significatif ($t = 1,1$) à un coefficient très significatif et bien plus élevé (310, $t = 8,2$) après le retrait d'une variable corrélée est le signe typique d'un biais de variable omise, pas d'une amélioration réelle de la précision.
- (b) Si l'ancienneté (retirée) est corrélée à l'âge (restée dans le modèle) et qu'elle a, par ailleurs, un effet propre sur le salaire, cet effet propre se retrouve entièrement absorbé dans le terme d'erreur du nouveau modèle — exactement le mécanisme du chapitre 2, où une variable omise corrélée à une variable incluse contamine l'erreur et biaise le coefficient estimé de cette dernière.
- (c) Il mesure désormais un **mélange** de l'effet propre de l'âge et de celui de l'ancienneté (qui lui est fortement corrélée) : ce n'est plus l'effet *ceteris paribus* de l'âge seul, mais un effet « contaminé » par tout ce que l'ancienneté, absente du nouveau modèle, aurait dû expliquer elle-même.
- (d) Le chercheur avait initialement un problème de **précision** (un VIF de 7,5, gênant mais sans biais, laissant le coefficient de l'âge imprécis mais toujours centré sur sa vraie valeur). En retirant l'ancienneté, il a échangé ce problème contre un problème de **biais** (un coefficient de l'âge désormais faussé, mais paraissant, à tort, plus « fiable » du fait de sa forte significativité). C'est précisément « le mauvais échange » dénoncé par le cours : une estimation imprécise mais juste vaut mieux qu'une estimation précise en apparence, mais fausse.