

Introduction à l'économétrie

Chapitre 13 : La multicollinéarité

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'économétrie

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Calculer et lire des VIF

Trois variables explicatives d'un modèle donnent, lorsqu'on les régresse chacune sur toutes les autres : $X_1, R_1^2 = 0,85$; $X_2, R_2^2 = 0,95$; $X_3, R_3^2 = 0,20$.

- (a) Calculer le VIF de chacune des trois variables.
- (b) Classer chacune selon les repères usuels du cours (« rien à signaler », « à surveiller », « sérieuse »).
- (c) Un VIF de 6,67 signifie que la variance du coefficient de X_1 est combien de fois plus grande qu'elle ne le serait si X_1 était indépendante des autres variables? Par quel facteur son écart-type est-il, en conséquence, multiplié?
- (d) X_3 , avec $R_3^2 = 0,20$, a-t-elle un problème de multicollinéarité? Justifier à partir du seuil usuel.

Exercice 2 — Les quatre symptômes, ensemble

Un modèle de salaire est estimé deux fois. Modèle A (sans la variable « expérience totale ») : coefficient de l'ancienneté $\hat{\beta} = 250$, écart-type 12, $R^2 = 0,620$. Modèle B (avec « expérience totale », très corrélée à l'ancienneté) : coefficient de l'ancienneté $\hat{\beta} = -30$, écart-type 980, $R^2 = 0,621$.

- (a) Calculer le rapport entre l'écart-type du modèle B et celui du modèle A . Ce gonflement correspond-il au premier symptôme du cours?
- (b) Le coefficient de l'ancienneté devient-il non significatif dans le modèle B (calculer $t = \hat{\beta}/\widehat{\sigma}(\hat{\beta})$ pour les deux modèles, seuil 1,96)?
- (c) Le signe du coefficient de l'ancienneté dans le modèle B est-il économiquement plausible? Quel symptôme cela illustre-t-il?
- (d) Comparer les deux R^2 . Le modèle a-t-il perdu en pouvoir prédictif entre A et B ? Qu'a-t-il, à la place, perdu?

Exercice 3 — Retirer, ou ne pas retirer?

Deux cas se présentent à un analyste.

- C_1 . Une variable « revenu du ménage en dirhams » et une variable « revenu du ménage en dollars » (la seconde n'étant que la première divisée par un taux de change constant) figurent, par erreur de saisie, toutes deux dans le même modèle.
 - C_2 . Une variable « niveau de diplôme des parents » et une variable « revenu des parents pendant l'enfance », fortement corrélées mais économiquement distinctes, figurent toutes deux dans un modèle de réussite scolaire, chacune justifiée par une théorie différente.
- (a) Pour C_1 : les deux variables apportent-elles une information réellement distincte? Est-il justifié de retirer l'une des deux?
 - (b) Pour C_2 : les deux variables sont-elles, elles aussi, redondantes au sens économique, ou chacune capture-t-elle un mécanisme différent malgré leur corrélation statistique?
 - (c) Le cours affirme : « retirer une variable uniquement si l'on peut justifier économiquement qu'elle n'a pas sa place ». Appliquer cette règle à C_1 , puis à C_2 .
 - (d) Pourquoi serait-il dangereux, dans le cas C_2 , de retirer l'une des deux variables uniquement parce que son VIF est élevé ou son t est faible?

2 Exercice cumulatif (chapitre 13 et chapitres précédents)

Exercice 4 — Quantifier la colinéarité de la R&D et des brevets

Le chapitre 9 (exercice 6) avait étudié un modèle à deux variables, R&D et brevets, corrélées à $r = 0,97$, qui produisait un F global significatif mais des t individuels non significatifs.

- (a) Avec seulement deux variables explicatives, le R^2_j de la régression de l'une sur l'autre est simplement r^2 . Calculer r^2 pour $r = 0,97$.
- (b) En déduire le VIF des deux variables (identique pour les deux, dans ce cas à deux variables).
- (c) Ce VIF dépasse-t-il le seuil de « multicollinéarité sérieuse » du cours (10) ?
- (d) Ce résultat quantifie, avec un chiffre précis, le diagnostic qualitatif déjà posé au chapitre 9 (« F significatif, t non significatifs, signature de la multicollinéarité »). Comparer ce VIF de 16,9 au VIF maximal du modèle M4 du cours (2,08, pour Tanger) : de quel ordre de grandeur le cas R&D/brevets est-il plus sévère ?
- (e) Le cours rapporte, pour un modèle artificiellement dégradé (M6), un VIF de 8 084 pour l'ancienneté. En comparant 16,9 (R&D/brevets), 2,08 (M4, Tanger) et 8 084 (M6, ancienneté), que peut-on dire de l'étendue des VIF rencontrés en pratique, du « sain » au « fabriqué pour l'exemple » ?

3 Applications en sciences économiques

Exercice 5 — Deux variables théoriquement justifiées, mais corrélées

Une étude sur la réussite scolaire inclut le diplôme des parents et leur revenu pendant l'enfance de l'élève, deux variables corrélées à $r = 0,70$ (VIF $\approx 2,0$ pour chacune, dans un modèle à plusieurs variables).

- (a) Un VIF de 2,0 appelle-t-il une action corrective, selon les repères usuels du cours ?
- (b) Ces deux variables sont-elles justifiées par des mécanismes économiques **distincts** (capital culturel transmis par le diplôme des parents, contre ressources matérielles associées au revenu) ?
- (c) Sachant que la multicollinéarité ne biaise rien et que ces deux variables sont théoriquement justifiées, laquelle des quatre options du cours (retirer, combiner, collecter plus de données, ne rien faire) est la plus appropriée ici ?
- (d) Si un étudiant proposait de « simplifier » le modèle en retirant le revenu des parents, quel risque le cours identifie-t-il précisément (indice : le nom du problème que cela créerait) ?

Exercice 6 — Le mauvais échange

Un chercheur, préoccupé par un VIF de 7,5 sur la variable « ancienneté dans l'entreprise » (corrélée à « âge du salarié », également dans le modèle), décide de retirer l'ancienneté. Le coefficient de l'âge, auparavant $\hat{\beta} = 45$ (non significatif, $t = 1,1$), devient, après le retrait, $\hat{\beta} = 310$ avec $t = 8,2$ (très significatif).

- (a) Le nouveau coefficient de l'âge (310, très significatif) est-il un résultat plus « propre », ou le symptôme d'un nouveau problème ?
- (b) Rappeler le mécanisme du chapitre 2 : que devient, dans le terme d'erreur, une variable retirée du modèle (ici, l'ancienneté) si elle est corrélée à la variable restante (l'âge) et qu'elle a, par ailleurs, un effet propre sur le salaire ?
- (c) Le coefficient de l'âge après retrait (310) mesure-t-il encore l'effet **propre** de l'âge, ou un mélange de l'effet de l'âge et de celui de l'ancienneté (qui lui est fortement corrélée) ?
- (d) En quoi cet exemple illustre-t-il très concrètement l'avertissement du cours : « c'est très exactement le mauvais échange » (échanger un problème de précision, sans biais, contre un problème de biais) ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) $VIF_1 = 1/(1 - 0,85) = 1/0,15 \approx 6,67$. $VIF_2 = 1/(1 - 0,95) = 1/0,05 = 20,0$. $VIF_3 = 1/(1 - 0,20) = 1/0,80 = 1,25$.
- (b) X_1 (6,67) : « à surveiller » (entre 5 et 10). X_2 (20,0) : « multicolinéarité sérieuse » (> 10). X_3 (1,25) : « rien à signaler » (< 5).
- (c) La variance du coefficient de X_1 est 6,67 fois plus grande qu'elle ne le serait si X_1 était indépendante des autres variables. Son écart-type, la racine carrée de la variance, est donc multiplié par $\sqrt{6,67} \approx 2,58$.
- (d) Non, X_3 n'a pas de problème de multicolinéarité significatif : son VIF de 1,25 est très inférieur au seuil de 5 à partir duquel le cours recommande de commencer à surveiller la situation.

Correction — Exercice 2

- (a) $980/12 \approx 81,7$: l'écart-type est multiplié par un facteur d'environ 82. Oui, ce gonflement massif correspond exactement au premier symptôme du cours.
- (b) Modèle A : $t = 250/12 \approx 20,8$ (très significatif). Modèle B : $t = -30/980 \approx -0,031$ (totalement non significatif). Oui, le coefficient devient non significatif dans le modèle B.
- (c) Non, un coefficient **négalif** pour l'ancienneté n'est pas économiquement plausible (on n'attend pas qu'une ancienneté plus grande réduise le salaire). Cela illustre le troisième symptôme : des coefficients qui prennent des valeurs absurdes.
- (d) Les deux R^2 sont pratiquement identiques (0,620 contre 0,621) : le modèle n'a **pas** perdu de pouvoir prédictif. Il a perdu, à la place, sa capacité à **attribuer** l'effet à l'une ou l'autre des deux variables corrélées — exactement le quatrième symptôme, le plus révélateur selon le cours.

Correction — Exercice 3

- (a) Non, les deux variables de C_1 n'apportent **aucune** information distincte : l'une est une transformation exacte (linéaire) de l'autre. Il est parfaitement justifié de retirer l'une des deux — ce n'est même pas un cas de multicolinéarité « imparfaite » au sens du chapitre, mais un doublon pur et simple, proche d'une colinéarité parfaite (H5).
- (b) Non, les deux variables de C_2 ne sont pas redondantes au sens économique : chacune capture un mécanisme **distinct** (capital culturel pour le diplôme des parents, ressources matérielles pour le revenu), même si elles sont statistiquement corrélées dans l'échantillon.
- (c) Pour C_1 : retirer l'une des deux variables est justifié, puisqu'elle n'a économiquement **aucune** place propre dans le modèle (c'est un doublon, pas une variable distincte). Pour C_2 : aucune des deux ne doit être retirée sur ce seul critère, puisque chacune est justifiée par un mécanisme économique différent, quelle que soit leur corrélation statistique.
- (d) Retirer l'une des deux variables de C_2 uniquement à cause d'un VIF élevé ou d'un t faible reviendrait à créer une **variable omise** : si la variable retirée a un effet propre sur la réussite scolaire (ce qui est probable, étant justifiée par un mécanisme distinct), son absence contaminera le terme d'erreur et biaiserait le coefficient de la variable restante, corrélée à elle — un problème de biais bien plus grave que le problème de précision qu'on cherchait à corriger.

2 Exercice cumulatif

Correction — Exercice 4

- (a) $r^2 = 0,97^2 = 0,9409$.
- (b) $VIF = 1/(1 - 0,9409) = 1/0,0591 \approx 16,92$.
- (c) Oui, $16,92 > 10$: ce VIF dépasse le seuil de « multicolinéarité sérieuse ».
- (d) $16,92/2,08 \approx 8,1$: le cas R&D/brevets est environ 8 fois plus sévère, en VIF, que le pire cas rencontré

dans le modèle M4 du cours (Tanger, 2,08) — ce dernier restant, selon le cours, « parfaitement sain ». (e) Les VIF rencontrés en pratique s'étendent sur une échelle considérable : de 2,08 (données réelles saines, M4), à 16,9 (un cas réel de forte corrélation entre deux variables théoriquement proches, R&D/brevets, déjà « sérieux »), jusqu'à 8 084 (un cas **extrême**, fabriqué délibérément par le cours pour illustrer le phénomène à son paroxysme). Cette échelle montre qu'un VIF « sérieux » selon les repères usuels (> 10) reste, malgré tout, très loin des valeurs qu'une colinéarité **quasi parfaite** peut produire.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) Non, un VIF de 2,0 est très inférieur au seuil de 5 à partir duquel une surveillance est recommandée : « rien à signaler ».
- (b) Oui, les deux variables sont justifiées par des mécanismes distincts : le capital culturel transmis par le diplôme des parents n'est pas la même chose que les ressources matérielles associées à leur revenu, même si les deux tendent à être corrélées dans la population.
- (c) « Ne rien faire » est la plus appropriée : la multicollinéarité, ici modeste ($VIF \approx 2,0$) qui plus est, ne biaise rien, et les deux variables sont théoriquement justifiées — il n'y a donc aucune raison économique de les retirer, les combiner, ou de chercher davantage de données uniquement pour ce motif.
- (d) Retirer le revenu des parents créerait un problème de **variable omise** : si le revenu a un effet propre sur la réussite scolaire (ressources matérielles, accès à des activités éducatives, etc.) et qu'il est corrélé au diplôme des parents resté dans le modèle, son retrait biaiserait le coefficient du diplôme, qui absorberait alors une partie de l'effet du revenu retiré.

Correction — Exercice 6

- (a) C'est le symptôme d'un **nouveau problème**, pas un résultat plus propre : le passage d'un coefficient non significatif ($t = 1,1$) à un coefficient très significatif et bien plus élevé ($310, t = 8,2$) après le retrait d'une variable corrélée est le signe typique d'un biais de variable omise, pas d'une amélioration réelle de la précision.
- (b) Si l'ancienneté (retirée) est corrélée à l'âge (restée dans le modèle) et qu'elle a, par ailleurs, un effet propre sur le salaire, cet effet propre se retrouve entièrement absorbé dans le terme d'erreur du nouveau modèle — exactement le mécanisme du chapitre 2, où une variable omise corrélée à une variable incluse contamine l'erreur et biaise le coefficient estimé de cette dernière.
- (c) Il mesure désormais un **mélange** de l'effet propre de l'âge et de celui de l'ancienneté (qui lui est fortement corrélée) : ce n'est plus l'effet *ceteris paribus* de l'âge seul, mais un effet « contaminé » par tout ce que l'ancienneté, absente du nouveau modèle, aurait dû expliquer elle-même.
- (d) Le chercheur avait initialement un problème de **précision** (un VIF de 7,5, gênant mais sans biais, laissant le coefficient de l'âge imprécis mais toujours centré sur sa vraie valeur). En retirant l'ancienneté, il a échangé ce problème contre un problème de **biais** (un coefficient de l'âge désormais faussé, mais paraissant, à tort, plus « fiable » du fait de sa forte significativité). C'est précisément « le mauvais échange » dénoncé par le cours : une estimation imprécise mais juste vaut mieux qu'une estimation précise en apparence, mais fausse.