

Chapitre 13

La multicolinéarité

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Économétrie — Introduction

1 Exercices du chapitre

Exercice 1 — Calculer et lire des VIF

Trois variables explicatives d'un modèle donnent, lorsqu'on les régresse chacune sur toutes les autres : $X_1, R_1^2 = 0,85$; $X_2, R_2^2 = 0,95$; $X_3, R_3^2 = 0,20$.

- (a) Calculer le VIF de chacune des trois variables.
- (b) Classer chacune selon les repères usuels du cours (« rien à signaler », « à surveiller », « sérieuse »).
- (c) Un VIF de 6,67 signifie que la variance du coefficient de X_1 est combien de fois plus grande qu'elle ne le serait si X_1 était indépendante des autres variables? Par quel facteur son écart-type est-il, en conséquence, multiplié?
- (d) X_3 , avec $R_3^2 = 0,20$, a-t-elle un problème de multicollinéarité? Justifier à partir du seuil usuel.

Exercice 2 — Les quatre symptômes, ensemble

Un modèle de salaire est estimé deux fois. Modèle A (sans la variable « expérience totale ») : coefficient de l'ancienneté $\hat{\beta} = 250$, écart-type 12, $R^2 = 0,620$. Modèle B (avec « expérience totale », très corrélée à l'ancienneté) : coefficient de l'ancienneté $\hat{\beta} = -30$, écart-type 980, $R^2 = 0,621$.

- (a) Calculer le rapport entre l'écart-type du modèle B et celui du modèle A . Ce gonflement correspond-il au premier symptôme du cours?
- (b) Le coefficient de l'ancienneté devient-il non significatif dans le modèle B (calculer $t = \hat{\beta}/\widehat{\sigma}(\hat{\beta})$ pour les deux modèles, seuil 1,96)?
- (c) Le signe du coefficient de l'ancienneté dans le modèle B est-il économiquement plausible? Quel symptôme cela illustre-t-il?
- (d) Comparer les deux R^2 . Le modèle a-t-il perdu en pouvoir prédictif entre A et B ? Qu'a-t-il, à la place, perdu?

Exercice 3 — Retirer, ou ne pas retirer?

Deux cas se présentent à un analyste.

- C_1 . Une variable « revenu du ménage en dirhams » et une variable « revenu du ménage en dollars » (la seconde n'étant que la première divisée par un taux de change constant) figurent, par erreur de saisie, toutes deux dans le même modèle.
 - C_2 . Une variable « niveau de diplôme des parents » et une variable « revenu des parents pendant l'enfance », fortement corrélées mais économiquement distinctes, figurent toutes deux dans un modèle de réussite scolaire, chacune justifiée par une théorie différente.
- (a) Pour C_1 : les deux variables apportent-elles une information réellement distincte? Est-il justifié de retirer l'une des deux?
 - (b) Pour C_2 : les deux variables sont-elles, elles aussi, redondantes au sens économique, ou chacune capture-t-elle un mécanisme différent malgré leur corrélation statistique?
 - (c) Le cours affirme : « retirer une variable uniquement si l'on peut justifier économiquement qu'elle n'a pas sa place ». Appliquer cette règle à C_1 , puis à C_2 .
 - (d) Pourquoi serait-il dangereux, dans le cas C_2 , de retirer l'une des deux variables uniquement parce que son VIF est élevé ou son t est faible?

2 Exercice cumulatif (chapitre 13 et chapitres précédents)

Exercice 4 — Quantifier la colinéarité de la R&D et des brevets

Le chapitre 9 (exercice 6) avait étudié un modèle à deux variables, R&D et brevets, corrélées à $r = 0,97$, qui produisait un F global significatif mais des t individuels non significatifs.

- (a) Avec seulement deux variables explicatives, le R_j^2 de la régression de l'une sur l'autre est simplement r^2 . Calculer r^2 pour $r = 0,97$.
- (b) En déduire le VIF des deux variables (identique pour les deux, dans ce cas à deux variables).
- (c) Ce VIF dépasse-t-il le seuil de « multicollinéarité sérieuse » du cours (10) ?
- (d) Ce résultat quantifie, avec un chiffre précis, le diagnostic qualitatif déjà posé au chapitre 9 (« F significatif, t non significatifs, signature de la multicollinéarité »). Comparer ce VIF de 16,9 au VIF maximal du modèle M4 du cours (2,08, pour Tanger) : de quel ordre de grandeur le cas R&D/brevets est-il plus sévère ?
- (e) Le cours rapporte, pour un modèle artificiellement dégradé (M6), un VIF de 8084 pour l'ancienneté. En comparant 16,9 (R&D/brevets), 2,08 (M4, Tanger) et 8084 (M6, ancienneté), que peut-on dire de l'étendue des VIF rencontrés en pratique, du « sain » au « fabriqué pour l'exemple » ?

3 Applications en sciences économiques

Exercice 5 — Deux variables théoriquement justifiées, mais corrélées

Une étude sur la réussite scolaire inclut le diplôme des parents et leur revenu pendant l'enfance de l'élève, deux variables corrélées à $r = 0,70$ (VIF $\approx 2,0$ pour chacune, dans un modèle à plusieurs variables).

- (a) Un VIF de 2,0 appelle-t-il une action corrective, selon les repères usuels du cours ?
- (b) Ces deux variables sont-elles justifiées par des mécanismes économiques **distincts** (capital culturel transmis par le diplôme des parents, contre ressources matérielles associées au revenu) ?
- (c) Sachant que la multicollinéarité ne biaise rien et que ces deux variables sont théoriquement justifiées, laquelle des quatre options du cours (retirer, combiner, collecter plus de données, ne rien faire) est la plus appropriée ici ?
- (d) Si un étudiant proposait de « simplifier » le modèle en retirant le revenu des parents, quel risque le cours identifie-t-il précisément (indice : le nom du problème que cela créerait) ?

Exercice 6 — Le mauvais échange

Un chercheur, préoccupé par un VIF de 7,5 sur la variable « ancienneté dans l'entreprise » (corrélée à « âge du salarié », également dans le modèle), décide de retirer l'ancienneté. Le coefficient de l'âge, auparavant $\hat{\beta} = 45$ (non significatif, $t = 1,1$), devient, après le retrait, $\hat{\beta} = 310$ avec $t = 8,2$ (très significatif).

- (a) Le nouveau coefficient de l'âge (310, très significatif) est-il un résultat plus « propre », ou le symptôme d'un nouveau problème ?
- (b) Rappeler le mécanisme du chapitre 2 : que devient, dans le terme d'erreur, une variable retirée du modèle (ici, l'ancienneté) si elle est corrélée à la variable restante (l'âge) et qu'elle a, par ailleurs, un effet propre sur le salaire ?
- (c) Le coefficient de l'âge après retrait (310) mesure-t-il encore l'effet **propre** de l'âge, ou un mélange de l'effet de l'âge et de celui de l'ancienneté (qui lui est fortement corrélée) ?
- (d) En quoi cet exemple illustre-t-il très concrètement l'avertissement du cours : « c'est très exactement le mauvais échange » (échanger un problème de précision, sans biais, contre un problème de biais) ?