Introduction à l'économétrie

Chapitre 13 : La multicolinéarité

Jaouad Madkour

29 octobre 2026

Plan du chapitre

Le problème **2**
Ce dont il s'agit . . . 2
La démonstration . . . 2
Comment la démonstration a été fabriquée . . . 2
Les quatre symptômes . . . 3

La mesurer **3**
Le facteur d'inflation de la variance . . . 3
Sur les cinq ménages . . . 4
Le VIF, de 1 à l'infini . . . 4
Sur nos données . . . 4
Comment le lire . . . 5

Que faire **5**
Les remèdes, dans l'ordre . . . 5
Le piège du remède . . . 6
Le cas des années et des mois . . . 6

Sur machine **6**
La multicolinéarité fabriquée, avec R . . . 6
Les VIF de M4 avec Python . . . 7
Deux présentations du même diagnostic . . . 7

S'entraîner **7**
Exercice 1 : du R^2 au VIF . . . 7
Exercice 1 : solution . . . 7
Exercice 2 : symptômes sur une sortie . . . 8
Exercice 2 : solution . . . 8
Exercice 3 : retirer ou garder . . . 8
Exercice 3 : solution . . . 8

Ce qu'il faut retenir **9**
Le résumé du chapitre . . . 9

Le problème

Ce dont il s'agit

Multicolinéarité

Deux ou plusieurs variables explicatives sont **fortement liées entre elles**, sans l'être parfaitement.
Le calcul aboutit — H5 n'est pas violée — mais il devient instable.

La question à laquelle on ne peut plus répondre

Le *ceteris paribus* demande l'effet d'une variable **les autres étant constantes**.
Si deux variables bougent toujours ensemble, les données ne contiennent aucune observation où l'une varie et pas l'autre. **On demande au modèle de séparer ce que les données n'ont jamais séparé.**

La démonstration

on ajoute la *même* variable, en mois à un mois près : corrélation 0,99994, VIF = 7 695

	M2 — ancienneté en années		**M6** — années *et* mois	
	coefficient	t	coefficient	t
Ancienneté (années)	270,27	23,06	−1 040,25	−1,01
Ancienneté (mois)	—	—	109,24	1,28
Bac+2	1 099,57	6,93	1 102,44	6,96
Bac+5	3 336,99	18,11	3 338,28	18,13
R^2	0,6418		0,6429	

Les quatre symptômes de la multicolinéarité, tous visibles ici.

1. Les coefficients deviennent *absurdes* : une année d'ancienneté ferait perdre 1 040 dirhams. **2.** Ils deviennent *non significatifs* alors que la variable compte manifestement. **3.** Les écarts-types *explosent* : 1 026 contre 11,72. **4.** Le R^2, lui, ne bouge pas — il monte même très légèrement.

Le diagnostic tient dans cette dernière ligne. Le modèle prédit toujours aussi bien ; il est simplement devenu incapable de *séparer* les rôles. Demander l'effet des années à mois constants n'a aucun sens : c'est la même information deux fois.

Remèdes : retirer l'une des deux, les combiner, ou ne rien faire si le coefficient litigieux n'est pas celui qui intéresse. La multicolinéarité ne biaise rien — elle rend seulement imprécis.

Comment la démonstration a été fabriquée

Une variable presque copiée

On crée l'ancienneté **en mois**, à un mois près : 12× années, plus −1, 0 ou +1 selon le numéro du salarié. La corrélation avec l'ancienneté en années vaut 0,999935.

Ensemble, les deux variables comptent massivement

Séparément, aucun des deux t n'est significatif : −1,01 et 1,28. Mais le Fisher partiel qui les retire **ensemble** donne $F = 267$, avec $q = 2$. L'information est là ; c'est son **attribution** qui est impossible — le cas d'école du chapitre 9.

Les quatre symptômes

Ils vont ensemble

1. Les **écarts-types explosent** : 1 026 contre 11,72.
2. Les coefficients deviennent **non significatifs** alors que les variables comptent.
3. Ils prennent des valeurs **absurdes** — ici, un signe négatif pour l'ancienneté.
4. Le R^2 **ne bouge pas** : 0,6418 contre 0,6429.

Le quatrième est le plus révélateur

Le modèle prédit toujours aussi bien. Il a seulement perdu la capacité d'**attribuer**. C'est exactement le cas d'école du chapitre 9 : un F global significatif avec des t individuels qui ne le sont pas.

La mesurer

Le facteur d'inflation de la variance

Sa définition

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$

où R_j^2 est le R^2 de la régression de x_j sur **toutes les autres** variables explicatives.

D'où vient son nom

L'erreur-type d'un coefficient s'écrit

$$V(\hat{\beta}_j) = \frac{\sigma_\varepsilon^2}{S_{jj}\,(1 - R_j^2)} = \frac{\sigma_\varepsilon^2}{S_{jj}} \times \text{VIF}_j$$

La variance est celle qu'on aurait si x_j était indépendant des autres, **multipliée** par le VIF. C'est la formule de Frisch-Waugh : seule la part de x_j non expliquée par les autres, $S_{jj}(1 - R_j^2)$, sert à l'estimer.

Démonstration : Le facteur d'inflation de la variance : $V(\hat{\beta}_j) = \sigma_\varepsilon^2/(S_{jj}(1 - R_j^2))$

Soit u le résidu de la régression de x_j sur toutes les autres colonnes de X, constante comprise. On a vu (démonstrations de Frisch-Waugh, chapitre 7, et de la loi de Student, chapitre 9) que $\hat{\beta}_j = \beta_j + \sum_i u_i \varepsilon_i / \sum_i u_i^2$. Les erreurs étant non corrélées et de même variance,

$$V(\hat{\beta}_j) = \frac{\sigma_\varepsilon^2}{\sum_i u_i^2}.$$

Or $\sum_i u_i^2$ est la somme des carrés résiduels de la régression de x_j sur les autres variables. Cette régression a pour somme des carrés totale $S_{jj} = \sum_i (x_{ji} - \overline{x}_j)^2$ et pour coefficient de détermination R_j^2, donc $\sum_i u_i^2 = S_{jj}\,(1 - R_j^2)$ et

$$V(\hat{\beta}_j) = \frac{\sigma_\varepsilon^2}{S_{jj}(1 - R_j^2)} = \frac{\sigma_\varepsilon^2}{S_{jj}} \times \frac{1}{1 - R_j^2} = \frac{\sigma_\varepsilon^2}{S_{jj}} \times \text{VIF}_j.$$

Puisque $0 \leq R_j^2 < 1$ tant que H5 tient, $\text{VIF}_j \geq 1$: les autres variables ne peuvent que gonfler la variance. Avec deux explicatives, R_j^2 est le r^2 entre elles (chapitre 4). Sur les cinq ménages, $\sum_i u_i^2 = 20 = 40 \times (1 - 0{,}5)$: $\hat{\sigma}(\hat{\beta}_R) = \sqrt{2{,}5/20} = 0{,}354$.

■

Sur les cinq ménages

Revenu et taille

La régression du revenu sur la taille donne $r^2 = 20^2/(40 \times 20) = 0{,}5$: $\text{VIF} = 1/(1 - 0{,}5) = 2$.

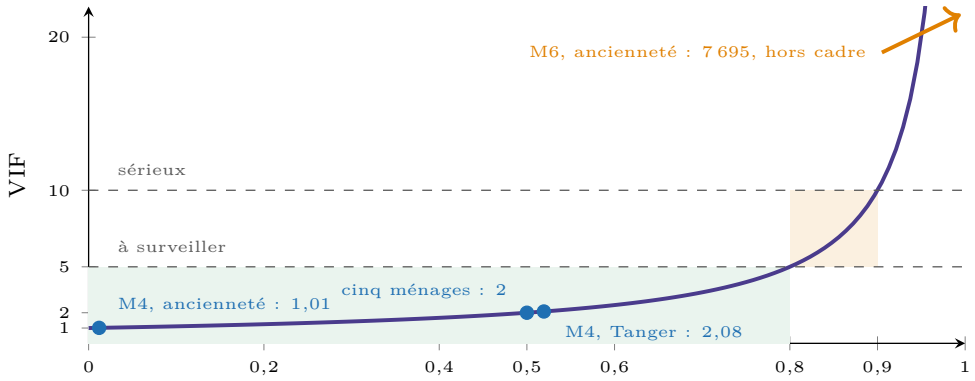
$$\hat{\sigma}(\hat{\beta}_R) = \sqrt{\frac{2{,}5}{40 \times 0{,}5}} = \sqrt{0{,}125} = 0{,}354 \quad \text{au lieu de} \quad \sqrt{\frac{2{,}5}{40}} = 0{,}25$$

Un facteur racine de deux

Le VIF multiplie la **variance** par 2, donc l'erreur-type par $\sqrt{2} = 1{,}41$. C'est la hausse vue au chapitre 9, de 0,25 à 0,354 — qui avait fait tomber le t du revenu de 3 à 1,41, avec la baisse du coefficient.

Le VIF, de 1 à l'infini

$\text{VIF}_j = 1/(1 - R_j^2)$: lent au début, explosif à la fin



R_j^2 : part de x_j expliquée par les autres variables

Sur nos données

Quatre VIF

Modèle	Variable	R_j^2	VIF
M4	ancienneté	0,012	1,01
M4	Casablanca	0,492	1,97
M4	Tanger	0,519	2,08

M6	ancienneté	0,99987	7 695

Pourquoi les régions ont un VIF de 2

Les trois indicatrices régionales sont liées entre elles **par construction** : un salarié qui n'est ni à Rabat ni à Tanger a de bonnes chances d'être à Casablanca. Un VIF autour de 2 pour un groupe d'indicatrices est normal, et sans conséquence.

Comment le lire

Les repères usuels

VIF	Lecture
< 5	rien à signaler
5 à 10	à surveiller
> 10	multicolinéarité sérieuse

Ce que le VIF signifie littéralement

Un VIF de 4 signifie que la variance du coefficient est **quatre fois** plus grande qu'elle ne le serait si la variable était indépendante des autres. L'écart-type est donc doublé.
Notre modèle M4 est parfaitement sain : le plus grand VIF vaut 2,08. **La multicolinéarité n'est pas un problème dans nos données réelles — il a fallu la fabriquer pour la montrer.**

Que faire

Les remèdes, dans l'ordre

Quatre options

1. **Retirer** l'une des variables redondantes.
2. Les **combiner** en un indice unique.
3. **Collecter plus de données** — cela réduit toutes les variances.
4. **Ne rien faire.**

La quatrième option est légitime, et souvent la bonne

La multicolinéarité **ne biaise rien**. Les prévisions restent excellentes, le R^2 est intact, et les coefficients non touchés par le problème restent parfaitement estimés.
Si le coefficient qui vous intéresse n'est pas parmi ceux qui sont brouillés, **il n'y a rien à corriger**. Sur notre modèle M6, les coefficients du diplôme sont inchangés à quelques dirhams près.

Le piège du remède

Retirer une variable est plus dangereux que la garder

Supprimer une variable colinéaire pour « nettoyer » le modèle revient à créer une **variable omise**.
On échange alors un problème de précision — sans biais — contre un problème de biais.
C'est très exactement le mauvais échange, et le chapitre 16 dira pourquoi.

La règle de décision

Retirer une variable uniquement si l'on peut justifier **économiquement** qu'elle n'a pas sa place dans le modèle.
Jamais parce que son t est faible, jamais parce que son VIF est élevé. **La spécification se décide sur la théorie, pas sur les diagnostics.**

Le cas des années et des mois

Ici, retirer est légitime

Années et mois mesurent **la même chose** : la théorie ne prévoit aucun effet des mois « à années égales ». Retirer les mois ne crée aucune variable omise, puisque l'information est déjà dans les années.

Ce qui distingue ce cas de celui des cinq ménages

Revenu et taille sont liés (VIF $= 2$), mais ce sont **deux causes distinctes** de la consommation. Retirer la taille ferait remonter la pente du revenu de 0,5 à 0,75 : un biais de 0,25, que le chapitre 16 calculera exactement.

Sur machine

La multicolinéarité fabriquée, avec R

```
sal <- read.csv("salaires.csv", stringsAsFactors = TRUE)
sal$mois <- 12 * sal$anciennete + (sal$id %% 3 - 1)  # mois
cor(sal$anciennete, sal$mois)
# [1] 0.999935
m6 <- lm(salaire ~ anciennete + mois + diplome, data = sal)
round(summary(m6)$coefficients[c("anciennete", "mois"), ], 2)
#             Estimate Std. Error t value Pr(>|t|)
# anciennete -1040.25    1026.27   -1.01     0.31
# mois         109.24      85.54    1.28     0.20
car::vif(m6)                      # GVIF pour le facteur diplôme
#                  GVIF Df GVIF^(1/(2*Df))
# anciennete 7695.099103  1       87.721714
# mois       7695.149209  1       87.722000
# diplome       1.002594  2        1.000648
```

Les VIF de M4 avec Python

```
import pandas as pd
import statsmodels.formula.api as smf
from statsmodels.stats.outliers_influence import \
    variance_inflation_factor as vif
sal = pd.read_csv("salaires.csv")
f = "salaire ~ anciennete + diplome + sexe + region"
X = smf.ols(f, data=sal).fit().model
v = pd.Series([vif(X.exog, j) for j in range(1, 8)],
              index=X.exog_names[1:]).round(2)
print(v.tolist())                  # dans l'ordre des colonnes
# [1.17, 1.18, 1.01, 1.97, 1.81, 2.08, 1.01]
print(v.idxmax(), v.max())
# region[T.Tanger-Tetouan] 2.08
```

Deux présentations du même diagnostic

Par colonne ou par variable

Python : un VIF par **colonne**. R, avec `car::vif` : un VIF **généralisé** par variable, qui regroupe les indicatrices d'un facteur — 1,003 pour le diplôme de M6.

Le VIF ne regarde que les explicatives

Il se calcule **sans** la variable expliquée : c'est une propriété du plan d'observation, pas du modèle. On peut donc le calculer avant toute estimation, pour savoir si les données permettront de séparer les effets.

S'entraîner

Exercice 1 : du R² au VIF

Quatre degrés de liaison

Pour $R_j^2 = 0{,}5$; 0,8 ; 0,9 ; 0,99 :

1. Calculer le VIF.
2. Par combien l'erreur-type du coefficient est-elle multipliée ?
3. Combien d'observations supplémentaires faudrait-il, en proportion, pour compenser le VIF de 0,9 ?

Exercice 1 : solution

Tout se joue au-delà de 0,9

1. VIF : 2 ; 5 ; 10 ; 100.
2. Erreur-type multipliée par $\sqrt{\text{VIF}}$: 1,41 ; 2,24 ; 3,16 ; 10.
3. La variance baisse comme $1/n$: il faut **dix fois** plus d'observations pour compenser un VIF de 10. C'est pourquoi « collecter plus de données » est le remède sûr, et rarement le remède possible.

Exercice 2 : symptômes sur une sortie

Un modèle de demande

On explique les ventes de 40 magasins par le prix du produit et le prix moyen des concurrents, corrélés à 0,97. Résultat : $R^2 = 0{,}81$, $F = 79$, mais aucun des deux t ne dépasse 1,2, et le prix propre a un signe positif.

1. Calculer le VIF de chaque prix.
2. Quels symptômes reconnaît-on ?
3. Que conseiller ?

Exercice 2 : solution

Tous les symptômes, une variable théorique

1. Avec deux variables, $R_j^2 = 0{,}97^2 = 0{,}941$: VIF $= 1/0{,}059 = 16{,}9$.
2. F très significatif, t effondrés, signe absurde, R^2 élevé : le tableau complet.
3. Ne pas retirer un des prix : la théorie de la demande exige les deux. Mieux vaut estimer l'effet du **prix relatif** — un indice qui combine les deux — ou réunir des magasins où les deux prix varient indépendamment.

Exercice 3 : retirer ou garder

Trois paires de variables liées

Pour chaque paire, faut-il retirer l'une des deux ?

1. Le poids d'un colis en kilogrammes et en grammes.
2. L'âge et l'expérience professionnelle d'un salarié.
3. Le revenu et la taille du ménage, dans la fonction de consommation.

Exercice 3 : solution

Une seule paire est redondante

1. **Oui** : c'est la même grandeur dans deux unités — colinéarité parfaite, le calcul est même impossible.
2. **Non**, en général : ce sont deux mécanismes distincts — vieillissement et accumulation de savoir-faire — même s'ils sont liés. On garde les deux et l'on accepte des coefficients moins précis.
3. **Non** : deux causes distinctes de la consommation, avec un VIF de 2 seulement. Retirer la taille biaiserait la pente du revenu.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. La multicolinéarité, c'est demander de **séparer ce que les données n'ont jamais séparé**.
2. Quatre symptômes : écarts-types gonflés, t effondrés, coefficients absurdes, R^2 intact.
3. $V(\hat{\beta}_j) = \sigma_\varepsilon^2 / S_{jj} \times \text{VIF}_j$: cinq ménages, VIF $= 2$, erreur-type $\times 1{,}41$.
4. Au-delà de 10, c'est sérieux. Nos données réelles : 2,08 au plus.
5. **Elle ne biaise rien** : ne rien faire est souvent la bonne décision.
6. Retirer une variable colinéaire crée une **variable omise**, sauf si elle mesure la même chose.

La suite

Passons à une violation qui, elle, est présente dans presque toutes les données individuelles — et que nos salaires exhibent de façon spectaculaire : l'**hétéroscédasticité**.