# Introduction à l'économétrie

Chapitre 13 : La multicolinéarité

Jaouad Madkour

23 octobre 2026

## Plan du chapitre

**Le problème** **2**
Ce dont il s'agit . . . 2
La démonstration . . . 2
Comment la démonstration a été fabriquée . . . 2
Les quatre symptômes . . . 3

**La mesurer** **3**
Le facteur d'inflation de la variance . . . 3
Sur les cinq ménages . . . 3
Le VIF, de 1 à l'infini . . . 4
Sur nos données . . . 4
Comment le lire . . . 4

**Que faire** **5**
Les remèdes, dans l'ordre . . . 5
Le piège du remède . . . 5
Le cas des années et des mois . . . 5

**Sur machine** **6**
La multicolinéarité fabriquée, avec R . . . 6
Les VIF de M4 avec Python . . . 6
Deux présentations du même diagnostic . . . 7

**S'entraîner** **7**
Exercice 1 : du $R^2$ au VIF . . . 7
Exercice 1 : solution . . . 7
Exercice 2 : symptômes sur une sortie . . . 7
Exercice 2 : solution . . . 8
Exercice 3 : retirer ou garder . . . 8
Exercice 3 : solution . . . 8

**Ce qu'il faut retenir** **8**
Le résumé du chapitre . . . 8

# Le problème

## Ce dont il s'agit

**Multicolinéarité**

Deux ou plusieurs variables explicatives sont **fortement liées entre elles**, sans l'être parfaitement.
Le calcul aboutit — H5 n'est pas violée — mais il devient instable.

**La question à laquelle on ne peut plus répondre**

Le *ceteris paribus* demande l'effet d'une variable **les autres étant constantes**.
Si deux variables bougent toujours ensemble, les données ne contiennent aucune observation où l'une varie et pas l'autre. **On demande au modèle de séparer ce que les données n'ont jamais séparé.**

## La démonstration

on ajoute la *même* variable, en mois à un mois près : corrélation 0,99994, VIF = 7 695

| | **M2** — ancienneté en années | | **M6** — années *et* mois | |
|---|---|---|---|---|
| | coefficient | $t$ | coefficient | $t$ |
| Ancienneté (années) | 270,27 | 23,06 | −1 040,25 | −1,01 |
| Ancienneté (mois) | — | — | 109,24 | 1,28 |
| Bac+2 | 1 099,57 | 6,93 | 1 102,44 | 6,96 |
| Bac+5 | 3 336,99 | 18,11 | 3 338,28 | 18,13 |
| $R^2$ | 0,6418 | | 0,6429 | |

**Les quatre symptômes de la multicolinéarité, tous visibles ici.**

**1.** Les coefficients deviennent *absurdes* : une année d'ancienneté ferait perdre 1 040 dirhams. **2.** Ils deviennent *non significatifs* alors que la variable compte manifestement. **3.** Les écarts-types *explosent* : 1 026 contre 11,72. **4.** Le $R^2$, lui, ne bouge pas — il monte même très légèrement.

**Le diagnostic tient dans cette dernière ligne.** Le modèle prédit toujours aussi bien ; il est simplement devenu incapable de *séparer* les rôles. Demander l'effet des années à mois constants n'a aucun sens : c'est la même information deux fois.

Remèdes : retirer l'une des deux, les combiner, ou ne rien faire si le coefficient litigieux n'est pas celui qui intéresse. La multicolinéarité ne biaise rien — elle rend seulement imprécis.

## Comment la démonstration a été fabriquée

**Une variable presque copiée**

On crée l'ancienneté **en mois**, à un mois près : 12× années, plus −1, 0 ou +1 selon le numéro du salarié. La corrélation avec l'ancienneté en années vaut 0,999935.

**Ensemble, les deux variables comptent massivement**

Séparément, aucun des deux $t$ n'est significatif : −1,01 et 1,28. Mais le Fisher partiel qui les retire **ensemble** donne $F = 267$, avec $q = 2$. L'information est là ; c'est son **attribution** qui est impossible — le cas d'école du chapitre 9.

### Les quatre symptômes

**Ils vont ensemble**

1. Les **écarts-types explosent** : 1 026 contre 11,72.
2. Les coefficients deviennent **non significatifs** alors que les variables comptent.
3. Ils prennent des valeurs **absurdes** — ici, un signe négatif pour l'ancienneté.
4. Le $R^2$ **ne bouge pas** : 0,6418 contre 0,6429.

**Le quatrième est le plus révélateur**

Le modèle prédit toujours aussi bien. Il a seulement perdu la capacité d'**attribuer**. C'est exactement le cas d'école du chapitre 9 : un $F$ global significatif avec des $t$ individuels qui ne le sont pas.

## La mesurer

### Le facteur d'inflation de la variance

**Sa définition**

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$

où $R_j^2$ est le $R^2$ de la régression de $x_j$ sur **toutes les autres** variables explicatives.

**D'où vient son nom**

L'erreur-type d'un coefficient s'écrit

$$V(\hat{\beta}_j) = \frac{\sigma_\varepsilon^2}{S_{jj}\,(1 - R_j^2)} = \frac{\sigma_\varepsilon^2}{S_{jj}} \times \text{VIF}_j$$

La variance est celle qu'on aurait si $x_j$ était indépendant des autres, **multipliée** par le VIF. C'est la formule de Frisch-Waugh : seule la part de $x_j$ non expliquée par les autres, $S_{jj}(1 - R_j^2)$, sert à l'estimer.

### Sur les cinq ménages

**Revenu et taille**

La régression du revenu sur la taille donne $r^2 = 20^2/(40 \times 20) = 0{,}5$ : VIF $= 1/(1 - 0{,}5) = 2$.

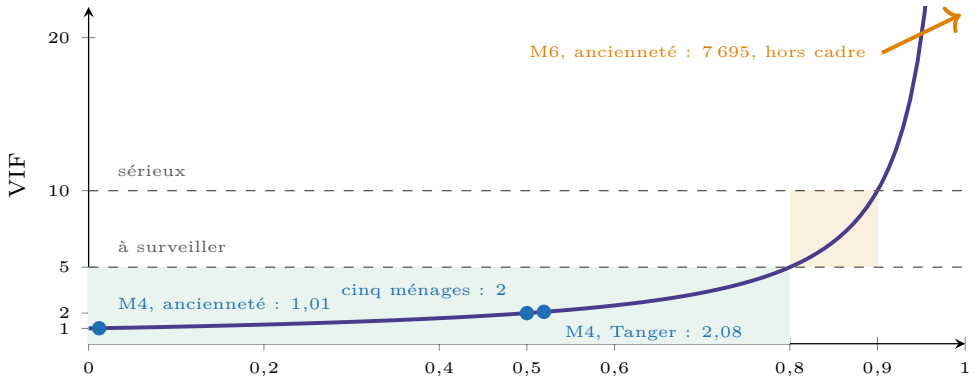
$$\hat{\sigma}(\hat{\beta}_R) = \sqrt{\frac{2{,}5}{40 \times 0{,}5}} = \sqrt{0{,}125} = 0{,}354 \quad \text{au lieu de} \quad \sqrt{\frac{2{,}5}{40}} = 0{,}25$$

**Un facteur racine de deux**

Le VIF multiplie la **variance** par 2, donc l'erreur-type par $\sqrt{2} = 1{,}41$. C'est la hausse vue au chapitre 9, de 0,25 à 0,354 — qui avait fait tomber le $t$ du revenu de 3 à 1,41, avec la baisse du coefficient.

## Le VIF, de 1 à l'infini

$\text{VIF}_j = 1/(1 - R_j^2)$ : lent au début, explosif à la fin




$R_j^2$ : part de $x_j$ expliquée par les autres variables

## Sur nos données

**Quatre VIF**

| Modèle | Variable | $R_j^2$ | VIF |
|---|---|---|---|
| M4 | ancienneté | 0,012 | 1,01 |
| M4 | Casablanca | 0,492 | 1,97 |
| M4 | Tanger | 0,519 | 2,08 |
| M6 | ancienneté | 0,99987 | 7 695 |

**Pourquoi les régions ont un VIF de 2**

Les trois indicatrices régionales sont liées entre elles **par construction** : un salarié qui n'est ni à Rabat ni à Tanger a de bonnes chances d'être à Casablanca. Un VIF autour de 2 pour un groupe d'indicatrices est normal, et sans conséquence.

## Comment le lire

**Les repères usuels**

| VIF | Lecture |
|---|---|
| $< 5$ | rien à signaler |
| 5 à 10 | à surveiller |
| $> 10$ | multicolinéarité sérieuse |

**Ce que le VIF signifie littéralement**

Un VIF de 4 signifie que la variance du coefficient est **quatre fois** plus grande qu'elle ne le serait si la variable était indépendante des autres. L'écart-type est donc doublé.
Notre modèle M4 est parfaitement sain : le plus grand VIF vaut 2,08. **La multicolinéarité n'est pas un problème dans nos données réelles — il a fallu la fabriquer pour la montrer.**

## Que faire

### Les remèdes, dans l'ordre

**Quatre options**

1. **Retirer** l'une des variables redondantes.
2. Les **combiner** en un indice unique.
3. **Collecter plus de données** — cela réduit toutes les variances.
4. **Ne rien faire.**

**La quatrième option est légitime, et souvent la bonne**

La multicolinéarité **ne biaise rien**. Les prévisions restent excellentes, le $R^2$ est intact, et les coefficients non touchés par le problème restent parfaitement estimés.
Si le coefficient qui vous intéresse n'est pas parmi ceux qui sont brouillés, **il n'y a rien à corriger**. Sur notre modèle M6, les coefficients du diplôme sont inchangés à quelques dirhams près.

### Le piège du remède

**Retirer une variable est plus dangereux que la garder**

Supprimer une variable colinéaire pour « nettoyer » le modèle revient à créer une **variable omise**.
On échange alors un problème de précision — sans biais — contre un problème de biais. **C'est très exactement le mauvais échange**, et le chapitre 16 dira pourquoi.

**La règle de décision**

Retirer une variable uniquement si l'on peut justifier **économiquement** qu'elle n'a pas sa place dans le modèle.
Jamais parce que son $t$ est faible, jamais parce que son VIF est élevé. **La spécification se décide sur la théorie, pas sur les diagnostics.**

### Le cas des années et des mois

**Ici, retirer est légitime**

Années et mois mesurent **la même chose** : la théorie ne prévoit aucun effet des mois « à années égales ». Retirer les mois ne crée aucune variable omise, puisque l'information est déjà dans les années.

**Ce qui distingue ce cas de celui des cinq ménages**

Revenu et taille sont liés (VIF $= 2$), mais ce sont **deux causes distinctes** de la consommation. Retirer la taille ferait remonter la pente du revenu de 0,5 à 0,75 : un biais de 0,25, que le chapitre 16 calculera exactement.

## Sur machine

### La multicolinéarité fabriquée, avec R

```r
sal <- read.csv("salaires.csv", stringsAsFactors = TRUE)
sal$mois <- 12 * sal$anciennete + (sal$id %% 3 - 1)  # mois
cor(sal$anciennete, sal$mois)
# [1] 0.999935
m6 <- lm(salaire ~ anciennete + mois + diplome, data = sal)
round(summary(m6)$coefficients[c("anciennete", "mois"), ], 2)
#             Estimate Std. Error t value Pr(>|t|)
# anciennete -1040.25    1026.27   -1.01     0.31
# mois         109.24      85.54    1.28     0.20
car::vif(m6)                      # GVIF pour le facteur diplôme
#                   GVIF Df GVIF^(1/(2*Df))
# anciennete 7695.099103  1       87.721714
# mois       7695.149209  1       87.722000
# diplome       1.002594  2        1.000648
```

### Les VIF de M4 avec Python

```python
import pandas as pd
import statsmodels.formula.api as smf
from statsmodels.stats.outliers_influence import \
    variance_inflation_factor as vif
sal = pd.read_csv("salaires.csv")
f = "salaire ~ anciennete + diplome + sexe + region"
X = smf.ols(f, data=sal).fit().model
v = pd.Series([vif(X.exog, j) for j in range(1, 8)],
              index=X.exog_names[1:]).round(2)
print(v.tolist())                 # dans l'ordre des colonnes
# [1.17, 1.18, 1.01, 1.97, 1.81, 2.08, 1.01]
print(v.idxmax(), v.max())
# region[T.Tanger-Tetouan] 2.08
```

### Deux présentations du même diagnostic

**Par colonne ou par variable**

Python : un VIF par **colonne**. R, avec `car::vif` : un VIF **généralisé** par variable, qui regroupe les indicatrices d'un facteur — 1,003 pour le diplôme de M6.

**Le VIF ne regarde que les explicatives**

Il se calcule **sans** la variable expliquée : c'est une propriété du plan d'observation, pas du modèle. On peut donc le calculer avant toute estimation, pour savoir si les données permettront de séparer les effets.

## S'entraîner

### Exercice 1 : du R² au VIF

**Quatre degrés de liaison**

Pour $R_j^2 = 0{,}5$ ; 0,8 ; 0,9 ; 0,99 :

1. Calculer le VIF.
2. Par combien l'erreur-type du coefficient est-elle multipliée ?
3. Combien d'observations supplémentaires faudrait-il, en proportion, pour compenser le VIF de 0,9 ?

### Exercice 1 : solution

**Tout se joue au-delà de 0,9**

1. VIF : 2 ; 5 ; 10 ; 100.
2. Erreur-type multipliée par $\sqrt{\text{VIF}}$ : 1,41 ; 2,24 ; 3,16 ; 10.
3. La variance baisse comme $1/n$ : il faut **dix fois** plus d'observations pour compenser un VIF de 10. C'est pourquoi « collecter plus de données » est le remède sûr, et rarement le remède possible.

### Exercice 2 : symptômes sur une sortie

**Un modèle de demande**

On explique les ventes de 40 magasins par le prix du produit et le prix moyen des concurrents, corrélés à 0,97. Résultat : $R^2 = 0{,}81$, $F = 79$, mais aucun des deux $t$ ne dépasse 1,2, et le prix propre a un signe positif.

1. Calculer le VIF de chaque prix.
2. Quels symptômes reconnaît-on ?
3. Que conseiller ?

### Exercice 2 : solution

**Tous les symptômes, une variable théorique**

1. Avec deux variables, $R_j^2 = 0{,}97^2 = 0{,}941$ : VIF $= 1/0{,}059 = 16{,}9$.
2. $F$ très significatif, $t$ effondrés, signe absurde, $R^2$ élevé : le tableau complet.
3. Ne pas retirer un des prix : la théorie de la demande exige les deux. Mieux vaut estimer l'effet du **prix relatif** — un indice qui combine les deux — ou réunir des magasins où les deux prix varient indépendamment.

### Exercice 3 : retirer ou garder

**Trois paires de variables liées**

Pour chaque paire, faut-il retirer l'une des deux ?

1. Le poids d'un colis en kilogrammes et en grammes.
2. L'âge et l'expérience professionnelle d'un salarié.
3. Le revenu et la taille du ménage, dans la fonction de consommation.

### Exercice 3 : solution

**Une seule paire est redondante**

1. **Oui** : c'est la même grandeur dans deux unités — colinéarité parfaite, le calcul est même impossible.
2. **Non**, en général : ce sont deux mécanismes distincts — vieillissement et accumulation de savoir-faire — même s'ils sont liés. On garde les deux et l'on accepte des coefficients moins précis.
3. **Non** : deux causes distinctes de la consommation, avec un VIF de 2 seulement. Retirer la taille biaiserait la pente du revenu.

## Ce qu'il faut retenir

### Le résumé du chapitre

**Six points**

1. La multicolinéarité, c'est demander de **séparer ce que les données n'ont jamais séparé**.
2. Quatre symptômes : écarts-types gonflés, $t$ effondrés, coefficients absurdes, $R^2$ intact.
3. $V(\hat{\beta}_j) = \sigma_\varepsilon^2 / S_{jj} \times \text{VIF}_j$ : cinq ménages, VIF $= 2$, erreur-type $\times 1{,}41$.
4. Au-delà de 10, c'est sérieux. Nos données réelles : 2,08 au plus.
5. **Elle ne biaise rien** : ne rien faire est souvent la bonne décision.
6. Retirer une variable colinéaire crée une **variable omise**, sauf si elle mesure la même chose.

**La suite**

Passons à une violation qui, elle, est présente dans presque toutes les données individuelles — et que nos salaires exhibent de façon spectaculaire : l'**hétéroscédasticité**.