

Introduction à l'économétrie

Chapitre 13 : La multicolinéarité

Jaouad Madkour

24 septembre 2026

Plan du chapitre

Le problème	1
Ce dont il s'agit	1
La démonstration	2
Les quatre symptômes	2
La mesurer	2
Comment le lire	3
Que faire	3
Les remèdes, dans l'ordre	3
Le piège du remède	3
Ce qu'il faut retenir	4
Le résumé du chapitre	4

Le problème

Ce dont il s'agit

Multicolinéarité

Deux ou plusieurs variables explicatives sont **fortement liées entre elles**, sans l'être parfaitement.

Le calcul aboutit — H_5 n'est pas violée — mais il devient instable.

La question à laquelle on ne peut plus répondre

Le *ceteris paribus* demande l'effet d'une variable **les autres étant constantes**.

Si deux variables bougent toujours ensemble, les données ne contiennent aucune observation où l'une varie et pas l'autre. **On demande au modèle de séparer ce que les données n'ont jamais séparé.**

La démonstration

on ajoute la *même* variable, exprimée en mois : corrélation 0,99994, VIF = 8 084

	M2 — ancienneté en années		M6 — années <i>et</i> mois	
	coefficient	<i>t</i>	coefficient	<i>t</i>
Ancienneté (années)	270,27	23,06	-1 404,96	-1,34
Ancienneté (mois)	—	—	139,58	1,59
Bac+2	1 099,57	6,93	1 095,86	6,92
Bac+5	3 336,99	18,11	3 336,00	18,13
R^2	0,6418		0,6436	

Les quatre symptômes de la multicollinéarité, tous visibles ici.

1. Les coefficients deviennent *absurdes* : une année d'ancienneté ferait perdre 1 405 dirhams. 2. Ils deviennent *non significatifs* alors que la variable compte manifestement. 3. Les écarts-types *explorent* : 1 051 contre 11,72. 4. Le R^2 , lui, ne bouge pas — il monte même très légèrement.

Le diagnostic tient dans cette dernière ligne. Le modèle prédit toujours aussi bien ; il est simplement devenu incapable de *séparer* les rôles. Demander l'effet des années à mois constants n'a aucun sens : c'est la même information deux fois.

Remèdes : retirer l'une des deux, les combiner, ou ne rien faire si le coefficient litigieux n'est pas celui qui intéresse. La multicollinéarité ne biaise rien — elle rend seulement imprécis.

Les quatre symptômes

Ils vont ensemble

1. Les **écarts-types explosent** : 1 051 contre 11,72.
2. Les coefficients deviennent **non significatifs** alors que les variables comptent.
3. Ils prennent des valeurs **absurdes** — ici, un signe négatif pour l'ancienneté.
4. Le R^2 **ne bouge pas** : 0,6418 contre 0,6436.

Le quatrième est le plus révélateur

Le modèle prédit toujours aussi bien. Il a seulement perdu la capacité d'**attribuer**. C'est exactement le cas d'école du chapitre 9 : un F global significatif avec des t individuels qui ne le sont pas.

La mesurer

Le facteur d'inflation de la variance

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$

où R_j^2 est le R^2 de la régression de x_j sur **toutes les autres** variables explicatives.

Sur nos données

Modèle	Variable	R_j^2	VIF
M4	ancienneté	0,012	1,01
M4	Casablanca	0,492	1,97
M4	Tanger	0,519	2,08
M6	ancienneté	0,999876	8 084

Comment le lire

Les repères usuels

VIF	Lecture
< 5	rien à signaler
5 à 10	à surveiller
> 10	multicolinéarité sérieuse

Ce que le VIF signifie littéralement

Un VIF de 4 signifie que la variance du coefficient est **quatre fois** plus grande qu'elle ne le serait si la variable était indépendante des autres. L'écart-type est donc doublé.

Notre modèle M4 est parfaitement sain : le plus grand VIF vaut 2,08. **La multicolinéarité n'est pas un problème dans nos données réelles — il a fallu la fabriquer pour la montrer.**

Que faire

Les remèdes, dans l'ordre

Quatre options

1. **Retirer** l'une des variables redondantes.
2. Les **combiner** en un indice unique.
3. **Collecter plus de données** — cela réduit toutes les variances.
4. **Ne rien faire.**

La quatrième option est légitime, et souvent la bonne

La multicolinéarité **ne biaise rien**. Les prévisions restent excellentes, le R^2 est intact, et les coefficients non touchés par le problème restent parfaitement estimés.

Si le coefficient qui vous intéresse n'est pas parmi ceux qui sont brouillés, **il n'y a rien à corriger**. Sur notre modèle M6, les coefficients du diplôme sont inchangés au dirham près.

Le piège du remède

Retirer une variable est plus dangereux que la garder

Supprimer une variable colinéaire pour « nettoyer » le modèle revient à créer une **variable omise**.

On échange alors un problème de précision — sans biais — contre un problème de biais. **C'est très exactement le mauvais échange**, et le chapitre 16 dira pourquoi.

La règle de décision

Retirer une variable uniquement si l'on peut justifier **économiquement** qu'elle n'a pas sa place dans le modèle.

Jamais parce que son t est faible, jamais parce que son VIF est élevé. **La spécification se**

décide sur la théorie, pas sur les diagnostics.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. La multicolinéarité, c'est demander de **séparer ce que les données n'ont jamais séparé**.
2. Quatre symptômes : écarts-types gonflés, t effondrés, coefficients absurdes, R^2 intact.
3. Le quatrième est le diagnostic : le modèle prédit bien mais n'attribue plus.
4. $VIF_j = 1/(1 - R_j^2)$; au-delà de 10, c'est sérieux. Nos données réelles : 2,08 au plus.
5. **Elle ne biaise rien** : ne rien faire est souvent la bonne décision.
6. Retirer une variable colinéaire crée une **variable omise** — un problème bien pire.

La suite

Passons à une violation qui, elle, est présente dans presque toutes les données individuelles — et que nos salaires exhibent de façon spectaculaire.