

Chapitre 17

Normalité et points influents

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Économétrie — Introduction

1 Exercices du chapitre

Correction — Exercice 1

- (a) $JB = 500 \left(\frac{0,563^2}{6} + \frac{(3,607 - 3)^2}{24} \right) = 500 (0,05283 + 0,01535) \approx 34,09$, conforme au 34,1 du cours.
- (b) $34,09 > 5,99$: la normalité est largement rejetée.
- (c) Avec $n = 25$ et les mêmes S et K : $JB = 25 \times 0,06818 \approx 1,70$, très inférieur à 5,99 : la normalité **n'est plus rejetée** dans ce petit échantillon.
- (d) Sur $n = 500$, le rejet de la normalité (question b) n'a **aucune conséquence** sur les tests et intervalles de confiance : le théorème central limite garantit leur validité, quelle que soit la forme exacte de la distribution des erreurs. Sur $n = 25$, la situation est plus subtile que le simple résultat numérique de (c) ne le suggère : le calcul montre que le test de Jarque-Bera a beaucoup **moins de puissance** à ce niveau d'effectif — la même asymétrie et le même aplatissement produisent une statistique bien plus faible, simplement parce qu'elle est proportionnelle à n . Cela ne signifie pas que les résidus seraient « plus normaux » à $n = 25$: cela signifie que le test est moins capable de détecter l'écart. Or si une non-normalité réelle et détectée survenait sur un échantillon de cette taille, elle **invaliderait** bel et bien les tests usuels, faute de pouvoir invoquer le théorème central limite — d'où la mise en garde du cours : « regardez toujours n avant de décider si le rejet vous concerne ».

Correction — Exercice 2

- (a) P_1 : levier fort, résidu faible. P_2 : résidu fort, levier faible. P_3 : levier fort *et* résidu fort.
- (b) Non, le retrait de P_1 ne changerait pas fortement la droite : puisque son salaire observé est déjà proche de ce que prédit le modèle, ce point **confirme** la tendance déjà estimée par les autres observations plutôt que de la contredire — son levier fort signale seulement qu'il est isolé en x , pas qu'il tire la droite dans une direction différente.
- (c) Non, le retrait de P_2 ne changerait la droite qu'à peine : un point central en x (proche de la moyenne des autres observations) a, par construction, peu de « bras de levier » pour faire pivoter la droite de régression, même si son écart en y est important — son gros résidu affecte la somme des carrés des résidus, mais pas la pente estimée.
- (d) P_3 est le plus susceptible d'être une observation influente : c'est la combinaison d'un levier fort (position isolée en x , donc un grand « bras de levier ») *et* d'un gros résidu (le point ne suit pas la tendance des autres) qui permet à une seule observation de faire pivoter significativement la droite estimée — exactement le cas que le cours identifie comme « le seul qu'un simple examen des résidus ne signale pas comme extraordinaire » (le résidu seul, en y , peut y paraître modéré une fois la droite déplacée pour s'en rapprocher).

Correction — Exercice 3

- (a) $4/500 = 0,008$.
- (b) Oui : $0,015 > 0,008$, la distance de Cook de ce salarié dépasse le seuil d'alerte usuel.
- (c) Non : le cours est explicite, ce seuil est un seuil **d'alerte**, non de suppression automatique. Un dépassement signale seulement qu'il faut examiner le point de plus près, pas qu'il faut le retirer.
- (d) Dans l'ordre : (1) est-ce une **erreur de saisie**? Si oui, on la corrige. (2) L'observation appartient-elle à la **population étudiée**? Sinon (par exemple un dirigeant dans un fichier d'employés), elle n'y a pas sa place. (3) Le modèle est-il **mal spécifié** (une non-linéarité produisant des points apparemment aberrants)? (4) Si aucune de ces trois raisons ne s'applique : c'est une observation légitime, et on la garde.

2 Exercice cumulatif

Correction — Exercice 4

- (a) Une variable étirée à droite (beaucoup de salaires modestes, quelques salaires très élevés) produit mécaniquement les deux symptômes à la fois : elle engendre de l'**hétéroscédasticité** car les salariés à hauts salaires ont, en valeur absolue, une marge de variation bien plus grande autour de la droite (chapitre 14) ; et elle engendre de l'**asymétrie des résidus** car quelques valeurs extrêmes à droite (les très hauts salaires, souvent mal expliqués par le modèle) étirent la distribution des résidus dans cette même direction.
- (b) Non : les écarts-types robustes de White ne corrigent que la mesure de l'incertitude (la variance des coefficients) ; ils ne modifient en rien la distribution des résidus eux-mêmes, donc ils ne corrigent pas l'asymétrie.
- (c) Parce que les deux symptômes proviennent de la même source structurelle — une variable expliquée dont l'échelle est étirée à droite — plutôt que de deux mécanismes indépendants qu'il faudrait traiter séparément. C'est précisément pourquoi une seule et même transformation (le logarithme) est susceptible de corriger les deux à la fois, alors que deux causes réellement indépendantes auraient exigé deux remèdes distincts.
- (d) Le diagramme quantile-quantile (QQ-plot) des résidus est le graphique qui permet de repérer précisément l'asymétrie : c'est lui qui montre le « décrochage en haut à droite » évoqué par le cours, signalant que les plus grands résidus sont plus extrêmes que ne le prédirait une distribution normale.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) Oui, la première vérification porte sur une éventuelle erreur de saisie. On la distingue d'une observation authentique en retournant, si possible, à la source des données (bulletin de paie, contrat) pour confirmer que le montant est réel et non un chiffre mal transcrit (par exemple un zéro de trop).
- (b) Non : si l'objectif de l'étude est d'estimer le rendement du diplôme et de l'ancienneté pour les postes **non dirigeants**, un directeur général relève d'une population différente (rémunération liée à des logiques de gouvernance, de risque, de marché des dirigeants, sans commune mesure avec la grille salariale des employés) — il n'a donc pas sa place dans cet échantillon au regard de la question posée.
- (c) Le cours recommande d'estimer le modèle **avec et sans** cette observation, et de publier les deux résultats si les conclusions diffèrent — c'est ce qu'on appelle un test de robustesse.
- (d) Si les conclusions changent radicalement selon l'inclusion ou non de cette seule observation, l'analyste doit conclure que son résultat initial n'était **pas solide** : selon le cours, « une conclusion qui n'y survit pas n'était pas une conclusion ». Il doit alors présenter honnêtement cette fragilité plutôt que de choisir silencieusement la version qui l'arrange.

Correction — Exercice 6

- (a) Oui : avec seulement 22 observations, très en-dessous du seuil de trente évoqué par le cours, le rejet de la normalité invalide potentiellement les tests usuels sur les coefficients — à la différence du cas à 500 observations.
- (b) Le théorème central limite est un résultat **asymptotique** : il garantit une approximation normale des estimateurs seulement quand n devient suffisamment grand. Avec 22 observations, l'échantillon est trop petit pour que cette approximation soit fiable, quelle que soit la vraie loi des erreurs.
- (c) Oui : le chiffre d'affaires, comme le salaire, est une variable économique typiquement étirée à droite (beaucoup de petites entreprises, quelques très grandes) — exactement le type de variable pour lequel le cours recommande une transformation logarithmique, qui peut à la fois réduire l'asymétrie des résidus et stabiliser leur variance.
- (d) La règle générale est de toujours regarder la taille de l'échantillon avant d'interpréter un rejet de la normalité des résidus : au-delà d'une trentaine d'observations environ, le théorème central limite rend

ce rejet sans conséquence pratique sur les tests et intervalles de confiance ; en-deçà, il devient décisif et appelle une transformation de la variable ou une méthode de rééchantillonnage.