

Introduction à l'économétrie

Chapitre 17 : Normalité et points influents

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'économétrie

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Calculer et interpréter Jarque-Bera

Sur le modèle M2 du cours ($n = 500$), l'asymétrie des résidus est $S = 0,563$ et l'aplatissement $K = 3,607$.

- (a) Calculer $JB = n \left(\frac{S^2}{6} + \frac{(K - 3)^2}{24} \right)$.
- (b) Comparer au seuil $\chi^2_2 = 5,99$. La normalité est-elle rejetée ?
- (c) Si l'échantillon comptait seulement $n = 25$ observations au lieu de 500, avec les mêmes S et K , recalculer JB . Le rejet a-t-il encore lieu ?
- (d) Sur un échantillon de $n = 500$, le rejet de la normalité invalide-t-il les tests et intervalles de confiance sur les coefficients ? Et sur un échantillon de $n = 25$?

Exercice 2 — Résidu, levier, influence : ne pas confondre

Trois observations d'un même échantillon sont décrites.

- P_1 . Un salarié dont le salaire observé est très proche de ce que prédit le modèle, mais dont l'ancienneté est très supérieure à celle de tous les autres salariés de l'échantillon.
 - P_2 . Un salarié dont le salaire observé s'écarte fortement de la prédiction du modèle, mais dont l'ancienneté et le diplôme sont proches de la moyenne de l'échantillon.
 - P_3 . Un salarié dont le salaire observé s'écarte fortement de la prédiction du modèle *et* dont l'ancienneté est très supérieure à celle de tous les autres salariés.
- (a) Pour chacun des trois profils, indiquer s'il présente un levier fort, un gros résidu, les deux, ou aucun des deux.
 - (b) Le retrait de P_1 changerait-il fortement la droite de régression estimée ? Pourquoi le cours dit-il qu'un levier fort sans résidu « confirme » la droite plutôt que de la menacer ?
 - (c) Le retrait de P_2 changerait-il fortement la droite ? Pourquoi un gros résidu « au centre du nuage » la déplace-t-il à peine ?
 - (d) Lequel des trois profils est le plus susceptible d'être une observation **influente** au sens du cours, c'est-à-dire dont le retrait changerait effectivement la droite ?

Exercice 3 — La distance de Cook et la marche à suivre

Sur l'échantillon de 500 salariés du cours, un salarié présente une distance de Cook $D_i = 0,015$.

- (a) Calculer le seuil d'alerte usuel $4/n$ pour $n = 500$.
- (b) La distance de Cook de ce salarié dépasse-t-elle ce seuil ?
- (c) Ce dépassement signifie-t-il que l'observation doit être automatiquement supprimée ?
- (d) Énumérer, dans l'ordre proposé par le cours, les quatre questions à se poser avant de décider quoi faire de cette observation.

2 Exercice cumulatif (chapitre 17 et chapitres précédents)

Exercice 4 — Un même symptôme, deux diagnostics

Le chapitre 14 avait établi que l'écart-type des résidus était environ 1,6 fois plus grand chez les salariés très diplômés que chez les salariés faiblement diplômés (hétéroscédasticité). Ce chapitre montre, sur le même type de variable (le salaire), une asymétrie des résidus $S = 0,563$ et un rejet de la normalité ($JB = 34,1$).

- (a) Le cours affirme qu'une distribution de résidus étirée à droite « accompagne presque toujours »

une variable expliquée elle-même étirée, comme les salaires. En quoi une variable étirée à droite (beaucoup de valeurs modestes, quelques valeurs très élevées) peut-elle produire *simultanément* de l'hétéroscédasticité *et* de l'asymétrie des résidus ?

- (b) Le chapitre 14 proposait deux remèdes possibles à l'hétéroscédasticité : les écarts-types robustes (qui « réparent la conséquence ») et le logarithme (qui « supprime parfois la cause »). Ce chapitre affirme que le logarithme corrige *aussi* l'asymétrie des résidus. Le remède « écarts-types robustes » du chapitre 14 corrige-t-il, lui, l'asymétrie des résidus de ce chapitre ?
- (c) Pourquoi peut-on dire que l'hétéroscédasticité (chapitre 14) et l'asymétrie des résidus (ce chapitre) sont, sur ce type de données, deux symptômes d'une seule et même cause plutôt que deux problèmes indépendants ?
- (d) Le chapitre 12 (carte des violations) mentionnait quatre graphiques de diagnostic des résidus. Lequel de ces graphiques permet précisément de repérer l'asymétrie étudiée dans ce chapitre ?

3 Applications en sciences économiques

Exercice 5 — Un test de robustesse, pas une suppression

Dans un fichier de 500 salariés d'une entreprise, le salaire du directeur général, très supérieur à tous les autres, apparaît comme un point à la fois à fort levier (ancienneté et diplôme atypiques) et à gros résidu.

- (a) En suivant les quatre questions du cours dans l'ordre, la première chose à vérifier est-elle une erreur de saisie. Comment la distinguer d'une observation authentique ?
- (b) Un directeur général appartient-il, au sens du cours, à la même « population étudiée » qu'un employé standard, si l'objectif de l'étude est d'estimer le rendement du diplôme et de l'ancienneté pour les postes non dirigeants ?
- (c) Si l'analyste décide de retirer cette observation, quelle bonne pratique le cours recommande-t-il pour rester méthodologiquement rigoureux (indice : estimer « avec et sans ») ?
- (d) Si les conclusions de l'étude (signe et significativité des coefficients clés) changent radicalement selon que l'on inclut ou non le directeur général, que doit conclure l'analyste sur la solidité de son résultat initial ?

Exercice 6 — La normalité compte, cette fois

Une étude sur 22 petites entreprises exportatrices régresse leur chiffre d'affaires sur trois variables explicatives. Le test de Jarque-Bera rejette la normalité des résidus.

- (a) Avec $n = 22$, le rejet de la normalité invalide-t-il les tests usuels sur les coefficients, contrairement au cas de $n = 500$ étudié dans ce chapitre ?
- (b) Pourquoi le théorème central limite, invoqué pour l'échantillon de 500 salariés, ne s'applique-t-il pas de la même façon avec seulement 22 observations ?
- (c) Le cours propose deux solutions face à une non-normalité décisive sur petit échantillon : transformer la variable expliquée, ou recourir à des méthodes de rééchantillonnage. Le chiffre d'affaires, comme le salaire, est-il un type de variable pour lequel une transformation logarithmique est plausible ?
- (d) Formuler la règle générale, en une phrase, que le cours recommande d'appliquer systématiquement avant de décider si un rejet de normalité doit inquiéter l'analyste.

1 Exercices du chapitre

Correction — Exercice 1

- (a) $JB = 500 \left(\frac{0,563^2}{6} + \frac{(3,607 - 3)^2}{24} \right) = 500 (0,05283 + 0,01535) \approx 34,09$, conforme au 34,1 du cours.
- (b) $34,09 > 5,99$: la normalité est largement rejetée.
- (c) Avec $n = 25$ et les mêmes S et K : $JB = 25 \times 0,06818 \approx 1,70$, très inférieur à 5,99 : la normalité **n'est plus rejetée** dans ce petit échantillon.
- (d) Sur $n = 500$, le rejet de la normalité (question b) n'a **aucune conséquence** sur les tests et intervalles de confiance : le théorème central limite garantit leur validité, quelle que soit la forme exacte de la distribution des erreurs. Sur $n = 25$, la situation est plus subtile que le simple résultat numérique de (c) ne le suggère : le calcul montre que le test de Jarque-Bera a beaucoup **moins de puissance** à ce niveau d'effectif — la même asymétrie et le même aplatissement produisent une statistique bien plus faible, simplement parce qu'elle est proportionnelle à n . Cela ne signifie pas que les résidus seraient « plus normaux » à $n = 25$: cela signifie que le test est moins capable de détecter l'écart. Or si une non-normalité réelle et détectée survenait sur un échantillon de cette taille, elle **invaliderait** bel et bien les tests usuels, faute de pouvoir invoquer le théorème central limite — d'où la mise en garde du cours : « regardez toujours n avant de décider si le rejet vous concerne ».

Correction — Exercice 2

- (a) P_1 : levier fort, résidu faible. P_2 : résidu fort, levier faible. P_3 : levier fort *et* résidu fort.
- (b) Non, le retrait de P_1 ne changerait pas fortement la droite : puisque son salaire observé est déjà proche de ce que prédit le modèle, ce point **confirme** la tendance déjà estimée par les autres observations plutôt que de la contredire — son levier fort signale seulement qu'il est isolé en x , pas qu'il tire la droite dans une direction différente.
- (c) Non, le retrait de P_2 ne changerait la droite qu'à peine : un point central en x (proche de la moyenne des autres observations) a, par construction, peu de « bras de levier » pour faire pivoter la droite de régression, même si son écart en y est important — son gros résidu affecte la somme des carrés des résidus, mais pas la pente estimée.
- (d) P_3 est le plus susceptible d'être une observation influente : c'est la combinaison d'un levier fort (position isolée en x , donc un grand « bras de levier ») *et* d'un gros résidu (le point ne suit pas la tendance des autres) qui permet à une seule observation de faire pivoter significativement la droite estimée — exactement le cas que le cours identifie comme « le seul qu'un simple examen des résidus ne signale pas comme extraordinaire » (le résidu seul, en y , peut y paraître modéré une fois la droite déplacée pour s'en rapprocher).

Correction — Exercice 3

- (a) $4/500 = 0,008$.
- (b) Oui : $0,015 > 0,008$, la distance de Cook de ce salarié dépasse le seuil d'alerte usuel.
- (c) Non : le cours est explicite, ce seuil est un seuil **d'alerte**, non de suppression automatique. Un dépassement signale seulement qu'il faut examiner le point de plus près, pas qu'il faut le retirer.
- (d) Dans l'ordre : (1) est-ce une **erreur de saisie**? Si oui, on la corrige. (2) L'observation appartient-elle à la **population étudiée**? Sinon (par exemple un dirigeant dans un fichier d'employés), elle n'y a pas sa place. (3) Le modèle est-il **mal spécifié** (une non-linéarité produisant des points apparemment aberrants)? (4) Si aucune de ces trois raisons ne s'applique : c'est une observation légitime, et on la garde.

2 Exercice cumulatif

Correction — Exercice 4

- (a) Une variable étirée à droite (beaucoup de salaires modestes, quelques salaires très élevés) produit mécaniquement les deux symptômes à la fois : elle engendre de l'**hétéroscédasticité** car les salariés à hauts salaires ont, en valeur absolue, une marge de variation bien plus grande autour de la droite (chapitre 14) ; et elle engendre de l'**asymétrie des résidus** car quelques valeurs extrêmes à droite (les très hauts salaires, souvent mal expliqués par le modèle) étirent la distribution des résidus dans cette même direction.
- (b) Non : les écarts-types robustes de White ne corrigent que la mesure de l'incertitude (la variance des coefficients) ; ils ne modifient en rien la distribution des résidus eux-mêmes, donc ils ne corrigent pas l'asymétrie.
- (c) Parce que les deux symptômes proviennent de la même source structurelle — une variable expliquée dont l'échelle est étirée à droite — plutôt que de deux mécanismes indépendants qu'il faudrait traiter séparément. C'est précisément pourquoi une seule et même transformation (le logarithme) est susceptible de corriger les deux à la fois, alors que deux causes réellement indépendantes auraient exigé deux remèdes distincts.
- (d) Le diagramme quantile-quantile (QQ-plot) des résidus est le graphique qui permet de repérer précisément l'asymétrie : c'est lui qui montre le « décrochage en haut à droite » évoqué par le cours, signalant que les plus grands résidus sont plus extrêmes que ne le prédirait une distribution normale.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) Oui, la première vérification porte sur une éventuelle erreur de saisie. On la distingue d'une observation authentique en retournant, si possible, à la source des données (bulletin de paie, contrat) pour confirmer que le montant est réel et non un chiffre mal transcrit (par exemple un zéro de trop).
- (b) Non : si l'objectif de l'étude est d'estimer le rendement du diplôme et de l'ancienneté pour les postes **non dirigeants**, un directeur général relève d'une population différente (rémunération liée à des logiques de gouvernance, de risque, de marché des dirigeants, sans commune mesure avec la grille salariale des employés) — il n'a donc pas sa place dans cet échantillon au regard de la question posée.
- (c) Le cours recommande d'estimer le modèle **avec et sans** cette observation, et de publier les deux résultats si les conclusions diffèrent — c'est ce qu'on appelle un test de robustesse.
- (d) Si les conclusions changent radicalement selon l'inclusion ou non de cette seule observation, l'analyste doit conclure que son résultat initial n'était **pas solide** : selon le cours, « une conclusion qui n'y survit pas n'était pas une conclusion ». Il doit alors présenter honnêtement cette fragilité plutôt que de choisir silencieusement la version qui l'arrange.

Correction — Exercice 6

- (a) Oui : avec seulement 22 observations, très en-dessous du seuil de trente évoqué par le cours, le rejet de la normalité invalide potentiellement les tests usuels sur les coefficients — à la différence du cas à 500 observations.
- (b) Le théorème central limite est un résultat **asymptotique** : il garantit une approximation normale des estimateurs seulement quand n devient suffisamment grand. Avec 22 observations, l'échantillon est trop petit pour que cette approximation soit fiable, quelle que soit la vraie loi des erreurs.
- (c) Oui : le chiffre d'affaires, comme le salaire, est une variable économique typiquement étirée à droite (beaucoup de petites entreprises, quelques très grandes) — exactement le type de variable pour lequel le cours recommande une transformation logarithmique, qui peut à la fois réduire l'asymétrie des résidus et stabiliser leur variance.
- (d) La règle générale est de toujours regarder la taille de l'échantillon avant d'interpréter un rejet de la normalité des résidus : au-delà d'une trentaine d'observations environ, le théorème central limite rend

ce rejet sans conséquence pratique sur les tests et intervalles de confiance ; en-deçà, il devient décisif et appelle une transformation de la variable ou une méthode de rééchantillonnage.