Introduction à l'économétrie

Chapitre 17 : Normalité et points influents

Jaouad Madkour

29 octobre 2026

Plan du chapitre

La normalité des résidus **2**
Ce qu'on regarde . . . 2
Le test de Jarque-Bera . . . 2
Et cela n'a aucune conséquence . . . 3
Le test devient sévère avec n . . . 3
Ce que le rejet révèle quand même . . . 4

Des points qui pèsent trop **4**
Levier et résidu . . . 4
Les trois notions . . . 4
Le levier, mesuré . . . 5
La distance de Cook . . . 6
Cook, à la main, sur les cinq ménages . . . 7
Retirer C, retirer E . . . 7
Sur les salariés . . . 7
Avec et sans les trente-trois . . . 8
Que faire d'un point influent . . . 8

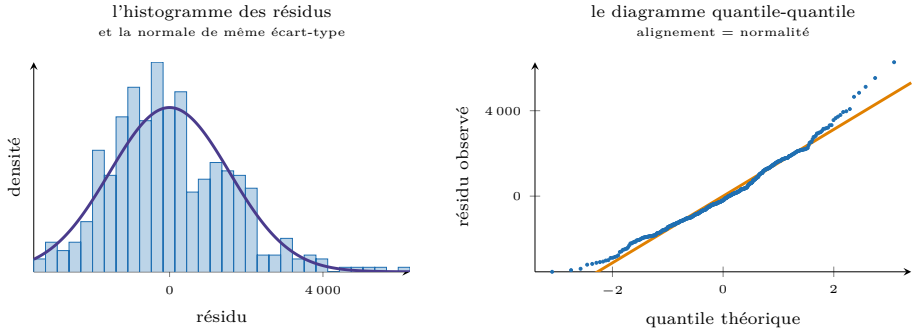
Sur machine **8**
Levier et influence avec R . . . 8
Normalité et influence avec Python . . . 9

S'entraîner **9**
Exercice 1 : leviers et Cook à la main . . . 9
Exercice 1 : solution . . . 9
Exercice 2 : Jarque-Bera et taille d'échantillon . . . 10
Exercice 2 : solution . . . 10
Exercice 3 : décider du sort d'un point . . . 10
Exercice 3 : solution . . . 10

Ce qu'il faut retenir **10**
Le résumé du chapitre . . . 10

La normalité des résidus

Ce qu'on regarde



Les résidus sont étirés à droite : asymétrie 0,56, aplatissement 3,61, Jarque-Bera = 34,1 contre un seuil de 5,99. La normalité est rejetée.

Et cela n'a aucune conséquence ici. Avec cinq cents observations, le théorème central limite rend les coefficients approximativement normaux quelle que soit la loi des erreurs. Tests et intervalles restent valides.

Le diagnostic n'est donc pas inutile pour autant : le décrochage dans le coin supérieur droit signale quelques salaires très élevés, dont le chapitre suivant examinera l'influence.

Le test de Jarque-Bera

Il combine asymétrie et aplatissement

$$JB = n\left(\frac{S^2}{6} + \frac{(K-3)^2}{24}\right) \sim \chi^2_2$$

où S est le coefficient d'asymétrie et K l'aplatissement — les indicateurs de forme du chapitre 8 de la statistique descriptive.

Sur le modèle M2

$$JB = 500\left(\frac{0{,}563^2}{6} + \frac{0{,}607^2}{24}\right) = 500\,(0{,}0528 + 0{,}0154) = 34{,}1$$

contre un seuil de 5,99. La normalité est rejetée : les résidus sont étirés vers la droite, $S = 0{,}563$, et un peu trop concentrés, $K = 3{,}607$.

Démonstration : Pourquoi JB suit approximativement un χ^2_2 sous la normalité

Soient z_i les résidus centrés et réduits, $S = \frac{1}{n}\sum_i z_i^3$ l'asymétrie et $K = \frac{1}{n}\sum_i z_i^4$ l'aplatissement. Si les erreurs sont normales et n grand, on admet que centrer et réduire avec la moyenne et l'écart-type estimés revient à corriger z^3 en $z^3 - 3z$ et z^4 en $z^4 - 6z^2 + 3$ (on retire la part déjà expliquée par z et z^2) :

$$S \approx \frac{1}{n}\sum_i H_3(z_i), \quad K - 3 \approx \frac{1}{n}\sum_i H_4(z_i),$$

$$H_3(z) = z^3 - 3z, \qquad H_4(z) = z^4 - 6z^2 + 3.$$

Pour $z \sim \mathcal{N}(0,1)$, les moments sont $E(z^2) = 1$, $E(z^4) = 3$, $E(z^6) = 15$ et $E(z^8) = 105$. On calcule : $E(H_3) = 0$ et $E(H_4) = 3 - 6 + 3 = 0$;

$$V(H_3) = E(z^6) - 6E(z^4) + 9E(z^2) = 15 - 18 + 9 = 6,$$

$$\begin{aligned} V(H_4) &= E(z^8) - 12E(z^6) + 42E(z^4) - 36E(z^2) + 9 \\ &= 105 - 180 + 126 - 36 + 9 = 24, \end{aligned}$$

et $E(H_3 H_4) = 0$, car c'est une fonction impaire d'une loi symétrique. Par le théorème central limite, S et $K - 3$ sont approximativement normales, indépendantes, de variances $6/n$ et $24/n$. Alors

$$JB = n\Big(\frac{S^2}{6} + \frac{(K-3)^2}{24}\Big) = \Big(\frac{S}{\sqrt{6/n}}\Big)^2 + \Big(\frac{K-3}{\sqrt{24/n}}\Big)^2$$

est la somme des carrés de deux normales centrées réduites indépendantes : un χ^2_2.

Une loi limite. La convergence est lente : sur des échantillons normaux de 500 observations, le seuil de 5,99 rejette 4,7 % des fois, et il faut de l'ordre de 10 000 observations pour que la loi simulée soit indiscernable d'un χ^2_2.

■

Et cela n'a aucune conséquence

Pourquoi on peut passer outre

Avec cinq cents observations, le théorème central limite rend $\hat{\beta}_j$ approximativement normal **quelle que soit la loi des erreurs**.
Tests, p-values et intervalles restent valides. **H6 ne servait qu'aux petits échantillons.**

Quand elle importe vraiment

En dessous de trente observations — bilans d'un petit échantillon d'entreprises, séries macro courtes, expériences de laboratoire — la non-normalité invalide les tests.
Il faut alors soit transformer la variable expliquée, soit recourir à des méthodes de rééchantillonnage. **Regardez toujours n avant de décider si le rejet vous concerne.**

Le test devient sévère avec n

Une statistique proportionnelle à n

À forme des résidus donnée, JB croît comme n. Les mêmes $S = 0{,}563$ et $K = 3{,}607$ donneraient :

Même forme, trois tailles

n	JB	Conclusion à 5 %
20	1,36	non rejet
100	6,81	rejet

500 34,1 rejet massif

Le paradoxe : le test rejette quand la normalité ne sert plus à rien, et accepte quand elle compterait. C'est la raison de regarder le graphique avant le chiffre.

Ce que le rejet révèle quand même

Un diagnostic utile, pour une autre raison

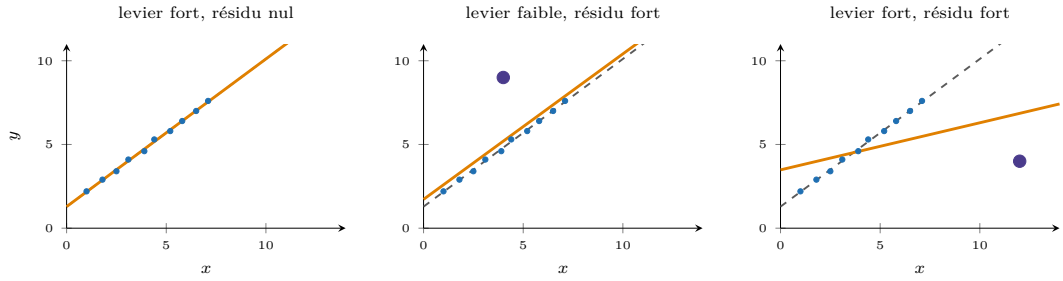
Le décrochage en haut à droite du diagramme quantile-quantile signale quelques salaires très supérieurs à ce que le modèle prédit.
Ce n'est pas un problème de normalité : c'est une poignée d'observations particulières. **Et celles-là méritent qu'on les regarde.**

L'asymétrie appelle souvent le logarithme

Une distribution de résidus étirée à droite accompagne presque toujours une variable expliquée elle-même étirée — salaires, revenus, patrimoines, chiffres d'affaires.
Passer au logarithme corrige simultanément l'asymétrie **et** l'hétéroscédasticité du chapitre 14. C'est l'objet du chapitre 18.

Des points qui pèsent trop

Levier et résidu



Trois points ajoutés, trois situations très différentes. La droite en pointillé est celle d'origine.

Levier : le point est-il loin des autres *en* x ? **Résidu** : est-il loin de la droite *en* y ?

Seule la combinaison des deux est dangereuse. Un levier fort sans résidu confirme la droite ; un gros résidu au centre la déplace à peine. C'est le troisième cas qui bascule tout — et c'est le seul qu'un simple examen des résidus ne signale pas comme extraordinaire.

D'où la distance de **Cook**, qui combine les deux, et la règle usuelle : examiner tout point dont la distance dépasse $4/n$. Non pour le supprimer — une observation ne se supprime pas parce qu'elle dérange — mais pour comprendre *pourquoi* il est là.

Les trois notions

À ne pas confondre

Notion	Question
Résidu	le point est-il loin de la droite, en y ?
Levier	est-il loin des autres, en x ?

Influence son retrait changerait-il la droite ?

Seule la troisième compte

Un levier fort sans résidu **confirme** la droite. Un gros résidu au centre du nuage la déplace à peine.
C'est leur combinaison qui bascule tout — et c'est le seul cas qu'un simple examen des résidus ne signale pas comme extraordinaire.

Le levier, mesuré

En régression simple

$$h_i = \frac{1}{n} + \frac{(x_i - \overline{x})^2}{S_{xx}} \qquad \sum_i h_i = k + 1$$

Le levier ne dépend que des x : c'est la **distance au centre** du nuage, en abscisse.

Les cinq ménages

$h = \frac{1}{5} + \frac{16}{40} = 0{,}6$ pour A et E ; $\frac{1}{5} + \frac{4}{40} = 0{,}3$ pour B et D ; 0,2 pour C. Somme : 2, le nombre de paramètres.
Les deux ménages extrêmes portent à eux seuls 60 % du levier total.

Démonstration : Le levier : $h_i = 1/n + (x_i - \overline{x})^2/S_{xx}$, de somme $k+1$

Les valeurs ajustées sont $\hat{y} = X\hat{\beta} = Hy$ avec $H = X(X'X)^{-1}X'$ (démonstration de la forme matricielle, chapitre 7). Le **levier** de l'observation i est $h_i = H_{ii}$: le poids de y_i dans sa propre valeur ajustée, $\hat{y}_i = h_i y_i + \sum_{j \neq i} H_{ij} y_j$.

Régression simple. D'après le chapitre 6, $\hat{y}_i = \overline{y} + \hat{\beta}_1(x_i - \overline{x}) = \sum_j \left(\frac{1}{n} + (x_i - \overline{x})\, w_j\right) y_j$ avec $w_j = (x_j - \overline{x})/S_{xx}$. Le poids de y_i lui-même est

$$h_i = \frac{1}{n} + (x_i - \overline{x})\, w_i = \frac{1}{n} + \frac{(x_i - \overline{x})^2}{S_{xx}}.$$

La somme. $\sum_i h_i = \mathrm{tr}(H) = k + 1$ (démonstration du chapitre 7 sur les degrés de liberté). On le vérifie ici : $\sum_i h_i = 1 + S_{xx}/S_{xx} = 2$.

Les bornes. Dans un modèle avec constante, $h_i \geq 1/n$. Et comme H est symétrique et idempotente, $h_i = H_{ii} = \sum_j H_{ij}^2 \geq H_{ii}^2 = h_i^2$, donc $h_i \leq 1$. Un point à fort levier tire la droite vers lui : la variance de son résidu, $\sigma_\varepsilon^2(1 - h_i)$, est d'autant plus faible.

■

La distance de Cook

Elle combine les deux

$$D_i = \frac{e_i^2}{(k+1)\,\hat{\sigma}_\varepsilon^2} \cdot \frac{h_i}{(1-h_i)^2}$$

où h_i est le levier de l'observation i. Elle mesure de combien **l'ensemble des prévisions** changerait si l'on retirait ce point.

Le seuil usuel

$$D_i > \frac{4}{n}$$

Sur nos cinq cents salariés : $D_i > 0{,}008$. C'est un seuil d'**alerte**, non de suppression.

Démonstration : La distance de Cook : $D_i = \frac{e_i^2}{(k+1)\hat{\sigma}_\varepsilon^2} \cdot \frac{h_i}{(1-h_i)^2}$

Par définition, D_i mesure de combien l'ensemble des prévisions bouge quand on retire l'observation i :

$$D_i = \frac{\big\|\hat{y} - \hat{y}_{(i)}\big\|^2}{(k+1)\,\hat{\sigma}_\varepsilon^2}, \qquad \hat{y}_{(i)} = X\hat{\beta}_{(i)},$$

où $\hat{\beta}_{(i)}$ est le coefficient estimé **sans** l'observation i.

Étape 1 : retirer une observation. Notons $A = X'X$ et x_i la i-ième ligne de X, écrite en colonne ; $h_i = x_i' A^{-1} x_i$. Sans l'observation i, la matrice devient $A - x_i x_i'$ et le second membre des équations normales $X'y - x_i y_i$. On vérifie par multiplication que

$$(A - x_i x_i')^{-1} = A^{-1} + \frac{A^{-1} x_i x_i' A^{-1}}{1 - h_i}.$$

Avec $A^{-1}X'y = \hat{\beta}$ et $x_i'\hat{\beta} = \hat{y}_i$,

$$\hat{\beta}_{(i)} = \hat{\beta} + A^{-1}x_i\Big(-y_i + \frac{\hat{y}_i - h_i y_i}{1-h_i}\Big) = \hat{\beta} - \frac{A^{-1}x_i\, e_i}{1-h_i},$$

puisque $-y_i(1-h_i) + \hat{y}_i - h_i y_i = \hat{y}_i - y_i = -e_i$.

Étape 2 : l'écart des prévisions. $\hat{y} - \hat{y}_{(i)} = X(\hat{\beta} - \hat{\beta}_{(i)}) = XA^{-1}x_i\, e_i/(1-h_i)$, et

$$\big\|\hat{y} - \hat{y}_{(i)}\big\|^2 = \frac{e_i^2}{(1-h_i)^2}\, x_i' A^{-1} X'X A^{-1} x_i = \frac{h_i\, e_i^2}{(1-h_i)^2}.$$

En divisant par $(k+1)\hat{\sigma}_\varepsilon^2$, on obtient la formule. Sur les cinq ménages, pour E : $D_E = \frac{1}{2 \times 2{,}5} \times \frac{0{,}6}{0{,}4^2} = 0{,}75$.

Un sous-produit. La prévision de y_i faite **sans** l'observation i se trompe de $y_i - x_i'\hat{\beta}_{(i)} = e_i + h_i e_i/(1-h_i) = e_i/(1-h_i)$: le résidu est d'autant plus sous-estimé que le levier est fort. C'est ce résidu, mis au carré, qu'utilise la variance HC3 du chapitre 14.

■

Cook, à la main, sur les cinq ménages

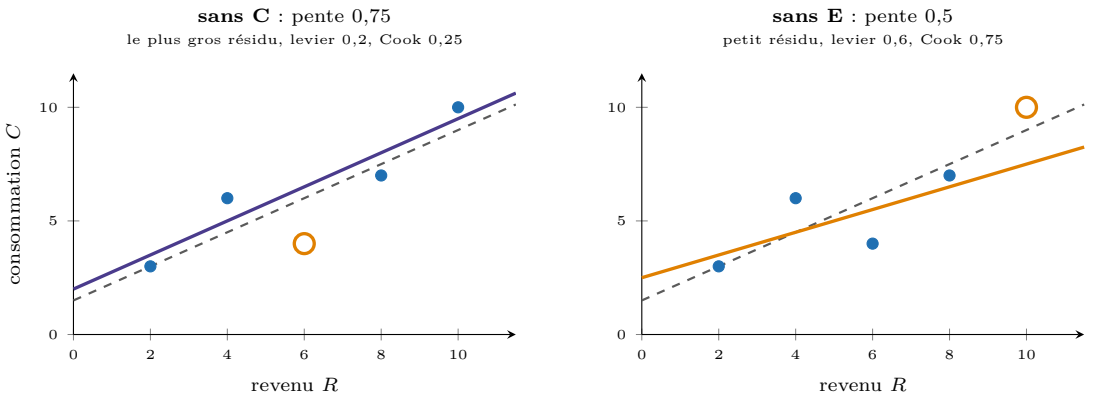
Deux paramètres, variance résiduelle 2,5

Ménage	A	B	C	D	E
résidu e	0	1,5	-2	$-0{,}5$	1
levier h	0,6	0,3	0,2	0,3	0,6
Cook D	0	0,276	0,25	0,031	0,75

Le plus influent n'a pas le plus gros résidu

E s'écarte de la droite d'un millier seulement, mais il est au bout du levier : $D_E = \frac{1}{5} \times \frac{0{,}6}{0{,}16} = 0{,}75$. C, avec le plus gros résidu, -2, est au centre : $D_C = 0{,}25$.

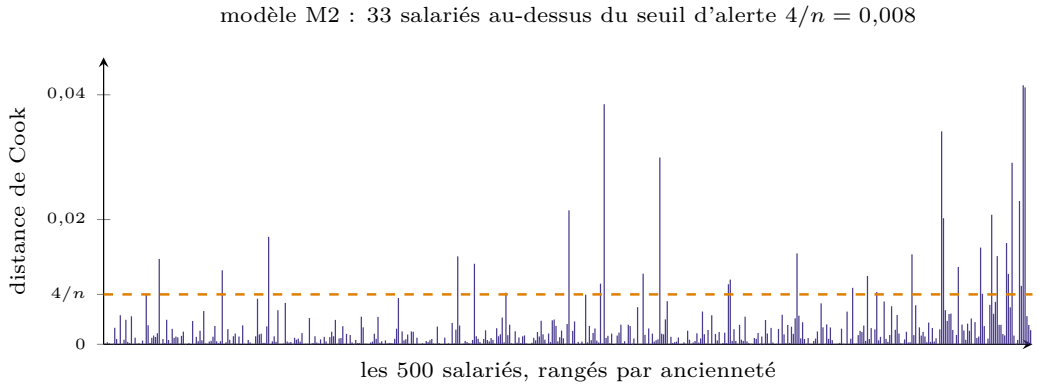
Retirer C, retirer E



La distance de Cook avait raison

Sans C, la pente ne bouge pas : 0,75 — seule la constante monte, de 1,5 à 2. Sans E, elle tombe à 0,5. **Le résidu ne disait pas lequel comptait ; le levier, si.**

Sur les salariés



Trente-trois salariés au-dessus de 4/n

Le plus influent, avec $D = 0{,}042$: un Bac+2 de trente ans d'ancienneté payé 16 180 dirhams. Aucun n'approche 1, le seuil où un point déplacerait à lui seul toute la droite.

Avec et sans les trente-trois

Le test de robustesse

Coefficient	M2 complet	Sans les 33
Ancienneté	270,27	253,69
Bac+2	1 099,57	1 066,61
Bac+5	3 336,99	3 104,43

Les conclusions survivent

Les coefficients baissent de 3 à 7 % — les salariés retirés sont surtout des salaires élevés —, mais tous restent du même ordre et très significatifs. **Une conclusion qui survit à ce test est solide ; on publie les deux colonnes.**

Que faire d'un point influent

Quatre questions, dans cet ordre

1. Est-ce une **erreur de saisie** ? On la corrige.
2. Appartient-il à la **population étudiée** ? Un dirigeant dans un fichier d'employés n'y a pas sa place.
3. Le modèle est-il **mal spécifié** ? Une non-linéarité produit des points apparemment aberrants.
4. Si rien de tout cela : **c'est une observation, et on la garde.**

La règle déontologique

On ne supprime pas une observation parce qu'elle dérange.
La bonne pratique consiste à estimer le modèle avec et sans, et à publier les deux si les conclusions diffèrent. C'est ce qu'on appelle un test de **robustesse** — et une conclusion qui n'y survit pas n'était pas une conclusion.

Sur machine

Levier et influence avec R

```
R <- c(2, 4, 6, 8, 10)
C <- c(3, 6, 4, 7, 10)
m <- lm(C ~ R)
round(hatvalues(m), 3)              # leviers
#   1   2   3   4   5
# 0.6 0.3 0.2 0.3 0.6
```

```r
round(cooks.distance(m), 3)          # distances de Cook
#     1     2     3     4     5
# 0.000 0.276 0.250 0.031 0.750
coef(lm(C[-5] ~ R[-5]))              # sans le ménage E
# (Intercept)       R[-5]
#         2.5         0.5
```

Normalité et influence avec Python

```python
import pandas as pd
import statsmodels.formula.api as smf
from statsmodels.stats.stattools import jarque_bera
sal = pd.read_csv("salaires.csv")
m2 = smf.ols("salaire ~ ancienne te + diplome", data=sal).fit()
jb, p, S, K = jarque_bera(m2.resid)
print(round(jb, 2), f"{p:.1e}", round(S, 3), round(K, 3))
# 34.06 4.0e-08 0.563 3.607
cook = m2.get_influence().cooks_distance[0]
garde = cook <= 4 / len(sal)            # 33 salariés écartés
m2s = smf.ols(m2.model.formula, data=sal[garde]).fit()
print(m2s.params.round(2).tolist())     # sans eux
# [3473.98, 1066.61, 3104.43, 253.69]
```

S'entraîner

Exercice 1 : leviers et Cook à la main

Les quatre magasins

Pour $x = 1, 2, 4, 5$ ($\overline{x} = 3$, $S_{xx} = 10$), résidus 0 ; 0,5 ; $-1{,}5$; 1 et $\hat{\sigma}^2_\varepsilon = 1{,}75$:

1. Calculer les quatre leviers et vérifier leur somme.
2. Calculer les quatre distances de Cook.
3. Quel magasin est le plus influent ? A-t-il le plus gros résidu ?

Exercice 1 : solution

Le quatrième magasin, malgré un résidu moyen

1. $h = 0{,}25 + d^2/10$: 0,65 ; 0,35 ; 0,35 ; 0,65, de somme 2.
2. $D = e^2/(2 \times 1{,}75) \times h/(1-h)^2$: 0 ; 0,059 ; 0,533 ; 1,516.
3. Le **quatrième** ($D = 1{,}52$), au bout du levier ; le troisième a le plus gros résidu, $-1{,}5$, mais un levier moindre. Avec quatre points, aucun n'est anodin.

Exercice 2 : Jarque-Bera et taille d'échantillon

Une asymétrie modérée

Les résidus d'un modèle ont une asymétrie $S = 0{,}3$ et un aplatissement $K = 3{,}5$.

1. Calculer JB pour $n = 200$ et conclure ($\chi^2_2 = 5{,}99$).
2. Même question pour $n = 2\,000$.
3. Dans lequel des deux cas la non-normalité menace-t-elle les tests de Student ?

Exercice 2 : solution

Le test et l'enjeu vont en sens contraire

1. $JB = 200\,(0{,}09/6 + 0{,}25/24) = 200 \times 0{,}0254 = 5{,}08 < 5{,}99$: non rejet.
2. 50,8 : rejet massif.
3. **Aucun des deux**, en pratique : 200 et 2 000 observations suffisent au théorème central limite. La non-normalité ne menace les tests qu'en dessous d'une trentaine d'observations — là où Jarque-Bera n'a presque aucune puissance.

Exercice 3 : décider du sort d'un point

Quatre salariés atypiques

Pour chacun, que faire ?

1. Un salaire de 175 000 dirhams, alors que la fiche de paie indique 17 500.
2. Le directeur général, inclus par erreur dans un fichier d'employés.
3. Un salarié de trente-cinq ans d'ancienneté dont le salaire dépasse nettement la droite, alors que la relation semble s'infléchir en fin de carrière.
4. Un Bac+5 bien payé, sans rien d'anormal dans son dossier.

Exercice 3 : solution

Corriger, exclure, respécifier, garder

1. **Corriger** : c'est une erreur de saisie, avec la bonne valeur sous la main.
2. **Exclure**, en le disant : il n'appartient pas à la population étudiée.
3. **Respécifier** : le point signale une forme fonctionnelle à revoir — un terme quadratique, chapitre 18.
4. **Garder** : c'est une observation. On peut estimer avec et sans, et publier les deux.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. **Jarque-Bera** combine asymétrie et aplatissement : 34,1 ici, la normalité est rejetée.
2. **Sans conséquence** sur cinq cents observations ; décisive en dessous de trente.
3. Le **levier** $h_i = 1/n + (x_i - \overline{x})^2/S_{xx}$ ne dépend que des x : 0,6 pour les ménages extrêmes.
4. **Cook** combine résidu et levier : E, au petit résidu, est le plus influent (0,75).

5. Salaires : 33 points au-dessus de $4/n$, et des conclusions qui survivent à leur retrait.
6. On ne supprime pas une observation gênante : on estime **avec et sans**, et l'on publie les deux.

La suite

Trois chapitres ont conclu de la même manière : le logarithme réglerait le problème. Le chapitre 18 le prend au sérieux.