

Introduction à l'économétrie

Chapitre 4 : La qualité de l'ajustement

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'économétrie

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — La décomposition, de bout en bout

On étudie l'ancienneté X (en années) et le salaire Y (en milliers de DH) de 4 employés : $X = (1, 3, 5, 7)$, $Y = (4, 5, 7, 8)$. On admet la droite estimée $\hat{Y} = 3,2 + 0,7X$.

- Calculer $\bar{Y}$.
- Calculer les quatre valeurs prédites $\hat{Y}_i$.
- Calculer $SCT = \sum_i (Y_i - \bar{Y})^2$, $SCE = \sum_i (\hat{Y}_i - \bar{Y})^2$ et $SCR = \sum_i (Y_i - \hat{Y}_i)^2$. Vérifier l'identité $SCT = SCE + SCR$.
- En déduire R^2 . Ce salaire est-il, selon ce modèle, largement expliqué par la seule ancienneté?

Exercice 2 — L'ordre des quatre questions

Une étude affirme avoir estimé la fonction de demande d'un bien : $\hat{Q} = 120 + 15P$, où Q est la quantité demandée et P le prix. Le rapport indique fièrement un $R^2 = 0,95$.

- Rappeler les quatre questions, dans l'ordre, que le cours recommande de se poser face à un modèle estimé.
- Répondre à la première question pour ce modèle : le signe du coefficient sur le prix (+15) est-il conforme à la théorie économique élémentaire de la demande?
- Sachant cela, la valeur $R^2 = 0,95$ change-t-elle quoi que ce soit au jugement porté sur ce modèle?
- Reformuler, avec vos propres mots, l'avertissement du cours : « un modèle aux coefficients absurdes et au R^2 de 0,95 ne vaut rien » — pourquoi le R^2 est-il, dans la méthode du cours, examiné **en dernier**, et non en premier?

Exercice 3 — L'écart-type résiduel, souvent plus parlant

Une étude sur $n = 27$ ménages estime la relation entre revenu et consommation. On admet $SCR = 2\,500$ (en unités de milliers de DH au carré).

- Rappeler la formule de $\hat{\sigma}_\varepsilon$, et pourquoi le dénominateur est $n - 2$ plutôt que n (indice : deux paramètres ont été estimés).
- Calculer $\hat{\sigma}_\varepsilon$ pour cette étude.
- Traduire ce résultat en une phrase compréhensible par un directeur commercial, sans utiliser le mot « résidu » ni le symbole $\hat{\sigma}_\varepsilon$.
- En quoi cette phrase est-elle plus immédiatement utile, pour une décision opérationnelle, qu'une annonce du type « $R^2 = 0,80$ »?

2 Exercice cumulatif (chapitre 4 et chapitres précédents)

Exercice 4 — Deux ajustements extrêmes, revisités

On reprend deux résultats déjà obtenus au chapitre 3 : (i) sur les cinq ménages $R = (2, 3, 4, 5, 6)$, $C = (2,2, 2,8, 3,3, 3,6, 4,1)$, la droite $\hat{C} = 1,36 + 0,46R$ (exercice 1 du chapitre 3) ; (ii) sur les trois points $X = (1, 2, 3)$, $Y = (10, 1, 10)$, la droite horizontale $\hat{Y} = 7 + 0 \times X$ (exercice 3 du chapitre 3).

- Pour le jeu (i), on admet $SCT = 2,14$ et $SCR = 0,024$. Calculer SCE , puis R^2 .
- Pour le jeu (ii), on avait calculé $\bar{Y} = 7$ et une droite horizontale $\hat{Y} = 7$ pour tout X . Que vaut nécessairement $SCE = \sum_i (\hat{Y}_i - \bar{Y})^2$ dans ce cas précis? En déduire R^2 sans calcul supplémentaire.
- Le cours affirme : « $R^2 = 0$ signifie que la droite est horizontale ». Le jeu (ii) confirme-t-il cette affirmation dans les deux sens (une droite horizontale a-t-elle nécessairement $R^2 = 0$, et $R^2 = 0$ implique-t-il une droite horizontale)?

- (d) Ces deux résultats ($R^2 \approx 0,989$ contre $R^2 = 0$) sont-ils comparables au sens de la mise en garde du cours (« un R^2 ne se compare qu'à variable expliquée identique ») ? Justifier à partir de la nature très différente des deux variables expliquées (C , une consommation économique réelle, contre Y , une suite de points choisie arbitrairement pour illustrer une propriété algébrique).
- (e) Rappeler enfin le résultat du chapitre 3 (exercice cumulatif) sur les quatre ménages de revenu identique du chapitre 1 : $V(R) = 0$ empêchait de calculer $\hat{\beta}_1$. R^2 est-il, pour la même raison, calculable sur ces quatre ménages ?

3 Applications en sciences économiques

Exercice 5 — Comparer, ou ne pas comparer, deux R^2

Un institut de recherche a produit trois modèles indépendants :

- Modèle A : taux de criminalité expliqué par le taux de chômage, $R^2 = 0,25$.
 - Modèle B : taux de criminalité expliqué par la densité de population, $R^2 = 0,60$.
 - Modèle C : croissance du PIB expliquée par le taux d'investissement, $R^2 = 0,72$.
- (a) Les modèles A et B portent-ils sur la **même** variable expliquée ? Peut-on légitimement en conclure que la densité de population « explique mieux » la criminalité que le chômage ?
 - (b) Les modèles B et C portent-ils sur la même variable expliquée ? Peut-on en conclure que le taux d'investissement « explique mieux » la croissance du PIB que la densité de population n'explique la criminalité ?
 - (c) Formuler, à partir de ces trois modèles, la règle précise qui distingue une comparaison légitime d'une comparaison illégitime entre deux R^2 .
 - (d) Le modèle A ($R^2 = 0,25$), pris isolément et sans comparaison, doit-il être jugé « mauvais » pour autant ? Rappeler pourquoi un R^2 modeste peut être un résultat parfaitement acceptable sur des données individuelles ou hétérogènes.

Exercice 6 — La phrase qu'un responsable RH comprend

Le cours rapporte que le modèle salaire/ancienneté donne $R^2 = 0,40$ et $\hat{\sigma}_\varepsilon = 2\,008$ DH.

- (a) Un responsable des ressources humaines vous demande : « votre modèle, il est bon ou pas ? ». Laquelle des deux statistiques ($R^2 = 0,40$ ou $\hat{\sigma}_\varepsilon = 2\,008$ DH) mobiliseriez-vous en premier pour lui répondre de façon opérationnelle ?
- (b) Si ce responsable doit décider d'une fourchette de négociation salariale pour un nouvel embauché à partir de son ancienneté prévue, quelle des deux statistiques lui est directement utile pour fixer cette fourchette ?
- (c) Le $R^2 = 0,40$ est-il pour autant inutile ? À quelle question (portant sur la part du salaire **expliquée** par l'ancienneté, par opposition à d'autres facteurs comme le poste ou le diplôme) répond-il, que $\hat{\sigma}_\varepsilon$ ne permet pas de trancher ?
- (d) En quoi cet exemple illustre-t-il que R^2 et $\hat{\sigma}_\varepsilon$ sont deux mesures **complémentaires** de la qualité d'un modèle, plutôt que deux mesures concurrentes dont il faudrait choisir une seule ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) $\bar{Y} = (4 + 5 + 7 + 8)/4 = 24/4 = 6$.
- (b) $\hat{Y}_1 = 3,2 + 0,7 \times 1 = 3,9$; $\hat{Y}_2 = 3,2 + 0,7 \times 3 = 5,3$; $\hat{Y}_3 = 3,2 + 0,7 \times 5 = 6,7$; $\hat{Y}_4 = 3,2 + 0,7 \times 7 = 8,1$.
- (c) $SCT = (4-6)^2 + (5-6)^2 + (7-6)^2 + (8-6)^2 = 4 + 1 + 1 + 4 = 10$. $SCE = (3,9-6)^2 + (5,3-6)^2 + (6,7-6)^2 + (8,1-6)^2 = 4,41 + 0,49 + 0,49 + 4,41 = 9,8$. $SCR = (4-3,9)^2 + (5-5,3)^2 + (7-6,7)^2 + (8-8,1)^2 = 0,01 + 0,09 + 0,09 + 0,01 = 0,2$. Vérification : $9,8 + 0,2 = 10 = SCT$. ✓
- (d) $R^2 = 9,8/10 = 0,98$. Oui, avec ces données, l'ancienneté seule explique 98 % de la variance du salaire — un ajustement exceptionnellement élevé, atypique sur données individuelles réelles (où l'on dépasse rarement 0,5), ce qui rappelle qu'il s'agit ici d'un petit jeu de données pédagogique et non d'une enquête représentative.

Correction — Exercice 2

- (a) 1) Les signes sont-ils conformes à la théorie ? 2) Les ordres de grandeur sont-ils plausibles ? 3) Les coefficients sont-ils significatifs ? 4) Enfin, quel est le R^2 ?
- (b) Non : la théorie élémentaire de la demande prédit une relation **négative** entre prix et quantité demandée (loi de la demande), pas positive. Le signe +15 est donc **non conforme**.
- (c) Non, cela ne change rien au jugement défavorable déjà porté à la question (b) : un R^2 élevé ne rachète pas un signe économiquement absurde. Le modèle échoue dès la première question de la méthode, avant même d'atteindre le R^2 .
- (d) Un R^2 élevé signifie seulement que le modèle **s'ajuste statistiquement bien** aux données de l'échantillon — il ne garantit en rien que la relation estimée soit économiquement sensée. Un coefficient de signe absurde suggère un problème plus grave (variable omise, causalité inversée, erreur de spécification, coïncidence sur un petit échantillon atypique) qu'un simple ajustement imparfait. Le cours place le R^2 en dernier précisément parce qu'un bon ajustement statistique ne peut **jamais** racheter une relation qui contredit la théorie économique ; l'inverse (des coefficients justes mais un R^2 modeste) reste, lui, un résultat digne d'intérêt.

Correction — Exercice 3

- (a) $\hat{\sigma}_\varepsilon = \sqrt{SCR/(n-2)}$. Le dénominateur est $n-2$ et non n parce que **deux** paramètres (β_0 et β_1) ont été estimés à partir des mêmes données, ce qui « consomme » deux degrés de liberté — exactement le même principe que pour la variance corrigée du cours d'inférence.
- (b) $\hat{\sigma}_\varepsilon = \sqrt{2\,500/(27-2)} = \sqrt{2\,500/25} = \sqrt{100} = 10$ (milliers de DH), soit 10 000 DH.
- (c) « Notre modèle se trompe typiquement d'environ 10 000 DH lorsqu'il prédit la consommation d'un ménage à partir de son revenu. »
- (d) Cette phrase donne directement un ordre de grandeur, exprimé dans l'unité concrète du problème (des DH, pas un nombre sans dimension entre 0 et 1), immédiatement interprétable pour évaluer si l'erreur typique du modèle est acceptable au regard d'une décision opérationnelle (par exemple, calibrer une marge de sécurité budgétaire) — alors que « $R^2 = 0,80$ » ne dit rien, à lui seul, de l'ampleur **concrète** de l'erreur.

2 Exercice cumulatif

Correction — Exercice 4

- (a) $SCE = SCT - SCR = 2,14 - 0,024 = 2,116$. $R^2 = 2,116/2,14 \approx 0,9888$.
- (b) Puisque $\hat{Y}_i = 7 = \bar{Y}$ pour chacun des trois points, chaque écart $\hat{Y}_i - \bar{Y}$ est nul, donc $SCE = 0$. D'où $R^2 = 0/SCT = 0$, sans le moindre calcul supplémentaire.

(c) Oui, le jeu (ii) confirme l'affirmation dans le sens « droite horizontale $\Rightarrow R^2 = 0$ » (démontré en (b)). Il ne prouve pas la réciproque logique en général (elle est cependant vraie aussi, car $SCE = 0$ implique que tous les $\hat{Y}_i$ sont égaux à $\bar{Y}$, donc que la pente $\hat{\beta}_1$ est nécessairement nulle, ce qui définit précisément une droite horizontale) — les deux sens de l'affirmation sont donc corrects, et le jeu (ii) en offre une illustration concrète du premier.

(d) Non, ils ne sont pas comparables au sens de la mise en garde du cours : les deux variables expliquées (C , une consommation réelle de ménages, contre Y , une suite de trois valeurs choisie arbitrairement pour illustrer une propriété algébrique) n'ont **aucun rapport** économique entre elles. Le contraste 0,989 contre 0 n'enseigne donc rien sur « quel type de relation s'ajuste mieux » en général : il illustre seulement les deux bornes extrêmes que R^2 peut atteindre, sur deux exemples délibérément choisis à des fins pédagogiques différentes.

(e) Non, R^2 n'est pas calculable non plus, et pour la même raison structurelle : si $\hat{\beta}_1$ lui-même n'est pas défini (division par $V(R) = 0$), alors $\hat{Y}_i$ ne peut pas être calculé, et ni SCE ni R^2 n'ont de sens. L'absence de variation dans la variable explicative bloque toute la chaîne de calcul du chapitre 3 comme du chapitre 4.

3 Applications en sciences économiques

Correction — Exercice 5

(a) Oui, les modèles A et B portent sur la **même** variable expliquée (le taux de criminalité). La comparaison est donc légitime : avec $R^2 = 0,60 > 0,25$, la densité de population explique effectivement une part plus grande de la variance de la criminalité, dans cet échantillon, que le taux de chômage seul.

(b) Non, les modèles B et C portent sur des variables expliquées **différentes** (criminalité contre croissance du PIB). Il est donc illégitime d'en conclure quoi que ce soit en comparant directement 0,72 à 0,60 : ce sont deux phénomènes de nature complètement différente, dont la variance « explicable en principe » n'a aucune raison d'être comparable.

(c) Deux R^2 ne peuvent être comparés de façon informative que s'ils portent sur la **même variable expliquée** (éventuellement sur le même échantillon) : comparer des modèles qui tentent d'expliquer la **même** grandeur, avec des variables explicatives différentes, est légitime ; comparer des modèles portant sur des grandeurs **différentes** ne l'est pas.

(d) Non : un $R^2 = 0,25$ sur une grandeur socio-économique aussi multifactorielle que la criminalité (qui dépend de très nombreux facteurs autres que le seul chômage : démographie, politiques pénales, pauvreté, éducation, etc.) peut représenter un résultat tout à fait significatif et utile, conformément à la mise en garde du cours selon laquelle un R^2 modeste est la norme, et non l'exception, sur des données individuelles ou des phénomènes complexes et hétérogènes.

Correction — Exercice 6

(a) $\hat{\sigma}_\varepsilon = 2008$ DH : exprimé directement dans l'unité du salaire, il donne immédiatement une idée concrète de l'erreur typique de prédiction, alors que $R^2 = 0,40$ (un nombre abstrait entre 0 et 1) demande une interprétation supplémentaire pour devenir parlant à un non-spécialiste.

(b) $\hat{\sigma}_\varepsilon$ est directement utile : connaître l'erreur typique de 2008 DH permet de construire une fourchette autour du salaire prédit (par exemple, prédiction $\pm$ un ou deux $\hat{\sigma}_\varepsilon$), utilisable telle quelle dans une négociation. $R^2 = 0,40$, seul, ne donne aucune fourchette chiffrée en dirhams.

(c) Non, il n'est pas inutile : il répond à la question « quelle **part** de la variabilité totale des salaires l'ancienneté explique-t-elle, par rapport à tout ce qui reste inexpliqué (poste, diplôme, négociation individuelle, etc.) ? », une question de **décomposition des sources de variabilité** à laquelle $\hat{\sigma}_\varepsilon$, qui ne renseigne que sur l'ampleur **absolue** de l'erreur, ne répond pas.

(d) Cet exemple montre que les deux mesures répondent à des questions **différentes et complémentaires** : R^2 répond à « quelle part de la variance est expliquée » (une question relative, sans unité, utile pour comparer des variables explicatives entre elles sur la même variable expliquée) ; $\hat{\sigma}_\varepsilon$ répond à « de combien, concrètement, le modèle se trompe-t-il » (une question absolue, dans l'unité du

problème, utile pour une décision opérationnelle). Un bon compte rendu de résultats économétriques rapporte les deux, plutôt que de n'en choisir qu'une seule.