Introduction à l'économétrie

Chapitre 4 : La qualité de l'ajustement

Jaouad Madkour

29 octobre 2026

Plan du chapitre

La décomposition **2**
Couper l'écart en deux . . . 2
Les trois sommes de carrés . . . 2
Pourquoi le double produit est nul . . . 2
À la main, sur les cinq ménages . . . 3

Coefficient de détermination **3**
Sa définition . . . 3
Sur nos trois terrains . . . 4
Ce qu'il ne dit pas . . . 5
Les deux erreurs de lecture . . . 5
La bonne façon de juger un modèle . . . 5

L'écart-type résiduel **6**
La mesure oubliée . . . 6
Sur les trois terrains . . . 6
Pourquoi diviser par n moins 2 . . . 6

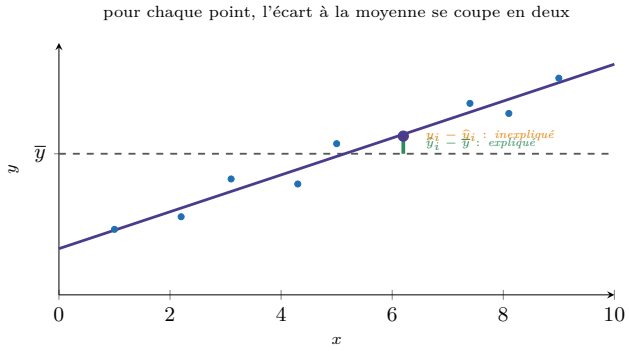
Sur machine **7**
La décomposition avec R . . . 7
La décomposition avec Python . . . 8

S'entraîner **8**
Exercice 1 : décomposer à la main . . . 8
Exercice 1 : solution . . . 8
Exercice 2 : lire une sortie partielle . . . 8
Exercice 2 : solution . . . 9
Exercice 3 : un R^2 trompeur . . . 9
Exercice 3 : solution . . . 9

Ce qu'il faut retenir **9**
Le résumé du chapitre . . . 9

La décomposition

Couper l'écart en deux



La décomposition, terme à terme

$y_i - \overline{y} = (\widehat{y}_i - \overline{y}) + (y_i - \widehat{y}_i)$

En élevant au carré et en sommant, le double produit s'annule — c'est une propriété des moindres carrés, non une approximation :

$$\underbrace{\text{SCT}}_{\text{totale}} = \underbrace{\text{SCE}}_{\text{expliquée}} + \underbrace{\text{SCR}}_{\text{résiduelle}}$$

C'est exactement la décomposition de l'analyse de la variance, chapitre 17 du cours d'inférence. L'ANOVA découpait selon des groupes ; la régression découpe selon une droite.

D'où $R^2 = \text{SCE}/\text{SCT}$, qui n'est autre que le η^2 de l'ANOVA.

Les trois sommes de carrés

L'identité fondamentale

$$\underbrace{\sum_i (y_i - \overline{y})^2}_{\text{SCT}} = \underbrace{\sum_i (\widehat{y}_i - \overline{y})^2}_{\text{SCE}} + \underbrace{\sum_i (y_i - \widehat{y}_i)^2}_{\text{SCR}}$$

Totale, expliquée, résiduelle.

Le double produit s'annule exactement

En développant le carré, il apparaît un terme croisé $2\sum_i (\widehat{y}_i - \overline{y}) e_i$.
Il est **nul** — conséquence directe des deux propriétés algébriques du chapitre 3. Ce n'est pas une approximation : c'est une identité, et elle ne vaut que pour les moindres carrés.

Pourquoi le double produit est nul

Deux lignes

La droite passe par le point moyen : $\widehat{y}_i - \overline{y} = \widehat{\beta}_1 (x_i - \overline{x})$. Donc

$$\sum_i (\widehat{y}_i - \overline{y})\, e_i = \widehat{\beta}_1 \Big(\sum_i x_i e_i - \overline{x} \sum_i e_i \Big) = \widehat{\beta}_1 (0 - 0) = 0$$

Une conséquence utile au calcul

La même égalité donne $\text{SCE} = \widehat{\beta}_1^2 \, S_{xx}$: la part expliquée se calcule **sans valeurs ajustées**, avec la pente et la somme des carrés de x.
Sur les cinq ménages : $0{,}75^2 \times 40 = 22{,}5$.

Démonstration : La décomposition SCT = SCE + SCR, et SCE = $\hat{\beta}_1^2 S_{xx}$

Pour chaque observation, $y_i - \overline{y} = (\hat{y}_i - \overline{y}) + (y_i - \hat{y}_i) = (\hat{y}_i - \overline{y}) + e_i$. En élevant au carré et en sommant,

$$\sum_i (y_i - \overline{y})^2 = \sum_i (\hat{y}_i - \overline{y})^2 + 2\sum_i (\hat{y}_i - \overline{y})\, e_i + \sum_i e_i^2.$$

Le terme central est le double produit. La droite passe par le point moyen (propriété 3 du chapitre 3), donc $\hat{y}_i = \overline{y} + \hat{\beta}_1(x_i - \overline{x})$ et

$$\sum_i (\hat{y}_i - \overline{y})\, e_i = \hat{\beta}_1 \Big(\sum_i x_i e_i - \overline{x} \sum_i e_i \Big) = \hat{\beta}_1 \,(0 - 0) = 0$$

par les propriétés 1 et 2. Il reste SCT = SCE + SCR. Enfin SCE = $\sum_i \hat{\beta}_1^2 (x_i - \overline{x})^2 = \hat{\beta}_1^2 S_{xx}$.

■

À la main, sur les cinq ménages

Les trois sommes, colonne par colonne

Ménage	C	$\widehat{C}$	$C - \overline{C}$	$\widehat{C} - \overline{C}$	e
A	3	3	−3	−3	0
B	6	4,5	0	−1,5	1,5
C	4	6	−2	0	−2
D	7	7,5	1	1,5	−0,5
E	10	9	4	3	1
Carrés			SCT = 30	SCE = 22,5	SCR = 7,5

Point par point, l'identité ne tient pas

Pour le ménage B : $0^2 \neq (-1{,}5)^2 + 1{,}5^2$. La décomposition ne vaut que **pour les sommes** : c'est la somme des doubles produits qui s'annule, pas chacun d'eux.

Coefficient de détermination

Sa définition

Le R^2

$$R^2 = \frac{\text{SCE}}{\text{SCT}} = 1 - \frac{\text{SCR}}{\text{SCT}} \qquad 0 \leq R^2 \leq 1$$

C'est la **part de la variance de y dont le modèle rend compte**.

Trois identités à connaître

En régression simple, $R^2 = r^2$: le carré du coefficient de corrélation linéaire.
C'est aussi le η^2 de l'analyse de la variance, chapitre 17 de l'inférence — même quantité, autre découpage.

Et $R^2 = 0$ signifie que la droite est **horizontale** : la meilleure prévision est alors la moyenne.

Démonstration : $R^2 = r^2$, et R^2 reste entre 0 et 1

Notons $S_{yy} = \sum_i (y_i - \overline{y})^2 = \text{SCT}$. Comme $\text{SCE} = \hat{\beta}_1^2 S_{xx}$ et $\hat{\beta}_1 = S_{xy}/S_{xx}$,

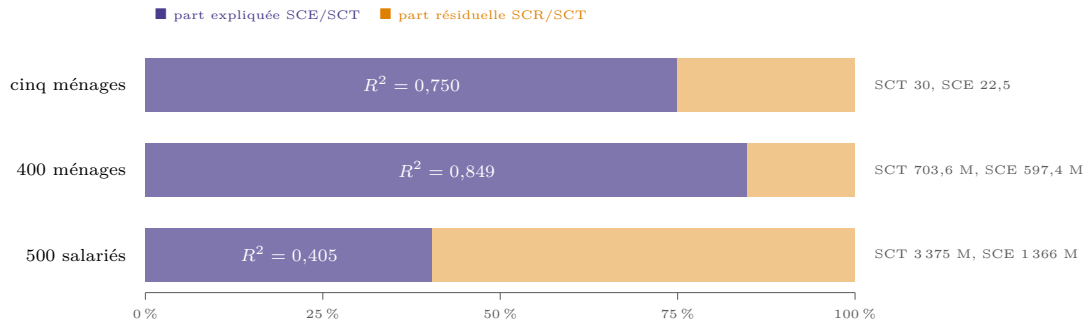
$$R^2 = \frac{\text{SCE}}{\text{SCT}} = \frac{S_{xy}^2/S_{xx}}{S_{yy}} = \frac{S_{xy}^2}{S_{xx}\,S_{yy}} = \left(\frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}}\right)^2 = r^2,$$

puisque $r = \text{cov}(x,y)/(\sigma_x\sigma_y) = S_{xy}/\sqrt{S_{xx}S_{yy}}$ (le facteur n se simplifie).

Les bornes viennent de la décomposition : SCE et SCR sont des sommes de carrés, donc positives, et leur somme vaut SCT. Chacune est donc comprise entre 0 et SCT, et $0 \le R^2 \le 1$. Au passage, $r^2 \le 1$: on retrouve que $|r| \le 1$. Enfin $R^2 = 0$ équivaut à $\hat{\beta}_1^2 S_{xx} = 0$, c'est-à-dire à $\hat{\beta}_1 = 0$: la droite est horizontale.

■

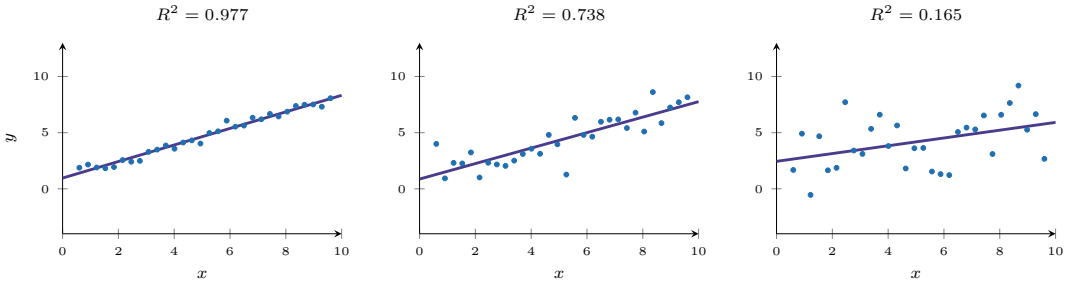
Sur nos trois terrains



Trois calculs, une même formule

Cinq ménages : $22{,}5/30 = 0{,}75$, et $r^2 = 0{,}866^2 = 0{,}75$. Salaires : $1\,366{,}4/3\,375{,}1 = 0{,}405$, et $r^2 = 0{,}6363^2 = 0{,}405$. Ménages : $597{,}4/703{,}6 = 0{,}849$.

Ce qu'il ne dit pas



Les trois droites ont la même pente. Seule change la dispersion autour d'elles.

Le R^2 mesure la *part de la variance expliquée*, non l'intensité de l'effet. Un R^2 faible avec une pente forte et significative est parfaitement possible — et c'est le cas ordinaire en économie des ménages, où l'on explique rarement plus de la moitié de la variance.

Ne jamais juger un modèle sur le seul R^2. Un R^2 de 0,30 sur des données individuelles est un bon résultat ; un R^2 de 0,99 sur une série temporelle est souvent le signe que les deux variables croissent simplement avec le temps.

Les deux erreurs de lecture

Un R^2 faible n'est pas un mauvais résultat

Sur des données **individuelles**, on explique rarement plus de la moitié de la variance : les comportements humains sont irréductiblement dispersés.
Nos salaires donnent $R^2 = 0{,}40$ avec la seule ancienneté. C'est un bon résultat, et la pente est significative à $t = 18{,}4$.

Un R^2 élevé n'est pas non plus un bon résultat

Notre enquête de ménages donne $R^2 = 0{,}849$: bien plus élevé que sur les salaires, et c'est normal — le revenu détermine la consommation de façon beaucoup plus directe que l'ancienneté ne détermine le salaire.
Un R^2 ne se compare qu'entre modèles portant sur la même variable expliquée. Comparer 0,40 sur les salaires et 0,85 sur la consommation ne dit rien : ce ne sont pas les mêmes phénomènes.

La bonne façon de juger un modèle

Quatre questions, dans cet ordre

1. Les **signes** des coefficients sont-ils conformes à la théorie ?
2. Leurs **ordres de grandeur** sont-ils plausibles ?
3. Sont-ils **significatifs** ?
4. Enfin, quel est le R^2 ?

Le R^2 arrive en dernier, et ce n'est pas un hasard

Un modèle aux coefficients absurdes et au R^2 de 0,95 ne vaut rien. Un modèle aux coefficients justes et au R^2 de 0,30 enseigne quelque chose.
On ne publie pas un R^2, on publie un coefficient et son intervalle.

L'écart-type résiduel

La mesure oubliée

Dans l'unité de la variable expliquée

$$\hat{\sigma}_\varepsilon = \sqrt{\frac{\text{SCR}}{n-2}}$$

C'est l'écart-type des résidus, **dans l'unité de la variable expliquée**.

Elle est souvent plus parlante que le R^2

Sur nos salaires, $\hat{\sigma}_\varepsilon = 2\,008$ dirhams : le modèle se trompe typiquement de deux mille dirhams sur un salaire individuel.
Voilà une phrase qu'un directeur des ressources humaines comprend immédiatement. « $R^2 = 0{,}40$ » ne lui dit rien.

Sur les trois terrains

Trois écarts-types résiduels

Terrain	SCR	$n-2$	$\hat{\sigma}_\varepsilon$
Cinq ménages	7,5	3	$\sqrt{2{,}5} = 1{,}58$ millier de dh
400 ménages	106,2 millions	398	517 dh
500 salariés	2 008,6 millions	498	2 008 dh

Rapporté à la moyenne

517 dirhams sur une consommation moyenne de 2 779 : une erreur typique de 19 %. 2 008 sur un salaire moyen de 7 158 : 28 %. **Le classement des deux modèles est le même qu'avec le R^2, mais il se dit en dirhams.**

Pourquoi diviser par n moins 2

Deux contraintes pèsent sur les résidus

Les résidus vérifient $\sum e_i = 0$ et $\sum x_i e_i = 0$. Sur cinq ménages, trois résidus connus fixent donc les deux autres : il ne reste que $n-2=3$ **résidus libres**.

C'est le n moins 1 de la variance d'échantillon

Au cours d'inférence, on divisait par $n-1$ parce qu'on avait estimé une moyenne. Ici, deux paramètres estimés, deux degrés de liberté perdus : c'est le $n-2$ du chapitre 20 de l'inférence. **Diviser par n sous-estimerait systématiquement σ_ε** — et d'autant plus que n est petit.

Démonstration : Pourquoi SCR$/(n-2)$: $E(\text{SCR}) = (n-2)\sigma_\varepsilon^2$

On suppose le modèle $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, les x_i étant donnés, avec $E(\varepsilon_i) = 0$, $V(\varepsilon_i) = \sigma_\varepsilon^2$ et des erreurs non corrélées entre elles. Posons $A = \sum_i (x_i - \overline{x})\,\varepsilon_i$.

La pente estimée. En moyennant le modèle, $\overline{y} = \beta_0 + \beta_1 \overline{x} + \overline{\varepsilon}$, donc $y_i - \overline{y} = \beta_1 (x_i - \overline{x}) + (\varepsilon_i - \overline{\varepsilon})$. Multiplié par $x_i - \overline{x}$ puis sommé, cela donne $S_{xy} = \beta_1 S_{xx} + A$ (car $\sum_i (x_i - \overline{x})\,\overline{\varepsilon} = 0$), donc $\hat{\beta}_1 = \beta_1 + A/S_{xx}$.

La somme des carrés des résidus. D'après la décomposition, $\text{SCR} = S_{yy} - \hat{\beta}_1^2 S_{xx}$. Or

$$S_{yy} = \beta_1^2 S_{xx} + 2\beta_1 A + \sum_i (\varepsilon_i - \overline{\varepsilon})^2,$$

$$\hat{\beta}_1^2 S_{xx} = \beta_1^2 S_{xx} + 2\beta_1 A + \frac{A^2}{S_{xx}},$$

et la différence est

$$\text{SCR} = \sum_i (\varepsilon_i - \overline{\varepsilon})^2 - \frac{A^2}{S_{xx}}.$$

L'espérance. Le premier terme est la somme des carrés des écarts à la moyenne de n variables de variance σ_ε^2 : son espérance vaut $(n-1)\,\sigma_\varepsilon^2$, comme pour la variance d'échantillon du cours d'inférence. Pour le second, $E(A) = 0$ et, les erreurs étant non corrélées, $E(A^2) = V(A) = \sum_i (x_i - \overline{x})^2 \sigma_\varepsilon^2 = \sigma_\varepsilon^2 S_{xx}$. Donc

$$E(\text{SCR}) = (n-1)\,\sigma_\varepsilon^2 - \sigma_\varepsilon^2 = (n-2)\,\sigma_\varepsilon^2.$$

Diviser SCR par $n-2$ donne ainsi une estimation sans biais de σ_ε^2 ; la diviser par n la sous-estimerait d'un facteur $(n-2)/n$, soit $3/5$ sur les cinq ménages.

■

Sur machine

La décomposition avec R

```
R <- c(2, 4, 6, 8, 10)
C <- c(3, 6, 4, 7, 10)
m <- lm(C ~ R)
anova(m)                    # SCE puis SCR
# Analysis of Variance Table
#
# Response: C
#           Df Sum Sq Mean Sq F value  Pr(>F)
# R          1   22.5    22.5       9 0.05767
# Residuals  3    7.5     2.5
summary(m)$r.squared
# [1] 0.75
sigma(m)                    # racine de SCR / (n - 2)
# [1] 1.581139
```

La décomposition avec Python

```
import numpy as np, pandas as pd
import statsmodels.formula.api as smf
sal = pd.read_csv("salaires.csv")
m1 = smf.ols("salaire ~ ancienete", data=sal).fit()
sc = np.array([m1.centered_tss, m1.ess, m1.ssr])
print((sc / 1e6).round(2))           # SCT, SCE, SCR en millions
# [3375.06 1366.42 2008.64]
print(round(m1.rsquared, 4), round(np.sqrt(m1.scale), 2))
# 0.4049 2008.34
```

La table d'analyse de la variance contient tout

La sortie `anova` de R donne SCE (22,5), SCR (7,5) et leur rapport corrigé des degrés de liberté, $F = 9$. Ce F et sa p-value, 0,058, sont l'objet du chapitre 5.

S'entraîner

Exercice 1 : décomposer à la main

Les quatre magasins, suite

On reprend $x = 1, 2, 4, 5$ et $y = 2, 4, 5, 9$, de droite $\hat{y} = 0{,}5 + 1{,}5\,x$.

1. Calculer SCT, SCE et SCR. Vérifier l'identité.
2. En déduire R^2, puis le vérifier par r^2.
3. Calculer l'écart-type résiduel.

Exercice 1 : solution

Un R^2 de 0,865

1. $\overline{y} = 5$: SCT $= 9 + 1 + 0 + 16 = 26$. Résidus 0 ; 0,5 ; $-1{,}5$; 1 : SCR $= 3{,}5$. SCE $= 1{,}5^2 \times 10 = 22{,}5$, et $22{,}5 + 3{,}5 = 26$.
2. $R^2 = 22{,}5/26 = 0{,}865$. Et $r = 15/\sqrt{10 \times 26} = 0{,}930$, dont le carré vaut 0,865.
3. $\hat{\sigma}_\varepsilon = \sqrt{3{,}5/2} = 1{,}32$ millier de dirhams.

Exercice 2 : lire une sortie partielle

Ce qu'on peut reconstruire

Une régression simple sur $n = 102$ observations donne SCT $= 800$ et SCR $= 600$.

1. Calculer R^2 et $\hat{\sigma}_\varepsilon$.
2. Le coefficient de corrélation vaut-il 0,5 ou $-0{,}5$?
3. Un collègue obtient $R^2 = 0{,}60$ en expliquant le **logarithme** de la même variable. Son modèle est-il meilleur ?

Exercice 2 : solution

Le signe ne se lit pas dans le R^2

1. $R^2 = 1 - 600/800 = 0{,}25$; $\hat{\sigma}_\varepsilon = \sqrt{600/100} = 2{,}45$.
2. Impossible à dire : $r^2 = 0{,}25$ donne $|r| = 0{,}5$. **Le signe est celui de la pente**, que la décomposition efface.
3. On ne peut pas conclure : les deux R^2 ne portent pas sur la même variance — celle de y et celle de $\ln y$. Le chapitre 18 y revient.

Exercice 3 : un R² trompeur

Deux études concurrentes

L'étude A explique la consommation **nationale** de 1990 à 2023 par le revenu national : $R^2 = 0{,}98$. L'étude B explique la consommation de 400 ménages par leur revenu : $R^2 = 0{,}85$.

1. Peut-on dire que l'étude A est meilleure ?
2. Quel phénomène, vu en introduction, peut gonfler le R^2 de A ?
3. Quelle information serait plus parlante que le R^2 pour l'étude B ?

Exercice 3 : solution

Un R^2 se lit avec ses données

1. Non : les variables expliquées diffèrent — un agrégat, des ménages — et les structures aussi.
2. La **tendance commune** : deux séries qui montent avec le temps donnent un R^2 élevé même sans relation. C'est la régression fallacieuse ; A relève des séries temporelles, hors de ce cours.
3. L'écart-type résiduel, 517 dirhams, et surtout la **pente** avec son intervalle : c'est elle qui répond à la question de Keynes.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. $\text{SCT} = \text{SCE} + \text{SCR}$: le double produit s'annule, propriété exacte des MCO.
2. $R^2 = \text{SCE}/\text{SCT}$: la part de variance expliquée, entre 0 et 1 ; 0,75 sur les cinq ménages.
3. En régression simple, $R^2 = r^2$ — et c'est le η^2 de l'ANOVA.
4. Un R^2 **faible** est normal sur données individuelles ; il ne se compare qu'à **variable expliquée identique**.
5. $\hat{\sigma}_\varepsilon = \sqrt{\text{SCR}/(n-2)}$ parle en dirhams : 2 008 sur les salaires.
6. On divise par $n - 2$: deux contraintes pèsent sur les résidus.

La suite

Le R^2 décrit l'échantillon. Il ne dit rien de la population — et c'est pourtant sur elle que porte la question économique. Le chapitre 5 fait le pas, avec les outils du cours d'inférence.