Introduction à l'économétrie

Chapitre 9 : Les trois niveaux de test

Jaouad Madkour

23 octobre 2026

Plan du chapitre

Trois questions différentes **2**
Ce qu'ils demandent . . . 2
Le test global de Fisher . . . 2
Ce que le F global vaut vraiment . . . 2
Le test global, sur les cinq ménages . . . 3

Les tests individuels **3**
La question qu'ils posent . . . 3
Le revenu des cinq ménages, seul puis accompagné . . . 3
Le cas d'école qui déroute . . . 4

Le test de restrictions **4**
Tester plusieurs coefficients ensemble . . . 4
Sur les cinq ménages : retirer la taille . . . 4
Quand il est indispensable . . . 5
La région, d'un bloc . . . 5
Tester une hypothèse économique . . . 5
Casablanca et Rabat : une même prime ? . . . 6

Sur machine **6**
Le Fisher partiel avec R . . . 6
Une contrainte linéaire avec R . . . 6
Les trois tests avec Python . . . 7
Ce que disent les sorties . . . 7

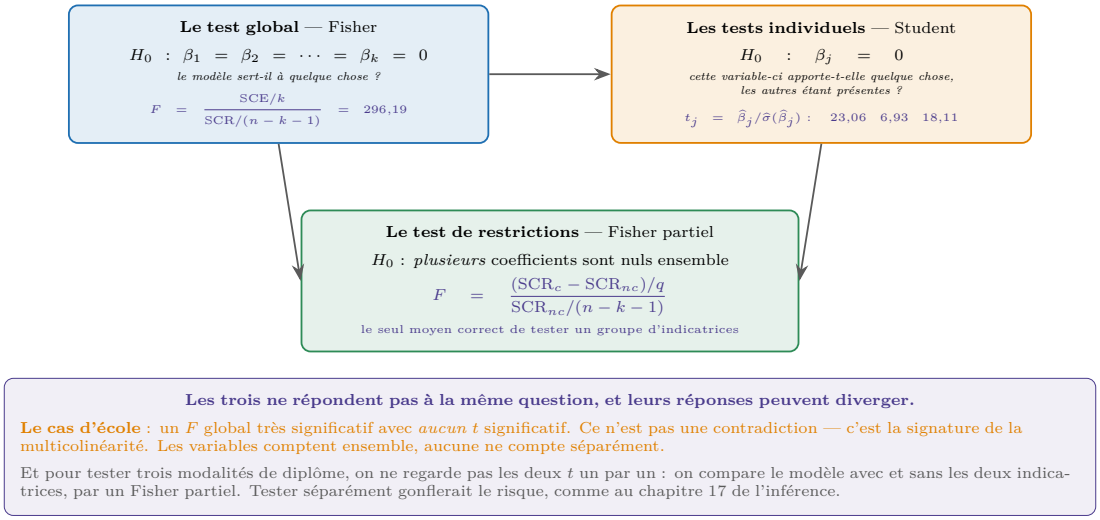
S'entraîner **7**
Exercice 1 : un Fisher partiel à la main . . . 7
Exercice 1 : solution . . . 8
Exercice 2 : le F global à partir du R^2 . . . 8
Exercice 2 : solution . . . 8
Exercice 3 : quel test pour quelle question . . . 8
Exercice 3 : solution . . . 8

Ce qu'il faut retenir **9**

Le résumé du chapitre 9

Trois questions différentes

Ce qu'ils demandent



Les trois ne répondent pas à la même question, et leurs réponses peuvent diverger.

Le cas d'école : un F global très significatif avec *aucun* t significatif. Ce n'est pas une contradiction — c'est la signature de la multicolinéarité. Les variables comptent ensemble, aucune ne compte séparément.

Et pour tester trois modalités de diplôme, on ne regarde pas les deux t un par un : on compare le modèle avec et sans les deux indicatrices, par un Fisher partiel. Tester séparément gonflerait le risque, comme au chapitre 17 de l'inférence.

Le test global de Fisher

Le modèle sert-il à quelque chose

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_k = 0$$

$$F = \frac{\text{SCE}/k}{\text{SCR}/(n-k-1)} \sim \text{Fisher à } k \text{ et } n-k-1 \text{ degrés de liberté}$$

Sur le modèle M2

$$F = \frac{\text{SCE}/3}{\text{SCR}/496} = \frac{2\,166{,}0/3}{1\,209{,}1/496} = 296{,}19 \qquad p < 0{,}0001$$

On rejette : l'ensemble des variables explique significativement le salaire.

Ce que le F global vaut vraiment

C'est le test le moins informatif des trois

H_0 affirme que **toutes** les variables sont sans effet. Sur des données économiques réelles, cette hypothèse est presque toujours fausse — et donc presque toujours rejetée.
Un F significatif est un minimum, non un résultat. **On ne publie pas un modèle sur la foi de son F.**

Le lien avec le R^2

$$F = \frac{R^2/k}{(1-R^2)/(n-k-1)}$$

Les deux mesurent la même chose ; le F y ajoute seulement les degrés de liberté. En régression simple, $F = t^2$: sur les cinq ménages, $F = 9 = 3^2$.

Le test global, sur les cinq ménages

Revenu et taille, deux degrés de liberté au dénominateur

$$F = \frac{\text{SCE}/2}{\text{SCR}/2} = \frac{25/2}{5/2} = 5 \qquad \text{seuil } F_{2\,;2} = 19{,}0 \qquad p = 0{,}17$$

Avec $R^2 = 0{,}833$, on ne rejette même pas l'hypothèse que **rien** n'explique la consommation.

Un R^2 élevé ne suffit pas

Par la formule : $F = (0{,}833/2)/(0{,}167/2) = 5$. Le R^2 est grand, mais il repose sur **deux** degrés de liberté. Le même R^2 sur 400 ménages donnerait un F de près de mille.

Les tests individuels

La question qu'ils posent

Une variable, les autres étant présentes

$$H_0 : \beta_j = 0 \qquad t_j = \frac{\hat{\beta}_j}{\hat{\sigma}(\hat{\beta}_j)} \sim \text{Student à } n-k-1 \text{ ddl}$$

Les quatre derniers mots sont essentiels

Le t de l'ancienneté ne dit pas si l'ancienneté compte : il dit si elle **apporte quelque chose que le diplôme et la région n'apportent pas déjà**.
Une variable peut être décisive seule et non significative en présence d'une autre qui la double. Ce n'est pas une contradiction, c'est le sens du *ceteris paribus*.

Le revenu des cinq ménages, seul puis accompagné

Le même coefficient, deux questions

Modèle	$\hat{\beta}_R$	erreur-type	t
C sur R	0,75	0,25	3,00
C sur R et T	0,50	0,354	1,41

Pourquoi le t baisse

Le coefficient baisse — une partie de l'effet brut revenait à la taille — et son erreur-type **monte**, de 0,25 à 0,354 : revenu et taille sont liés, la part « libre » du revenu est plus petite. C'est le prix du *ceteris paribus*, et le chapitre 13 le chiffrera.

Le cas d'école qui déroute

Un F très significatif, aucun t significatif

Cela se produit, et ce n'est pas une erreur de calcul.
C'est la signature de la **multicolinéarité** : les variables comptent ensemble, mais aucune ne se distingue des autres. Le chapitre 13 en donnera une démonstration complète sur nos données.

La règle de lecture

Un F significatif dit qu'il y a de l'information dans le bloc. Les t disent d'où elle vient. **Quand le premier parle et que les seconds se taisent, l'information est là mais on ne sait pas à qui l'attribuer.**

Le test de restrictions

Tester plusieurs coefficients ensemble

Le Fisher partiel

$$F = \frac{(\mathrm{SCR}_{\text{contraint}} - \mathrm{SCR}_{\text{libre}})/q}{\mathrm{SCR}_{\text{libre}}/(n-k-1)}$$

où q est le nombre de restrictions testées, et k le nombre de variables du modèle libre.

La logique, en une phrase

On estime le modèle **avec** et **sans** les variables en question, et l'on regarde de combien la somme des carrés résiduels augmente quand on les retire.
Si elle augmente peu, elles n'apportaient rien.

Sur les cinq ménages : retirer la taille

Une seule restriction

Modèle contraint : C sur R, SCR $= 7{,}5$. Modèle libre : C sur R et T, SCR $= 5$.

$$F = \frac{(7{,}5-5)/1}{5/2} = 1 = t_T^2$$

Pour une seule restriction, F est le carré de t

Le Fisher partiel à $q = 1$ et le test de Student du coefficient sont **le même test**. Le Fisher n'apporte du nouveau qu'à partir de deux restrictions.

Quand il est indispensable

Les groupes d'indicatrices

Le diplôme est représenté par **deux** indicatrices. Tester leurs deux t séparément gonflerait le risque, exactement comme les comparaisons deux à deux du chapitre 17 de l'inférence.
La question correcte est : *le diplôme, dans son ensemble, apporte-t-il quelque chose ?* Elle exige un Fisher partiel à $q = 2$ restrictions.

Le diplôme, testé correctement

Modèle libre M2 contre modèle contraint M1 :
Sommes des carrés résiduels, en millions : 2 009 contre 1 209.

$$F = \frac{(2\,009 - 1\,209)/2}{1\,209/496} = 164{,}0 \qquad \text{contre un seuil de } 3{,}01$$

Le diplôme compte, et le test le dit d'un seul coup — sans multiplier les risques.

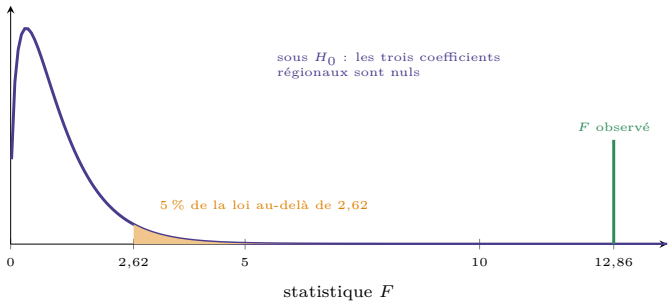
La région, d'un bloc

Trois indicatrices, trois restrictions

M3 (sans région) contre M4 (avec) : SCR = 1 206,9 et 1 119,2 millions.

$$F = \frac{(1\,206{,}9 - 1\,119{,}2)/3}{1\,119{,}2/492} = \frac{29{,}25}{2{,}275} = 12{,}86 \qquad \text{seuil } F_{3\,;492} = 2{,}62$$

la région, testée d'un bloc : Fisher à 3 et 492 degrés de liberté



Tester une hypothèse économique

Le test de restrictions n'est pas réservé aux blocs

Il permet de tester toute contrainte **linéaire** sur les coefficients : $\beta_1 = \beta_2$, $\beta_1 + \beta_2 = 1$, $\beta_3 = 0{,}5$.

Un exemple classique

Dans une fonction de production $\ln Q = \beta_0 + \beta_1 \ln K + \beta_2 \ln L + \varepsilon$, l'hypothèse de **rendements d'échelle constants** s'écrit $\beta_1 + \beta_2 = 1$.
C'est une hypothèse économique, testable par un simple Fisher partiel. **C'est ici que la**

boucle du chapitre 1 se referme : la théorie impose une contrainte, les données l'acceptent ou la refusent.

Casablanca et Rabat : une même prime ?

Une contrainte d'égalité

Dans M4, Casablanca vaut 1 177,84 et Rabat 978,52, par rapport aux « Autres » régions. Le modèle contraint par $\beta_{\text{Casa}} = \beta_{\text{Rabat}}$ a une SCR de 1 121,5 millions :

$$F = \frac{(1\,121{,}5 - 1\,119{,}2)/1}{1\,119{,}2/492} = 1{,}02 \qquad p = 0{,}31$$

Deux coefficients différents, une même prime

Deux cents dirhams d'écart entre les deux estimations, et pourtant **aucune différence significative** : les deux grandes villes paient, à caractéristiques égales, une prime qu'on ne sait pas distinguer. On pourrait les réunir en une seule indicatrice.

Sur machine

Le Fisher partiel avec R

```r
sal <- read.csv("salaires.csv", stringsAsFactors = TRUE)
m3 <- lm(salaire ~ anciennete + diplome + sexe, data = sal)
m4 <- update(m3, . ~ . + region)
anova(m3, m4)                       # la région, d'un bloc
# Analysis of Variance Table
#
# Model 1: salaire ~ anciennete + diplome + sexe
# Model 2: salaire ~ anciennete + diplome + sexe + region
#   Res.Df        RSS Df Sum of Sq      F    Pr(>F)
# 1    495 1206944677
# 2    492 1119208042  3  87736635 12.856 4.238e-08
```

Une contrainte linéaire avec R

```r
sal <- read.csv("salaires.csv", stringsAsFactors = TRUE)
m4 <- lm(salaire ~ anciennete + diplome + sexe + region, sal)
car::linearHypothesis(m4, "regionCasablanca = regionRabat")
# Linear hypothesis test
#
# Hypothesis:
# regionCasablanca - regionRabat = 0
#
# Model 1: restricted model
# Model 2: salaire ~ anciennete + diplome + sexe + region
#
```

```
#   Res.Df        RSS Df Sum of Sq      F Pr(>F)
# 1    493 1121524731
# 2    492 1119208042  1   2316689 1.0184 0.3134
```

Les trois tests avec Python

```
import pandas as pd
import statsmodels.formula.api as smf
sal = pd.read_csv("salaires.csv")
f3 = "salaire ~ anciennete + diplome + sexe"
m3 = smf.ols(f3, data=sal).fit()
m4 = smf.ols(f3 + " + region", data=sal).fit()
print(round(m4.fvalue, 2), m4.df_model, m4.df_resid)   # F global
# 141.67 7.0 492.0
F, p, q = m4.compare_f_test(m3)    # Fisher partiel, la région
print(round(F, 3), f"{p:.1e}", q)
# 12.856 4.2e-08 3.0
ft = m4.f_test("region[T.Casablanca] = region[T.Rabat]")
print(round(float(ft.fvalue), 4), round(float(ft.pvalue), 4))
# 1.0184 0.3134
```

Ce que disent les sorties

Trois commandes, trois questions

`fvalue` : le test global. `compare_f_test` en Python, `anova(m3, m4)` en R : le Fisher partiel entre deux modèles emboîtés — les deux SCR, $q = 3$ et $F = 12{,}86$. `f_test` et `linearHypothesis` : n'importe quelle contrainte linéaire, écrite en clair.

Emboîtés, et sur les mêmes observations

Le Fisher partiel ne compare que des modèles **emboîtés** — l'un est l'autre avec des coefficients contraints — et estimés sur **les mêmes lignes**. Comparer M4 à un modèle en logarithme, ou à un modèle estimé sans quelques salariés, n'aurait aucun sens.

S'entraîner

Exercice 1 : un Fisher partiel à la main

Deux variables de trop

Sur $n = 100$ entreprises, un modèle libre à $k = 5$ variables a une SCR de 480. Sans deux de ses variables, la SCR passe à 520.

1. Écrire l'hypothèse testée.
2. Calculer la statistique F.
3. Conclure à 5 %, sachant que $F_{2\,;94} = 3{,}09$.

Exercice 1 : solution

Les deux variables comptent

1. H_0 : les deux coefficients retirés sont **tous deux nuls**.
2. $F = \dfrac{(520 - 480)/2}{480/94} = \dfrac{20}{5{,}106} = 3{,}92$.
3. $3{,}92 > 3{,}09$: on rejette H_0. Au moins une des deux variables apporte une information que les trois autres n'apportent pas.

Exercice 2 : le F global à partir du R^2

Un modèle qui ne dit presque rien

Sur $n = 50$ observations, un modèle à $k = 4$ variables donne $R^2 = 0{,}25$. Aucun des quatre t ne dépasse 1,6.

1. Calculer le F global ($F_{4\,;45} = 2{,}58$) et conclure.
2. Comment concilier ce résultat avec les quatre t ?

Exercice 2 : solution

Le bloc parle, les variables se taisent

1. $F = \dfrac{0{,}25/4}{0{,}75/45} = \dfrac{0{,}0625}{0{,}0167} = 3{,}75 > 2{,}58$: on rejette l'hypothèse que les quatre variables sont toutes sans effet.
2. Les variables sont probablement **liées entre elles** : ensemble elles expliquent quelque chose, séparément aucune ne se distingue. C'est la signature de la multicolinéarité, chapitre 13.

Exercice 3 : quel test pour quelle question

Quatre questions sur M4

Pour chaque question, indiquer le test et le nombre de restrictions q.

1. Le modèle explique-t-il quelque chose du salaire ?
2. Le sexe compte-t-il, à caractéristiques égales ?
3. La région compte-t-elle ?
4. Le Bac+5 rapporte-t-il exactement trois fois le Bac+2 ?

Exercice 3 : solution

Un test par question

1. Le F **global**, $q = 7$: $F = 141{,}7$, rejet.
2. Le t du sexe, ou un Fisher partiel à $q = 1$ — c'est le même test : $t = 1{,}27$, non significatif.
3. Le Fisher partiel à $q = 3$: $F = 12{,}86$, rejet.
4. Une contrainte linéaire, $\beta_5 = 3\,\beta_2$, testée par un Fisher à $q = 1$ — `linearHypothesis` en R, `f_test` en Python.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. F **global** : toutes les variables sont-elles sans effet ? Presque toujours rejeté, donc peu informatif.
2. t **individuels** : cette variable apporte-t-elle quelque chose **que les autres n'apportent pas** ?
3. **Fisher partiel** : plusieurs coefficients ensemble ; à $q = 1$, c'est t^2 — 1 pour la taille des cinq ménages.
4. Il est **obligatoire** pour un groupe d'indicatrices : diplôme 164,0, région 12,86.
5. Il teste aussi les contraintes **économiques** : rendements constants, égalité de deux primes.
6. Un F significatif avec aucun t significatif signale la **multicolinéarité**.

La suite

Le diplôme, la région et le sexe ne sont pas des nombres : ce sont des catégories. Le chapitre 10 explique comment elles entrent dans une régression, et quel piège les guette.