

Chapitre 16

La variable omise

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Économétrie — Introduction

1 Exercices du chapitre

Correction — Exercice 1

- (a) $\gamma\delta = 150 \times 0,4 = 60$.
- (b) $E(\hat{\beta}_1^{\text{simple}}) = \beta_1 + \gamma\delta = 20 + 60 = 80$: le coefficient simple surestime très largement le vrai coefficient $\beta_1 = 20$.
- (c) Oui, le biais change de signe : $\gamma\delta = 150 \times (-0,4) = -60$, donc $E(\hat{\beta}_1^{\text{simple}}) = 20 - 60 = -40$: le coefficient simple devient même négatif, alors que le vrai effet est positif.
- (d) Le biais serait nul, quelle que soit la valeur de δ : $\gamma\delta = 0 \times \delta = 0$. Le cours insiste précisément sur ce point : il faut **les deux** conditions (effet de z sur y , et liaison de z avec x) pour qu'un biais apparaisse.

Correction — Exercice 2

- (a) Les capacités individuelles ont vraisemblablement un effet **positif** sur le salaire : $\gamma > 0$.
- (b) Les capacités individuelles sont vraisemblablement **positivement** liées au niveau de diplôme (les personnes plus performantes tendent à pousser leurs études plus loin) : $\delta > 0$.
- (c) D'après le tableau des signes, $\gamma > 0$ et $\delta > 0$ donnent une **surestimation** du coefficient du diplôme.
- (d) Le chercheur peut écrire que le rendement du diplôme qu'il a estimé est « au plus » égal à la valeur mesurée : le vrai effet causal du diplôme seul, une fois les capacités neutralisées, est probablement plus faible que ce que son estimation indique.

Correction — Exercice 3

- (a) Non : aucun test appliqué aux données disponibles ne détecte le biais de variable omise, car par définition la variable manquante n'est pas dans les données — contrairement à l'hétéroscédasticité et au regroupement, qui se lisent dans les données observées (les résidus, la structure de l'échantillon).
- (b) Non : il n'existe aucune formule équivalente. Une formule comme celle de White ou celle des écarts-types de grappe recalcule seulement la **précision** des coefficients, sans les changer ; le biais de variable omise affecte directement le **coefficient lui-même**, et aucun recalcul de l'écart-type ne peut réparer cela.
- (c) Si l'on se procure la variable omise, le problème disparaît entièrement : il suffit de l'ajouter au modèle (le premier des quatre remèdes, par ordre de préférence) pour retrouver un coefficient sans biais sur la variable d'intérêt.
- (d) Trois points : (1) sans la variable, aucun test statistique ne peut signaler sa présence — le R^2 peut être élevé, les résidus impeccables, et le biais rester invisible ; (2) sans la variable, aucun calcul mécanique ne peut corriger le coefficient — il n'y a pas de « bonne formule » à appliquer ; (3) tout ce qui reste possible est un raisonnement économique sur le signe probable de γ et de δ , pour au moins qualifier le sens du biais, même sans en connaître l'ampleur.

2 Exercice cumulatif

Correction — Exercice 4

- (a) $277,1674 - 270,2694 = 6,898$.
- (b) Bac+2 : $1\,099,5705 \times (-0,002907) \approx -3,196$. Bac+5 : $3\,336,9916 \times 0,003025 \approx +10,094$. Somme : $-3,196 + 10,094 \approx 6,898$.
- (c) Oui : la somme des deux produits $\gamma\delta$ (6,898) correspond exactement, à la quatrième décimale près, à l'écart observé entre les deux coefficients calculé en (a) (6,898).
- (d) Ce calcul montre que le « piège du remède » du chapitre 13 n'est pas une simple prudence rhétorique : le biais introduit en retirant une variable colinéaire (ici, retirer le diplôme du modèle de l'ancienneté) obéit à une **identité algébrique exacte**, $\gamma\delta$, calculable au dixième de dirham près dès que l'on dispose des deux régressions — ce n'est pas une vague possibilité, mais un phénomène aussi

mesurable qu'un coefficient lui-même.

(e) Ce calcul confirme que la ligne « orange » de la carte des violations mérite un traitement à part, car elle est la seule à corrompre la quantité que l'analyste veut réellement estimer — le coefficient. Les lignes « grises » (hétéroscédasticité, regroupement) laissent ce coefficient intact et ne dégradent que la mesure de son incertitude (écart-type, test, intervalle de confiance) : une distinction de nature, entre un problème d'**exactitude** et un problème de **précision**, que seule la variable omise viole du premier type.

3 Applications en sciences économiques

Correction — Exercice 5

(a) Non, le remède « ajouter la variable » n'est pas disponible ici, puisque le milieu social n'est observé dans aucune base de données accessible à l'étude — c'est précisément l'hypothèse de l'énoncé.

(b) Le diplôme des parents (suggéré par le cours), ou de façon équivalente leur profession, leur revenu pendant l'enfance, ou le type d'établissement scolaire fréquenté, sont des substituts observables raisonnables : ils sont corrélés au milieu social sans en être une mesure directe, mais permettent d'en capter une partie de l'effet.

(c) Une donnée de panel permet de comparer un même individu à lui-même à différentes dates. Le milieu social de l'enfance, étant **constant dans le temps** pour un individu donné, est alors automatiquement éliminé par la comparaison intra-individuelle (les effets fixes), sans qu'il soit jamais nécessaire de le mesurer ou de l'observer directement.

(d) L'instrumentation est citée en dernier car elle exige de trouver une variable remplissant une condition très exigeante et rarement vérifiable directement (liée à x , mais totalement indépendante de ε) ; elle est aussi la plus technique et la plus sujette à débat sur sa validité, alors que les trois remèdes précédents (ajouter la variable, substitut, panel) reposent sur des données ou des structures plus directement observables et plus faciles à justifier.

Correction — Exercice 6

(a) Elle affirme une relation de **causalité** : le verbe « augmente » suppose que le diplôme *produit* cet écart de salaire, toutes choses égales par ailleurs et sans réserve.

(b) Non, elle affirme seulement une relation d'**association** : elle décrit un écart de salaire observé entre diplômés et non-diplômés, *à ancienneté et région comparables*, sans prétendre que le diplôme en est la cause exclusive.

(c) Elle est plus **faible** car elle renonce à affirmer une causalité pleine et entière — elle ne dit rien de ce qui se passerait si l'on changeait le diplôme d'une personne « toutes choses égales par ailleurs » au sens strict (capacités comprises). Elle est plus **solide** car elle correspond exactement à ce que les données permettent réellement d'établir, sans dépasser les limites imposées par les capacités individuelles non observées.

(d) Il risquerait de **surestimer** l'effet réel d'une année de diplôme supplémentaire : puisque les capacités individuelles sont positivement corrélées au diplôme (exercice 2), le coefficient mesuré capte à la fois l'effet propre du diplôme et une partie de l'effet des capacités des personnes plus diplômées — une politique de subvention fondée sur ce chiffre surestimerait le gain salarial induit par le diplôme seul.