

Introduction à l'économétrie

Chapitre 16 : La variable omise

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'économétrie

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Appliquer la formule du biais

Le vrai modèle est $y = \beta_0 + \beta_1 x + \gamma z + \varepsilon$, avec $\gamma = 150$. La régression de z sur x donne une pente $\delta = 0,4$.

- (a) Calculer le biais $\gamma\delta$ attendu si l'on omet z et qu'on régresse y sur x seul.
- (b) Si le vrai coefficient est $\beta_1 = 20$, quelle sera la valeur espérée du coefficient de la régression simple?
- (c) Si, au contraire, $\delta = -0,4$ (même $\gamma = 150$), le biais change-t-il de signe? Recalculer $E(\hat{\beta}_1^{\text{simple}})$ dans ce cas.
- (d) Si z n'avait aucun effet sur y ($\gamma = 0$), quel serait le biais, quelle que soit la valeur de δ ?

Exercice 2 — Raisonner sur le signe, sans données

Un chercheur régresse le salaire sur le diplôme seul, sans observer les capacités individuelles des salariés.

- (a) Les capacités individuelles ont-elles, selon toute vraisemblance, un effet positif, négatif ou nul sur le salaire (quel est le signe de γ)?
- (b) Les capacités individuelles sont-elles, selon toute vraisemblance, positivement ou négativement liées au niveau de diplôme (quel est le signe de δ)?
- (c) En utilisant le tableau des signes du cours, quel est le sens du biais sur le coefficient du diplôme : surestimation ou sous-estimation?
- (d) Le chercheur ne connaît pas l'ampleur du biais. Quelle formulation prudente peut-il néanmoins écrire à propos de son estimation du rendement du diplôme (indice : « au plus »)?

Exercice 3 — Ce qui distingue ce problème de tous les autres

On compare le biais de variable omise aux problèmes des chapitres 14 (hétéroscédasticité) et 15 (erreurs groupées).

- (a) L'hétéroscédasticité et le regroupement se détectent par des tests statistiques (Breusch-Pagan, White, comparaison des écarts-types). Le biais de variable omise se détecte-t-il de la même façon par un test appliqué aux données disponibles?
- (b) L'hétéroscédasticité et le regroupement se corrigent par une formule (écarts-types robustes, écarts-types de grappe), sans changer les coefficients. Existe-t-il une formule équivalente qui « corrige » un coefficient biaisé par une variable omise, sans disposer de cette variable?
- (c) Si l'on parvient à se procurer la variable omise elle-même, que devient le problème?
- (d) En trois points, résumer pourquoi le cours affirme que le biais de variable omise « se raisonne, il ne se calcule pas ».

2 Exercice cumulatif (chapitre 16 et chapitres précédents)

Exercice 4 — Vérifier l'identité algébrique sur les données du cours

Le cours rapporte, sur le modèle salaire déjà utilisé aux chapitres 7 à 14 : coefficient de l'ancienneté sans le diplôme, 277,1674 ; avec le diplôme, 270,2694. La régression auxiliaire du diplôme sur l'ancienneté donne, pour Bac+2, $\gamma = 1\,099,5705$ et $\delta = -0,002907$; pour Bac+5, $\gamma = 3\,336,9916$ et $\delta = 0,003025$.

- (a) Calculer l'écart observé entre les deux coefficients de l'ancienneté ($277,1674 - 270,2694$).
- (b) Calculer le produit $\gamma\delta$ pour Bac+2, puis pour Bac+5, et sommer les deux.
- (c) Cette somme correspond-elle, à la précision 1 près, à l'écart calculé en (a) ?

- (d) Le chapitre 13 avait averti d'un « piège du remède » : retirer une variable colinéaire pour « simplifier » un modèle crée précisément ce problème de variable omise. En vous appuyant sur le calcul ci-dessus, expliquer en une phrase pourquoi ce piège n'est pas une simple mise en garde qualitative, mais un phénomène que l'on peut chiffrer exactement.
- (e) Le chapitre 12 (carte des violations) plaçait la variable omise sur la seule ligne « orange », celle qui biaise les coefficients. Pourquoi ce calcul exact confirme-t-il que cette ligne mérite un traitement à part des lignes « grises » (hétéroscédasticité, regroupement), qui ne biaisent, elles, que la précision ?

3 Applications en sciences économiques

Exercice 5 — Choisir le bon remède

Une étude cherche à mesurer l'effet causal du milieu social de l'enfance sur la réussite professionnelle à l'âge adulte, mais le « milieu social » n'est observé dans aucune base de données disponible.

- (a) Le remède « ajouter la variable » est-il disponible ici ? Pourquoi ?
- (b) Le cours propose, à défaut, de trouver un **substitut observable**. Proposer une variable observable qui pourrait servir de substitut raisonnable au milieu social (le cours suggère un exemple : le diplôme des parents).
- (c) Si l'étude disposait de données de **panel** suivant les mêmes individus dans le temps, en quoi cela permettrait-il, selon le cours, d'éliminer l'effet du milieu social sans jamais l'observer directement ?
- (d) Le remède « instrumenter » est présenté par le cours comme dépassant son cadre. Sans entrer dans la technique, pourquoi ce remède est-il, par ordre de préférence, cité en dernier plutôt qu'en premier ?

Exercice 6 — Deux phrases, deux métiers

Une étude régresse le salaire sur le diplôme, l'ancienneté et la région, sans observer les capacités individuelles. Le coefficient du diplôme indique un écart de salaire de 44 %.

- (a) La phrase « le diplôme augmente le salaire de 44 % » affirme-t-elle une relation de **causalité**, d'**association**, ou les deux à la fois ?
- (b) La phrase « les diplômés gagnent 44 % de plus, à ancienneté et région comparables » affirme-t-elle la même chose ? Que décrit-elle exactement ?
- (c) Pourquoi le cours affirme-t-il que la seconde phrase est « plus faible et plus solide » que la première — en quel sens est-elle plus faible, et en quel sens est-elle plus solide ?
- (d) Un décideur public qui s'appuierait sur la première phrase pour dimensionner une politique de subvention aux études risquerait-il de surestimer ou de sous-estimer l'effet réel d'une année de diplôme supplémentaire, si les capacités individuelles sont bien corrélées positivement au diplôme (comme à l'exercice 2) ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) $\gamma\delta = 150 \times 0,4 = 60$.
- (b) $E(\hat{\beta}_1^{\text{simple}}) = \beta_1 + \gamma\delta = 20 + 60 = 80$: le coefficient simple surestime très largement le vrai coefficient $\beta_1 = 20$.
- (c) Oui, le biais change de signe : $\gamma\delta = 150 \times (-0,4) = -60$, donc $E(\hat{\beta}_1^{\text{simple}}) = 20 - 60 = -40$: le coefficient simple devient même négatif, alors que le vrai effet est positif.
- (d) Le biais serait nul, quelle que soit la valeur de δ : $\gamma\delta = 0 \times \delta = 0$. Le cours insiste précisément sur ce point : il faut **les deux** conditions (effet de z sur y , et liaison de z avec x) pour qu'un biais apparaisse.

Correction — Exercice 2

- (a) Les capacités individuelles ont vraisemblablement un effet **positif** sur le salaire : $\gamma > 0$.
- (b) Les capacités individuelles sont vraisemblablement **positivement** liées au niveau de diplôme (les personnes plus performantes tendent à pousser leurs études plus loin) : $\delta > 0$.
- (c) D'après le tableau des signes, $\gamma > 0$ et $\delta > 0$ donnent une **surestimation** du coefficient du diplôme.
- (d) Le chercheur peut écrire que le rendement du diplôme qu'il a estimé est « au plus » égal à la valeur mesurée : le vrai effet causal du diplôme seul, une fois les capacités neutralisées, est probablement plus faible que ce que son estimation indique.

Correction — Exercice 3

- (a) Non : aucun test appliqué aux données disponibles ne détecte le biais de variable omise, car par définition la variable manquante n'est pas dans les données — contrairement à l'hétéroscédasticité et au regroupement, qui se lisent dans les données observées (les résidus, la structure de l'échantillon).
- (b) Non : il n'existe aucune formule équivalente. Une formule comme celle de White ou celle des écarts-types de grappe recalcule seulement la **précision** des coefficients, sans les changer ; le biais de variable omise affecte directement le **coefficient lui-même**, et aucun recalcul de l'écart-type ne peut réparer cela.
- (c) Si l'on se procure la variable omise, le problème disparaît entièrement : il suffit de l'ajouter au modèle (le premier des quatre remèdes, par ordre de préférence) pour retrouver un coefficient sans biais sur la variable d'intérêt.
- (d) Trois points : (1) sans la variable, aucun test statistique ne peut signaler sa présence — le R^2 peut être élevé, les résidus impeccables, et le biais rester invisible ; (2) sans la variable, aucun calcul mécanique ne peut corriger le coefficient — il n'y a pas de « bonne formule » à appliquer ; (3) tout ce qui reste possible est un raisonnement économique sur le signe probable de γ et de δ , pour au moins qualifier le sens du biais, même sans en connaître l'ampleur.

2 Exercice cumulatif

Correction — Exercice 4

- (a) $277,1674 - 270,2694 = 6,898$.
- (b) $\text{Bac}+2 : 1\,099,5705 \times (-0,002907) \approx -3,196$. $\text{Bac}+5 : 3\,336,9916 \times 0,003025 \approx +10,094$. Somme : $-3,196 + 10,094 \approx 6,898$.
- (c) Oui : la somme des deux produits $\gamma\delta$ (6,898) correspond exactement, à la quatrième décimale près, à l'écart observé entre les deux coefficients calculé en (a) (6,898).
- (d) Ce calcul montre que le « piège du remède » du chapitre 13 n'est pas une simple prudence rhétorique : le biais introduit en retirant une variable colinéaire (ici, retirer le diplôme du modèle de l'ancienneté) obéit à une **identité algébrique exacte**, $\gamma\delta$, calculable au dixième de dirham près dès que l'on dispose des deux régressions — ce n'est pas une vague possibilité, mais un phénomène aussi

mesurable qu'un coefficient lui-même.

(e) Ce calcul confirme que la ligne « orange » de la carte des violations mérite un traitement à part, car elle est la seule à corrompre la quantité que l'analyste veut réellement estimer — le coefficient. Les lignes « grises » (hétéroscédasticité, regroupement) laissent ce coefficient intact et ne dégradent que la mesure de son incertitude (écart-type, test, intervalle de confiance) : une distinction de nature, entre un problème d'**exactitude** et un problème de **précision**, que seule la variable omise viole du premier type.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) Non, le remède « ajouter la variable » n'est pas disponible ici, puisque le milieu social n'est observé dans aucune base de données accessible à l'étude — c'est précisément l'hypothèse de l'énoncé.
- (b) Le diplôme des parents (suggéré par le cours), ou de façon équivalente leur profession, leur revenu pendant l'enfance, ou le type d'établissement scolaire fréquenté, sont des substituts observables raisonnables : ils sont corrélés au milieu social sans en être une mesure directe, mais permettent d'en capter une partie de l'effet.
- (c) Une donnée de panel permet de comparer un même individu à lui-même à différentes dates. Le milieu social de l'enfance, étant **constant dans le temps** pour un individu donné, est alors automatiquement éliminé par la comparaison intra-individuelle (les effets fixes), sans qu'il soit jamais nécessaire de le mesurer ou de l'observer directement.
- (d) L'instrumentation est citée en dernier car elle exige de trouver une variable remplissant une condition très exigeante et rarement vérifiable directement (liée à x , mais totalement indépendante de ε) ; elle est aussi la plus technique et la plus sujette à débat sur sa validité, alors que les trois remèdes précédents (ajouter la variable, substitut, panel) reposent sur des données ou des structures plus directement observables et plus faciles à justifier.

Correction — Exercice 6

- (a) Elle affirme une relation de **causalité** : le verbe « augmente » suppose que le diplôme *produit* cet écart de salaire, toutes choses égales par ailleurs et sans réserve.
- (b) Non, elle affirme seulement une relation d'**association** : elle décrit un écart de salaire observé entre diplômés et non-diplômés, *à ancienneté et région comparables*, sans prétendre que le diplôme en est la cause exclusive.
- (c) Elle est plus **faible** car elle renonce à affirmer une causalité pleine et entière — elle ne dit rien de ce qui se passerait si l'on changeait le diplôme d'une personne « toutes choses égales par ailleurs » au sens strict (capacités comprises). Elle est plus **solide** car elle correspond exactement à ce que les données permettent réellement d'établir, sans dépasser les limites imposées par les capacités individuelles non observées.
- (d) Il risquerait de **surestimer** l'effet réel d'une année de diplôme supplémentaire : puisque les capacités individuelles sont positivement corrélées au diplôme (exercice 2), le coefficient mesuré capte à la fois l'effet propre du diplôme et une partie de l'effet des capacités des personnes plus diplômées — une politique de subvention fondée sur ce chiffre surestimerait le gain salarial induit par le diplôme seul.