

Chapitre 16

La variable omise

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Économétrie — Introduction

1 Exercices du chapitre

Exercice 1 — Appliquer la formule du biais

Le vrai modèle est $y = \beta_0 + \beta_1 x + \gamma z + \varepsilon$, avec $\gamma = 150$. La régression de z sur x donne une pente $\delta = 0,4$.

- (a) Calculer le biais $\gamma\delta$ attendu si l'on omet z et qu'on régresse y sur x seul.
- (b) Si le vrai coefficient est $\beta_1 = 20$, quelle sera la valeur espérée du coefficient de la régression simple?
- (c) Si, au contraire, $\delta = -0,4$ (même $\gamma = 150$), le biais change-t-il de signe? Recalculer $E(\hat{\beta}_1^{\text{simple}})$ dans ce cas.
- (d) Si z n'avait aucun effet sur y ($\gamma = 0$), quel serait le biais, quelle que soit la valeur de δ ?

Exercice 2 — Raisonner sur le signe, sans données

Un chercheur régresse le salaire sur le diplôme seul, sans observer les capacités individuelles des salariés.

- (a) Les capacités individuelles ont-elles, selon toute vraisemblance, un effet positif, négatif ou nul sur le salaire (quel est le signe de γ)?
- (b) Les capacités individuelles sont-elles, selon toute vraisemblance, positivement ou négativement liées au niveau de diplôme (quel est le signe de δ)?
- (c) En utilisant le tableau des signes du cours, quel est le sens du biais sur le coefficient du diplôme : surestimation ou sous-estimation?
- (d) Le chercheur ne connaît pas l'ampleur du biais. Quelle formulation prudente peut-il néanmoins écrire à propos de son estimation du rendement du diplôme (indice : « au plus »)?

Exercice 3 — Ce qui distingue ce problème de tous les autres

On compare le biais de variable omise aux problèmes des chapitres 14 (hétéroscédasticité) et 15 (erreurs groupées).

- (a) L'hétéroscédasticité et le regroupement se détectent par des tests statistiques (Breusch-Pagan, White, comparaison des écarts-types). Le biais de variable omise se détecte-t-il de la même façon par un test appliqué aux données disponibles?
- (b) L'hétéroscédasticité et le regroupement se corrigent par une formule (écarts-types robustes, écarts-types de grappe), sans changer les coefficients. Existe-t-il une formule équivalente qui « corrige » un coefficient biaisé par une variable omise, sans disposer de cette variable?
- (c) Si l'on parvient à se procurer la variable omise elle-même, que devient le problème?
- (d) En trois points, résumer pourquoi le cours affirme que le biais de variable omise « se raisonne, il ne se calcule pas ».

2 Exercice cumulatif (chapitre 16 et chapitres précédents)

Exercice 4 — Vérifier l'identité algébrique sur les données du cours

Le cours rapporte, sur le modèle salaire déjà utilisé aux chapitres 7 à 14 : coefficient de l'ancienneté sans le diplôme, 277,1674 ; avec le diplôme, 270,2694. La régression auxiliaire du diplôme sur l'ancienneté donne, pour Bac+2, $\gamma = 1\,099,5705$ et $\delta = -0,002907$; pour Bac+5, $\gamma = 3\,336,9916$ et $\delta = 0,003025$.

- (a) Calculer l'écart observé entre les deux coefficients de l'ancienneté ($277,1674 - 270,2694$).
- (b) Calculer le produit $\gamma\delta$ pour Bac+2, puis pour Bac+5, et sommer les deux.
- (c) Cette somme correspond-elle, à la précision près, à l'écart calculé en (a)?

- (d) Le chapitre 13 avait averti d'un « piège du remède » : retirer une variable colinéaire pour « simplifier » un modèle crée précisément ce problème de variable omise. En vous appuyant sur le calcul ci-dessus, expliquer en une phrase pourquoi ce piège n'est pas une simple mise en garde qualitative, mais un phénomène que l'on peut chiffrer exactement.
- (e) Le chapitre 12 (carte des violations) plaçait la variable omise sur la seule ligne « orange », celle qui biaise les coefficients. Pourquoi ce calcul exact confirme-t-il que cette ligne mérite un traitement à part des lignes « grises » (hétéroscédasticité, regroupement), qui ne biaisent, elles, que la précision ?

3 Applications en sciences économiques

Exercice 5 — Choisir le bon remède

Une étude cherche à mesurer l'effet causal du milieu social de l'enfance sur la réussite professionnelle à l'âge adulte, mais le « milieu social » n'est observé dans aucune base de données disponible.

- (a) Le remède « ajouter la variable » est-il disponible ici ? Pourquoi ?
- (b) Le cours propose, à défaut, de trouver un **substitut observable**. Proposer une variable observable qui pourrait servir de substitut raisonnable au milieu social (le cours suggère un exemple : le diplôme des parents).
- (c) Si l'étude disposait de données de **panel** suivant les mêmes individus dans le temps, en quoi cela permettrait-il, selon le cours, d'éliminer l'effet du milieu social sans jamais l'observer directement ?
- (d) Le remède « instrumenter » est présenté par le cours comme dépassant son cadre. Sans entrer dans la technique, pourquoi ce remède est-il, par ordre de préférence, cité en dernier plutôt qu'en premier ?

Exercice 6 — Deux phrases, deux métiers

Une étude régresse le salaire sur le diplôme, l'ancienneté et la région, sans observer les capacités individuelles. Le coefficient du diplôme indique un écart de salaire de 44 %.

- (a) La phrase « le diplôme augmente le salaire de 44 % » affirme-t-elle une relation de **causalité**, d'**association**, ou les deux à la fois ?
- (b) La phrase « les diplômés gagnent 44 % de plus, à ancienneté et région comparables » affirme-t-elle la même chose ? Que décrit-elle exactement ?
- (c) Pourquoi le cours affirme-t-il que la seconde phrase est « plus faible et plus solide » que la première — en quel sens est-elle plus faible, et en quel sens est-elle plus solide ?
- (d) Un décideur public qui s'appuierait sur la première phrase pour dimensionner une politique de subvention aux études risquerait-il de surestimer ou de sous-estimer l'effet réel d'une année de diplôme supplémentaire, si les capacités individuelles sont bien corrélées positivement au diplôme (comme à l'exercice 2) ?