Introduction à l'économétrie

Chapitre 16 : La variable omise

Jaouad Madkour

29 octobre 2026

Plan du chapitre

Le seul problème qui biaise **2**
- Le mécanisme . . . 2
- La formule . . . 2
- D'où vient la formule . . . 2
- Sur les cinq ménages . . . 3
- La vérification, à la quatrième décimale . . . 4
- Pourquoi il est si petit ici . . . 4
- Une troisième vérification : omettre la région . . . 4
- Le cas dangereux . . . 5

Prévoir le sens du biais **5**
- On peut souvent raisonner . . . 5
- Ce qui distingue ce problème de tous les autres . . . 5

Les remèdes **6**
- Quatre voies . . . 6
- Et si l'on ne peut rien faire . . . 6

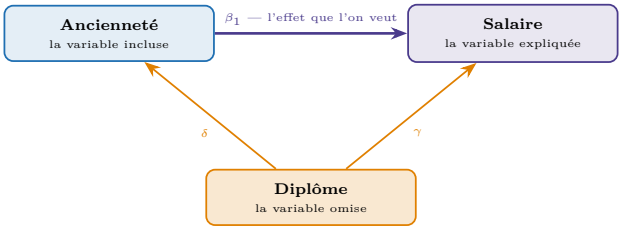
Sur machine **6**
- La formule vérifiée avec R . . . 6
- Les cinq ménages avec Python . . . 7

S'entraîner **7**
- Exercice 1 : retrouver la liaison . . . 7
- Exercice 1 : solution . . . 7
- Exercice 2 : le sens du biais . . . 7
- Exercice 2 : solution . . . 8
- Exercice 3 : de la variable omise au coefficient net . . . 8
- Exercice 3 : solution . . . 8

Ce qu'il faut retenir **8**
- Le résumé du chapitre . . . 8

Le seul problème qui biaise

Le mécanisme



La formule du biais

$\underbrace{\hat{\beta}_1^{\text{simple}}}_{277{,}17} = \underbrace{\beta_1}_{270{,}27} + \underbrace{\gamma\,\delta}_{\text{le biais}}$

Le biais est le produit de deux effets : celui de la variable omise sur y, et sa liaison avec la variable incluse.

La vérification, sur nos données

$1\,099{,}57 \times (-0{,}002907) = -3{,}20$
$3\,336{,}99 \times (+0{,}003025) = +10{,}09$
total $= +6{,}898$

et $277{,}1674 - 270{,}2694 = 6{,}898$. La formule ne prédit pas approximativement : elle prédit *exactement*.

Deux conditions, et il faut les deux pour qu'il y ait biais.

La variable omise doit **influencer** y ($\gamma \neq 0$) *et* **être liée à la variable incluse** ($\delta \neq 0$). Si l'une des deux manque, l'omission est sans conséquence sur le coefficient.

Ici le biais est minuscule — sept dirhams sur deux cent soixante-dix — parce que δ est presque nul : dans cette entreprise, ancienneté et diplôme sont pratiquement indépendants. **Le danger vient des cas où ils ne le sont pas** : régresser le salaire sur la seule expérience en oubliant le diplôme, dans une population où les deux vont de pair, donnerait un coefficient massivement surestimé.

Et rien, dans la sortie du logiciel, ne l'aurait signalé.

La formule

Le biais de variable omise

Si le vrai modèle est $y = \beta_0 + \beta_1 x + \gamma z + \varepsilon$ et qu'on estime y sur x seul :

$$E(\hat{\beta}_1^{\text{simple}}) = \beta_1 + \gamma\,\delta$$

où δ est la pente de la régression de z sur x.

Elle se lit en une phrase

Le biais est le produit de **l'effet de la variable omise sur** y et de **sa liaison avec la variable incluse**.
Il faut les deux. Si la variable omise n'influence pas y, ou si elle est indépendante de x, l'omission est sans conséquence sur le coefficient.

D'où vient la formule

Trois lignes

La pente simple vaut S_{xy}/S_{xx}. Avec $y = \beta_0 + \beta_1 x + \gamma z + \varepsilon$:

$$\frac{S_{xy}}{S_{xx}} = \beta_1 + \gamma\,\frac{S_{xz}}{S_{xx}} + \frac{S_{x\varepsilon}}{S_{xx}} = \beta_1 + \gamma\,\delta + \frac{S_{x\varepsilon}}{S_{xx}}$$

Le dernier terme est d'espérance nulle si ε est exogène. Il reste $\beta_1 + \gamma\delta$.

Sur l'échantillon, une identité exacte

Avec les **coefficients estimés**, la relation n'est plus une espérance : c'est une identité algébrique,

$$\hat{\beta}_1^{\text{simple}} = \hat{\beta}_1 + \hat{\gamma}\,\hat{\delta}$$

vraie au centime près, pour n'importe quelles données. C'est ce qu'on va vérifier deux fois.

Démonstration : Le biais de variable omise est une identité : $\hat{\beta}^{\text{court}} = \hat{\beta}_1 + \widehat{\Delta}, \hat{\gamma}$

Écrivons le modèle long estimé $y = X_1\hat{\beta}_1 + X_2\hat{\gamma} + e$, où X_1 contient la constante et les variables que l'on garde, X_2 celles que le modèle court omet. Les équations normales disent que les résidus sont orthogonaux à toutes les colonnes : $X_1'e = 0$. En multipliant l'égalité par X_1',

$$X_1'y = X_1'X_1\,\hat{\beta}_1 + X_1'X_2\,\hat{\gamma}.$$

Le modèle court régresse y sur X_1 seul, donc

$$\hat{\beta}^{\text{court}} = (X_1'X_1)^{-1}X_1'y = \hat{\beta}_1 + \underbrace{(X_1'X_1)^{-1}X_1'X_2}_{\widehat{\Delta}}\,\hat{\gamma}.$$

Chaque colonne de $\widehat{\Delta}$ est le vecteur des coefficients de la régression d'une variable omise sur X_1 : c'est la pente $\hat{\delta}$ du texte. Avec une variable incluse x et une omise z, $\hat{\delta} = S_{xz}/S_{xx}$ et l'identité se lit $S_{xy}/S_{xx} = \hat{\beta}_1 + \hat{\gamma}\,\hat{\delta}$. Elle vaut pour n'importe quelles données, sans aucune hypothèse sur les erreurs ; plusieurs variables omises ajoutent chacune leur produit.

Le biais. Si le vrai modèle est $y = X_1\beta_1 + X_2\gamma + \varepsilon$, l'estimateur court vaut

$$\hat{\beta}^{\text{court}} = (X_1'X_1)^{-1}X_1'y = \beta_1 + \widehat{\Delta}\,\gamma + (X_1'X_1)^{-1}X_1'\varepsilon.$$

Sous H2, le dernier terme est d'espérance nulle, les X étant donnés : $E(\hat{\beta}^{\text{court}}) = \beta_1 + \widehat{\Delta}\,\gamma$. Le biais $\widehat{\Delta}\,\gamma$ est nul si $\gamma = 0$ (la variable omise n'agit pas sur y) ou si $\widehat{\Delta} = 0$ (elle n'a aucune liaison avec les variables incluses) : il faut **les deux** pour qu'il existe. Sur les cinq ménages, $\hat{\delta} = S_{RT}/S_{RR} = 20/40$ et $0{,}75 = 0{,}5 + 0{,}5 \times 0{,}5$.

■

Sur les cinq ménages

Omettre la taille

Pente simple du revenu : 0,75. Avec la taille : $\hat{\beta}_R = 0{,}5$ et $\hat{\gamma} = 0{,}5$. Pente de la taille sur le revenu : $\hat{\delta} = S_{RT}/S_{RR} = 20/40 = 0{,}5$.

$$0{,}5 + 0{,}5 \times 0{,}5 = 0{,}75$$

Un biais de cinquante pour cent

Omettre la taille gonfle l'effet du revenu de moitié : 0,75 au lieu de 0,5. Les deux conditions sont réunies — la taille agit sur la consommation ($\gamma = 0{,}5$) **et** elle est liée au revenu

($\delta = 0{,}5$).

La vérification, à la quatrième décimale

Sur nos salaires

Coefficient de l'ancienneté, sans le diplôme : 277,1674. Avec le diplôme : 270,2694.

$$1\,099{,}5705 \times (-0{,}002907) = -3{,}197$$

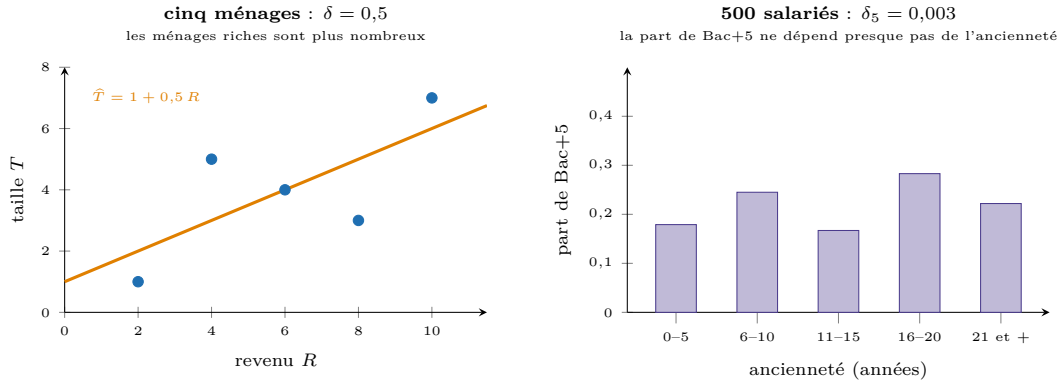
$$3\,336{,}9916 \times (+0{,}003025) = +10{,}095$$

$$\text{total} = +6{,}898$$

Et l'écart observé vaut exactement 6,898

$277{,}1674 - 270{,}2694 = 6{,}898$.
La formule ne prédit pas approximativement : elle prédit exactement. Avec deux variables omises — les deux indicatrices —, on additionne les deux produits $\gamma\delta$.

Pourquoi il est si petit ici



Parce que la liaison est presque nulle

Les trois diplômes ont la même ancienneté moyenne, à un an près : 10,1 ; 9,8 ; 10,6 ans. δ vaut trois millièmes : sept dirhams de biais sur deux cent soixante-dix. **C'est une propriété de ces données-là, pas une règle générale.**

Une troisième vérification : omettre la région

Le coefficient du Bac+5, avec et sans région

Sans région (M2) : 3 336,99. Avec région (M5) : 3 273,48. Écart : 63,51 dirhams.
Les Bac+5 sont un peu plus souvent à Casablanca, Rabat et Tanger, régions qui paient davantage. Régressée sur les variables de M2, chaque indicatrice régionale a pour coefficient du Bac+5 $\hat{\delta} = 0{,}0268$; 0,0136 ; 0,0398, pour des primes de 1 174, 965 et 474 dirhams :

$$1\,174 \times 0{,}0268 + 965 \times 0{,}0136 + 474 \times 0{,}0398 \approx 63{,}5$$

Une part du « rendement du diplôme » était géographique

Sans la région, le Bac+5 s'attribue 63 dirhams qui reviennent au lieu de travail. Petit, ici ; mais le même mécanisme, avec une variable fortement liée, ferait un biais considérable.

Le cas dangereux

Une variable liée et influente

Régresser le salaire sur la seule **expérience** dans une population où les plus expérimentés sont aussi les plus diplômés donnerait un coefficient massivement surestimé.
L'expérience capterait alors l'effet du diplôme. Et **rien, dans la sortie du logiciel, ne l'aurait signalé** : le R^2 serait honorable, le t écrasant, les résidus impeccables.

C'est le cas des cinq ménages

Là, l'omission gonfle le coefficient de 50 %, et la régression simple paraît pourtant correcte : pente positive, inférieure à 1, conforme à Keynes. **Rien ne trahit l'omission** — sauf de connaître la variable manquante.

Prévoir le sens du biais

On peut souvent raisonner

Le tableau des signes

γ	δ	Biais
+	+	**surestimation**
+	−	sous-estimation
−	+	sous-estimation
−	−	**surestimation**

Un raisonnement d'économiste, sans données

« J'ai omis les capacités individuelles. Elles augmentent le salaire ($\gamma > 0$) et vont de pair avec le diplôme ($\delta > 0$). Donc mon coefficient du diplôme est **surestimé**. »
On ne connaît pas l'ampleur du biais — mais on en connaît le **sens**, et cela suffit souvent à qualifier le résultat : « le rendement du diplôme est **au plus** de tant ».

Ce qui distingue ce problème de tous les autres

Trois différences

1. **Aucun test ne le détecte** — la variable manquante n'est pas dans les données.
2. **Aucune formule ne le répare** — ce n'est pas une correction d'écart-type.
3. **Il se raisonne, il ne se calcule pas** — sauf à disposer de la variable, auquel cas il suffit de l'ajouter.

La conséquence sur la façon de travailler

Un travail économétrique sérieux consacre plus de temps à la **spécification** qu'à l'estimation.
Choisir les variables, justifier leur présence, énumérer celles qui manquent et en discuter le sens : c'est cela, le métier. **L'estimation, elle, prend une ligne de code.**

Les remèdes

Quatre voies

Par ordre de préférence

1. **Ajouter la variable**, si elle existe dans les données.
2. Trouver un **substitut** observable — le diplôme des parents pour le milieu social.
3. Utiliser une structure de données qui l'élimine : **panel**, effets fixes.
4. **Instrumenter** : trouver une variable liée à x mais pas à ε.

Les deux dernières dépassent ce cours

Les données de panel permettent d'éliminer tout ce qui est constant pour un individu — les capacités, par exemple — sans jamais l'observer.
Les variables instrumentales sont la réponse générale, et le chapitre 19 en dira un mot. **Les deux font l'objet de l'économétrie de Master.**

Et si l'on ne peut rien faire

Le dire

Un résultat honnête accompagné de ses limites vaut mieux qu'un résultat présenté comme causal alors qu'il ne l'est pas.
La formulation correcte existe : « le diplôme est **associé** à un salaire supérieur de tant, sans qu'on puisse exclure que les capacités individuelles y contribuent ».

C'est la différence entre deux métiers

Celui qui écrit « le Bac+5 **augmente** le salaire de 54,5 % » a dépassé ce que ses données autorisent.
Celui qui écrit « les Bac+5 gagnent 54,5 % de plus que les Bac, à ancienneté et région comparables » dit exactement ce qu'il a mesuré. **La seconde phrase est plus faible et plus solide.**

Sur machine

La formule vérifiée avec R

```
sal <- read.csv("salaires.csv", stringsAsFactors = TRUE)
b_simple <- coef(lm(salaire ~ anciennete, data = sal))[2]
m2 <- lm(salaire ~ anciennete + diplome, data = sal)
gam <- coef(m2)[c("diplomeBac+2", "diplomeBac+5")]
```

```r
d2 <- coef(lm(I(diplome == "Bac+2") ~ anciennete, data = sal))[2]
d5 <- coef(lm(I(diplome == "Bac+5") ~ anciennete, data = sal))[2]
c(prevu = sum(gam * c(d2, d5)),                # formule
  observe = unname(b_simple - coef(m2)[2]))    # écart réel
#    prevu  observe
# 6.897967 6.897967
```

Les cinq ménages avec Python

```python
import pandas as pd
import statsmodels.formula.api as smf
cinq = pd.DataFrame({"R": [2, 4, 6, 8, 10], "C": [3, 6, 4, 7, 10],
                     "T": [1, 5, 4, 3, 7]})
brut = smf.ols("C ~ R", data=cinq).fit().params["R"]
m = smf.ols("C ~ R + T", data=cinq).fit()
delta = smf.ols("T ~ R", data=cinq).fit().params["R"]
print(round(brut, 4), round(m.params["R"], 4), round(delta, 4))
# 0.75 0.5 0.5
print(round(m.params["R"] + m.params["T"] * delta, 4))  # = brut
# 0.75
```

S'entraîner

Exercice 1 : retrouver la liaison

Ce que la formule permet de déduire

Une pente simple vaut 2. Après ajout d'une variable z, la même pente vaut 1,2 et z a pour coefficient 0,8.

1. Quelle est la pente $\hat{\delta}$ de z sur x ?
2. De combien la pente simple surestimait-elle l'effet de x, en pourcentage ?
3. Que vaudrait le biais si z et x étaient indépendants ?

Exercice 1 : solution

Une liaison de 1

1. $2 = 1{,}2 + 0{,}8\,\hat{\delta}$, d'où $\hat{\delta} = 0{,}8/0{,}8 = 1$.
2. Le biais vaut 0,8 sur un effet net de 1,2 : une surestimation de 67 %.
3. Nul : $\hat{\delta} = 0$ annule le produit, quel que soit l'effet de z.

Exercice 2 : le sens du biais

Trois omissions

Pour chacune, prévoir le signe de γ, de δ et du biais.

1. Ventes d'un produit expliquées par son prix, sans le revenu des clients, dans un échantillon où les magasins des quartiers riches pratiquent des prix plus élevés.
2. Salaire expliqué par le diplôme, sans les capacités.

3. Rendement agricole expliqué par l'engrais, sans la qualité du sol, sachant que les agriculteurs mettent plus d'engrais sur les sols pauvres.

Exercice 2 : solution

Deux surestimations, une sous-estimation

1. $\gamma > 0$ (le revenu fait acheter), $\delta > 0$ (prix plus élevés là où les clients sont riches) : biais **positif**. L'effet du prix, négatif, paraît **moins négatif** qu'il n'est.
2. $\gamma > 0$, $\delta > 0$: le rendement du diplôme est **surestimé**.
3. $\gamma > 0$ (un bon sol rend plus), $\delta < 0$ (plus d'engrais sur les sols pauvres) : biais **négatif**. L'effet de l'engrais est **sous-estimé**.

Exercice 3 : de la variable omise au coefficient net

Avec deux sommes seulement

On sait que $S_{xx} = 20$, $S_{xz} = 10$, que la pente simple de y sur x vaut 4, et que z a pour coefficient 3 dans le modèle complet.

1. Calculer $\hat{\delta}$.
2. En déduire le coefficient net de x.
3. Lequel des deux coefficients répond à la question « que se passe-t-il si x augmente, z restant fixé » ?

Exercice 3 : solution

Un effet net de 2,5

1. $\hat{\delta} = S_{xz}/S_{xx} = 10/20 = 0{,}5$.
2. $4 = \hat{\beta}_1 + 3 \times 0{,}5$, d'où $\hat{\beta}_1 = 2{,}5$.
3. Le coefficient **net**, 2,5 : c'est le *ceteris paribus*. La pente simple, 4, mélange l'effet de x et celui de z qui l'accompagne.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. C'est la **seule** violation qui biaise les coefficients eux-mêmes.
2. Biais $= \gamma\,\delta$: effet de la variable omise sur y, fois sa liaison avec x — il faut les deux.
3. Sur l'échantillon, c'est une **identité exacte** : $0{,}75 = 0{,}5 + 0{,}5 \times 0{,}5$ pour les cinq ménages.
4. Salaires : +6,898 prédits, +6,898 observés ; la région omise ajoute 63,5 au Bac+5.
5. On peut souvent en **prévoir le sens** par le raisonnement économique, sans données.
6. Aucun test ne le détecte, aucune formule ne le répare : **c'est un problème de spécification**.

La suite

Il reste deux diagnostics à passer en revue — la normalité des résidus et les observations qui pèsent trop lourd. Le chapitre 17 les traite ensemble, car ils se lisent sur les mêmes graphiques.