

Chapitre 10

Les variables qualitatives

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Économétrie — Introduction

1 Exercices du chapitre

Correction — Exercice 1

- (a) $k - 1 = 4 - 1 = 3$ indicatrices.
- (b) Pour chaque salarié, exactement une des quatre régions est vraie : son indicatrice vaut 1 et les trois autres valent 0. La somme des quatre indicatrices vaut donc toujours $0 + 0 + 0 + 1 = 1$, quel que soit le salarié.
- (c) La colonne « constante » du modèle vaut, par définition, 1 pour **chaque** observation. La somme des quatre indicatrices régionales, elle aussi constamment égale à 1, est donc **identique** à la colonne de la constante : les colonnes de X sont linéairement dépendantes (la constante est une combinaison exacte des quatre indicatrices), ce qui rend $X'X$ singulière — son inverse, nécessaire au calcul de $\hat{\beta} = (X'X)^{-1}X'y$, n'existe pas.
- (d) Non, la région Nord ne disparaît pas : elle devient la modalité de **référence**, absorbée dans la constante. Les coefficients des indicatrices Centre, Sud, Est se lisent comme des écarts **par rapport** au Nord.

Correction — Exercice 2

- (a) Bac : $\hat{S} = 4000$. Bac+2 : $\hat{S} = 4000 + 1100 = 5100$. Bac+5 : $\hat{S} = 4000 + 3337 = 7337$.
- (b) Le nouvel intercept est le salaire prédit de la nouvelle référence (Bac+5) : $\hat{\beta}'_0 = 7337$.
- (c) Coefficient du Bac (par rapport à Bac+5) = $4000 - 7337 = -3337$. Coefficient du Bac+2 (par rapport à Bac+5) = $5100 - 7337 = -2237$.
- (d) Bac : $7337 + (-3337) = 4000$. $\checkmark$ Bac+2 : $7337 + (-2237) = 5100$. $\checkmark$ Bac+5 (référence) : 7337. $\checkmark$ Les trois salaires prédits sont bien retrouvés à l'identique : le cours a raison, le choix de la référence ne change strictement rien aux prévisions du modèle (ni à son R^2 , ni à son F), seulement à la façon dont les coefficients doivent être lus.

Correction — Exercice 3

- (a) $\hat{S} = 4000 + 200 \times 10 + 1500 \times 0 + 150 \times 10 \times 0 = 4000 + 2000 = 6000$.
- (b) $\hat{S} = 4000 + 200 \times 10 + 1500 \times 1 + 150 \times 10 \times 1 = 4000 + 2000 + 1500 + 1500 = 9000$.
- (c) Pour la référence, le rendement de l'ancienneté est $\hat{\beta}_1 = 200$ DH/an. Pour les Bac+5, il est $\hat{\beta}_1 + \hat{\beta}_3 = 200 + 150 = 350$ DH/an.
- (d) Oui, $|t| = 2,5 > 1,96$: le rendement de l'ancienneté diffère significativement selon le diplôme. Si t avait valu 0,8 ($|t| < 1,96$), il aurait fallu revenir au modèle « à droites parallèles » (sans interaction), plus simple et donc préférable, qui attribue un rendement unique de l'ancienneté à tous les niveaux de diplôme.

2 Exercice cumulatif

Correction — Exercice 4

- (a) $H_0 : \beta_{\text{interaction}} = 0$ (le rendement de l'ancienneté est le même pour les Bac+5 que pour les autres diplômés).
- (b) Non : $|t| = 1,2 < 1,96$. On ne rejette pas H_0 au seuil usuel de 5 %.
- (c) Cette absence de signification suggère plutôt qu'on ne peut **pas**, sur ces données, distinguer statistiquement les deux rendements — elle ne prouve en rien qu'ils sont **identiques**, seulement que l'écart observé (45 DH/an) n'est pas assez net, au vu de la précision de l'estimation, pour être jugé différent de zéro.
- (d) Oui : puisque l'interaction n'est pas significative, revenir au modèle sans interaction — exactement M4 du chapitre 8, avec son rendement unique de 266,74 DH/an — est justifié par la règle du cours (préférer le modèle le plus simple compatible avec les données).

(e) Si $t = 3,1$ avait été significatif, il aurait fallu impérativement conserver, dans le modèle final, les termes **simples** de l'ancienneté (A) et du Bac+5 (D_5), en plus du terme d'interaction $A \times D_5$ — la première règle de rédaction du cours : ne jamais introduire une interaction sans les effets simples qui la composent, sous peine de biaiser l'interprétation des coefficients restants.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) Non : $|t| = 0,8 < 1,96$, ce coefficient n'est pas statistiquement significatif au seuil usuel.
- (b) « À ancienneté et diplôme donnés (les deux autres variables du modèle M3), le salaire d'une femme est, dans cet échantillon, inférieur de 120 DH à celui d'un homme — un écart non significatif. »
- (c) Ce résultat ne permet de conclure qu'à l'absence d'écart significatif **à ancienneté et diplôme égaux**, dans cet échantillon précis : il ne dit strictement rien sur d'éventuels écarts liés à d'autres dimensions non contrôlées par le modèle, ni sur la situation dans d'autres entreprises ou secteurs.
- (d) Le poste occupé (des femmes potentiellement moins représentées dans les postes les mieux rémunérés, à diplôme égal), le temps de travail (temps partiel plus fréquent chez les femmes dans certains contextes), l'avancement de carrière (rythme de promotion), ou la négociation salariale individuelle pourraient tous masquer un écart réel qui n'apparaît pas dans le seul salaire de base à ancienneté et diplôme identiques — exactement l'avertissement du cours sur le caractère toujours partiel du *ceteris paribus*.

Correction — Exercice 6

- (a) Retirer l'observation du fichier, ou lui attribuer une indicatrice qui lui laisse sa propre constante.
- (b) Oui, très significatif : $|t| = 4,2 \gg 1,96$.
- (c) Cette solution « se voit » car l'indicatrice $D_{\text{touristique}}$ apparaît explicitement dans la sortie de régression, avec son coefficient et son test de signification, visibles par quiconque relit le rapport ; elle « se teste » car son coefficient est soumis au même test t que n'importe quelle autre variable, permettant de vérifier objectivement si ce magasin est réellement atypique. Une suppression silencieuse, elle, ne laisse aucune trace dans les résultats rapportés.
- (d) Un collègue qui reproduirait l'analyse à partir du fichier complet (avec les 45 magasins) obtiendrait des résultats **différents** de ceux rapportés, sans en connaître la raison, ce qui jetterait un doute légitime sur la fiabilité ou l'honnêteté de l'étude initiale — la différence entre une décision de modélisation transparente (l'indicatrice, documentée et testée) et une manipulation non déclarée des données (la suppression silencieuse), exactement la distinction que le cours met en garde.