

Introduction à l'économétrie

Chapitre 10 : Les variables qualitatives

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Introduction à l'économétrie

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — La règle des $k - 1$

Une entreprise emploie des salariés répartis en quatre régions : Nord, Centre, Sud, Est.

- (a) Combien d'indicateurs régionaux le cours recommande-t-il d'inclure dans le modèle?
- (b) Un analyste inclut, par erreur, **quatre** indicateurs (une par région) **en plus** de la constante. Montrer que la somme des quatre indicateurs vaut 1 pour **chaque** observation.
- (c) En quoi cette somme, constamment égale à 1, reproduit-elle exactement la colonne de la constante? Pourquoi la matrice $X'X$ devient-elle, dans ce cas, singulière (non inversible)?
- (d) Si l'analyste corrige son erreur en retirant l'indicateur « Nord » (gardant Centre, Sud, Est), la région Nord « disparaît »-elle de l'analyse pour autant? Quel rôle joue-t-elle désormais?

Exercice 2 — Changer de référence ne change rien... sauf la lecture

Le cours rapporte, avec le Bac comme référence : +1 100 DH pour un Bac+2, +3 337 DH pour un Bac+5. On admet un intercept $\hat{\beta}_0 = 4\,000$ (incorporant les autres variables, ici maintenues constantes).

- (a) Calculer le salaire prédit pour un Bac, un Bac+2 et un Bac+5 (à ancienneté, sexe et région donnés).
- (b) On souhaite maintenant prendre le Bac+5 comme référence. Quel est le nouvel intercept $\hat{\beta}'_0$?
- (c) Calculer les nouveaux coefficients (par rapport au Bac+5) pour le Bac et pour le Bac+2.
- (d) Vérifier que les trois salaires prédits à la question (a) sont retrouvés à **l'identique** avec cette nouvelle paramétrisation. Le cours a-t-il raison d'affirmer que le choix de la référence « ne change rien au modèle, seulement la lecture »?

Exercice 3 — Une interaction, pas à pas

On estime $S = \beta_0 + \beta_1 A + \beta_2 D_5 + \beta_3 (A \times D_5) + \varepsilon$, avec $\hat{\beta}_0 = 4\,000$, $\hat{\beta}_1 = 200$, $\hat{\beta}_2 = 1\,500$, $\hat{\beta}_3 = 150$ (A : ancienneté en années; $D_5 = 1$ si Bac+5, 0 sinon).

- (a) Calculer le salaire prédit pour un salarié de la référence (non Bac+5), $A = 10$ ans.
- (b) Calculer le salaire prédit pour un salarié Bac+5, $A = 10$ ans.
- (c) Quel est le rendement d'une année d'ancienneté (la pente en A) pour la référence? Pour les Bac+5?
- (d) Un test donne $t = 2,5$ pour $\hat{\beta}_3$ (seuil 1,96). Le rendement de l'ancienneté diffère-t-il significativement selon le diplôme? Si ce t avait plutôt valu 0,8, quel modèle plus simple (rappeler la règle du cours) aurait-il fallu préférer?

2 Exercice cumulatif (chapitre 10 et chapitres précédents)

Exercice 4 — L'ancienneté rapporte-t-elle pareil à tous les diplômés ?

On enrichit le modèle M4 du chapitre 8 (ancienneté, diplôme, sexe, région) d'un terme d'interaction ancienneté $\times$ Bac+5, pour tester si le rendement net de l'ancienneté (266,74 DH/an, chapitre 7) est le même pour les Bac+5 que pour les autres diplômés. Le coefficient de l'interaction est estimé à $\hat{\beta}_{\text{interaction}} = 45$, avec $t = 1,2$.

- (a) Énoncer H_0 pour ce test d'interaction.
- (b) Au seuil usuel (1,96), peut-on rejeter H_0 ?
- (c) Cette absence de signification suggère-t-elle que le rendement de l'ancienneté est significativement **différent** entre Bac+5 et les autres, ou plutôt qu'on ne peut pas, sur ces données, distinguer les deux rendements? ¹

- (d) Le cours recommande, dans un modèle avec interaction non significative, de « revenir au modèle à droites parallèles — plus simple, donc préférable ». Le modèle M4 du chapitre 8 (sans interaction), qui attribue un rendement **unique** de 266,74 DH/an à l'ancienneté pour tous les niveaux de diplôme, est-il donc justifié par ce résultat ?
- (e) Si, au contraire, le t de l'interaction avait valu 3,1, quelle règle de rédaction rappelée par ce chapitre faudrait-il impérativement respecter en gardant ce terme d'interaction dans le modèle final ?

3 Applications en sciences économiques

Exercice 5 — L'écart de salaire entre hommes et femmes, et ses limites

Dans le modèle M3 du chapitre 8 (ajout du sexe), le coefficient de l'indicatrice « femme » est estimé à -120 DH, avec $t = -0,8$.

- (a) Ce coefficient est-il statistiquement significatif au seuil usuel de 5 % ?
- (b) Interpréter ce coefficient de -120 DH au sens *ceteris paribus*, en précisant **quelles** variables sont maintenues constantes dans cette comparaison (indice : rappeler la liste des variables du modèle M3).
- (c) Ce résultat (-120 DH, non significatif) permet-il de conclure qu'il n'existe **aucun** écart salarial entre hommes et femmes dans l'entreprise, en toute généralité, ou seulement qu'il n'y en a pas, dans cet échantillon, à **ancienneté et diplôme égaux** ?
- (d) Le cours rappelle que « le *ceteris paribus* est toujours partiel ». Quels facteurs, non présents dans ce modèle (poste occupé, temps partiel, promotion, négociation salariale individuelle), pourraient masquer un écart réel qui se manifesterait par d'autres canaux que le salaire de base à diplôme et ancienneté identiques ?

Exercice 6 — Un site atypique : indicatrice ou suppression ?

Une chaîne de distribution régresse le chiffre d'affaires mensuel de 45 magasins sur leur surface et leur effectif. Un magasin, situé dans une zone touristique exceptionnelle, réalise un chiffre d'affaires très supérieur à ce que sa surface et son effectif prédiraient.

- (a) Rappeler les deux attitudes possibles, selon le cours, face à cette observation atypique.
- (b) L'analyste choisit d'ajouter une indicatrice $D_{\text{touristique}}$ valant 1 pour ce seul magasin, et obtient un coefficient de +180 000 DH avec $t = 4,2$. Ce coefficient est-il significatif ?
- (c) En quoi cette solution « se voit et se teste », contrairement à la suppression pure et simple de cette ligne du fichier de données ?
- (d) Si l'analyste avait supprimé le magasin sans le signaler dans son rapport, quel risque cela ferait-il courir à la crédibilité de l'étude si un collègue tentait de reproduire les résultats à partir du fichier complet ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) $k - 1 = 4 - 1 = 3$ indicatrices.
- (b) Pour chaque salarié, exactement une des quatre régions est vraie : son indicatrice vaut 1 et les trois autres valent 0. La somme des quatre indicatrices vaut donc toujours $0 + 0 + 0 + 1 = 1$, quel que soit le salarié.
- (c) La colonne « constante » du modèle vaut, par définition, 1 pour **chaque** observation. La somme des quatre indicatrices régionales, elle aussi constamment égale à 1, est donc **identique** à la colonne de la constante : les colonnes de X sont linéairement dépendantes (la constante est une combinaison exacte des quatre indicatrices), ce qui rend $X'X$ singulière — son inverse, nécessaire au calcul de $\hat{\beta} = (X'X)^{-1}X'y$, n'existe pas.
- (d) Non, la région Nord ne disparaît pas : elle devient la modalité de **référence**, absorbée dans la constante. Les coefficients des indicatrices Centre, Sud, Est se lisent comme des écarts **par rapport** au Nord.

Correction — Exercice 2

- (a) Bac : $\hat{S} = 4\,000$. Bac+2 : $\hat{S} = 4\,000 + 1\,100 = 5\,100$. Bac+5 : $\hat{S} = 4\,000 + 3\,337 = 7\,337$.
- (b) Le nouvel intercept est le salaire prédit de la nouvelle référence (Bac+5) : $\hat{\beta}_0' = 7\,337$.
- (c) Coefficient du Bac (par rapport à Bac+5) = $4\,000 - 7\,337 = -3\,337$. Coefficient du Bac+2 (par rapport à Bac+5) = $5\,100 - 7\,337 = -2\,237$.
- (d) Bac : $7\,337 + (-3\,337) = 4\,000$. $\checkmark$ Bac+2 : $7\,337 + (-2\,237) = 5\,100$. $\checkmark$ Bac+5 (référence) : $7\,337$.
 $\checkmark$ Les trois salaires prédits sont bien retrouvés à l'identique : le cours a raison, le choix de la référence ne change strictement rien aux prévisions du modèle (ni à son R^2 , ni à son F), seulement à la façon dont les coefficients doivent être lus.

Correction — Exercice 3

- (a) $\hat{S} = 4\,000 + 200 \times 10 + 1\,500 \times 0 + 150 \times 10 \times 0 = 4\,000 + 2\,000 = 6\,000$.
- (b) $\hat{S} = 4\,000 + 200 \times 10 + 1\,500 \times 1 + 150 \times 10 \times 1 = 4\,000 + 2\,000 + 1\,500 + 1\,500 = 9\,000$.
- (c) Pour la référence, le rendement de l'ancienneté est $\hat{\beta}_1 = 200$ DH/an. Pour les Bac+5, il est $\hat{\beta}_1 + \hat{\beta}_3 = 200 + 150 = 350$ DH/an.
- (d) Oui, $|t| = 2,5 > 1,96$: le rendement de l'ancienneté diffère significativement selon le diplôme. Si t avait valu 0,8 ($|t| < 1,96$), il aurait fallu revenir au modèle « à droites parallèles » (sans interaction), plus simple et donc préférable, qui attribue un rendement unique de l'ancienneté à tous les niveaux de diplôme.

2 Exercice cumulatif

Correction — Exercice 4

- (a) $H_0 : \beta_{\text{interaction}} = 0$ (le rendement de l'ancienneté est le même pour les Bac+5 que pour les autres diplômés).
- (b) Non : $|t| = 1,2 < 1,96$. On ne rejette pas H_0 au seuil usuel de 5 %.
- (c) Cette absence de signification suggère plutôt qu'on ne peut **pas**, sur ces données, distinguer statistiquement les deux rendements — elle ne prouve en rien qu'ils sont **identiques**, seulement que l'écart observé (45 DH/an) n'est pas assez net, au vu de la précision de l'estimation, pour être jugé différent de zéro.
- (d) Oui : puisque l'interaction n'est pas significative, revenir au modèle sans interaction — exactement M4 du chapitre 8, avec son rendement unique de 266,74 DH/an — est justifié par la règle du cours (préférer le modèle le plus simple compatible avec les données).

(e) Si $t = 3,1$ avait été significatif, il aurait fallu impérativement conserver, dans le modèle final, les termes **simples** de l'ancienneté (A) et du Bac+5 (D_5), en plus du terme d'interaction $A \times D_5$ — la première règle de rédaction du cours : ne jamais introduire une interaction sans les effets simples qui la composent, sous peine de biaiser l'interprétation des coefficients restants.

3 Applications en sciences économiques

Correction — Exercice 5

- (a) Non : $|t| = 0,8 < 1,96$, ce coefficient n'est pas statistiquement significatif au seuil usuel.
- (b) « À ancienneté et diplôme donnés (les deux autres variables du modèle M3), le salaire d'une femme est, dans cet échantillon, inférieur de 120 DH à celui d'un homme — un écart non significatif. »
- (c) Ce résultat ne permet de conclure qu'à l'absence d'écart significatif **à ancienneté et diplôme égaux**, dans cet échantillon précis : il ne dit strictement rien sur d'éventuels écarts liés à d'autres dimensions non contrôlées par le modèle, ni sur la situation dans d'autres entreprises ou secteurs.
- (d) Le poste occupé (des femmes potentiellement moins représentées dans les postes les mieux rémunérés, à diplôme égal), le temps de travail (temps partiel plus fréquent chez les femmes dans certains contextes), l'avancement de carrière (rythme de promotion), ou la négociation salariale individuelle pourraient tous masquer un écart réel qui n'apparaît pas dans le seul salaire de base à ancienneté et diplôme identiques — exactement l'avertissement du cours sur le caractère toujours partiel du *ceteris paribus*.

Correction — Exercice 6

- (a) Retirer l'observation du fichier, ou lui attribuer une indicatrice qui lui laisse sa propre constante.
- (b) Oui, très significatif : $|t| = 4,2 \gg 1,96$.
- (c) Cette solution « se voit » car l'indicatrice $D_{\text{touristique}}$ apparaît explicitement dans la sortie de régression, avec son coefficient et son test de signification, visibles par quiconque relit le rapport ; elle « se teste » car son coefficient est soumis au même test t que n'importe quelle autre variable, permettant de vérifier objectivement si ce magasin est réellement atypique. Une suppression silencieuse, elle, ne laisse aucune trace dans les résultats rapportés.
- (d) Un collègue qui reproduirait l'analyse à partir du fichier complet (avec les 45 magasins) obtiendrait des résultats **différents** de ceux rapportés, sans en connaître la raison, ce qui jetterait un doute légitime sur la fiabilité ou l'honnêteté de l'étude initiale — la différence entre une décision de modélisation transparente (l'indicatrice, documentée et testée) et une manipulation non déclarée des données (la suppression silencieuse), exactement la distinction que le cours met en garde.