Introduction à l'économétrie

Chapitre 10 : Les variables qualitatives

Jaouad Madkour

29 octobre 2026

Plan du chapitre

Faire entrer une catégorie **2**
- Le problème . . . 2
- Des indicatrices seules : des moyennes . . . 2
- Pourquoi des moyennes . . . 2
- Ce qu'elle fait au modèle . . . 3
- La règle des k moins 1 . . . 4
- Le choix de la référence . . . 4
- Le codage 1, 2, 3, chiffré . . . 5

Les interactions **6**
- Quand l'effet dépend du groupe . . . 6
- Le modèle . . . 6
- Sur nos salariés . . . 7
- Deux règles de rédaction . . . 7

Un dernier usage **8**
- Isoler un sous-groupe particulier . . . 8

Sur machine **8**
- La référence avec R . . . 8
- L'interaction avec R . . . 8
- Les indicatrices avec Python . . . 9

S'entraîner **9**
- Exercice 1 : une indicatrice à la main . . . 9
- Exercice 1 : solution . . . 9
- Exercice 2 : lire une interaction . . . 9
- Exercice 2 : solution . . . 10
- Exercice 3 : le piège des indicatrices . . . 10
- Exercice 3 : solution . . . 10

Ce qu'il faut retenir **10**
- Le résumé du chapitre . . . 10

Faire entrer une catégorie

Le problème

On ne régresse pas sur des mots

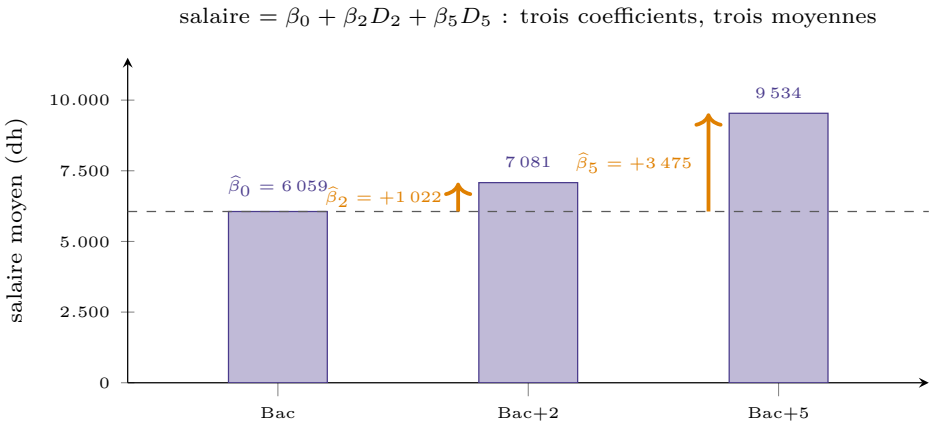
Le diplôme prend trois valeurs : Bac, Bac+2, Bac+5. La région en prend quatre, le sexe deux.
Les coder 1, 2, 3 serait une faute : cela imposerait que l'écart entre Bac et Bac+2 soit exactement le même qu'entre Bac+2 et Bac+5, et que l'ordre ait un sens arithmétique. Pour la région, ce serait absurde.

La variable indicatrice

Une **indicatrice** vaut 1 si la modalité est présente, 0 sinon.

$$D_2 = \begin{cases} 1 & \text{si Bac+2} \\ 0 & \text{sinon} \end{cases} \qquad D_5 = \begin{cases} 1 & \text{si Bac+5} \\ 0 & \text{sinon} \end{cases}$$

Des indicatrices seules : des moyennes



Ce que valent les coefficients

Sans autre variable, la constante est la **moyenne de la référence**, 6 059 dirhams pour le Bac ; chaque coefficient est un **écart de moyennes** : $7\,081 - 6\,059 = 1\,022$, $9\,534 - 6\,059 = 3\,475$.

Pourquoi des moyennes

Les moindres carrés dans chaque groupe

Pour un Bac, le modèle prédit β_0 ; pour un Bac+2, $\beta_0 + \beta_2$. Minimiser la somme des carrés revient à choisir, **dans chaque groupe séparément**, la valeur la plus proche de tous ses membres : leur moyenne.

Démonstration : Une régression sur des indicatrices redonne les moyennes de groupes

Dans le modèle $y = \beta_0 + \beta_2 D_2 + \beta_5 D_5 + \varepsilon$, un salarié de chaque groupe a pour prévision $\mu_{\text{Bac}} = \beta_0$, $\mu_2 = \beta_0 + \beta_2$ ou $\mu_5 = \beta_0 + \beta_5$. La somme des carrés se découpe par groupe :

$$S = \sum_{i \in \text{Bac}} (y_i - \mu_{\text{Bac}})^2 + \sum_{i \in 2} (y_i - \mu_2)^2 + \sum_{i \in 5} (y_i - \mu_5)^2,$$

chaque terme ne dépendant que de sa propre prévision. Pour un groupe g de n_g salariés, de moyenne $\overline{y}_g$,

$$\sum_{i \in g} (y_i - \mu)^2 = \sum_{i \in g} (y_i - \overline{y}_g)^2 + n_g (\overline{y}_g - \mu)^2,$$

car le double produit $2(\overline{y}_g - \mu) \sum_{i \in g} (y_i - \overline{y}_g)$ est nul. Le minimum est atteint en $\mu = \overline{y}_g$. La correspondance $(\beta_0, \beta_2, \beta_5) \leftrightarrow (\mu_{\text{Bac}}, \mu_2, \mu_5)$ étant bijective,

$$\hat{\beta}_0 = \overline{y}_{\text{Bac}}, \qquad \hat{\beta}_2 = \overline{y}_2 - \overline{y}_{\text{Bac}}, \qquad \hat{\beta}_5 = \overline{y}_5 - \overline{y}_{\text{Bac}}.$$

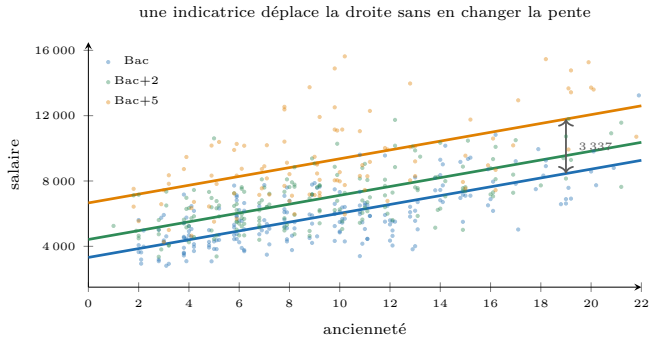
La part expliquée est alors $\text{SCE} = \sum_g n_g (\overline{y}_g - \overline{y})^2$, la variance inter-groupes de l'analyse de la variance : $R^2 = \eta^2$.

■

L'analyse de la variance, déguisée

Le R^2 de cette régression vaut 0,258 : c'est le η^2 de l'ANOVA du chapitre 17 de l'inférence, et son F est celui de l'ANOVA. **Une régression sur des indicatrices est une analyse de la variance.**

Ce qu'elle fait au modèle



Trois modalités, deux indicatrices

$\widehat{S} = 3\,320 + 270\,A + 1\,100\,D_2 + 3\,337\,D_5$

Le Bac n'a pas d'indicatrice : c'est la **modalité de référence**, absorbée dans la constante. Les deux coefficients se lisent *par rapport à elle*.

Le piège des indicatrices

Mettre les trois rendrait leur somme égale à 1, donc colinéaire à la constante : le modèle serait insoluble. **Toujours $k - 1$ indicatrices pour k modalités.**

Ici les droites sont *parallèles* : le modèle suppose que le rendement d'une année d'ancienneté est le même pour tous. C'est une hypothèse — que le chapitre suivant lève.

La règle des k moins 1

Le piège de la colinéarité parfaite

Pour k modalités, on met $k-1$ **indicatrices**, jamais k.
Les trois réunies auraient une somme constamment égale à 1, donc identique à la constante : la matrice $X'X$ serait singulière et le modèle n'aurait aucune solution.

Démonstration : Pourquoi k indicatrices et une constante rendent $X'X$ singulière

Chaque observation appartient à une seule modalité, donc $D_1 + D_2 + \cdots + D_k = 1$: la colonne de 1 est la somme des k colonnes d'indicatrices. Le vecteur $v = (1, -1, \ldots, -1)$ (constante, puis les k indicatrices) vérifie alors $Xv = 0$, donc $X'Xv = 0$: la matrice n'est pas inversible (voir la forme matricielle, chapitre 7).

Concrètement, pour tout nombre c, le jeu de coefficients $(\beta_0 + c,\ \beta_1 - c, \ldots,\ \beta_k - c)$ donne exactement les mêmes valeurs ajustées : il existe une infinité de solutions, et rien ne permet d'en préférer une : le modèle n'a pas de solution unique. Avec $k - 1$ indicatrices, la somme n'est plus constante et les colonnes sont indépendantes, pourvu que chaque modalité soit présente dans les données.

■

La modalité écartée n'est pas perdue

Elle devient la **référence**, absorbée dans la constante. Les coefficients des autres se lisent **par rapport à elle**.
Ici : 1 100 dirhams de plus pour un Bac+2 que pour un Bac, 3 337 de plus pour un Bac+5, à ancienneté égale. Le Bac ne disparaît pas — il est le zéro de l'échelle.

Le choix de la référence

Il ne change rien, et il change tout

Prendre le Bac+5 en référence donnerait −3 337 pour le Bac : mêmes écarts, signes inversés.
Le modèle est **strictement identique** — mêmes prévisions, même R^2, même F.
Mais la lecture change. **On choisit comme référence la modalité la plus naturelle** — la plus nombreuse, ou celle qui sert de point de comparaison dans le débat.

Démonstration : Le choix de la référence ne change ni les ajustements, ni le R^2, ni le F

Écrivons le même modèle de deux façons, les « autres termes » (l'ancienneté, par exemple) étant identiques. Avec le Bac pour référence, il prévoit $\beta_0 + \beta_2 D_2 + \beta_5 D_5 +$ (autres termes). Avec le Bac+5 pour référence, il prévoit $\beta'_0 + \beta'_{\text{Bac}} D_{\text{Bac}} + \beta'_2 D_2 +$ (autres termes). Chaque salarié ayant un seul diplôme, $D_{\text{Bac}} = 1 - D_2 - D_5$, et la seconde écriture devient

$$(\beta'_0 + \beta'_{\text{Bac}}) + (\beta'_2 - \beta'_{\text{Bac}})\, D_2 - \beta'_{\text{Bac}}\, D_5 + (\text{autres termes}).$$

Les deux écritures donnent les mêmes prévisions si

$$\beta'_{\text{Bac}} = -\beta_5, \qquad \beta'_2 = \beta_2 - \beta_5, \qquad \beta'_0 = \beta_0 + \beta_5,$$

les autres coefficients restant inchangés. Cette correspondance est bijective : à tout jeu de coefficients d'une écriture répond un jeu de l'autre qui donne les **mêmes valeurs ajustées**, donc la même SCR. Le minimum de SCR est donc le même, atteint par deux jeux jumeaux : mêmes valeurs ajustées, même R^2, même F. Seuls les coefficients changent, et le Bac, qui était à 0, passe à $-\hat{\beta}_5 = -3\,337$.

Le cas général. Changer de référence remplace la matrice X par $\tilde{X} = XA$, où A est inversible : les colonnes de $\tilde{X}$ sont des combinaisons des colonnes de X, et réciproquement. Les valeurs ajustées sont inchangées :

$$\begin{aligned}\tilde{X}(\tilde{X}'\tilde{X})^{-1}\tilde{X}'y &= XA\,A^{-1}(X'X)^{-1}(A')^{-1}A'X'y \\ &= X(X'X)^{-1}X'y.\end{aligned}$$

■

Les logiciels choisissent pour vous

R prend la première modalité dans l'ordre alphabétique : ici « Bac », par chance le bon choix.
Sur d'autres données, l'ordre alphabétique donne une référence absurde. **Vérifiez toujours laquelle a été retenue avant de lire les coefficients** : c'est une source d'erreur d'interprétation très fréquente.

Le codage 1, 2, 3, chiffré

Ce que le codage numérique impose

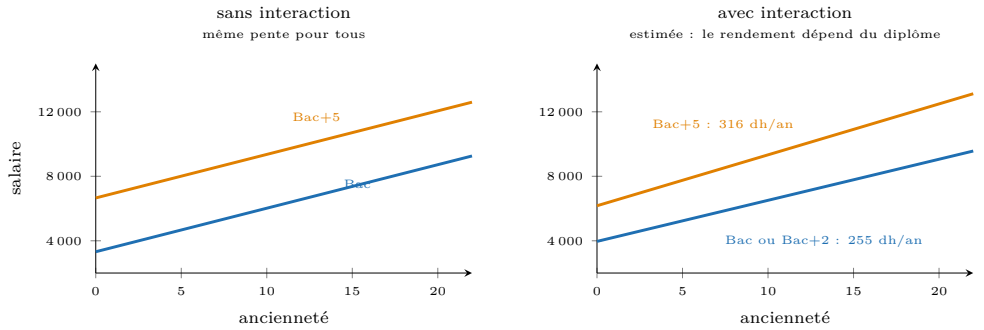
Codage du diplôme	Bac → Bac+2	Bac+2 → Bac+5	R^2
indicatrices (M2)	+1 100	+2 237	0,642
rangs 1, 2, 3	+1 594	+1 594	0,631
années d'études 0, 2, 5	+1 324	+1 986	0,640

Un codage numérique est une contrainte, et elle se teste

Les rangs imposent deux écarts égaux : le Fisher partiel contre M2 donne $F = 14{,}4$, **rejeté**. Les années d'études imposent 662 dirhams par année d'études : $F = 2{,}55$, $p = 0{,}11$, **non rejeté**. Un codage numérique n'est pas interdit : il doit être justifié, et vérifié.

Les interactions

Quand l'effet dépend du groupe



$$\widehat{S} = \beta_0 + \beta_1 A + \beta_2 D_5 + \underbrace{\beta_3 (A \times D_5)}_{\text{le terme d'interaction}}$$

Une indicatrice seule déplace la droite ; multipliée par une variable, elle en change la pente. L'interaction répond à une question que le modèle additif ne pose même pas : *le rendement de l'ancienneté est-il le même selon le diplôme ?*

Sur nos salariés, $\widehat{\beta_3} = 61$ dirhams par année ($t = 2{,}08$, $p = 0{,}038$) : le rendement de l'ancienneté est plus élevé pour les Bac+5, de justesse significativement. S'il ne l'était pas, on reviendrait au modèle à droites parallèles — plus simple, donc préférable.

Le modèle

Multiplier une indicatrice par une variable

$$S = \beta_0 + \beta_1 A + \beta_2 D_5 + \beta_3 (A \times D_5) + \varepsilon$$

- β_1 : le rendement de l'ancienneté **pour la référence**.
- $\beta_1 + \beta_3$: le rendement **pour les Bac+5**.
- β_3 : la **différence** de rendement entre les deux.

Démonstration : Le modèle avec interaction équivaut à deux régressions séparées

Pour un salarié non Bac+5 ($D_5 = 0$), le modèle prévoit $\beta_0 + \beta_1 A$; pour un Bac+5 ($D_5 = 1$), $(\beta_0 + \beta_2) + (\beta_1 + \beta_3)A$. Posons $(a_0, a_1) = (\beta_0, \beta_1)$ et $(c_0, c_1) = (\beta_0 + \beta_2,\ \beta_1 + \beta_3)$: la correspondance entre ces quatre nombres et $(\beta_0, \beta_1, \beta_2, \beta_3)$ est bijective. La somme des carrés se sépare en deux :

$$S = \sum_{D_5=0} (S_i - a_0 - a_1 A_i)^2 + \sum_{D_5=1} (S_i - c_0 - c_1 A_i)^2,$$

et chaque terme ne dépend que de son couple de paramètres. Il est donc minimisé séparément : $(\hat{a}_0, \hat{a}_1)$ est la droite des moindres carrés sur les non Bac+5 seuls, $(\hat{c}_0, \hat{c}_1)$ celle des Bac+5 seuls. Par conséquent

$$\hat{\beta}_1 = \hat{a}_1, \qquad \hat{\beta}_3 = \hat{c}_1 - \hat{a}_1, \qquad \hat{\beta}_2 = \hat{c}_0 - \hat{a}_0.$$

$\hat{\beta}_1 + \hat{\beta}_3 = 315{,}8$ est la pente estimée sur les seuls Bac+5, et l'écart de salaire entre les deux

droites à A années d'ancienneté vaut $\hat{\beta}_2 + \hat{\beta}_3 A$, soit $2\,211 + 20 \times 61 = 3\,431$ à vingt ans.

■

La question que l'interaction pose

Sans elle, le modèle **impose** que le rendement de l'ancienneté soit le même pour tous. C'est une hypothèse, jamais un fait.
L'interaction la lève et la teste : β_3 se teste comme n'importe quel coefficient. **S'il n'est pas significatif, on revient au modèle à droites parallèles** — plus simple, donc préférable.

Sur nos salariés

L'interaction estimée

$$\widehat{S} = 3\,962 + 254{,}8\,A + 2\,211\,D_5 + 61{,}0\,(A \times D_5) \qquad t_{\beta_3} = 2{,}08 \quad p = 0{,}038$$

Rendement d'une année d'ancienneté : 254,8 dirhams pour les Bac et Bac+2, 254,8 + 61,0 = 315,8 pour les Bac+5.

Ce que l'écart devient avec le temps

À l'embauche, un Bac+5 gagne 2 211 dirhams de plus ; après vingt ans, $2\,211 + 20 \times 61 = 3\,431$. **L'avantage du diplôme se creuse au fil de la carrière** — une conclusion que le modèle à droites parallèles ne pouvait pas formuler. Elle reste fragile : $p = 0{,}038$, tout près du seuil.

Deux règles de rédaction

À ne pas oublier

1. **Toujours conserver les termes simples** : si $A \times D_5$ est dans le modèle, A et D_5 doivent y être aussi.
2. **Ne jamais lire β_1 seul** dans un modèle avec interaction : il ne vaut que pour la référence.

L'usage politique de l'interaction

« L'effet d'une formation est-il le même pour les jeunes et les seniors ? » « Le rendement du diplôme diffère-t-il selon la région ? »
Ce sont des questions d'**hétérogénéité des effets**, et l'interaction est le seul moyen simple d'y répondre. Elles sont souvent plus intéressantes que l'effet moyen lui-même.

Un dernier usage

Isoler un sous-groupe particulier

Une indicatrice pour une poignée d'observations

Une indicatrice qui vaut 1 pour un petit groupe atypique — un service, un site, une catégorie de contrats — permet de **lui laisser sa propre constante** sans qu'il déforme le reste.

Une alternative à la suppression

Face à quelques observations manifestement particulières, deux attitudes : les retirer du fichier, ou leur donner une indicatrice.
La seconde est presque toujours préférable. Elle conserve l'information, elle est visible dans la sortie, et elle se teste. Retirer des lignes sans le dire ne se voit nulle part — c'est la différence entre une décision de modélisation et une manipulation.

Sur machine

La référence avec R

```
sal <- read.csv("salaires.csv", stringsAsFactors = TRUE)
levels(sal$diplome)                  # Bac sera la référence
# [1] "Bac"   "Bac+2" "Bac+5"
coef(lm(salaire ~ diplome, data = sal))      # trois moyennes
#  (Intercept) diplomeBac+2 diplomeBac+5
#     6058.904     1021.843     3475.488
sal$diplome <- relevel(sal$diplome, ref = "Bac+5")
coef(lm(salaire ~ diplome, data = sal))      # autre référence
#  (Intercept)   diplomeBac diplomeBac+2
#     9534.393    -3475.488    -2453.645
```

L'interaction avec R

```
sal <- read.csv("salaires.csv", stringsAsFactors = TRUE)
sal$D5 <- as.numeric(sal$diplome == "Bac+5")
mi <- lm(salaire ~ anciennete * D5, data = sal)
round(summary(mi)$coefficients, 3)
#               Estimate Std. Error t value Pr(>|t|)
# (Intercept)   3961.844    161.340  24.556    0.000
# anciennete     254.818     13.880  18.358    0.000
# D5            2210.789    354.957   6.228    0.000
# anciennete:D5   60.992     29.262   2.084    0.038
sum(coef(mi)[c("anciennete", "anciennete:D5")])  # pente Bac+5
# [1] 315.8106
```

Les indicatrices avec Python

```
import pandas as pd
import statsmodels.formula.api as smf
sal = pd.read_csv("salaires.csv")
pd.get_dummies(sal.diplome, dtype=int).head(3)   # trois colonnes
#    Bac  Bac+2  Bac+5
# 0    0      0      1
# 1    1      0      0
# 2    1      0      0
f = "salaire ~ anciennete + C(diplome, Treatment('Bac+5'))"
print(smf.ols(f, data=sal).fit().params.round(2).tolist())
# [6657.41, -3336.99, -2237.42, 270.27]
```

S'entraîner

Exercice 1 : une indicatrice à la main

Six salariés

Trois hommes gagnent 8, 10 et 12 milliers de dirhams ; trois femmes 7, 8 et 9. On régresse le salaire sur H, indicatrice des hommes.

1. Sans calcul de covariance, donner $\hat{\beta}_0$ et $\hat{\beta}_1$.
2. Les vérifier par la formule S_{xy}/S_{xx}.
3. Que deviennent-ils si l'on code plutôt F, indicatrice des femmes ?

Exercice 1 : solution

La moyenne des femmes, puis l'écart

1. $\hat{\beta}_0 = 8$, moyenne des femmes (la référence) ; $\hat{\beta}_1 = 10 - 8 = 2$.
2. $\overline{H} = 0{,}5$, $\overline{S} = 9$. $S_{HH} = 6 \times 0{,}25 = 1{,}5$; $S_{HS} = 0{,}5\,(-1+1+3) - 0{,}5\,(-2-1+0) = 1{,}5 + 1{,}5 = 3$. Pente $3/1{,}5 = 2$.
3. $\hat{\beta}_0 = 10$, moyenne des hommes, et $\hat{\beta}_1 = -2$. Même modèle, autre référence.

Exercice 2 : lire une interaction

Le rendement selon le diplôme

On a estimé $\widehat{S} = 3\,962 + 254{,}8\,A + 2\,211\,D_5 + 61{,}0\,(A \times D_5)$.

1. Écrire la droite des Bac+5 et celle des autres.
2. Calculer l'écart prévu entre un Bac+5 et un Bac, tous deux à 10 ans d'ancienneté.
3. Un collègue lit 254,8 comme « le rendement de l'ancienneté ». Qu'objecter ?

Exercice 2 : solution

Deux droites, deux pentes

1. Bac+5 : $(3\,962 + 2\,211) + (254{,}8 + 61{,}0)\,A = 6\,173 + 315{,}8\,A$. Autres : $3\,962 + 254{,}8\,A$.
2. $2\,211 + 61{,}0 \times 10 = 2\,821$ dirhams.
3. 254,8 n'est le rendement que pour la **référence**, les Bac et Bac+2. Pour les Bac+5, c'est 315,8. Dans un modèle avec interaction, un coefficient simple ne se lit jamais seul.

Exercice 3 : le piège des indicatrices

Quatre régions

Le fichier distingue quatre régions : Casablanca, Rabat, Tanger-Tétouan, Autres.

1. Combien d'indicatrices faut-il mettre avec une constante ? Que se passe-t-il si l'on en met quatre ?
2. Un étudiant code la région 1, 2, 3, 4 et l'entre comme une seule variable. Quelle hypothèse impose-t-il sans le dire ?
3. Comment tester si la région compte, d'un seul coup ?

Exercice 3 : solution

Trois indicatrices, un Fisher partiel

1. **Trois**. Avec quatre, leur somme vaut toujours 1, comme la constante : colinéarité parfaite. R renvoie `NA` pour l'une d'elles ; d'autres logiciels refusent l'estimation.
2. Que les régions soient **ordonnées** et **équidistantes** : passer de Casablanca à Rabat ferait le même effet que de Rabat à Tanger. Cela n'a aucun sens pour une variable nominale.
3. Par un **Fisher partiel** à $q = 3$ sur les trois indicatrices : $F = 12{,}86$ au chapitre 9.

Ce qu'il faut retenir

Le résumé du chapitre

Six points

1. Une **indicatrice** vaut 1 ou 0 ; un codage numérique est une contrainte, à justifier et à tester.
2. Pour k modalités, $k - 1$ **indicatrices** : sinon colinéarité parfaite et modèle insoluble.
3. Seules, les indicatrices donnent des **moyennes de groupe** : 6 059, +1 022, +3 475.
4. La modalité écartée devient la **référence** ; en changer ne change rien au modèle, seulement la lecture.
5. Une **interaction** fait varier la pente : 254,8 contre 315,8 dirhams par an, $p = 0{,}038$.
6. Une indicatrice pour un sous-groupe atypique vaut mieux que sa **suppression** : elle se voit et se teste.

La suite

Toute la mécanique est en place. Reste à savoir **à quelles conditions tout cela est vrai** : la quatrième partie énonce les hypothèses, la cinquième examine ce qui se passe quand elles tombent.