Introduction à l'économétrie

Chapitre 19 : Choisir un modèle, et le seuil de la causalité

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 23 octobre 2026

Plan du chapitre

Choisir

Le seuil de la causalité

La conclusion du cours

Sur machine

S’entraîner

Ce qu’il faut retenir

Choisir

Le compromis fondamental

Deux erreurs opposées

Trop peu de variables : risque de **variable omise**, donc de biais.

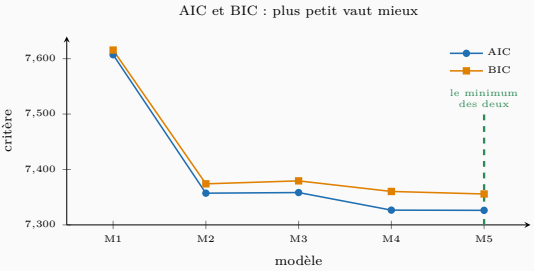
Trop de variables : perte de degrés de liberté, multicolinéarité, et un modèle qui décrit l'échantillon au lieu de la population.

Les deux erreurs ne se valent pas

Ajouter une variable inutile coûte de la **précision**. Omettre une variable pertinente coûte de la **justesse**.

En cas de doute, mieux vaut inclure. C'est le même arbitrage qu'au chapitre 13 : on ne troque pas un problème de variance contre un problème de biais.

Les critères d'information



Les cinq modèles

M1 ancienneté seule
M2 + diplôme
M3 + sexe
M4 + région
M5 = M4 *sans* le sexe

$\text{AIC} = n \ln\left(\frac{\text{SCR}}{n}\right) + 2p$

$\text{BIC} = n \ln\left(\frac{\text{SCR}}{n}\right) + p \ln n$

Les deux ajoutent une **pénalité** au manque d'ajustement. Le BIC pénalise plus lourdement : il choisit des modèles plus courts.

Ici les deux désignent M5, le modèle sans le sexe. La variable non significative est écartée par le critère, sans qu'on ait eu à trancher à la main.

La structure commune

$$\text{critère} = \underbrace{n \ln\left(\frac{\text{SCR}}{n}\right)}_{\text{mauvais ajustement}} + \underbrace{\text{pénalité} \times p}_{\text{complexité}}$$

p est le nombre de coefficients estimés, constante comprise. AIC pénalise de 2 par coefficient ; BIC de $\ln n$, soit $6{,}2$ ici. **Le BIC est donc plus sévère et choisit des modèles plus courts.**

Sur nos données, les deux s'accordent

Le minimum est atteint par **M5** — le modèle avec ancienneté, diplôme et région, **sans le sexe**.

La variable non significative est écartée par le critère, sans qu'on ait eu à trancher à la main. Les tests, les critères et le R^2 ajusté disent tous la même chose.

Un coefficient de moins

	SCR (millions)	$n \ln(\text{SCR}/n)$	p	AIC	BIC
M4	$1\,119{,}21$	$7\,310{,}64$	8	$7\,326{,}64$	$7\,360{,}36$
M5	$1\,122{,}89$	$7\,312{,}28$	7	$7\,326{,}28$	$7\,355{,}79$

Le sexe coûte plus qu'il ne rapporte

Ajouter le sexe fait baisser le premier terme de $1{,}64$ seulement. L'AIC le facture 2 : il préfère M5 de $0{,}36$. Le BIC le facture $6{,}21$: il préfère M5 de $4{,}57$. **Deux critères, une même réponse, une conviction différente.**

Seulement si n dépasse 7

Le BIC pénalise de $\ln n$, l'AIC de 2 : le BIC n'est plus sévère que si $\ln n > 2$, c'est-à-dire $n \geq 8$.

Sur les cinq ménages

Modèle	$n \ln(\text{SCR}/n)$	AIC	BIC
C sur R	$5 \ln 1{,}5 = 2{,}03$	$6{,}03$	$5{,}25$
C sur R et T	$5 \ln 1 = 0$	$6{,}00$	$4{,}83$

Avec $\ln 5 = 1{,}61 < 2$, c'est le BIC qui pénalise le moins. Les deux préfèrent de justesse le modèle avec la taille.

M4, puis M4 plus dix variables de hasard

Critère	M4	M4 $+10$ hasard	Choix
R^2 ajusté	$0{,}6637$	$0{,}6655$	le modèle **avec** le hasard
AIC	$7\,326{,}6$	$7\,333{,}6$	M4
BIC	$7\,360{,}4$	$7\,409{,}5$	M4, nettement

Trois sévérités

Le R^2 ajusté facture une variable au seuil $|t| > 1$: il s'est laissé prendre au chapitre 8. L'AIC exige à peu près $|t| > 1{,}4$, le BIC $|t| > 2{,}5$ sur 500 observations. **Plus le critère est sévère, moins il retient de bruit — et plus il risque d'écarter une variable faible mais réelle.**

Ce que les critères ne remplacent pas

Une variable théoriquement indispensable se garde

Si la théorie économique impose qu'une variable figure dans le modèle, elle y reste — même non significative, même si le critère préfère s'en passer.

Un modèle de demande sans le prix n'est pas un modèle de demande, quel que soit son AIC.

Et la sélection automatique est une mauvaise idée

Les procédures pas à pas — ajouter ou retirer selon les t — enchaînent des dizaines de tests et invalident tous les seuils, exactement comme la pêche aux résultats du chapitre 14 de l'inférence.

Le modèle final n'a alors plus de p-values interprétables, puisqu'il a été choisi *sur* les données qui servent à le tester.

Le seuil de la causalité

La question que tout le monde pose



Dans les deux cas, la variable explicative est corrélée au terme d'erreur : l'hypothèse H2 tombe, et le coefficient est biaisé.

C'est le mot d'**endogénéité**, et c'est le seuil où s'arrête ce cours. Les capacités non observées gonflent le rendement apparent du diplôme ; les ventes qui gonflent le budget publicitaire font surestimer l'effet de la publicité.

Aucun test ne le révèle, aucune correction d'écarts-types n'y remédie. La sortie du logiciel est parfaitement propre — et le coefficient reste faux.

Les réponses existent : variables instrumentales, doubles différences, discontinuité de régression, expériences contrôlées. Elles font l'objet de l'économétrie de niveau Master, et c'est le sujet qui a valu plusieurs prix Nobel depuis 2000. **Retenez seulement, de ce cours, que « significatif » ne veut jamais dire « causal ».**

Trois formulations, une seule correcte

Formulation	Statut
« Les Bac+5 gagnent $54{,}5\,\%$ de plus, à ancienneté comparable »	**correcte**
« Le Bac+5 est associé à $54{,}5\,\%$ de salaire en plus »	correcte
« Le Bac+5 **augmente** le salaire de $54{,}5\,\%$ »	**dépasse les données**

La troisième suppose ce qu'on n'a pas montré

Elle suppose que si l'on donnait un Bac+5 à un salarié pris au hasard, son salaire monterait de $54{,}5\,\%$.

Or les diplômés diffèrent des autres par bien d'autres choses — capacités, milieu, réseau, ambition — dont aucune n'est dans le fichier. **Une partie de l'écart leur revient.**

Endogénéité

La variable explicative est corrélée au terme d'erreur : $\mathrm{cov}(x, \varepsilon) \neq 0$.

L'hypothèse H2 tombe, et le coefficient est **biaisé**.

Ses trois sources

1. **Variable omise** — chapitre 16.
2. **Causalité inverse** — le budget publicitaire suit les ventes autant qu'il les précède.
3. **Erreur de mesure** sur la variable explicative.

Une simulation où l'on connaît la vérité

Des capacités que personne n'observe

On simule $5\,000$ salariés. La capacité c est tirée au hasard ; les études valent $12 + 2c$ plus un aléa ; le logarithme du salaire vaut $1 + 0{,}08 \times$ études $+ 0{,}10\,c$ plus un aléa.

Le vrai rendement d'une année d'études est $0{,}08$.

Ce que trouve la régression sans la capacité

$0{,}122$: une surestimation de moitié. La formule du chapitre 16 la prévoit : $\gamma = 0{,}10$, $\delta = \mathrm{cov}(\text{études}, c)/V(\text{études}) = 2/5 = 0{,}4$, d'où $0{,}08 + 0{,}10 \times 0{,}4 = 0{,}12$.

Avec la capacité dans le modèle : $0{,}082$ — Python, avec un autre tirage, trouve $0{,}119$ et $0{,}077$.

Mais dans un vrai fichier, la capacité n'est pas là.

L'atténuation

Si l'on observe $x^* = x + u$, avec u une erreur de mesure indépendante, la pente estimée tend vers

$$\beta_1 \times \frac{V(x)}{V(x) + V(u)}$$

un facteur **inférieur à un** : le coefficient est tiré vers zéro.

Sur une variable mal déclarée

Les revenus déclarés en enquête sont souvent arrondis, oubliés, sous-estimés. Si la variance de l'erreur de déclaration atteignait $20\,\%$ de celle du vrai revenu, la propension marginale estimée ne vaudrait plus que $1/1{,}2 = 83\,\%$ de la vraie. **L'erreur de mesure sur y ajoute du bruit ; sur x, elle biaise.**

Ce que le cours n'a pas résolu

Et ne pouvait pas résoudre

Aucun test ne détecte l'endogénéité. Aucune correction d'écarts-types n'y remédie. La sortie du logiciel reste parfaitement propre, et le coefficient reste faux.

C'est la limite de tout ce qui précède, et il vaut mieux la connaître que la découvrir dans un rapport publié.

Les réponses existent, et elles sont récentes

Variables instrumentales, doubles différences, discontinuité de régression, expériences contrôlées : ce sont les méthodes de l'**inférence causale**.

Elles font l'objet de l'économétrie de Master, et plusieurs prix Nobel d'économie leur ont été décernés depuis 2000. Toutes reposent sur une idée simple : **trouver, dans les données, quelque chose qui ressemble à une expérience.**

La conclusion du cours

Trois phrases, et elles suffisent

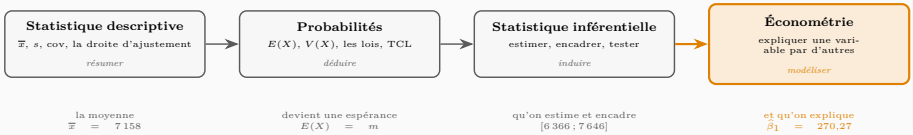
1. « Voici ce que j'ai mesuré, et avec quelle précision. »
2. « Voici les hypothèses sous lesquelles cette mesure est valide. »
3. « Voici ce que je ne peux pas conclure. »

La troisième est celle qui distingue le professionnel

Tout le monde sait produire une régression. Peu savent en énoncer les limites — et ce sont les seuls dont le travail résiste à l'examen.

« Significatif » ne veut jamais dire « causal ». Si vous ne deviez retenir qu'une phrase de ce cours, ce serait celle-là.

Ce que quatre cours ont construit



Un seul jeu de données a traversé les quatre cours : les mêmes cinq cents salariés.

La statistique descriptive en a tiré une moyenne, un écart-type et une droite d'ajustement. Les probabilités ont transformé la fréquence en probabilité et la moyenne en espérance. L'inférence a fait de ces cinq cents individus une population dont on tire des échantillons, pour estimer, encadrer et tester. L'économétrie, enfin, a posé qu'il existe une *relation vraie* entre le salaire, l'ancienneté, le diplôme et la région — et l'a mesurée.

Aucun de ces quatre cours n'a introduit d'outil que les précédents n'annonçaient pas. La covariance de la descriptive est devenue la pente ; le théorème central limite des probabilités a rendu les tests possibles ; l'erreur-type de l'inférence est devenue celle d'un coefficient. **C'est une seule discipline, enseignée en quatre fois.**

Sur machine

```r
sal <- read.csv("salaires.csv", stringsAsFactors = TRUE)
m4 <- lm(salaire ~ anciennete + diplome + sexe + region, sal)
m5 <- update(m4, . ~ . - sexe)
c(AIC(m4), AIC(m5))          # à une constante près du cours
# [1] 8747.578 8747.222
c(BIC(m4), BIC(m5))
# [1] 8785.510 8780.939
AIC(m4) - AIC(m5)            # l'écart, lui, est le même : 0,36
# [1] 0.3561047
```

Une constante qui ne change rien

R calcule l'AIC à partir de la vraisemblance, avec une constante en plus de la formule du cours : $8\,747{,}6$ au lieu de $7\,326{,}6$. **Seules les différences comptent**, et elles sont identiques : $0{,}36$.

La capacité omise, simulée avec R

```r
set.seed(20261022)
n <- 5000
capacite <- rnorm(n)                              # non observée
etudes <- 12 + 2 * capacite + rnorm(n)            # liée à la capacité
lsal <- 1 + 0.08 * etudes + 0.10 * capacite + rnorm(n, 0, 0.3)
round(coef(lm(lsal ~ etudes))[2], 4)                  # capacité omise
# etudes
# 0.1222
round(coef(lm(lsal ~ etudes + capacite))[2], 4)  # vrai effet 0,08
# etudes
# 0.0821
```

La capacité omise, simulée avec Python

```
import numpy as np
import statsmodels.api as sm
rng = np.random.default_rng(20261022)
n = 5000
capacite = rng.normal(size=n)                    # non observée
etudes = 12 + 2 * capacite + rng.normal(size=n)
lsal = 1 + 0.08 * etudes + 0.10 * capacite + rng.normal(0, 0.3, n)
X1 = sm.add_constant(etudes)
X2 = sm.add_constant(np.column_stack([etudes, capacite]))
print(sm.OLS(lsal, X1).fit().params[1].round(4))   # biaisé
# 0.1193
print(sm.OLS(lsal, X2).fit().params[1].round(4))   # 0,08
# 0.0766
```

S’entraîner

Deux modèles qui divisent les critères

Sur $n = 100$ observations : modèle A, $p = 3$ coefficients, SCR $= 500$; modèle B, $p = 5$, SCR $= 460$ ($\ln 5 = 1{,}609$; $\ln 4{,}6 = 1{,}526$; $\ln 100 = 4{,}605$).

1. Calculer l'AIC et le BIC des deux modèles.
2. Que choisit chaque critère ?
3. Comment trancher ?

Exercice 1 : solution

L'AIC prend B, le BIC prend A

1. A : $160{,}9 + 6 = 166{,}9$ et $160{,}9 + 13{,}8 = 174{,}8$. B : $152{,}6 + 10 = 162{,}6$ et $152{,}6 + 23{,}0 = 175{,}6$.
2. L'AIC préfère **B**, le BIC préfère **A** : les deux variables de B apportent assez pour l'AIC, pas assez pour le BIC.
3. Par la **théorie** : si les deux variables de B ont une raison économique d'être là, on les garde. Les critères départagent des modèles également justifiés, ils ne remplacent pas la justification.

Exercice 2 : associé ou causal

Quatre phrases de rapport

Lesquelles dépassent ce qu'une régression sur coupe instantanée permet d'affirmer ?

1. « Les ménages urbains consomment 99 dirhams de moins, à revenu et taille égaux. »
2. « Habiter en ville réduit la consommation de 99 dirhams. »
3. « Un dirham de revenu supplémentaire est associé à $0{,}70$ dirham de consommation. »
4. « Augmenter les salaires de $10\,\%$ augmentera la consommation de $7\,\%$. »

Exercice 2 : solution

Deux phrases de trop

1. **Correcte** : une association conditionnelle — et d'ailleurs non significative une fois les grappes corrigées, chapitre 15.
2. **Dépasse** : elle affirme qu'un ménage qui déménagerait changerait sa consommation.
3. **Correcte**.
4. **Dépasse** : c'est une prévision causale, et de surcroît une politique — la critique de Lucas du chapitre 6 s'applique.

Exercice 3 : d'où vient l'endogénéité

Trois régressions suspectes

Pour chacune, identifier la source d'endogénéité et le sens probable du biais.

1. Taux de criminalité des villes expliqué par le nombre de policiers.
2. Productivité des salariés expliquée par le suivi d'une formation volontaire.
3. Consommation expliquée par un revenu déclaré, souvent arrondi et mal mémorisé.

Exercice 3 : solution

Trois sources, trois biais

1. **Causalité inverse** : on envoie plus de policiers là où la criminalité est forte. L'effet de la police paraît **moins négatif**, voire positif.
2. **Variable omise** : les plus motivés suivent la formation et sont aussi plus productifs. L'effet de la formation est **surestimé**.
3. **Erreur de mesure** sur l'explicative : la propension marginale est **atténuée**, tirée vers zéro.

Ce qu’il faut retenir

Le résumé du chapitre

Six points

1. Trop peu de variables biaise ; trop de variables imprécise. **En cas de doute, inclure.**
2. **AIC et BIC** ajoutent une pénalité de complexité : 2 et $\ln n$ par coefficient.
3. Sur nos données, les deux choisissent **M5** ; face à dix variables de hasard, ils refusent ce que le R^2 ajusté acceptait.
4. Une variable **théoriquement indispensable** se garde ; la **sélection automatique** invalide les p-values.
5. **Endogénéité** : variable omise, causalité inverse, erreur de mesure — simulée, la capacité omise gonfle le rendement de moitié.
6. **« Significatif » ne veut jamais dire « causal ».**

La suite

Tout le cours a été conduit pièce par pièce. Le chapitre 20 enchaîne les pièces sur deux études complètes ; le chapitre 21 refait l'ensemble en R et en Python.