Introduction à l'économétrie

Chapitre 8 : Estimation et R carré ajusté

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 23 octobre 2026

Plan du chapitre

Le défaut du R carré

À la main, sur les cinq ménages

Sur nos données

Sur machine

S'entraîner

Ce qu'il faut retenir

Le défaut du R carré

Le R^2 ne peut jamais baisser

Ajouter une variable explicative ne peut pas augmenter la somme des carrés résiduels.

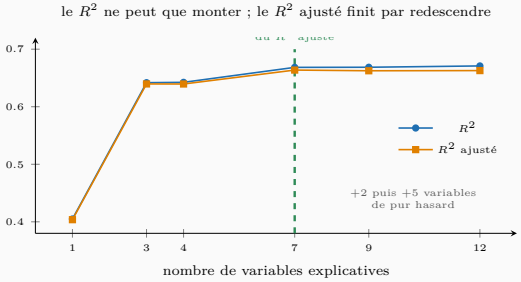
Au pire, son coefficient estimé sort nul et le modèle est inchangé. Le R^2 est donc **croissant par construction** avec le nombre de variables.

La conséquence est radicale

Choisir le modèle de plus grand R^2 revient à choisir **le modèle le plus long**, toujours.

En ajoutant assez de variables sans rapport, on atteint $R^2 = 1 -$ et l'on n'a rien expliqué du tout. Le R^2 est donc inutilisable pour comparer des modèles de tailles différentes.

La correction



Pourquoi le R^2 monte toujours

Ajouter une variable ne peut pas augmenter la somme des carrés résiduels : au pire, son coefficient sort nul. Le R^2 est donc **croissant par construction** — et par conséquent inutilisable pour choisir un modèle.

La correction

$$\overline{R}^2 = 1 - (1 - R^2)\frac{n-1}{n-k-1}$$

Elle facture chaque variable ajoutée. Les variables de hasard, tirées d'une loi normale, font monter le R^2 de 0,6684 à 0,6709 ; le R^2 ajusté, lui, baisse.

Le R^2 ajusté peut être négatif. Ce n'est pas une erreur de calcul : cela signale un modèle qui prédit moins bien que la simple moyenne.

Le R^2 ajusté

$$\overline{R}^2 = 1 - (1 - R^2)\,\frac{n-1}{n-k-1}$$

Chaque variable ajoutée réduit $n-k-1$, donc gonfle le second facteur : elle est **facturée**.

Ce que la facture signifie

Une variable n'améliore le R^2 ajusté que si elle apporte **plus qu'elle ne coûte en degré de liberté**.

On peut montrer que cela équivaut à ce que son $|t|$ dépasse 1 — un seuil bien plus permissif que $1{,}96$. Le R^2 ajusté est donc un critère **indulgent**, et le chapitre 19 en présentera de plus sévères.

Deux variances corrigées

Comme $1 - R^2 = \text{SCR}/\text{SCT}$:

$$\overline{R}^2 = 1 - \frac{\text{SCR}/(n-k-1)}{\text{SCT}/(n-1)} = 1 - \frac{\hat{\sigma}_\varepsilon^2}{s_y^2}$$

Maximiser l'un, c'est minimiser l'autre

s_y^2 ne dépend pas du modèle. **Le modèle de plus grand R^2 ajusté est celui de plus petit $\hat{\sigma}_\varepsilon$.**

Sur M4 : $s_y = 2\,600{,}70$ et $\hat{\sigma}_\varepsilon = 1\,508{,}25$, d'où
$1 - (1\,508{,}25/2\,600{,}70)^2 = 1 - 0{,}3363 = 0{,}6637$.

Ce qui distingue les deux

	R^2	R^2 ajusté
Ajout d'une variable	monte toujours	monte ou baisse
Valeurs possibles	$[0\,;1]$	peut être **négatif**
Usage	décrire l'ajustement	comparer des modèles

Un R^2 ajusté négatif n'est pas une erreur de calcul

Il signale un modèle qui prédit **moins bien que la simple moyenne** de y.

Cela arrive avec beaucoup de variables sur peu d'observations. Le message est clair : il faut retirer des variables, ou en collecter davantage.

À la main, sur les cinq ménages

Deux modèles, cinq ménages

	C sur R	C sur R et T
SCR	$7{,}5$	5
$R^2 = 1 - \text{SCR}/30$	$0{,}750$	$0{,}833$
$n - k - 1$	3	2
$\hat{\sigma}^2_\varepsilon$	$7{,}5/3 = 2{,}5$	$5/2 = 2{,}5$
$\overline{R}^2$	$1 - 0{,}25 \times \frac{4}{3} = 0{,}667$	$1 - \frac{1}{6} \times \frac{4}{2} = 0{,}667$

Le R^2 gagne huit points, le R^2 ajusté aucun

La taille fait baisser la somme des carrés résiduels de $7{,}5$ à 5, mais elle coûte un degré de liberté sur trois. **Les deux effets se compensent exactement** : même $\hat{\sigma}^2_\varepsilon$, même R^2 ajusté.

Le seuil, vérifié

Dans le modèle à deux variables, l'erreur-type de la taille vaut $0{,}5$ et son coefficient $0{,}5$: $t = 1$ **exactement**.

Or le R^2 ajusté monte si $|t| > 1$, baisse si $|t| < 1$, et ne bouge pas si $|t| = 1$.

La règle, en une phrase

Ajouter une variable fait passer $\hat{\sigma}^2_\varepsilon$ de $\text{SCR}_0/(n-k-1)$ à $\text{SCR}_1/(n-k-2)$. On montre que la seconde est plus petite si et seulement si $(\text{SCR}_0 - \text{SCR}_1)/\hat{\sigma}^2_1 > 1$ — c'est-à-dire $t^2 > 1$. Le chapitre 9 appellera ce rapport un **Fisher partiel**.

Sur nos données

Ce que chaque ajout apporte

Modèle	k	R^2	R^2 ajusté
M1 ancienneté	1	$0{,}405$	$0{,}404$
M2 + diplôme	3	$0{,}642$	$0{,}640$
M3 + sexe	4	$0{,}642$	$0{,}640$
M4 + région	7	$0{,}668$	$0{,}664$

Le sexe, au quatrième chiffre

M3 a un R^2 ajusté de $0{,}6395$ contre $0{,}6396$ pour M2 : il **baisse**. La règle le prévoyait, puisque le t du sexe vaut $0{,}93 < 1$.

La lecture, ligne par ligne

Le **diplôme** est décisif : le R^2 passe de $0{,}405$ à $0{,}642$. Il expliquait à lui seul un quart de la dispersion, comme l'ANOVA du chapitre 17 de l'inférence l'avait établi.

Le **sexe** n'apporte rien : R^2 inchangé, R^2 ajusté qui baisse au quatrième chiffre. La variable coûte plus qu'elle ne rapporte.

La **région** apporte encore deux points et demi. Le marché du travail marocain n'est pas homogène géographiquement.

La lecture concrète du progrès

Modèle	$\hat{\sigma}_\varepsilon$
M1	$2\,008$ dh
M2	$1\,561$ dh
M4	$1\,508$ dh

Elle dit la même chose, en dirhams

Le modèle complet se trompe typiquement de mille cinq cents dirhams sur un salaire individuel, contre deux mille pour le modèle initial.

C’est un progrès réel, et il reste modeste. Un tiers de la dispersion des salaires tient à des facteurs absents du fichier : poste, performance, négociation. Aucune régression ne fera mieux avec ces six colonnes.

M4, puis M4 plus des variables tirées au hasard

Modèle	k	R^2	R^2 ajusté
M4	7	0,6684	0,6637
M4 $+2$ variables de hasard	9	0,6686	0,6625
M4 $+5$ variables de hasard	12	0,6709	0,6628

Le R^2 ajusté résiste, sans être infaillible

Le R^2 monte avec du bruit, le R^2 ajusté baisse : c'est le cas de la figure. Mais avec **dix** variables de hasard, cinq ont par chance un $|t|$ supérieur à 1, et le R^2 ajusté remonte à $0{,}6655$ — au-dessus de M4. Le seuil $|t| > 1$ est trop indulgent ; le chapitre 19 proposera plus sévère.

Sur machine

```r
sal <- read.csv("salaires.csv", stringsAsFactors = TRUE)
m1 <- lm(salaire ~ anciennete, data = sal)
m2 <- update(m1, . ~ . + diplome)     # on ajoute une variable
m3 <- update(m2, . ~ . + sexe)
m4 <- update(m3, . ~ . + region)
r <- sapply(list(M1 = m1, M2 = m2, M3 = m3, M4 = m4), function(m)
  c(R2 = summary(m)$r.squared, R2aj = summary(m)$adj.r.squared))
round(t(r), 4)
#        R2   R2aj
# M1 0.4049 0.4037
# M2 0.6418 0.6396
# M3 0.6424 0.6395
# M4 0.6684 0.6637
```

```
import pandas as pd
import statsmodels.formula.api as smf
cinq = pd.DataFrame({"R": [2, 4, 6, 8, 10], "C": [3, 6, 4, 7, 10],
                     "T": [1, 5, 4, 3, 7]})
for f in ("C ~ R", "C ~ R + T"):
    m = smf.ols(f, data=cinq).fit()
    print(f, round(m.rsquared, 4), round(m.rsquared_adj, 4))
# C ~ R 0.75 0.6667
# C ~ R + T 0.8333 0.6667
m = smf.ols("C ~ R + T", data=cinq).fit()
print(m.tvalues.round(4).tolist())      # t de la taille : 1
# [0.5774, 1.4142, 1.0]
```

S’entraîner

Exercice 1 : deux modèles à comparer

Plus long ou plus court

Sur $n = 30$ entreprises, on estime deux modèles du chiffre d'affaires.

- Modèle A : $k = 3$ variables, $R^2 = 0{,}40$.
- Modèle B : $k = 10$ variables, $R^2 = 0{,}50$.

1. Calculer le R^2 ajusté de chacun.
2. Lequel retenir selon ce critère ?
3. Que penser du gain de R^2 de B ?

Exercice 1 : solution

Le modèle court l'emporte

1. A : $1 - 0{,}60 \times 29/26 = 0{,}331$. B : $1 - 0{,}50 \times 29/19 = 0{,}237$.
2. Le modèle **A**, malgré son R^2 plus faible.
3. Dix points de R^2 pour sept variables de plus, sur trente observations : c'est à peine ce que donnerait du bruit. Les sept variables ajoutées coûtent plus qu'elles ne rapportent.

Exercice 2 : un R² ajusté négatif

Douze observations, cinq variables

Un étudiant explique la croissance de 12 pays par 5 variables et obtient $R^2 = 0{,}30$.

1. Calculer le R^2 ajusté.
2. Comment l'interpréter ?
3. Que lui conseiller ?

Moins bien que la moyenne

1. $1 - 0{,}70 \times 11/6 = 1 - 1{,}283 = -0{,}283$.
2. Une fois les degrés de liberté facturés, le modèle prévoit **moins bien que la simple moyenne** des taux de croissance : $\hat{\sigma}_{\varepsilon}$ dépasse l'écart-type de y.
3. Réduire le nombre de variables à celles que la théorie impose, ou réunir davantage de pays. Six degrés de liberté ne permettent pas d'estimer six paramètres sérieusement.

Prévoir sans recalculer

On ajoute successivement à un modèle trois variables, de t respectifs $0{,}8$, $1{,}5$ et $-2{,}3$ une fois incluses.

1. Pour chacune, le R^2 ajusté monte-t-il ou baisse-t-il ?
2. Laquelle serait aussi retenue par un test à $5\,\%$?
3. Dans M3, le sexe a $t = 0{,}93$: que fallait-il attendre du R^2 ajusté ?

Le signe ne compte pas, la valeur absolue si

1. $0{,}8$: il **baisse**. $1{,}5$ et $-2{,}3$: il **monte**, car $|t| > 1$.
2. Seule la troisième dépasse $1{,}96$ en valeur absolue. La deuxième améliore le R^2 ajusté sans être significative : c'est l'indulgence du critère.
3. Une baisse, puisque $0{,}93 < 1$: $0{,}6396 \to 0{,}6395$. C'est exactement ce que donne le tableau.

Ce qu’il faut retenir

Le résumé du chapitre

Six points

1. Le R^2 **monte toujours** quand on ajoute une variable : il ne peut pas servir à choisir.
2. $\overline{R}^2 = 1 - (1 - R^2)\dfrac{n-1}{n-k-1} = 1 - \hat{\sigma}_\varepsilon^2 / s_y^2$: chaque variable est **facturée**.
3. Une variable améliore le R^2 ajusté dès que son $|t|$ dépasse 1 — critère indulgent.
4. Cinq ménages : la taille, de $t = 1$ exactement, laisse le R^2 ajusté à $0{,}667$.
5. Salaires : le diplôme est décisif, le sexe n'apporte rien, la région compte un peu.
6. Le R^2 ajusté peut être **négatif** : le modèle fait alors moins bien que la moyenne.

La suite

Avec plusieurs variables, une question nouvelle se pose : tester chaque coefficient séparément suffit-il ? Le chapitre 9 montre que non — et que trois tests différents cohabitent.