Introduction à l'économétrie

Chapitre 18 : Les formes fonctionnelles

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 23 octobre 2026

Plan du chapitre

Sortir de la droite

Le semi-logarithmique

Choisir une forme

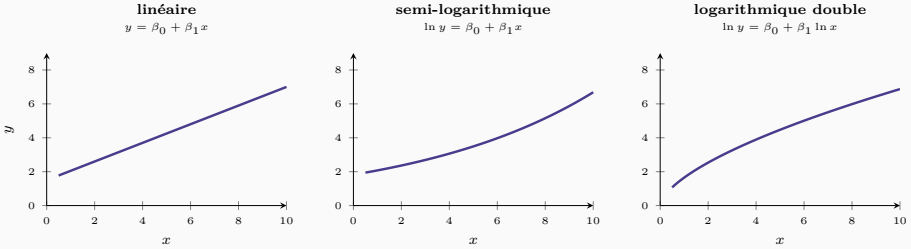
Sur machine

S'entraîner

Ce qu'il faut retenir

Sortir de la droite

Les trois formes usuelles



Les trois modèles restent linéaires *en les paramètres* : les moindres carrés s'appliquent sans changement.

On ne transforme pas la méthode, on transforme les *variables*. C'est pourquoi l'hypothèse H1 est bien moins restrictive qu'elle n'en a l'air.

Le choix se justifie économiquement, pas graphiquement. Le semi-logarithmique s'impose dès qu'un effet est naturellement *proportionnel* — un salaire augmente en pourcentage, pas en dirhams. Le double logarithme donne directement une **élasticité**, la grandeur que l'économiste manipule le plus souvent.

Attention : deux modèles dont la variable expliquée diffère — y et $\ln y$ — ont des R^2 **non comparables**.

Comment se lit chaque coefficient

Le tableau à connaître

Modèle	Écriture	Lecture de β_1
Linéaire	$y = \beta_0 + \beta_1 x$	$x + 1 : y + \beta_1$
Semi-log	$\ln y = \beta_0 + \beta_1 x$	$x + 1 : y + 100\beta_1\ \%$
Log-log	$\ln y = \beta_0 + \beta_1 \ln x$	$x + 1\,\% : y + \beta_1\ \%$
Linéaire-log	$y = \beta_0 + \beta_1 \ln x$	$x + 1\,\% : y + \beta_1/100$

Le troisième cas porte un nom

β_1 y est une **élasticité** : la variation relative de y pour une variation relative de x.

C'est la grandeur que l'économiste manipule le plus — élasticité-prix de la demande, élasticité-revenu, élasticité de substitution. **Le double logarithme la donne directement, sans calcul.**

Une dérivée suffit

Si $\ln y = \beta_0 + \beta_1 x$, alors $\dfrac{dy}{y} = \beta_1\, dx$: une unité de x en plus fait varier y de β_1 **en proportion**, soit $100\beta_1\ \%$.

Si $\ln y = \beta_0 + \beta_1 \ln x$, alors $\dfrac{dy}{y} = \beta_1 \dfrac{dx}{x}$: c'est la définition de l'élasticité.

L'élasticité de la consommation au revenu

Sur les 400 ménages, le modèle log-log donne $\widehat{\beta}_1 = 0{,}703$ (écart-type $0{,}019$) : $1\ \%$ **de revenu en plus est associé à** $0{,}70\ \%$ **de consommation en plus**.

Le modèle linéaire donnait une élasticité variable, $\beta_1 R/C$: au point moyen, $0{,}696 \times 2\,921{,}7/2\,779{,}4 = 0{,}732$.

Le semi-logarithmique

Pourquoi il s'impose sur les salaires

Trois raisons, et elles convergent

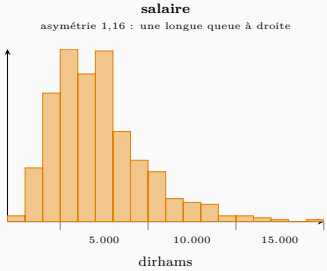
1. **Économique** : une augmentation se pense en pourcentage, pas en dirhams. Deux cents dirhams ne signifient pas la même chose sur trois mille et sur quinze mille.
2. **Statistique** : la distribution des salaires est étirée à droite ; celle des logarithmes est presque symétrique.
3. **Technique** : le logarithme réduit fortement l'hétéroscédasticité du chapitre 14.

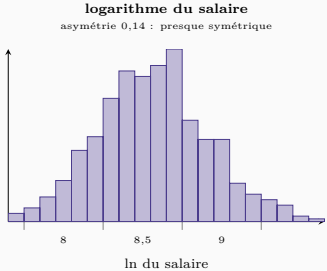
Un même geste règle trois problèmes

Ce n'est pas une coïncidence. Les trois symptômes — asymétrie, hétéroscédasticité, effets proportionnels — sont **trois manifestations du même fait** : la grandeur étudiée est multiplicative, non additive.

Le logarithme transforme les produits en sommes. Il rend additif ce qui l'était par nature.

La distribution, avant et après





Trois diagnostics, avant et après

Diagnostic	Salaire	Logarithme
Asymétrie de la variable	$1{,}16$	$0{,}14$
Breusch-Pagan	$71{,}9$	$8{,}25\ (p = 0{,}22)$
Jarque-Bera des résidus	rejet	$3{,}10\ (p = 0{,}21)$

L'équation de Mincer

variable expliquée : le **logarithme** du salaire

	Coefficient	**Statistique** t	**Lecture**
Constante	8,2158	280,2	le niveau de référence
Ancienneté	0,0345	22,33	+3,5 % **par année**
Bac+2	0,1786	8,59	+19,6 % contre le Bac
Bac+5	0,4353	17,96	+54,5 % **contre le Bac**
Casablanca	0,1655	5,75	+18,0 %
Rabat	0,1379	4,52	+14,8 %
Tanger-Tétouan	0,0592	2,15	+6,1 %
$n = 500$ $R^2 = 0{,}654$ $\widehat{\sigma}_\varepsilon = 0{,}20$			

L'équation de gains de Mincer

Publiée en 1974, c'est l'un des modèles les plus estimés de toute l'économie appliquée. Sa forme est exactement celle-ci : le *logarithme* du salaire expliqué par la formation et l'expérience.

Pourquoi le logarithme

Parce qu'un coefficient devient un **pourcentage**, directement comparable d'un pays et d'une époque à l'autre. Le rendement d'une année de formation se situe partout entre 5 et 10 % : c'est un ordre de grandeur universel, et il ne le serait pas en dirhams.

Une approximation, et sa correction

100β approche l'effet en pourcentage. Au-delà de 0,2, il faut la formule exacte $100(\mathrm{e}^{\beta} - 1)$: 0,4353 donne 54,5 % et non 43,5.

Deux formules

effet en pourcentage $\approx 100\,\beta$ exactement $= 100\,(\mathrm{e}^{\beta} - 1)$

Où l’approximation cesse d’être acceptable

β	100β	Valeur exacte
$0{,}0345$	$3{,}45\,\%$	$3{,}51\,\%$
$0{,}1786$	$17{,}86\,\%$	$19{,}56\,\%$
$0{,}4353$	$43{,}53\,\%$	$54{,}54\,\%$

Un écart de logarithmes est un rapport

Pour un Bac+5 et un Bac de même ancienneté et région, $\ln S_5 - \ln S_0 = \beta$, donc

$$\frac{S_5}{S_0} = \mathrm{e}^{\beta} = \mathrm{e}^{0{,}4353} = 1{,}5454$$

Le Bac+5 gagne $1{,}545$ fois le salaire du Bac : $54{,}5\,\%$ de plus.

La règle pratique

En dessous de $0{,}1$, l'approximation suffit. Au-delà de $0{,}2$, elle devient franchement fausse : onze points d'écart sur le Bac+5.

C'est une erreur d'interprétation très fréquente, et pour un β positif elle sous-estime toujours l'effet réel.

Choisir une forme

Sur quoi se décide le choix

Trois critères, dans cet ordre

1. La **théorie économique** : la relation est-elle proportionnelle, additive, à rendements décroissants ?
2. L'**interprétation voulue** : cherche-t-on une élasticité ou un effet en unités ?
3. Le **comportement des résidus** : la forme retenue les rend-elle homogènes ?

Le R^2 n'est pas dans la liste, et c'est délibéré

Deux modèles dont la variable expliquée diffère — y et $\ln y$ — ont des R^2 **non comparables** : ils ne portent pas sur la même variance.

Le modèle en niveau donne $R^2 = 0{,}667$, celui en logarithme $0{,}654$: cela ne dit **rien** de leur mérite respectif. **Cette comparaison est l'erreur la plus courante du chapitre.**

Le terme quadratique

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \varepsilon$$

Toujours linéaire en les paramètres : les MCO s'appliquent sans changement.

Ce qu'il capte, et pourquoi c'est utile ici

Un β_2 négatif décrit un effet à **rendements décroissants** — et l'expérience professionnelle en est le cas typique : les premières années rapportent beaucoup, les dernières peu.

L'équation de Mincer originale contient d'ailleurs l'expérience **et** son carré, précisément pour cela. Le maximum se situe en $-\beta_1/(2\beta_2)$.

Mincer avec l'ancienneté au carré

$$\widehat{\ln S} = \cdots + 0{,}0445\, A - 0{,}000361\, A^2 \qquad t_{A^2} = -2{,}26$$

Rendement marginal d'une année : $0{,}0445 - 2 \times 0{,}000361\, A$, soit $4{,}4\,\%$ à l'embauche et $2{,}3\,\%$ après trente ans.

Un maximum hors des données

Le salaire culminerait en $A = 0{,}0445/(2 \times 0{,}000361) = 61{,}7$ ans d'ancienneté : bien au-delà des 35 ans observés. Les rendements **décroissent**, sans jamais devenir négatifs dans le domaine des données. Le maximum calculé est une extrapolation, pas un résultat.

Deux mises en garde

Le logarithme et le zéro

$\ln 0$ n'existe pas. Sur des variables qui s'annulent — dépenses de publicité, exportations, heures supplémentaires — le passage au logarithme **supprime silencieusement des observations**.

Vérifiez toujours le nombre d'observations retenu par le logiciel après transformation.

La tentation de la forme flexible

On peut toujours améliorer l'ajustement en ajoutant des carrés, des cubes, des interactions.

On obtient alors un modèle qui décrit parfaitement l'échantillon et ne prédit rien. C'est le surajustement, et c'est le sujet du chapitre suivant.

Sur machine

```r
sal <- read.csv("salaires.csv", stringsAsFactors = TRUE)
mincer <- lm(log(salaire) ~ anciennete + diplome + region, sal)
b <- coef(mincer)[c("anciennete", "diplomeBac+2", "diplomeBac+5")]
cbind(beta = round(b, 4), approx = round(100 * b, 2),
      exact = round(100 * (exp(b) - 1), 2))
#                beta approx exact
# anciennete   0.0345   3.45  3.51
# diplomeBac+2 0.1786  17.86 19.56
# diplomeBac+5 0.4353  43.53 54.54
mq <- update(mincer, . ~ . + I(anciennete^2))   # le carré
round(coef(mq)[c("anciennete", "I(anciennete^2)")], 6)
#      anciennete I(anciennete^2)
#        0.044497       -0.000361
```

```
import numpy as np, pandas as pd
import statsmodels.formula.api as smf
men = pd.read_csv("menages.csv")
f = "np.log(consommation) ~ np.log(revenu)"
ll = smf.ols(f, data=men).fit()          # log-log
print(ll.params.round(4).tolist(), ll.bse.round(4).tolist())
# [2.33, 0.7031] [0.1476, 0.0188]
lin = smf.ols("consommation ~ revenu", data=men).fit()
b = lin.params["revenu"]                 # au point moyen
print(round(b * men.revenu.mean() / men.consommation.mean(), 4))
# 0.7316
```

Ce que disent les deux sorties

Le logarithme dans la formule

`log(salaire)` en R, `np.log(consommation)` en Python s'écrivent directement dans la formule : pas besoin de créer une colonne. `I(anciennete^2)` protège le carré, que la syntaxe des formules interpréterait autrement.

Deux élasticités voisines

Constante dans le modèle log-log, $0{,}703$; variable dans le modèle linéaire, $0{,}732$ au point moyen. Les deux disent la même chose : la consommation croît **moins vite** que le revenu, en proportion — la loi de Keynes, écrite en pourcentages.

S’entraîner

Un coefficient de 0,6

Interpréter $\hat{\beta}_1 = 0{,}6$ dans chacun des modèles suivants, avec Q la quantité vendue (en tonnes), P le prix (en dirhams) et D les dépenses de publicité (en milliers).

1. $Q = \beta_0 + \beta_1 D$
2. $\ln Q = \beta_0 + \beta_1 D$
3. $\ln Q = \beta_0 + \beta_1 \ln D$
4. $Q = \beta_0 + \beta_1 \ln D$

Exercice 1 : solution

Quatre lectures du même nombre

1. Mille dirhams de publicité en plus : $0{,}6$ tonne vendue en plus.
2. Mille dirhams en plus : environ $60\,\%$ de ventes en plus — exactement $100(\mathrm{e}^{0{,}6} - 1) = 82\,\%$.
3. $1\,\%$ de publicité en plus : $0{,}6\,\%$ de ventes en plus. C'est une **élasticité**.
4. $1\,\%$ de publicité en plus : $0{,}006$ tonne en plus.

Trois coefficients semi-log

Dans une équation de salaire en logarithme, on lit $\beta = 0{,}05$; $0{,}25$; $-0{,}30$.

1. Donner l'effet approché et l'effet exact de chacun.
2. Dans quel cas l'approximation est-elle acceptable ?
3. Pour un β négatif, l'approximation surestime-t-elle ou sous-estime-t-elle la baisse ?

L'erreur grandit avec le coefficient

1. $0{,}05$: $5\,\%$ contre $5{,}13\,\%$. $0{,}25$: $25\,\%$ contre $28{,}40\,\%$. $-0{,}30$: $-30\,\%$ contre $-25{,}92\,\%$.
2. Pour $0{,}05$: l'écart est d'un dixième de point.
3. Elle **surestime** la baisse : $-30\,\%$ au lieu de $-25{,}9\,\%$. Pour un coefficient positif, elle sous-estime la hausse. Dans les deux cas, l'exponentielle corrige.

Une courbe de salaire

On a estimé $\widehat{S} = 2\,000 + 300\,A - 5\,A^2$, en dirhams.

1. Quel est l'effet d'une année supplémentaire pour un salarié de 10 ans d'ancienneté ? de 25 ans ?
2. À quelle ancienneté le salaire ajusté est-il maximal ?
3. Si les données vont de 0 à 20 ans, que penser de ce maximum ?

Rendement décroissant, maximum à 30 ans

1. Rendement marginal $300 - 10\,A$: 200 dirhams à 10 ans, 50 à 25 ans.
2. $A = 300/(2 \times 5) = 30$ ans, pour $\widehat{S} = 2\,000 + 9\,000 - 4\,500 = 6\,500$ dirhams.
3. C'est une **extrapolation** : les données ne disent rien au-delà de 20 ans. On peut affirmer que le rendement décroît, pas que le salaire baisse après 30 ans.

Ce qu’il faut retenir

Le résumé du chapitre

Six points

1. Transformer les **variables** ne quitte pas les MCO : le modèle reste linéaire en les paramètres.
2. Semi-log : 100β est un **pourcentage**. Log-log : β est une **élasticité** $-0{,}703$ pour la consommation.
3. Sur les salaires, le logarithme règle trois problèmes d'un coup : asymétrie, hétéroscédasticité, non-normalité.
4. **Mincer** : $+3{,}5\,\%$ par année d'ancienneté, $+54{,}5\,\%$ pour un Bac+5 ; 100β n'est qu'une approximation.
5. Le terme quadratique décrit des **rendements décroissants** : $4{,}4\,\%$ puis $2{,}3\,\%$ par an.
6. Deux R^2 ne se comparent **jamais** si la variable expliquée diffère.

La suite

Une dernière question demeure : **quel modèle retenir**, et jusqu'où peut-on interpréter ses coefficients ? Le chapitre 19 clôt le cours sur le mot que tout le monde attend : la causalité.