Introduction à l'économétrie

Chapitre 6 : La prévision

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 23 octobre 2026

Plan du chapitre

Deux questions, pas une

Les deux intervalles

À la main, sur les cinq ménages

Les pièges de la prévision

Sur machine

S'entraîner

Ce qu'il faut retenir

Deux questions, pas une

Elle est immédiate

$$\hat{y}_h = \hat{\beta}_0 + \hat{\beta}_1 x_h$$

On remplace x par la valeur voulue dans la droite estimée.

Sur nos salaires

Pour dix ans d'ancienneté :

$$\hat{y} = 4\,347{,}23 + 277{,}17 \times 10 = 7\,118{,}93 \text{ dirhams}$$

Deux questions se cachent derrière ce nombre

« Quel est le salaire moyen des salariés ayant dix ans d'ancienneté ? »

« Quel sera le salaire de Karim, qui a dix ans d'ancienneté ? »

La réponse ponctuelle est la même : $7\,119$. La **précision** ne l'est pas du tout.

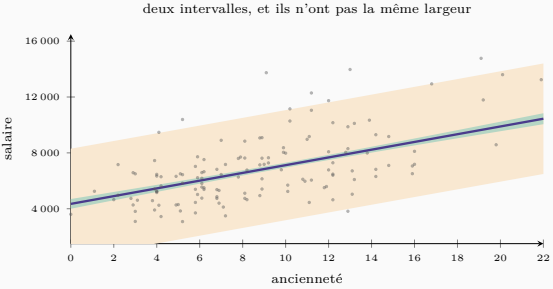
Pourquoi la seconde est plus incertaine

Prévoir une moyenne, c'est ignorer seulement où passe la vraie droite.

Prévoir un individu, c'est ignorer cela **et** son écart personnel à la droite — son ε, que rien ne permet d'anticiper.

Les deux intervalles

La figure décide



Deux questions différentes

La bande étroite encadre le *salaire moyen* des salariés ayant cette ancienneté. Elle se resserre quand n grandit.

La bande large encadre le salaire d'*un* salarié donné. Elle ne se resserre jamais en dessous de $\pm 1{,}96\,\widehat{\sigma}_\varepsilon$: l'individu garde son aléa propre.

$$\widehat{y}_h \pm t_{\alpha/2}\,\widehat{\sigma}\sqrt{\boxed{1} + \frac{1}{n} + \frac{(x_h - \overline{x})^2}{\sum (x_i - \overline{x})^2}}$$

Le 1 encadré n'apparaît que pour la prévision individuelle. C'est toute la différence.

Les deux bandes s'**évasent** en s'éloignant de $\overline{x}$: extrapoler coûte cher.

Elles ne diffèrent que par un terme

Intervalle de confiance de la moyenne :

$$\hat{y}_h \pm t_{\alpha/2}\,\hat{\sigma}_\varepsilon \sqrt{\frac{1}{n} + \frac{(x_h - \overline{x})^2}{\sum_i (x_i - \overline{x})^2}}$$

Intervalle de prévision d'une observation :

$$\hat{y}_h \pm t_{\alpha/2}\,\hat{\sigma}_\varepsilon \sqrt{\boxed{1} + \frac{1}{n} + \frac{(x_h - \overline{x})^2}{\sum_i (x_i - \overline{x})^2}}$$

Le 1 encadré est toute la différence

Il représente la variance de l'erreur individuelle, et il ne dépend pas de n : **l'intervalle individuel ne descendra jamais sous $\pm 1{,}96\,\hat{\sigma}_\varepsilon$.** L'aléa personnel ne se dilue pas.

Deux variances

La droite estimée passe par $(\overline{x}, \overline{y})$: $\hat{y}_h = \overline{y} + \hat{\beta}_1(x_h - \overline{x})$. Les deux termes sont non corrélés, d'où

$$V(\hat{y}_h) = \frac{\sigma_\varepsilon^2}{n} + (x_h - \overline{x})^2 \frac{\sigma_\varepsilon^2}{S_{xx}}$$

Pour un individu, $y_h - \hat{y}_h = \varepsilon_h - (\hat{y}_h - Ey_h)$: on ajoute la variance de ε_h, soit σ_ε^2.

Trois sources d'incertitude, trois termes

$1/n$: on ignore la **hauteur** exacte de la droite. $(x_h - \overline{x})^2/S_{xx}$: on ignore sa **pente**, et l'erreur grandit en s'éloignant du centre. 1 : on ignore l'**écart personnel**.

Les deux, chiffrés

$\hat{\sigma}_\varepsilon = 2\,008, n = 500, x_h = 10 \approx \overline{x}.$

Moyenne : $7\,119 \pm 1{,}96 \times 2\,008 \times 0{,}045 = [\,6\,943\ ;\ 7\,295\,]$

Individu : $7\,119 \pm 1{,}96 \times 2\,008 \times 1{,}001 = [\,3\,179\ ;\ 11\,059\,]$

Un écart qui décide de l'usage

Le premier intervalle est étroit : on peut fonder une grille salariale dessus.

Le second est immense : il ne permet **aucune décision individuelle**. Annoncer à Karim que son salaire sera entre trois mille et onze mille dirhams n'est pas une prévision, c'est un aveu.

À la main, sur les cinq ménages

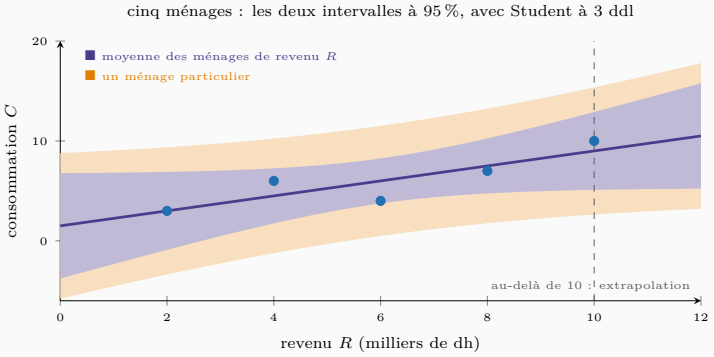
Variance résiduelle 2,5, n = 5, t de Student 3,182

R_h	$\widehat{C_h}$	moyenne	un ménage
6	6	$6 \pm 2{,}25$	$6 \pm 5{,}51$
10	9	$9 \pm 3{,}90$	$9 \pm 6{,}36$

Le détail du calcul

En $R = 6$, le facteur vaut $\frac{1}{5} + 0 = 0{,}2 : 3{,}182\sqrt{2{,}5 \times 0{,}2} = 2{,}25$. En $R = 10$, $\frac{1}{5} + \frac{(10-6)^2}{40} = 0{,}6 : 3{,}182\sqrt{2{,}5 \times 0{,}6} = 3{,}182 \times 1{,}225 = 3{,}90$.

Pour un ménage : $3{,}182 \times \sqrt{2{,}5 \times 1{,}6} = 3{,}182 \times 2 = 6{,}36$.



Ce que cinq ménages permettent de prévoir

Presque rien : un ménage de 10 milliers consommerait entre $2{,}6$ et $15{,}4$ milliers. L'étroitesse viendra du nombre — et, pour l'intervalle individuel, d'un $\hat{\sigma}_\varepsilon$ plus petit, que seule une meilleure spécification peut donner.

Les pièges de la prévision

Les bandes s’évasent

Le terme $(x_h - \overline{x})^2$ grandit dès qu’on s’écarte du centre : plus on extrapole, moins on est précis. C’est visible sur les deux figures.

Et ce n’est que la moitié du problème. **Rien ne garantit que la relation reste linéaire hors du domaine observé** — et là, aucune formule ne prévient.

De combien les bandes s’élargissent

Salaires, moyenne des salariés à 10 ans : ± 176 dirhams ; à 35 ans, l’ancienneté maximale du fichier : ± 756, plus de quatre fois plus.

Cinq ménages, à $R = 12$, hors des données : $\pm 5{,}28$ pour la moyenne, contre $\pm 2{,}25$ au centre.

Un exemple qui a coûté cher

Le domaine de validité

Extrapoler une hausse des prix de l'immobilier observée sur dix ans revient à supposer que le mécanisme qui l'a produite continue de jouer.

Les modèles de risque immobilier d'avant 2007 n'avaient jamais observé de baisse nationale des prix. Leur domaine de validité ne contenait pas l'événement qui allait survenir.

Une règle simple

Avant toute prévision, vérifier que x_h est **dans l'étendue** des données : entre 0 et 35 ans pour l'ancienneté, entre 402 et $12\,069$ dirhams pour le revenu des ménages. Au-delà, la prévision n'est plus une conclusion des données, c'est un pari.

Ce que la prévision suppose

Trois conditions, souvent tues

1. Le modèle est **bien spécifié** — les bonnes variables, la bonne forme.
2. La relation **reste stable** entre la période d'estimation et celle de prévision.
3. Le point à prévoir est **dans le domaine** des données observées.

La deuxième est la plus fragile

En économie, les comportements changent : une réforme fiscale, une crise, un changement de génération modifient la relation elle-même.

C'est la **critique de Lucas** : un modèle estimé sous un régime de politique économique cesse d'être valable si l'on change ce régime — précisément parce que les agents s'adaptent. **Le modèle ne peut donc pas servir à évaluer la politique qui le rendrait faux.**

Sur machine

```r
R <- c(2, 4, 6, 8, 10)
C <- c(3, 6, 4, 7, 10)
m <- lm(C ~ R)
nouv <- data.frame(R = c(6, 10))
predict(m, nouv, interval = "confidence")   # la moyenne
#   fit      lwr      upr
# 1   6 3.749671  8.250329
# 2   9 5.102315 12.897685
predict(m, nouv, interval = "prediction")   # un ménage
#   fit       lwr      upr
# 1   6 0.4878413 11.51216
# 2   9 2.6351074 15.36489
```

```
import pandas as pd
import statsmodels.formula.api as smf
sal = pd.read_csv("salaires.csv")
m1 = smf.ols("salaire ~ anciennete", data=sal).fit()
p = m1.get_prediction(pd.DataFrame({"anciennete": [10, 35]}))
t = p.summary_frame(alpha=0.05).round(1)
print(t[["mean", "mean_ci_lower", "mean_ci_upper"]])
#       mean  mean_ci_lower  mean_ci_upper
# 0   7118.9         6942.4         7295.4
# 1  14048.1        13291.8        14804.4
print(t[["obs_ci_lower", "obs_ci_upper"]])
#    obs_ci_lower  obs_ci_upper
# 0        3169.1       11068.7
# 1       10030.4       18065.8
```

Ce que disent les deux sorties

Deux mots changent tout

En R, `interval = "confidence"` donne l'intervalle de la moyenne, `"prediction"` celui d'un ménage : on retrouve $6 \pm 2{,}25$ et $6 \pm 5{,}51$.

En Python, `mean_ci` est l'intervalle de la moyenne, `obs_ci` celui d'un individu.

Quelques dirhams d'écart avec le calcul à la main

Pour les salaires à 10 ans, la machine donne $[3\,169\,;11\,069]$ et non $[3\,179\,;11\,059]$: elle prend le quantile de Student, $1{,}965$, là où nous avons pris $1{,}96$. À 35 ans, au bord du fichier, l'intervalle de la moyenne atteint ± 756 dirhams.

S’entraîner

Les quatre magasins, au centre et au bord

Avec $\widehat{y} = 0{,}5 + 1{,}5\,x$, $n = 4$, $\overline{x} = 3$, $S_{xx} = 10$, $\widehat{\sigma}^2_\varepsilon = 1{,}75$ et $t_2 = 4{,}303$:

1. Calculer les deux intervalles pour $x_h = 3$.
2. Puis pour $x_h = 6$, hors des données.
3. De combien l'intervalle de la moyenne s'est-il élargi ?

Plus de deux fois plus large au bord

1. $\widehat{y} = 5$. Moyenne : $4{,}303\sqrt{1{,}75 \times 0{,}25} = 2{,}85$, soit $[2{,}15\,;7{,}85]$. Magasin : $4{,}303\sqrt{1{,}75 \times 1{,}25} = 6{,}36$, soit $[-1{,}36\,;11{,}36]$.
2. $\widehat{y} = 9{,}5$. Le facteur vaut $0{,}25 + 9/10 = 1{,}15$. Moyenne : $4{,}303\sqrt{1{,}75 \times 1{,}15} = 6{,}10$. Magasin : $4{,}303\sqrt{1{,}75 \times 2{,}15} = 8{,}35$.
3. De $2{,}85$ à $6{,}10$: un facteur $2{,}1$. Et l'on extrapole, ce qu'aucune formule ne couvre.

Exercice 2 : choisir le bon intervalle

Trois décideurs

Pour chacun, dire quel intervalle utiliser.

1. Un ministère prévoit la consommation **totale** des ménages d'un quartier, connaissant leur revenu.
2. Une banque évalue la capacité de remboursement d'**un** ménage qui demande un crédit.
3. Une entreprise fixe le salaire d'embauche moyen de ses **futurs** ingénieurs débutants.

Exercice 2 : solution

Une moyenne ou un individu

1. **Moyenne** : sur un grand nombre de ménages, les écarts individuels se compensent.
2. **Individu** : la banque prête à ce ménage-là, avec son écart personnel. C'est pourquoi elle exige des garanties.
3. **Moyenne**, pour la grille ; mais chaque candidat négociera autour d'elle, dans la marge de l'intervalle individuel.

La limite des deux intervalles

Sur les salaires, $\hat{\sigma}_\varepsilon = 2\,008$.

1. Que devient la demi-largeur de l'intervalle de la moyenne, en $x_h = \overline{x}$, si n passe de 500 à $50\,000$?
2. Et celle de l'intervalle individuel ?
3. Quelle conclusion en tirer pour la prévision individuelle ?

L'aléa personnel ne se dilue pas

1. Elle vaut $1{,}96 \times 2\,008/\sqrt{n} : 176$ dirhams pour $n = 500$, $17{,}6$ pour $50\,000$. Elle tend vers 0.
2. Elle vaut $1{,}96 \times 2\,008\sqrt{1 + 1/n} : 3\,940$ puis $3\,936$. Elle ne descend pas sous $3\,936$.
3. Plus de données n'améliorent pas la prévision individuelle : il faut **d'autres variables**, qui réduisent $\hat{\sigma}_\varepsilon$. Le chapitre 7 les ajoute.

Ce qu’il faut retenir

Le résumé du chapitre

Six points

1. La prévision ponctuelle est immédiate : $\widehat{y}_h = \widehat{\beta}_0 + \widehat{\beta}_1 x_h$.
2. Deux questions se cachent derrière : prévoir une **moyenne** ou prévoir un **individu**.
3. Les deux formules ne diffèrent que par un 1 sous la racine — la variance de l'erreur individuelle.
4. Ce 1 ne dépend pas de n : l'intervalle individuel ne se resserre jamais complètement.
5. Salaires : $[6\,943\,;7\,295]$ contre $[3\,179\,;11\,059]$; cinq ménages à $R = 6$: $6 \pm 2{,}25$ contre $6 \pm 5{,}51$.
6. **Ne jamais extrapoler** hors du domaine observé, et se méfier des changements de régime.

La suite

Une seule variable explicative ne suffit à rien décrire : le salaire dépend aussi du diplôme et de la région. La troisième partie généralise tout ce qui précède — et introduit l'apport propre de l'économétrie : le **ceteris paribus**.