Introduction à l'économétrie

Chapitre 2 : Le modèle économétrique

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 23 octobre 2026

Plan du chapitre

Ajouter l'aléa

L'hypothèse décisive

Ce qu'affirme le modèle

Sur machine

S'entraîner

Ce qu'il faut retenir

Ajouter l’aléa

Le modèle économétrique

$$C_i = \beta_0 + \beta_1 R_i + \varepsilon_i$$

Le terme ε_i est l'**erreur** — ou perturbation, ou aléa. Il transforme une identité fausse en modèle statistique vrai.

Le modèle n'affirme plus la même chose

Sans ε : « ce ménage consomme exactement cela ». Avec ε : « il consomme cela **en moyenne**, à un écart près ».

La première proposition est réfutée par la première observation venue. La seconde est testable.

Deux parties dans chaque observation

Une part systématique, une part aléatoire

$$\underbrace{C_i}_{\text{observé}} = \underbrace{\beta_0 + \beta_1 R_i}_{\text{ce que le revenu explique}} + \underbrace{\varepsilon_i}_{\text{tout le reste}}$$

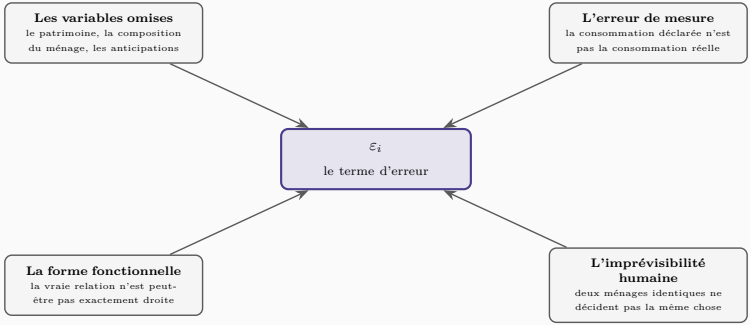
L'indice i est essentiel

Les paramètres β_0 et β_1 sont **les mêmes pour tous** les ménages : c'est la loi commune.

L'erreur ε_i est **propre à chacun** : c'est ce qui le distingue des autres ménages de même revenu.

Sur 400 ménages : deux paramètres à estimer, et 400 erreurs qu'on n'observera jamais.

Ce que contient le terme d'erreur



Le terme d'erreur n'est pas une faute : c'est l'aveu, écrit dans le modèle, de tout ce qu'il ne contient pas.

Les quatre sources n'ont pas le même statut. Les trois dernières sont *inévitables* et sans gravité : elles ajoutent du bruit, l'estimation reste juste en moyenne.

La première est d'une tout autre nature. Si une variable omise est corrélée à celles du modèle, l'erreur l'est aussi — et l'estimation devient **biaisée**. C'est le sens de l'hypothèse $E(\varepsilon_i \mid X_i) = 0$, et c'est la seule que l'économétrie ne sait pas réparer par une formule. Le chapitre 16 lui est consacré.

Les quatre sources n'ont pas le même statut

Trois sont bénignes

L'**erreur de mesure** sur C, la **forme fonctionnelle** approchée et l'**imprévisibilité humaine** ajoutent du bruit.

Elles rendent l'estimation moins précise. Elles ne la rendent pas fausse.

La quatrième ne l'est pas

Les **variables omises** sont d'une tout autre nature.

Si une variable absente du modèle est liée à celles qui y figurent, elle contamine l'erreur — et l'estimation devient **biaisée**. Tout le cours tourne autour de cette distinction.

L’hypothèse décisive

L'exogénéité

$$E(\varepsilon_i \mid X_i) = 0$$

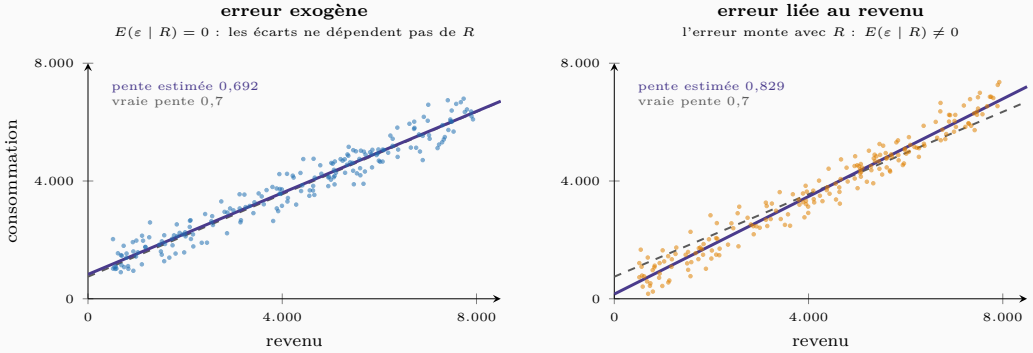
Connaissant la valeur de la variable explicative, l'erreur vaut zéro en moyenne. Autrement dit : **l'erreur ne contient rien de systématiquement lié à X.**

Ce qu'elle interdit

Elle n'interdit pas que l'erreur soit grande — le modèle peut expliquer peu.

Elle interdit qu'elle soit **orientée** selon X. Si les ménages à fort revenu étaient aussi ceux qui consomment davantage pour d'autres raisons — une famille plus nombreuse, par exemple — la pente estimée capterait les deux effets et attribuerait au revenu ce qui ne lui revient pas.

L'hypothèse, vue sur une simulation



Même vraie droite, même méthode, deux résultats

Les deux nuages obéissent à $C = 750 + 0{,}7\,R + \varepsilon$. À gauche l'erreur est exogène : la pente estimée vaut $0{,}692$. À droite elle monte avec le revenu : la méthode attribue cette montée au revenu, et trouve $0{,}829$.

La conséquence

Sous cette hypothèse, et sous elle seule, les estimateurs des moindres carrés sont **sans biais** :

$$E(\hat{\beta}_1) = \beta_1$$

Le contraste avec les autres hypothèses

Les hypothèses du chapitre 11 concernent la **précision** : elles décident si les écarts-types sont justes. Quand elles tombent, une correction technique répare tout.

L'exogénéité concerne la **justesse elle-même**. Quand elle tombe, aucune formule ne répare : **il faut changer de modèle ou de méthode.** C'est la ligne de partage de l'économétrie entière.

L'erreur est non corrélée à la variable explicative

$$E(\varepsilon_i \mid X_i) = 0 \implies E(\varepsilon_i) = 0 \quad \text{et} \quad \operatorname{cov}(X_i, \varepsilon_i) = 0$$

La première égalité vient de la moyenne des moyennes conditionnelles ; la seconde de $E(X\varepsilon) = E\big(X\,E(\varepsilon \mid X)\big) = 0$.

La réciproque est fausse, et cela compte

Une covariance nulle n'exclut pas une liaison non linéaire. L'exogénéité est **plus exigeante** : elle demande que l'erreur ne dépende de X d'aucune façon, en moyenne.

En pratique, c'est la covariance que l'on discute — et c'est elle que la variable omise viole au chapitre 16.

Deux mots que l'on confond souvent

$$\varepsilon_i = y_i - (\beta_0 + \beta_1 x_i) \qquad e_i = y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)$$

L'**erreur** se mesure à la vraie droite : elle est **inconnue**. Le **résidu** se mesure à la droite estimée : il est **calculé**.

C'est la distinction du cours d'inférence, appliquée point par point

m et $\overline{x}$, σ et s, β_1 et $\hat{\beta}_1$: à chaque fois, un paramètre inconnu et son estimation.

Ici, la même chose pour chaque observation. **Et c'est le résidu, seule quantité observable, qui servira à diagnostiquer l'erreur** — tout le chapitre 12 repose là-dessus.

Si un oracle révélait la vraie droite C = 1 + 0,8 R

Ménage	A	B	C	D	E	Somme
C	3	6	4	7	10	
erreur ε_i	0,4	1,8	−1,8	−0,4	1	1
résidu e_i	0	1,5	−2	−0,5	1	0

Deux séries voisines, pas identiques

Les résidus, mesurés à la droite estimée du chapitre 3, ne sont qu'une **image** des erreurs. Et ils somment **exactement** à zéro, les erreurs non : c'est une propriété de la méthode, pas des données.

Ce qu’affirme le modèle

La lecture rigoureuse

$$E(C \mid R) = \beta_0 + \beta_1 R$$

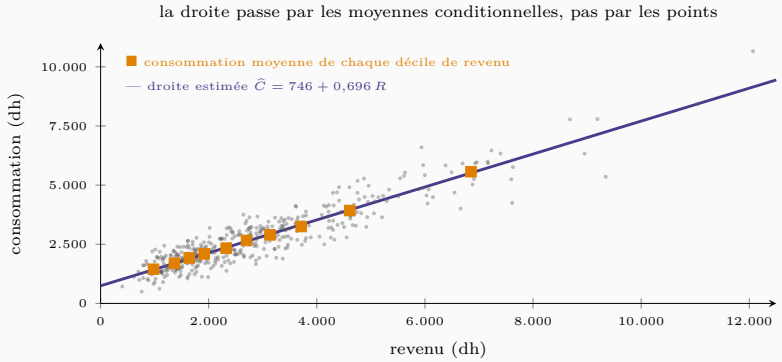
La droite ne prétend pas passer par les points : elle décrit **la moyenne de C pour chaque valeur de R**.

Une régression est une moyenne conditionnelle

C'est exactement la notion du chapitre 11 des probabilités — la distribution conditionnelle et sa moyenne.

La nouveauté n'est pas le concept : c'est qu'on suppose ces moyennes **alignées**, ce qui permet de les résumer par deux nombres au lieu d'une infinité.

Les moyennes conditionnelles, sur les 400 ménages



Dix moyennes, presque alignées

On range les ménages en dix déciles de revenu et l'on calcule la consommation moyenne de chacun : les dix carrés orange tombent presque sur la droite. **C'est ce que le modèle affirme, et c'est vérifiable.**

Une conséquence pratique

Ce qu'on peut et ne peut pas prédire

Le modèle prédit correctement la consommation **moyenne** des ménages à revenu donné.

Il ne prédit pas la consommation d'un ménage particulier — l'écart individuel lui échappe par construction. **C'est pourquoi le chapitre 6 donnera deux intervalles de prévision, et non un seul.**

La modestie du modèle est sa force

Un modèle qui prétendrait tout expliquer serait invérifiable. Celui-ci annonce d'emblée ce qu'il ignore, et le range dans ε.

C'est cette honnêteté d'écriture qui rend possible de mesurer sa fiabilité.

Sur machine

Simuler un modèle avec R

```r
set.seed(20261022)
n <- 1000
R <- runif(n, 500, 8000)              # revenus simulés
eps <- rnorm(n, 0, 400)               # erreur exogène
C <- 750 + 0.7 * R + eps              # le vrai modèle, connu
round(coef(lm(C ~ R)), 3)             # proche de 750 et 0,7
# (Intercept)           R
#     716.733       0.708
eps2 <- 0.15 * (R - mean(R)) + rnorm(n, 0, 400)
C2 <- 750 + 0.7 * R + eps2            # erreur liée à R
round(coef(lm(C2 ~ R)), 3)            # pente biaisée
# (Intercept)           R
#     102.644       0.857
```

```python
import numpy as np
rng = np.random.default_rng(20261022)
n = 1000
R = rng.uniform(500, 8000, n)
eps = rng.normal(0, 400, n)          # erreur exogène
C = 750 + 0.7 * R + eps
b1, b0 = np.polyfit(R, C, 1)
print(round(b0, 3), round(b1, 3))    # proche de 750 et 0,7
# 795.214 0.691
eps2 = 0.15 * (R - R.mean()) + rng.normal(0, 400, n)
C2 = 750 + 0.7 * R + eps2            # erreur liée à R
b1, b0 = np.polyfit(R, C2, 1)
print(round(b0, 3), round(b1, 3))    # pente biaisée
# 114.461 0.85
```

Ce que montrent les deux simulations

Le seul endroit où l'on connaît la vérité

Une simulation est le seul cas où β_1 est **connu** : $0{,}7$. Avec l'erreur exogène, les deux logiciels retrouvent $0{,}708$ et $0{,}691$ — les tirages diffèrent, pas la conclusion.

Avec l'erreur liée au revenu, $0{,}857$ et $0{,}850$. **Le biais ne disparaît pas avec** $n = 1\,000$: plus d'observations rendent l'estimation plus précise, autour de la mauvaise valeur.

Un laboratoire que l'économiste peut se payer

On ne peut pas expérimenter sur les ménages, mais on peut expérimenter sur des **ménages simulés** : fixer la vérité, appliquer la méthode, regarder ce qu'elle retrouve.

Le chapitre 11 s'en servira pour vérifier le théorème de Gauss-Markov sur des milliers d'échantillons.

S’entraîner

Trois salariés

On suppose connue la vraie relation $S = 4\,000 + 300\,A + \varepsilon$. Sur un échantillon, on a estimé $\widehat{S} = 4\,347 + 277\,A$.

Salarié	Ancienneté A	Salaire S
1	5	6 000
2	10	6 500
3	20	11 500

1. Calculer l'erreur et le résidu de chaque salarié.
2. Lequel des deux peut-on calculer dans une étude réelle ?

Exercice 1 : solution

Seul le résidu est observable

1. Erreurs : $6\,000 - 5\,500 = 500$; $6\,500 - 7\,000 = -500$; $11\,500 - 10\,000 = 1\,500$.
   Résidus : $6\,000 - 5\,732 = 268$; $6\,500 - 7\,117 = -617$; $11\,500 - 9\,887 = 1\,613$.
2. Le **résidu** seulement : il ne demande que la droite estimée. L'erreur suppose la vraie droite, que personne ne connaît en dehors d'une simulation.

Quatre sources d'écart

Dans le modèle $C = \beta_0 + \beta_1 R + \varepsilon$ estimé sur une enquête, dire si chaque source d'écart biaise $\hat{\beta}_1$ ou ajoute seulement du bruit.

1. Certains ménages arrondissent leur consommation à la centaine.
2. Un mariage dans la famille a fait exploser les dépenses du mois.
3. La taille du ménage est omise, et les ménages nombreux ont en moyenne des revenus plus élevés.
4. La vraie relation est légèrement courbe.

Exercice 2 : solution

Une seule est dangereuse

1. **Bruit** : une erreur de mesure sur la variable expliquée ne crée pas de biais.
2. **Bruit** : un événement imprévisible, sans lien avec le revenu.
3. **Biais** : la taille agit sur C et elle est liée à R. Elle passe dans ε, qui devient lié au revenu : $E(\varepsilon \mid R) \neq 0$. La pente capte une partie de l'effet de la taille — le chapitre 16 le chiffrera.
4. **Bruit** tant que la courbure est faible ; le chapitre 18 dira comment la modéliser si elle ne l'est pas.

Exercice 3 : lire une espérance conditionnelle

Le ménage D

On admet $E(C \mid R) = 1{,}5 + 0{,}75\,R$, en milliers de dirhams.

1. Quelle est la consommation moyenne des ménages qui gagnent 8 milliers ?
2. Le ménage D gagne 8 et consomme 7. Contredit-il le modèle ?
3. Un ménage gagnant 8 milliers consomme-t-il nécessairement $7{,}5$?

Une moyenne n'est pas une prédiction individuelle

1. $1{,}5 + 0{,}75 \times 8 = 7{,}5$ milliers de dirhams.
2. Non. Il est $0{,}5$ en dessous de la moyenne : c'est son écart individuel, que le modèle range dans ε. Le modèle ne dit rien de plus d'un ménage particulier.
3. Non : $7{,}5$ est la **moyenne** des ménages de ce revenu. Chacun s'en écarte, dans un sens ou dans l'autre — d'où les deux intervalles du chapitre 6.

Ce qu’il faut retenir

Le résumé du chapitre

Six points

1. $C_i = \beta_0 + \beta_1 R_i + \varepsilon_i$: le terme d'erreur transforme une identité fausse en modèle testable.
2. Il contient variables omises, erreurs de mesure, approximation de forme, et imprévisibilité.
3. Seules les **variables omises** sont dangereuses ; les trois autres sources ne font que du bruit.
4. $E(\varepsilon_i \mid X_i) = 0$ est l'hypothèse décisive : sans elle, l'estimation est biaisée.
5. **Erreur** inconnue, **résidu** calculé — comme m et $\overline{x}$.
6. La droite décrit une **espérance conditionnelle**, non les points eux-mêmes.

La suite

Le modèle est posé. Il reste à en estimer les deux paramètres à partir des données : c'est la méthode des moindres carrés — et l'on va dire **pourquoi** ce critère-là plutôt qu'un autre.