# Introduction à l'économétrie

## Chapitre 3 : Les moindres carrés ordinaires

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 23 octobre 2026

# Plan du chapitre

Le critère

À la main, sur les cinq ménages

Sur nos deux jeux de données

Ce que les formules disent

Sur machine

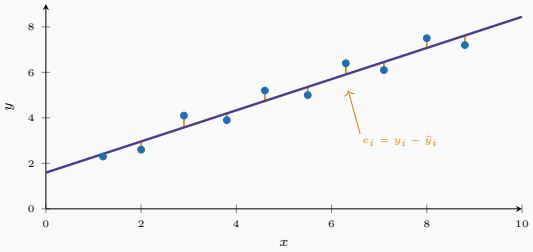
S'entraîner

Ce qu'il faut retenir

# Le critère

# Trois questions sur une même figure

les moindres carrés : on minimise la somme des carrés des segments verticaux




**Trois questions, trois réponses**

**Pourquoi vertical ?**
Parce qu'on explique $y$ *par* $x$. L'erreur porte sur $y$, pas sur $x$ : la distance pertinente est celle-là.

**Pourquoi au carré ?**
Pour que les écarts positifs et négatifs ne se compensent pas, et pour pénaliser davantage les gros écarts. La valeur absolue conviendrait aussi, mais elle n'est pas dérivable.

**Pourquoi cette droite-là ?**
Elle est *unique* : annuler les deux dérivées donne un système de deux équations à deux inconnues, résolu au chapitre 10 du cours de mathématiques.

## Ce que l'on minimise

$$\min_{\beta_0,\beta_1} \; S(\beta_0,\beta_1) = \sum_{i=1}^{n} \left(y_i - \beta_0 - \beta_1 x_i\right)^2$$

On cherche la droite qui rend la somme des carrés des écarts verticaux la plus petite possible.

## Un problème du cours de mathématiques

Une fonction de deux variables, dont on cherche le minimum : on annule les deux dérivées partielles.

C'est le chapitre 6 du cours de mathématiques pour la gestion, appliqué tel quel. Le système obtenu — deux équations, deux inconnues — se résout par la méthode du chapitre 10.

## Annuler les deux dérivées

$$\frac{\partial S}{\partial \beta_0} = -2 \sum_i (y_i - \beta_0 - \beta_1 x_i) = 0$$

$$\frac{\partial S}{\partial \beta_1} = -2 \sum_i x_i (y_i - \beta_0 - \beta_1 x_i) = 0$$

## La solution

$$\hat{\beta}_1 = \frac{\operatorname{cov}(x, y)}{V(x)} \qquad \hat{\beta}_0 = \overline{y} - \hat{\beta}_1 \, \overline{x}$$

## Trois lignes de calcul

La première équation, divisée par $n$, donne $\overline{y} = \beta_0 + \beta_1 \overline{x}$, donc $\beta_0 = \overline{y} - \beta_1 \overline{x}$.

On remplace dans la seconde : $\sum_i x_i \big[(y_i - \overline{y}) - \beta_1 (x_i - \overline{x})\big] = 0$.

Comme $\sum_i \overline{x}\,(y_i - \overline{y}) = 0$, on peut remplacer $x_i$ par $x_i - \overline{x}$ :

$$\beta_1 = \frac{\sum_i (x_i - \overline{x})(y_i - \overline{y})}{\sum_i (x_i - \overline{x})^2} = \frac{S_{xy}}{S_{xx}}$$

## Deux écritures de la même pente

En divisant haut et bas par $n$ : $S_{xy}/n = \mathrm{cov}(x, y)$ et $S_{xx}/n = V(x)$. **Les sommes de produits et la covariance donnent la même pente** ; à la main, on travaille avec les sommes.

# À la main, sur les cinq ménages

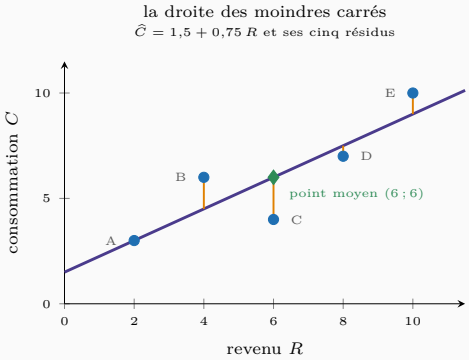
**Revenu et consommation, en milliers de dirhams**

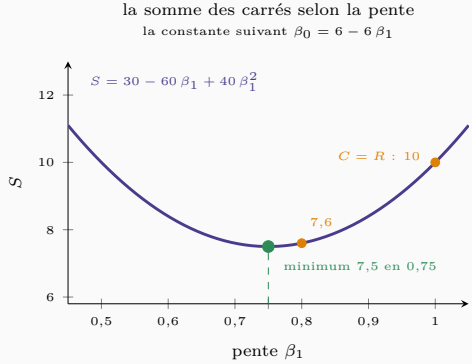
| Ménage | $R$ | $C$ | $R-\overline{R}$ | $C-\overline{C}$ | produit | $(R-\overline{R})^2$ |
|---|---|---|---|---|---|---|
| A | 2 | 3 | $-4$ | $-3$ | 12 | 16 |
| B | 4 | 6 | $-2$ | 0 | 0 | 4 |
| C | 6 | 4 | 0 | $-2$ | 0 | 0 |
| D | 8 | 7 | 2 | 1 | 2 | 4 |
| E | 10 | 10 | 4 | 4 | 16 | 16 |
| **Somme** | 30 | 30 | 0 | 0 | 30 | 40 |

**Les deux coefficients**

$$\hat{\beta}_1 = \frac{S_{RC}}{S_{RR}} = \frac{30}{40} = 0{,}75 \qquad \hat{\beta}_0 = \overline{C} - \hat{\beta}_1 \overline{R} = 6 - 0{,}75 \times 6 = 1{,}5$$

# La droite et ses résidus




## Valeurs ajustées et résidus

$\widehat{C} = 1{,}5 + 0{,}75\,R$ donne $3$ ; $4{,}5$ ; $6$ ; $7{,}5$ ; $9$. Résidus $e = C - \widehat{C}$ : $0$ ; $1{,}5$ ; $-2$ ; $-0{,}5$ ; $1$.

Leur somme des carrés : $0 + 2{,}25 + 4 + 0{,}25 + 1 = 7{,}5$.

# Aucune autre droite ne fait mieux

## Trois candidates, trois sommes de carrés

| Droite | Résidus | $S$ |
|---|---|---|
| $C = R$ | $1\,;2\,;-2\,;-1\,;0$ | $10$ |
| $C = 1{,}2 + 0{,}8\,R$ | $0{,}2\,;1{,}6\,;-2\,;-0{,}6\,;0{,}8$ | $7{,}6$ |
| $C = 1{,}5 + 0{,}75\,R$ | $0\,;1{,}5\,;-2\,;-0{,}5\,;1$ | $\mathbf{7{,}5}$ |

## La parabole de la figure le garantit

En imposant $\beta_0 = 6 - 6\,\beta_1$, la somme des carrés devient $S = 30 - 60\,\beta_1 + 40\,\beta_1^2$ : une parabole, minimale en $\beta_1 = 60/80 = 0{,}75$.

**Toute autre pente fait pire** — et toute autre constante aussi, puisque la meilleure passe par le point moyen.

# Sur nos deux jeux de données

## Les salaires

$$\text{cov} = 9\,859{,}9 \qquad V(x) = 35{,}574$$

$$\hat{\beta}_1 = \frac{9\,859{,}9}{35{,}574} = 277{,}17 \qquad \hat{\beta}_0 = 7\,158{,}26 - 277{,}17 \times 10{,}142 = 4\,347{,}23$$

## La consommation

$$\hat{\beta}_1 = \frac{2\,145\,709}{3\,082\,849} = 0{,}6960 \qquad \hat{\beta}_0 = 2\,779{,}43 - 0{,}6960 \times 2\,921{,}73 = 745{,}86$$

La propension marginale vaut $0{,}696$ : comprise entre zéro et un, comme Keynes l'annonçait. Et $\hat{\beta}_0 > 0$, comme il l'annonçait aussi.

# Ce que disent les deux droites

## Lire les coefficients dans leurs unités

**Salaires** : chaque année d'ancienneté est associée à $277$ dirhams de salaire mensuel en plus. La constante, $4\,347$ dirhams, est le salaire ajusté d'un débutant.

**Consommation** : sur chaque dirham de revenu supplémentaire, $0{,}70$ dirham est consommé et $0{,}30$ épargné. La constante, $746$ dirhams, est la consommation qu'aurait un ménage sans revenu.

## Une constante n'a pas toujours de sens propre

Aucun ménage de l'enquête n'a un revenu nul : le plus pauvre gagne $402$ dirhams. $745{,}86$ est donc une **extrapolation** de la droite, utile au calcul, à lire avec prudence.

Pour les salaires, l'ancienneté nulle existe — les débutants — et la constante se lit littéralement.

# Ce que les formules disent

## La covariance, normalisée

$$\hat{\beta}_1 = \frac{\operatorname{cov}(x, y)}{V(x)} \qquad \text{et} \qquad r = \frac{\operatorname{cov}(x, y)}{\sigma_x \, \sigma_y}$$

La pente et la corrélation ont le **même numérateur**. Ils portent donc toujours le même signe, et l'un est nul si et seulement si l'autre l'est.

## Le lien exact

$$\hat{\beta}_1 = r \, \frac{\sigma_y}{\sigma_x}$$

La corrélation est sans unité ; la pente ne l'est pas. **La pente dit combien, la corrélation dit à quel point.** Ce sont deux questions distinctes, et le chapitre 4 y reviendra.

## Le lien, vérifié deux fois

### Sur les cinq ménages

$\sigma_R = \sqrt{40/5} = 2{,}828$, $\sigma_C = \sqrt{30/5} = 2{,}449$, $r = 30/\sqrt{40 \times 30} = 0{,}866$.

$$r\,\frac{\sigma_C}{\sigma_R} = 0{,}866 \times \frac{2{,}449}{2{,}828} = 0{,}75$$

### Sur les salaires

$r = 0{,}6363$, $\sigma_S = 2\,598{,}10$, $\sigma_A = 5{,}964$ :

$$0{,}6363 \times \frac{2\,598{,}10}{5{,}964} = 277{,}2$$

Une corrélation moyenne, et pourtant une pente forte : $277$ dirhams par an, c'est près de $4\,\%$ du salaire moyen.

**Vraies par construction, quelles que soient les données**

1. $\sum_i e_i = 0$ : les résidus somment à zéro.
2. $\sum_i x_i e_i = 0$ : ils sont orthogonaux à la variable explicative.
3. La droite passe par le **point moyen** $(\overline{x}, \overline{y})$.

**Sur les cinq ménages**

$0 + 1{,}5 - 2 - 0{,}5 + 1 = 0$ ; $2 \times 0 + 4 \times 1{,}5 - 6 \times 2 - 8 \times 0{,}5 + 10 \times 1 = 0$ ;
$1{,}5 + 0{,}75 \times 6 = 6$.

Ce sont les deux équations normales, relues sur les résidus.

# Ce que ces propriétés ne prouvent pas

## Elles ne prouvent rien sur le modèle

Ces trois propriétés découlent des équations normales : elles sont vraies même si le modèle est absurde.

**Voir des résidus de somme nulle n'est donc pas un contrôle de qualité** — c'est une identité. Le vrai diagnostic viendra du chapitre 12.

## Pourquoi les erreurs, elles, ne somment pas à zéro

Au chapitre 2, les erreurs mesurées à la vraie droite sommaient à $1$. Les résidus somment à $0$ parce que la droite estimée est **choisie** pour cela : elle s'ajuste aux aléas de l'échantillon.

C'est la raison pour laquelle on divisera la somme des carrés des résidus par $n - 2$, et non par $n$, au chapitre 4.

## Trois raisons, dans l'ordre d'importance

1. **La solution est unique et explicite** : deux formules, aucun algorithme.
2. **Elle est optimale** : le théorème de Gauss-Markov, chapitre 11.
3. **Elle est dérivable** : la valeur absolue ne l'est pas en zéro.

## Sa faiblesse, et il faut la connaître

Le carré pénalise lourdement les grands écarts : une seule observation aberrante peut déplacer sensiblement la droite.

C'est le même compromis que celui de la moyenne contre la médiane, chapitre 6 de l'inférence. **Les moindres carrés sont efficaces et fragiles** — le chapitre 17 montrera comment repérer les points qui en abusent.

# Ce que deviennent les coefficients quand on change d'unité

## La pente suit le rapport des unités

Si $y$ est multiplié par $a$ et $x$ par $b$, la pente est multipliée par $a/b$ et la constante par $a$.

## Trois changements, sur nos données

Consommation et revenu **en dirhams** plutôt qu'en milliers : pente inchangée, $0{,}75$ ; constante $1\,500$ dirhams.

Salaire **en milliers** de dirhams : pente $0{,}277$ millier par année.

Ancienneté **en mois** : pente $277{,}17/12 = 23{,}10$ dirhams par mois. **Rien n'a changé dans la relation, seulement dans son écriture.**

# Sur machine

```r
R <- c(2, 4, 6, 8, 10)
C <- c(3, 6, 4, 7, 10)
m <- lm(C ~ R)
coef(m)
# (Intercept)           R
#        1.50        0.75
round(residuals(m), 4)
#    1    2    3    4    5
#  0.0  1.5 -2.0 -0.5  1.0
sum(residuals(m))            # nul, à l'arrondi machine près
# [1] -2.775558e-16
```

```
import pandas as pd
import statsmodels.formula.api as smf
cinq = pd.DataFrame({"R": [2, 4, 6, 8, 10],
                     "C": [3, 6, 4, 7, 10]})
m = smf.ols("C ~ R", data=cinq).fit()
print(m.params.round(4).to_dict())
# {'Intercept': 1.5, 'R': 0.75}
print(m.resid.round(4).tolist())
# [0.0, 1.5, -2.0, -0.5, 1.0]
```

```r
men <- read.csv("menages.csv")
coef(lm(consommation ~ revenu, data = men))
# (Intercept)      revenu
#  745.860473    0.696015
```

```python
import pandas as pd
import statsmodels.formula.api as smf
men = pd.read_csv("menages.csv")
mk = smf.ols("consommation ~ revenu", data=men).fit()
print(mk.params.round(4).to_dict())
# {'Intercept': 745.8605, 'revenu': 0.696}
```

**Ce que les sorties confirment**

$1{,}5$ et $0{,}75$ pour les cinq ménages, $745{,}86$ et $0{,}696$ pour les $400$. La somme des résidus vaut $10^{-16}$ et non zéro : c'est l'arrondi de la machine, pas un défaut de la méthode.

# S’entraîner

## Publicité et ventes

Quatre magasins : dépenses publicitaires $x$ et ventes $y$, en milliers de dirhams.

| Magasin | 1 | 2 | 3 | 4 |
|---|---|---|---|---|
| $x$ | 1 | 2 | 4 | 5 |
| $y$ | 2 | 4 | 5 | 9 |

1. Calculer $S_{xx}$, $S_{xy}$, puis la droite des moindres carrés.
2. Calculer les résidus et vérifier les deux premières propriétés algébriques.

**Une pente de 1,5**

1. $\overline{x} = 3, \overline{y} = 5$. Écarts : $x : -2, -1, 1, 2$ ; $y : -3, -1, 0, 4$. $S_{xx} = 4 + 1 + 1 + 4 = 10$ ; $S_{xy} = 6 + 1 + 0 + 8 = 15$. $\hat{\beta}_1 = 15/10 = 1{,}5$ et $\hat{\beta}_0 = 5 - 1{,}5 \times 3 = 0{,}5$.
2. Valeurs ajustées : $2$ ; $3{,}5$ ; $6{,}5$ ; $8$. Résidus : $0$ ; $0{,}5$ ; $-1{,}5$ ; $1$. $\sum e_i = 0$ et $\sum x_i e_i = 0 + 1 - 6 + 5 = 0$.

# Exercice 2 : changer d'unité

## Le salaire en milliers, l'ancienneté en mois

On a estimé $\widehat{S} = 4\,347{,}23 + 277{,}17\,A$, salaire en dirhams, ancienneté en années.

1. Écrire la droite si le salaire est exprimé en milliers de dirhams.
2. Puis si, en plus, l'ancienneté est exprimée en mois.
3. Le coefficient de corrélation change-t-il ?

**Les coefficients changent, la relation non**

1. Tout est divisé par $1\,000$ : $\widehat{S} = 4{,}347 + 0{,}277\,A$.
2. La pente est en plus divisée par $12$ : $\widehat{S} = 4{,}347 + 0{,}0231\,M$, avec $M$ l'ancienneté en mois. La constante ne bouge pas : un débutant a $0$ an comme $0$ mois.
3. Non : $r$ est **sans unité**, il reste $0{,}636$. C'est toute la différence entre « combien » et « à quel point ».

# Exercice 3 : une droite à partir de résumés

**Sans les données individuelles**

Une étude ne publie que : $n = 200$ entreprises, effectif moyen $\overline{x} = 40$ salariés, chiffre d'affaires moyen $\overline{y} = 12$ millions, $\sigma_x = 15$, $\sigma_y = 5$, $r = 0{,}6$.

1. Calculer la pente et la constante de la droite des moindres carrés de $y$ en $x$.
2. Quel chiffre d'affaires ajusté pour une entreprise de $55$ salariés ?
3. Pourquoi ne peut-on pas calculer les résidus ?

**Une pente de 0,2 million par salarié**

1. $\hat{\beta}_1 = r\,\sigma_y/\sigma_x = 0{,}6 \times 5/15 = 0{,}2$ million par salarié ; $\hat{\beta}_0 = 12 - 0{,}2 \times 40 = 4$ millions.
2. $4 + 0{,}2 \times 55 = 15$ millions de dirhams.
3. Les résidus demandent chaque couple $(x_i, y_i)$. Les cinq résumés suffisent pour la droite, **pas pour la juger** : c'est la limite des études qui ne publient pas leurs données.

# Ce qu’il faut retenir

## Six points

1. On minimise la somme des **carrés des écarts verticaux** : $\sum_i (y_i - \beta_0 - \beta_1 x_i)^2$.
2. $\hat{\beta}_1 = S_{xy}/S_{xx} = \mathrm{cov}(x,y)/V(x)$ et $\hat{\beta}_0 = \overline{y} - \hat{\beta}_1 \overline{x}$.
3. Cinq ménages : $30/40 = 0{,}75$ et $1{,}5$ ; aucune autre droite ne descend sous $S = 7{,}5$.
4. $\hat{\beta}_1 = r\,\sigma_y/\sigma_x$ : la pente dit **combien**, la corrélation dit **à quel point**.
5. Trois propriétés algébriques, vraies par construction — donc sans valeur de diagnostic.
6. Les MCO sont **efficaces et fragiles** : une observation extrême pèse lourd.

## La suite

La droite est calculée. Reste à savoir si elle vaut quelque chose : de quelle part de la dispersion rend-elle compte ? Le chapitre 4 y répond par une décomposition que le cours d'inférence a déjà rencontrée.