Introduction à l'économétrie

Chapitre 17 : Normalité et points influents

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 23 octobre 2026

Plan du chapitre

La normalité des résidus

Des points qui pèsent trop

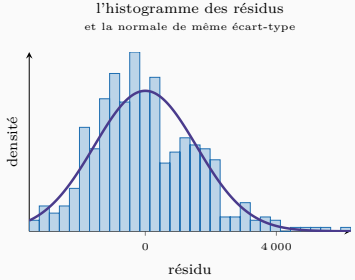
Sur machine

S'entraîner

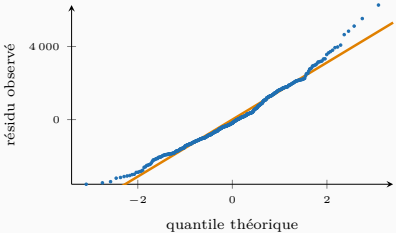
Ce qu'il faut retenir

La normalité des résidus

Ce qu'on regarde



l'histogramme des résidus
et la normale de même écart-type



le diagramme quantile-quantile
alignement = normalité

Les résidus sont étirés à droite : asymétrie 0,56, aplatissement 3,61, Jarque-Bera = 34,1 contre un seuil de 5,99. La normalité est rejetée.

Et cela n'a aucune conséquence ici. Avec cinq cents observations, le théorème central limite rend les coefficients approximativement normaux quelle que soit la loi des erreurs. Tests et intervalles restent valides.

Le diagnostic n'est donc pas inutile pour autant : le décrochage dans le coin supérieur droit signale quelques salaires très élevés, dont le chapitre suivant examinera l'influence.

Il combine asymétrie et aplatissement

$$JB = n\left(\frac{S^2}{6} + \frac{(K-3)^2}{24}\right) \sim \chi^2_2$$

où S est le coefficient d'asymétrie et K l'aplatissement — les indicateurs de forme du chapitre 8 de la statistique descriptive.

Sur le modèle M2

$$JB = 500\left(\frac{0{,}563^2}{6} + \frac{0{,}607^2}{24}\right) = 500\,(0{,}0528 + 0{,}0154) = 34{,}1$$

contre un seuil de $5{,}99$. La normalité est rejetée : les résidus sont étirés vers la droite, $S = 0{,}563$, et un peu trop concentrés, $K = 3{,}607$.

Et cela n'a aucune conséquence

Pourquoi on peut passer outre

Avec cinq cents observations, le théorème central limite rend $\hat{\beta}_j$ approximativement normal **quelle que soit la loi des erreurs**.

Tests, p-values et intervalles restent valides. **H6 ne servait qu'aux petits échantillons.**

Quand elle importe vraiment

En dessous de trente observations — bilans d'un petit échantillon d'entreprises, séries macro courtes, expériences de laboratoire — la non-normalité invalide les tests.

Il faut alors soit transformer la variable expliquée, soit recourir à des méthodes de rééchantillonnage. **Regardez toujours n avant de décider si le rejet vous concerne.**

Une statistique proportionnelle à n

À forme des résidus donnée, JB croît comme n. Les mêmes $S = 0{,}563$ et $K = 3{,}607$ donneraient :

Même forme, trois tailles

n	JB	Conclusion à $5\,\%$
20	$1{,}36$	non rejet
100	$6{,}81$	rejet
500	$34{,}1$	rejet massif

Le paradoxe : le test rejette quand la normalité ne sert plus à rien, et accepte quand elle compterait. C'est la raison de regarder le graphique avant le chiffre.

Ce que le rejet révèle quand même

Un diagnostic utile, pour une autre raison

Le décrochage en haut à droite du diagramme quantile-quantile signale quelques salaires très supérieurs à ce que le modèle prédit.

Ce n'est pas un problème de normalité : c'est une poignée d'observations particulières. **Et celles-là méritent qu'on les regarde.**

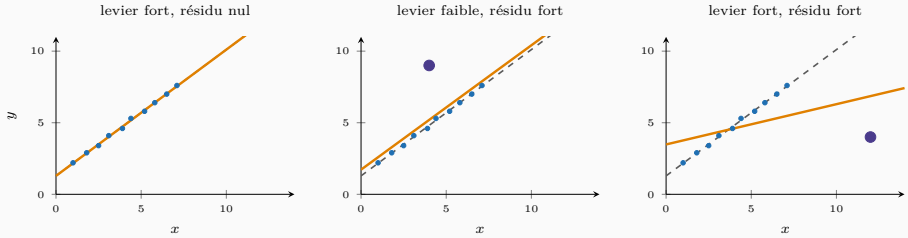
L'asymétrie appelle souvent le logarithme

Une distribution de résidus étirée à droite accompagne presque toujours une variable expliquée elle-même étirée — salaires, revenus, patrimoines, chiffres d'affaires.

Passer au logarithme corrige simultanément l'asymétrie **et** l'hétéroscédasticité du chapitre 14. C'est l'objet du chapitre 18.

Des points qui pèsent trop

Levier et résidu



Trois points ajoutés, trois situations très différentes. La droite en pointillé est celle d'origine.

Levier : le point est-il loin des autres *en x* ? **Résidu** : est-il loin de la droite *en y* ?

Seule la combinaison des deux est dangereuse. Un levier fort sans résidu confirme la droite ; un gros résidu au centre la déplace à peine. C'est le troisième cas qui bascule tout — et c'est le seul qu'un simple examen des résidus ne signale pas comme extraordinaire.

D'où la distance de **Cook**, qui combine les deux, et la règle usuelle : examiner tout point dont la distance dépasse $4/n$. Non pour le supprimer — une observation ne se supprime pas parce qu'elle dérange — mais pour comprendre *pourquoi* il est là.

À ne pas confondre

Notion	Question
Résidu	le point est-il loin de la droite, en y ?
Levier	est-il loin des autres, en x ?
Influence	son retrait changerait-il la droite ?

Seule la troisième compte

Un levier fort sans résidu **confirme** la droite. Un gros résidu au centre du nuage la déplace à peine.

C'est leur combinaison qui bascule tout — et c'est le seul cas qu'un simple examen des résidus ne signale pas comme extraordinaire.

En régression simple

$$h_i = \frac{1}{n} + \frac{(x_i - \overline{x})^2}{S_{xx}} \qquad \sum_i h_i = k + 1$$

Le levier ne dépend que des x : c'est la **distance au centre** du nuage, en abscisse.

Les cinq ménages

$h = \frac{1}{5} + \frac{16}{40} = 0{,}6$ pour A et E ; $\frac{1}{5} + \frac{4}{40} = 0{,}3$ pour B et D ; $0{,}2$ pour C. Somme : 2, le nombre de paramètres.

Les deux ménages extrêmes portent à eux seuls $60\,\%$ du levier total.

Elle combine les deux

$$D_i = \frac{e_i^2}{(k+1)\,\hat{\sigma}_\varepsilon^2} \cdot \frac{h_i}{(1-h_i)^2}$$

où h_i est le levier de l'observation i. Elle mesure de combien **l'ensemble des prévisions** changerait si l'on retirait ce point.

Le seuil usuel

$$D_i > \frac{4}{n}$$

Sur nos cinq cents salariés : $D_i > 0{,}008$. C'est un seuil d'**alerte**, non de suppression.

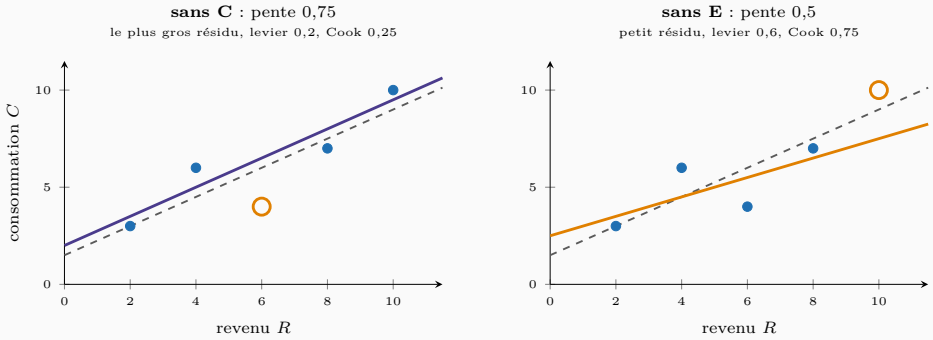
Deux paramètres, variance résiduelle 2,5

Ménage	A	B	C	D	E
résidu e	0	$1{,}5$	-2	$-0{,}5$	1
levier h	$0{,}6$	$0{,}3$	$0{,}2$	$0{,}3$	$0{,}6$
Cook D	0	$0{,}276$	$0{,}25$	$0{,}031$	$0{,}75$

Le plus influent n'a pas le plus gros résidu

E s'écarte de la droite d'un millier seulement, mais il est au bout du levier : $D_E = \frac{1}{5} \times \frac{0{,}6}{0{,}16} = 0{,}75$. C, avec le plus gros résidu, -2, est au centre : $D_C = 0{,}25$.

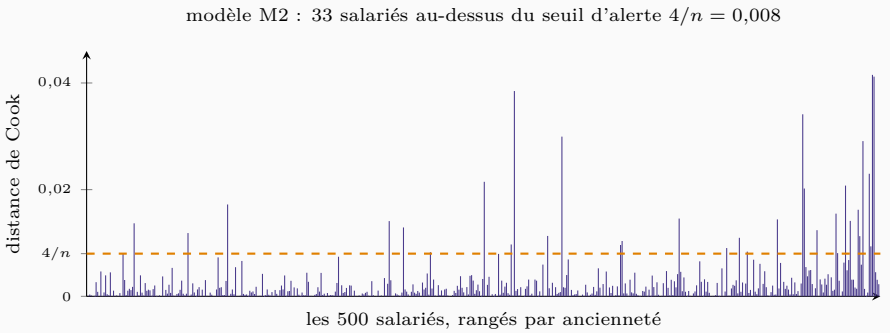
Retirer C, retirer E



La distance de Cook avait raison

Sans C, la pente ne bouge pas : $0{,}75$ — seule la constante monte, de $1{,}5$ à 2. Sans E, elle tombe à $0{,}5$. **Le résidu ne disait pas lequel comptait ; le levier, si.**

Sur les salariés



Trente-trois salariés au-dessus de 4/n

Le plus influent, avec $D = 0{,}042$: un Bac+2 de trente ans d'ancienneté payé $16\,180$ dirhams.

Aucun n'approche 1, le seuil où un point déplacerait à lui seul toute la droite.

Le test de robustesse

Coefficient	M2 complet	Sans les 33
Ancienneté	270,27	253,69
Bac+2	1 099,57	1 066,61
Bac+5	3 336,99	3 104,43

Les conclusions survivent

Les coefficients baissent de 3 à 7 % — les salariés retirés sont surtout des salaires élevés —, mais tous restent du même ordre et très significatifs. **Une conclusion qui survit à ce test est solide ; on publie les deux colonnes.**

Que faire d'un point influent

Quatre questions, dans cet ordre

1. Est-ce une **erreur de saisie** ? On la corrige.
2. Appartient-il à la **population étudiée** ? Un dirigeant dans un fichier d'employés n'y a pas sa place.
3. Le modèle est-il **mal spécifié** ? Une non-linéarité produit des points apparemment aberrants.
4. Si rien de tout cela : **c'est une observation, et on la garde.**

La règle déontologique

On ne supprime pas une observation parce qu'elle dérange.

La bonne pratique consiste à estimer le modèle avec et sans, et à publier les deux si les conclusions diffèrent. C'est ce qu'on appelle un test de **robustesse** — et une conclusion qui n'y survit pas n'était pas une conclusion.

Sur machine

```r
R <- c(2, 4, 6, 8, 10)
C <- c(3, 6, 4, 7, 10)
m <- lm(C ~ R)
round(hatvalues(m), 3)              # leviers
#   1   2   3   4   5
# 0.6 0.3 0.2 0.3 0.6
round(cooks.distance(m), 3)         # distances de Cook
#     1     2     3     4     5
# 0.000 0.276 0.250 0.031 0.750
coef(lm(C[-5] ~ R[-5]))             # sans le ménage E
# (Intercept)       R[-5]
#         2.5         0.5
```

```python
import pandas as pd
import statsmodels.formula.api as smf
from statsmodels.stats.stattools import jarque_bera
sal = pd.read_csv("salaires.csv")
m2 = smf.ols("salaire ~ anciennete + diplome", data=sal).fit()
jb, p, S, K = jarque_bera(m2.resid)
print(round(jb, 2), f"{p:.1e}", round(S, 3), round(K, 3))
# 34.06 4.0e-08 0.563 3.607
cook = m2.get_influence().cooks_distance[0]
garde = cook <= 4 / len(sal)            # 33 salariés écartés
m2s = smf.ols(m2.model.formula, data=sal[garde]).fit()
print(m2s.params.round(2).tolist())     # sans eux
# [3473.98, 1066.61, 3104.43, 253.69]
```

S’entraîner

Exercice 1 : leviers et Cook à la main

Les quatre magasins

Pour $x = 1, 2, 4, 5$ ($\overline{x} = 3$, $S_{xx} = 10$), résidus 0 ; $0{,}5$; $-1{,}5$; 1 et $\hat{\sigma}^2_\varepsilon = 1{,}75$:

1. Calculer les quatre leviers et vérifier leur somme.
2. Calculer les quatre distances de Cook.
3. Quel magasin est le plus influent ? A-t-il le plus gros résidu ?

Le quatrième magasin, malgré un résidu moyen

1. $h = 0{,}25 + d^2/10 : 0{,}65\,;\, 0{,}35\,;\, 0{,}35\,;\, 0{,}65$, de somme 2.
2. $D = e^2/(2 \times 1{,}75) \times h/(1-h)^2 : 0\,;\, 0{,}059\,;\, 0{,}533\,;\, 1{,}516$.
3. Le **quatrième** ($D = 1{,}52$), au bout du levier ; le troisième a le plus gros résidu, $-1{,}5$, mais un levier moindre. Avec quatre points, aucun n'est anodin.

Une asymétrie modérée

Les résidus d'un modèle ont une asymétrie $S = 0{,}3$ et un aplatissement $K = 3{,}5$.

1. Calculer JB pour $n = 200$ et conclure ($\chi^2_2 = 5{,}99$).
2. Même question pour $n = 2\,000$.
3. Dans lequel des deux cas la non-normalité menace-t-elle les tests de Student ?

Le test et l'enjeu vont en sens contraire

1. $JB = 200\,(0{,}09/6 + 0{,}25/24) = 200 \times 0{,}0254 = 5{,}08 < 5{,}99$: non rejet.
2. $50{,}8$: rejet massif.
3. **Aucun des deux**, en pratique : 200 et $2\,000$ observations suffisent au théorème central limite. La non-normalité ne menace les tests qu'en dessous d'une trentaine d'observations — là où Jarque-Bera n'a presque aucune puissance.

Quatre salariés atypiques

Pour chacun, que faire ?

1. Un salaire de $175\,000$ dirhams, alors que la fiche de paie indique $17\,500$.
2. Le directeur général, inclus par erreur dans un fichier d'employés.
3. Un salarié de trente-cinq ans d'ancienneté dont le salaire dépasse nettement la droite, alors que la relation semble s'infléchir en fin de carrière.
4. Un Bac+5 bien payé, sans rien d'anormal dans son dossier.

Exercice 3 : solution

Corriger, exclure, respécifier, garder

1. **Corriger** : c'est une erreur de saisie, avec la bonne valeur sous la main.
2. **Exclure**, en le disant : il n'appartient pas à la population étudiée.
3. **Respécifier** : le point signale une forme fonctionnelle à revoir — un terme quadratique, chapitre 18.
4. **Garder** : c'est une observation. On peut estimer avec et sans, et publier les deux.

Ce qu’il faut retenir

Le résumé du chapitre

Six points

1. **Jarque-Bera** combine asymétrie et aplatissement : $34{,}1$ ici, la normalité est rejetée.
2. **Sans conséquence** sur cinq cents observations ; décisive en dessous de trente.
3. Le **levier** $h_i = 1/n + (x_i - \overline{x})^2 / S_{xx}$ ne dépend que des x : $0{,}6$ pour les ménages extrêmes.
4. **Cook** combine résidu et levier : E, au petit résidu, est le plus influent $(0{,}75)$.
5. Salaires : 33 points au-dessus de $4/n$, et des conclusions qui survivent à leur retrait.
6. On ne supprime pas une observation gênante : on estime **avec et sans**, et l'on publie les deux.

La suite

Trois chapitres ont conclu de la même manière : le logarithme réglerait le problème. Le chapitre 18 le prend au sérieux.