

Introduction à l'économétrie

Chapitre 5 : La qualité de l'ajustement

Jaouad Madkour

19 août 2026

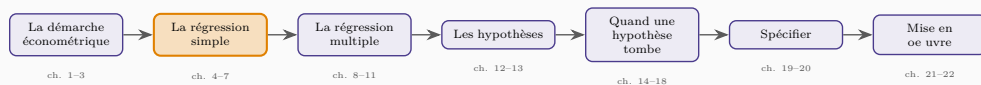
Faculté d'Économie et de Gestion de Tanger

La décomposition


Le coefficient de détermination

Ce qu'il faut retenir

La décomposition



Couper l'écart en deux



La décomposition, terme à terme

$$y_i - \bar{y} = (\hat{y}_i - \bar{y}) + (y_i - \hat{y}_i)$$

En élevant au carré et en sommant, le double produit s'annule — c'est une propriété des moindres carrés, non une approximation :

$$\underbrace{SCT}_{\text{totale}} = \underbrace{SCE}_{\text{expliquée}} + \underbrace{SCR}_{\text{résiduelle}}$$

C'est exactement la décomposition de l'analyse de la variance, chapitre 18 du cours d'inférence. L'ANOVA découpe selon des groupes ; la régression découpe selon une droite.

D'où $R^2 = SCE/SCT$, qui n'est autre que le η^2 de l'ANOVA.

L'identité fondamentale

$$\underbrace{\sum_i (y_i - \bar{y})^2}_{\text{SCT}} = \underbrace{\sum_i (\hat{y}_i - \bar{y})^2}_{\text{SCE}} + \underbrace{\sum_i (y_i - \hat{y}_i)^2}_{\text{SCR}}$$

Totale, expliquée, résiduelle.

Le double produit s'annule exactement

En développant le carré, il apparaît un terme croisé $2 \sum_i (\hat{y}_i - \bar{y}) e_i$.

Il est **nul** — conséquence directe des deux propriétés algébriques du chapitre 4. Ce n'est pas une approximation : c'est une identité, et elle ne vaut que pour les moindres carrés.

Le coefficient de détermination

Le R^2

$$R^2 = \frac{\text{SCE}}{\text{SCT}} = 1 - \frac{\text{SCR}}{\text{SCT}} \quad 0 \leq R^2 \leq 1$$

C'est la **part de la variance de y dont le modèle rend compte.**




Trois identités à connaître

En régression simple, $R^2 = r^2$: le carré du coefficient de corrélation linéaire.

C'est aussi le η^2 de l'analyse de la variance, chapitre 18 de l'inférence — même quantité, autre découpage.

Et $R^2 = 0$ signifie que la droite est **horizontale** : la meilleure prévision est alors la moyenne.

Ce qu'il ne dit pas



Les trois droites ont la même pente. Seule change la dispersion autour d'elles.

Le R^2 mesure la *part de la variance expliquée*, non l'intensité de l'effet. Un R^2 faible avec une pente forte et significative est parfaitement possible — et c'est le cas ordinaire en économie des ménages, où l'on explique rarement plus de la moitié de la variance.

Ne jamais juger un modèle sur le seul R^2 . Un R^2 de 0,30 sur des données individuelles est un bon résultat ; un R^2 de 0,99 sur une série temporelle est souvent le signe que les deux variables croissent simplement avec le temps.

Un R^2 faible n'est pas un mauvais résultat

Sur des données **individuelles**, on explique rarement plus de la moitié de la variance : les comportements humains sont irréductiblement dispersés.

Nos salaires donnent $R^2 = 0,40$ avec la seule ancienneté. C'est un bon résultat, et la pente est significative à $t = 18,4$.

Un R^2 élevé n'est pas non plus un bon résultat

Notre enquête de ménages donne $R^2 = 0,849$: bien plus élevé que sur les salaires, et c'est normal — le revenu détermine la consommation de façon beaucoup plus directe que l'ancienneté ne détermine le salaire.

Un R^2 ne se compare qu'entre modèles portant sur la même variable expliquée. Comparer 0,40 sur les salaires et 0,85 sur la consommation ne dit rien : ce ne sont pas les mêmes phénomènes.

Quatre questions, dans cet ordre

1. Les **signes** des coefficients sont-ils conformes à la théorie?
2. Leurs **ordres de grandeur** sont-ils plausibles?
3. Sont-ils **significatifs**?
4. Enfin, quel est le R^2 ?

Le R^2 arrive en dernier, et ce n'est pas un hasard

Un modèle aux coefficients absurdes et au R^2 de 0,95 ne vaut rien. Un modèle aux coefficients justes et au R^2 de 0,30 enseigne quelque chose.

On ne publie pas un R^2 , on publie un coefficient et son intervalle.

La mesure oubliée

$$\hat{\sigma}_\varepsilon = \sqrt{\frac{\text{SCR}}{n-2}}$$

C'est l'écart-type des résidus, **dans l'unité de la variable expliquée.**

Elle est souvent plus parlante que le R^2

Sur nos salaires, $\hat{\sigma}_\varepsilon = 2\,008$ dirhams : le modèle se trompe typiquement de deux mille dirhams sur un salaire individuel.

Voilà une phrase qu'un directeur des ressources humaines comprend immédiatement. « $R^2 = 0,40$ » ne lui dit rien. **Le $n - 2$ au dénominateur est celui du chapitre 21 de l'inférence : deux paramètres estimés, deux degrés de liberté perdus.**

Ce qu'il faut retenir

Six points

1. $SCT = SCE + SCR$: le double produit s'annule, propriété exacte des MCO.
2. $R^2 = SCE/SCT$: la part de variance expliquée, entre 0 et 1.
3. En régression simple, $R^2 = r^2$ — et c'est le η^2 de l'ANOVA.
4. Un R^2 **faible** est normal sur données individuelles; 0,40 ici.
5. Un R^2 ne se compare qu'à **variable expliquée identique** : 0,40 et 0,85 ne se confrontent pas.
6. $\hat{\sigma}_\epsilon = \sqrt{SCR/(n-2)}$ est souvent plus parlant : 2 008 dirhams.

La suite

Le R^2 décrit l'échantillon. Il ne dit rien de la population — et c'est pourtant sur elle que porte la question économique.

Le chapitre 6 fait le pas, et il n'introduira rien : tout a été démontré au chapitre 21 du cours d'inférence.