

Économétrie spatiale

Chapitre 5 : Modèles généraux et choix de spécification (SDM, SAC, tests LM)

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Économétrie spatiale

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Le modèle de Durbin spatial et la restriction du facteur commun

On considère le SDM $y = \rho Wy + X\beta + WX\theta + \varepsilon$.

- (a) Sous quelle contrainte sur θ le SDM se réduit-il exactement au modèle SAR du chapitre 3?
- (b) Sous quelle contrainte non linéaire sur θ le SDM devient-il équivalent au modèle SEM du chapitre 4?
- (c) Un chercheur estime un SAR simple et obtient $\hat{\beta} = 2,5$ et $\hat{\rho} = 0,35$. D'après la restriction du facteur commun, quelle valeur de θ serait compatible avec un modèle SEM sous-jacent?
- (d) Le chercheur estime ensuite un SDM complet et obtient $\hat{\theta} = -0,92$. Ce résultat est-il proche de la valeur attendue sous la restriction du facteur commun (question c)? Qu'en conclure, informellement, quant au choix entre SEM et SDM complet?

Exercice 2 — L'arbre de décision d'Anselin et Florax

Le seuil critique du χ^2 à un degré de liberté, au seuil de 5 %, vaut 3,841. Pour chacun des trois jeux de résultats suivants (obtenus après une première régression MCO), appliquer la procédure d'Anselin et Florax et indiquer le modèle à retenir.

- (a) $LM_\rho = 2,10$ (non significatif), $LM_\lambda = 1,50$ (non significatif).
- (b) $LM_\rho = 8,30$ (significatif), $LM_\lambda = 1,20$ (non significatif).
- (c) $LM_\rho = 6,70$ (significatif), $LM_\lambda = 7,90$ (significatif), puis en versions robustes : $LM_\rho^* = 1,10$ (non significatif), $LM_\lambda^* = 5,40$ (significatif).
- (d) Construire un quatrième scénario, non calculé, où les **deux** versions robustes resteraient significatives, et indiquer quel modèle la procédure recommanderait alors.

Exercice 3 — Deux philosophies de spécification

- (a) Résumer, en une phrase chacune, la démarche ascendante d'Anselin (partir des MCO) et la démarche descendante d'Elhorst (partir du SDM).
- (b) Quel est le principal risque de la démarche ascendante, que la démarche descendante permet d'éviter?
- (c) Quel est le principal coût de la démarche descendante, que la démarche ascendante permet d'éviter?
- (d) Pourquoi le cours recommande-t-il, en pratique, de rapporter les deux démarches plutôt que de choisir une seule a priori?

2 Exercice cumulatif (chapitre 5, chapitre 4, chapitre 3, chapitre 2 et chapitre 1)

Exercice 4 — Reprendre la décision SAR/SEM avec les outils du chapitre 5

On reprend le scénario du rendement agricole (chapitre 4, exercice cumulatif) sur les quatre régions du chapitre 1. Le chercheur dispose maintenant des deux tests de Lagrange sur les résidus MCO : $LM_\rho = 5,2$ (significatif), $LM_\lambda = 6,8$ (significatif). Les versions robustes donnent $LM_\rho^* = 0,9$ (non significatif) et $LM_\lambda^* = 4,1$ (significatif).

- (a) D'après l'arbre de décision d'Anselin et Florax, quel modèle la procédure recommande-t-elle?
- (b) Ce résultat statistique est-il cohérent avec le raisonnement économique du chapitre 4 (qualité du sol non observée, sans mécanisme direct entre parcelles)?
- (c) Le chapitre 2 avait établi que l'indice de Moran seul ne permettait pas de choisir entre SAR et

SEM. En quoi les tests LM_ρ et LM_λ de ce chapitre apportent-ils précisément l'information qui manquait alors ?

- (d) Si le chercheur avait obtenu $LM_\rho^* = 4,5$ et $LM_\lambda^* = 3,9$ (tous deux significatifs) au lieu des valeurs ci-dessus, quel modèle la procédure aurait-elle recommandé à la place, et pourquoi ce modèle est-il plus coûteux à estimer (chapitre 5) que SAR ou SEM seuls ?

3 Applications en sciences économiques

Exercice 5 — Choisir une spécification pour les prix immobiliers

Une étude sur les prix immobiliers de 300 quartiers obtient $LM_\rho = 12,4$ et $LM_\lambda = 9,8$ (tous deux significatifs), puis $LM_\rho^* = 6,1$ (significatif) et $LM_\lambda^* = 0,7$ (non significatif).

- (a) Quel modèle la procédure d'Anselin et Florax recommande-t-elle ?
- (b) Ce choix est-il cohérent avec l'idée, économiquement plausible pour des prix immobiliers, d'un véritable effet de comparaison entre biens voisins (chapitre 3) ?
- (c) Un collègue, partisan de la démarche d'Elhorst, propose d'estimer directement un SDM complet et de tester la restriction du facteur commun plutôt que de suivre l'arbre de décision. Les deux démarches sont-elles susceptibles d'aboutir à la même conclusion pratique ici ?

Exercice 6 — Un cas ambigu : pollution industrielle régionale

Une chercheuse étudie la concentration de particules fines dans 80 zones industrielles, et soupçonne à la fois un effet de diffusion atmosphérique réel entre zones voisines (le vent transporte la pollution) et un facteur climatique régional omis (un régime de vents dominants propre à toute une région). Elle obtient $LM_\rho = 15,2$, $LM_\lambda = 13,7$, $LM_\rho^* = 7,9$, $LM_\lambda^* = 6,3$ (tous significatifs au seuil de 5 %).

- (a) Que recommande la procédure d'Anselin et Florax face à ce résultat ?
- (b) En quoi ce résultat statistique est-il cohérent avec les deux mécanismes économiques que la chercheuse soupçonne simultanément ?
- (c) Quelle mise en garde du chapitre 5 s'applique particulièrement ici, concernant la difficulté d'estimer un tel modèle et sa sensibilité au choix de W_1 et W_2 ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) Sous $\theta = 0$ (aucun régresseur décalé spatialement), le SDM se réduit exactement au SAR.
- (b) Sous la restriction non linéaire $\theta = -\rho\beta$ (la restriction du facteur commun), le SDM devient équivalent au SEM.
- (c) $\theta = -\hat{\rho}\hat{\beta} = -0,35 \times 2,5 = -0,875$.
- (d) $\hat{\theta} = -0,92$ est très **proche** de la valeur attendue $-0,875$ sous la restriction du facteur commun (écart $\approx 0,045$). Cela suggère, de façon informelle, que les données sont **compatibles** avec un simple modèle SEM plutôt qu'avec la généralité complète du SDM — une conclusion qu'un test formel du rapport de vraisemblance permettrait de confirmer rigoureusement.

Correction — Exercice 2

- (a) $LM_\rho = 2,10 < 3,841$ et $LM_\lambda = 1,50 < 3,841$: aucun n'est significatif, les **MCO** suffisent.
- (b) $LM_\rho = 8,30 > 3,841$ est significatif, $LM_\lambda = 1,20 < 3,841$ ne l'est pas : retenir le modèle **SAR**.
- (c) Les deux tests simples sont significatifs ($6,70$ et $7,90 > 3,841$), il faut donc examiner les versions robustes : $LM_\rho^* = 1,10 < 3,841$ (non significatif), $LM_\lambda^* = 5,40 > 3,841$ (significatif) : retenir le modèle **SEM**.
- (d) Si les deux versions robustes LM_ρ^* et LM_λ^* restaient significatives simultanément, la procédure recommanderait le modèle combiné **SAC/SARAR**, qui superpose un lag spatial dans y et une erreur autorégressive spatiale.

Correction — Exercice 3

- (a) La démarche ascendante d'Anselin part des MCO et n'introduit de la complexité spatiale que si les tests LM la justifient ; la démarche descendante d'Elhorst part du modèle le plus général (SDM) et le restreint seulement si les données le permettent.
- (b) La démarche ascendante risque de rester bloquée sur un modèle trop restreint (par exemple SAR ou SEM simple) faute d'avoir jamais testé l'alternative plus large (SDM ou SAC) qui aurait pu être la vraie spécification.
- (c) La démarche descendante est plus coûteuse en calcul et en degrés de liberté, puisqu'elle estime d'emblée le modèle le plus riche (avec tous les régresseurs décalés spatialement WX) même quand une spécification plus simple aurait suffi.
- (d) Parce qu'aucune des deux démarches n'est unanimement supérieure : elles reposent sur des logiques différentes et un accord entre leurs conclusions renforce nettement la confiance dans la spécification finalement retenue, tandis qu'un désaccord signale un résultat fragile qui mérite un examen plus approfondi.

2 Exercice cumulatif (chapitre 5, chapitre 4, chapitre 3, chapitre 2 et chapitre 1)

Correction — Exercice 4

- (a) $LM_\rho = 5,2$ et $LM_\lambda = 6,8$ sont tous deux significatifs ($> 3,841$) : il faut examiner les versions robustes. $LM_\rho^* = 0,9$ n'est pas significatif, $LM_\lambda^* = 4,1$ l'est : la procédure recommande le modèle **SEM**.
- (b) **Oui** : le résultat statistique (SEM recommandé) est parfaitement cohérent avec le raisonnement économique du chapitre 4 — une variable omise (qualité du sol) spatialement corrélée, sans mécanisme direct de propagation entre parcelles, est précisément la signature qu'un modèle SEM est censé capturer.
- (c) L'indice de Moran détecte la présence d'une dépendance spatiale globale sans distinguer sa source ; les tests LM_ρ et LM_λ , en testant spécifiquement $H_0 : \rho = 0$ contre une alternative SAR d'une part,

$H_0 : \lambda = 0$ contre une alternative SEM d'autre part, apportent exactement la distinction qui manquait — ils permettent de trancher *statistiquement* entre les deux mécanismes, là où Moran ne pouvait offrir qu'un raisonnement économique a priori.

(d) Avec $LM_\rho^* = 4,5$ et $LM_\lambda^* = 3,9$ tous deux significatifs, la procédure recommanderait le modèle combiné **SAC/SARAR**. Ce modèle est plus coûteux à estimer car il superpose un lag spatial dans y et une erreur autorégressive spatiale, ce qui fragilise l'identification et rend les résultats plus sensibles au choix exact des matrices de pondération W_1 et W_2 — la généralité s'achète toujours en puissance statistique et en robustesse, comme le rappelle ce chapitre.

3 Applications en sciences économiques

Correction — Exercice 5

(a) $LM_\rho = 12,4$ et $LM_\lambda = 9,8$ significatifs, donc examen des versions robustes : $LM_\rho^* = 6,1$ significatif, $LM_\lambda^* = 0,7$ non significatif : la procédure recommande le modèle **SAR**.

(b) **Oui** : un véritable effet de comparaison entre biens voisins (les acheteurs comparent les prix affichés dans le voisinage avant de faire une offre) est exactement le type de mécanisme de rétroaction directe dans y que le modèle SAR est censé capturer, cohérent avec le résultat statistique.

(c) **Oui, plausiblement**. La démarche d'Elhorst, en estimant un SDM complet puis en testant la restriction du facteur commun ($\theta = -\rho\beta$), devrait ici rejeter cette restriction (puisque le SAR, non le SEM, est la spécification pertinente) et converger vers une conclusion compatible avec le SAR — les deux démarches, bien que méthodologiquement différentes, sont conçues pour converger sur les mêmes données lorsque le signal est suffisamment net.

Correction — Exercice 6

(a) Les deux tests simples et les deux versions robustes étant tous significatifs, la procédure recommande le modèle combiné **SAC/SARAR**.

(b) Ce résultat est cohérent avec la coexistence des deux mécanismes soupçonnés : la diffusion atmosphérique réelle entre zones voisines correspond au terme ρWy (dépendance substantielle logée dans y), tandis que le régime de vents dominants régional, non observé, correspond au terme λWu (corrélation nuisible logée dans l'erreur) — exactement la structure que le SAC/SARAR est conçu pour capturer simultanément.

(c) Le chapitre 5 met en garde sur le « prix de cette généralité » : le modèle SAC/SARAR est plus difficile à estimer (identification plus fragile, calcul plus lourd) et ses résultats deviennent particulièrement sensibles à la spécification exacte des matrices W_1 (pour le lag) et W_2 (pour l'erreur) — une mise en garde d'autant plus pertinente ici que la chercheuse pourrait légitimement choisir des critères de voisinage différents pour la diffusion atmosphérique (probablement liée aux vents dominants, donc directionnelle) et pour le facteur climatique régional (probablement plus diffus).