

Introduction

Corrélation et causalité : ce que la régression ne dit pas

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Inférence causale


1 Exercices du chapitre

Correction — Exercice 1

(a) Subventionnées : $280 + 170 = 450$ survies sur $800 + 200 = 1\,000$, soit **45 %**. Non subventionnées : $50 + 600 = 650$ survies sur $200 + 800 = 1\,000$, soit **65 %**.

(b) Écart global = $45\% - 65\% = -20$ points. Au vu de ce seul chiffre, la subvention semble **nuire** nettement à la survie des entreprises.

(c) Petites entreprises : $35\% - 25\% = +10$ points. Grandes entreprises : $85\% - 75\% = +10$ points. Ce résultat n'est **pas** cohérent, en apparence, avec la question (b) : dans chaque strate, la subvention **aide** de 10 points, alors que le chiffre global affiche -20 points. C'est exactement le paradoxe de Simpson : les entreprises subventionnées sont majoritairement des petites entreprises (au taux de survie structurellement plus bas), tandis que les non subventionnées sont majoritairement de grandes entreprises – la composition des groupes, non l'effet de la subvention, domine le chiffre global.




Correction — Exercice 2

(a) Subventionnées : 50 000 entreprises, $450 \times 50 = 22\,500$ survies, taux = $22\,500/50\,000 = 45\%$. Non subventionnées : 50 000 entreprises, $650 \times 50 = 32\,500$ survies, taux = $32\,500/50\,000 = 65\%$.

(b) Les taux sont **rigoureusement identiques** à ceux de l'exercice 1 (a) : 45 % et 65 %, malgré un effectif 50 fois plus grand.

(c) Multiplier les effectifs par 50 ne change **rien** au biais de composition : la même proportion de petites et grandes entreprises est présente dans chaque groupe, subventionné ou non, quel que soit le facteur d'échelle. Un échantillon plus grand donnerait une estimation plus **précise** de ce chiffre de -20 points (un intervalle de confiance plus étroit), mais ce chiffre resterait tout aussi **trompeur** sur l'effet réel de la subvention. C'est exactement l'affirmation de l'introduction : le problème est d'identification, pas de taille d'échantillon.




Correction — Exercice 3

(a) Avec campagne : $300 + 320 = 620$ sur $600 + 400 = 1\,000$, soit **62 %**. Sans campagne : $160 + 390 = 550$ sur $400 + 600 = 1\,000$, soit **55 %**.

(b) Écart global = $62\% - 55\% = +7$ points. Petits magasins : $50\% - 40\% = +10$ points. Grands magasins : $80\% - 65\% = +15$ points.

(c) Non, le signe **ne change pas** ici : la campagne aide dans les deux strates **et** globalement – aucun renversement de type Simpson. Ce qui reste vrai, en revanche, c’est que l’écart global (+7 points) n’est **ni** la moyenne simple des deux écarts par strate ($(10+15)/2 = 12,5$), **ni** égal à l’un ou l’autre : il dépend de la **composition** des groupes (ici, les petits magasins, à effet plus faible, sont surreprésentés parmi les magasins avec campagne, ce qui tire l’écart global vers le bas). La composition influence toujours le chiffre agrégé, qu’il y ait renversement de signe ou seulement une différence de magnitude.




2 Applications en sciences économiques

Correction — Exercice 4

(a) Hausse appliquée : $315 + 225 = 540$ sur $700 + 300 = 1\,000$, soit **54 %**. Pas de hausse : $105 + 455 = 560$ sur $300 + 700 = 1\,000$, soit **56 %**.

(b) Écart global = $54\% - 56\% = -2$ points. Régions urbaines : $45\% - 35\% = +10$ points. Régions rurales : $75\% - 65\% = +10$ points.

(c) Le débat public se trompe en s’appuyant sur le seul chiffre global : dans **chaque** région, la hausse du salaire minimum est associée à un taux d’emploi des jeunes **plus élevé** de 10 points, pas plus bas. Le petit écart global négatif (-2 points) provient de la composition : les régions urbaines, où la hausse a été surtout appliquée, ont un taux d’emploi structurellement plus bas que les régions rurales, où la hausse a été moins appliquée. Oui, la composition régionale joue un rôle déterminant : elle suffit à elle seule à retourner le signe d’un effet par ailleurs uniformément positif. (Il faut aussi noter, comme le rappelle l’introduction, que cette comparaison brute reste une association et non une preuve de causalité : les régions qui ont choisi d’appliquer la hausse peuvent différer d’autres façons non observées.)



Correction — Exercice 5

(a) Avec crédit : $100 + 150 = 250$ sur $250 + 750 = 1\,000$, soit **25 %**. Sans crédit : $225 + 25 = 250$ sur $750 + 250 = 1\,000$, soit **25 %**.

(b) Écart global = $25\% - 25\% = 0$ point. Jeunes entreprises : $40\% - 30\% = +10$ points. Entreprises

matures : $20\% - 10\% = +10$ points.

(c) Non, ce n'est **pas** cohérent avec ce qui se passe dans chacune des deux strates : le crédit d'impôt augmente l'investissement en R&D de 10 points chez les jeunes entreprises **et** chez les entreprises matures, un effet parfaitement uniforme – et pourtant le chiffre global affiche un écart **exactement nul**, masquant totalement cet effet réel. Un décideur qui s'appuierait uniquement sur le chiffre global commettrait une erreur d'**identification** particulièrement grave : il conclurait à l'absence totale d'effet, et pourrait recommander l'abandon d'une politique qui, en réalité, fonctionne de façon homogène dans toutes les catégories d'entreprises. C'est le cas le plus extrême du paradoxe de Simpson : non pas un renversement de signe, mais une annulation complète et trompeuse de l'effet apparent.

